



UNIVERSITÀ DEGLI STUDI DI SALERNO

Dipartimento di Informatica

Corso di Laurea Triennale in Informatica

TESI DI LAUREA

Med-ViX-Ray:

AI knowledge-guided e interpretabile per la diagnosi
assistita in radiologia toracica

RELATORE

Prof. Palomba Fabio

Università degli Studi di Salerno

CANDIDATO

Manuel Cieri

Matricola: 05121 20482

Anno Accademico 2024-2025

Questa tesi ha contribuito a piantare una Jacaranda mimosifolia in Tanzania grazie a Treedom.

<https://www.treedom.net/it/forest/sesa-random-forest>

Questa tesi è stata realizzata nel

sesa^{lab}
SOFTWARE ENGINEERING
SALERNO

Alla mia famiglia

Abstract

La classificazione automatica delle immagini radiografiche del torace rappresenta una sfida importante nel campo dell'intelligenza artificiale applicata alla medicina. Nonostante i recenti progressi ottenuti con modelli Transformer-based e approcci multimodali, molti sistemi risultano ancora scarsamente interpretabili e difficilmente integrabili nei workflow clinici. Inoltre, l'uso esplicito della conoscenza clinica rimane limitato in molte delle architetture proposte.

In questa tesi si propone **Med-ViX-Ray**, un modello *knowledge-guided* e interpretabile per la classificazione multilabel delle immagini CXR, basato su una estensione di Swin Transformer V2. Il modello integra un grafo clinico dei segni radiografici, utilizzato sia per iniettare un bias dinamico nei layer di attenzione, sia per modulare i logits finali tramite un meccanismo di *Graph Nudger*. È stata inoltre sviluppata una pipeline di estrazione delle regioni salienti che consente di guidare in modo più robusto l'apprendimento della componente *knowledge-guided*. L'architettura è stata inoltre progettata per poter essere estesa in futuro verso pipeline di refertazione automatica, in combinazione con modelli linguistici (LLM/SLM), non terminata a causa di limitazioni hardware.

I risultati ottenuti sul dataset MIMIC-CXR mostrano un miglioramento delle metriche di classificazione rispetto a una baseline fine-tuned, con **F1 micro**, **recall** e **AUC** in crescita, e confermano la maggiore coerenza semantica delle mappe di attenzione prodotte. Test preliminari in regime zero-shot su VINDR-CXR indicano inoltre una buona capacità di generalizzazione del modello anche comparata a modelli in letteratura.

Il lavoro contribuisce a superare i limiti di trasparenza e integrazione della conoscenza clinica nei modelli attuali, proponendo una pipeline interpretabile ed estensibile che apre nuove prospettive per l'adozione dell'AI nei contesti radiologici.

Indice

Elenco delle Figure	v
Elenco delle Tabelle	vi
1 Introduzione	1
1.1 Contesto Applicativo	1
1.2 Motivazioni e Obiettivi	1
1.3 Risultati Ottenuti	2
1.4 Struttura della Tesi	3
2 Background e stato dell'arte	4
2.1 Patologia e Clinica	5
2.1.1 La radiografia	6
2.1.2 Patologie dell'Apparato Respiratorio	9
2.1.3 Patologie Cardiaco-Mediastiniche	20
2.1.4 Altre Patologie	22
2.1.5 Indicazioni Aggiuntive	23
2.2 Ontologie Mediche	24
2.2.1 Unified Medical Language System	24
2.2.2 International Classification of Diseases	25
2.2.3 RadLex	25

2.3	Machine Learning e riconoscimento immagini	26
2.3.1	Machine Learning	26
2.3.2	Reti Neurali Convoluzionali	28
2.3.3	Struttura Generale di una CNN	29
2.3.4	Fondamenti dei Transformer e Computer Vision	34
2.3.5	Architettura del Vision Transformer (ViT)	36
2.4	Explainable AI	38
2.4.1	Concetti	39
2.4.2	Tecniche XAI per CNN	40
2.4.3	Tecniche XAI per ViT	43
2.5	Large e Small Language Models	46
2.5.1	Funzionamento in breve	46
2.5.2	Principali LLM	47
2.5.3	Small Language Models	48
2.6	Lavori precedenti	49
2.6.1	CXR e Machine Learning	50
2.6.2	Flamingo-CXR	53
2.6.3	RAD-DINO	56
2.7	Approccio della tesi	58
2.7.1	Confronto con la letteratura	58
2.7.2	XAI e Medicina	59
3	Metodi di Ricerca	61
3.1	Introduzione	61
3.2	Raccolta e preparazione dei dati	63
3.3	Visione generale della pipeline	63
3.3.1	Backbone neurale	66
3.4	Modellazione del grafo clinico	69
3.4.1	Motivazione e obiettivi	69
3.4.2	Preparazione e inizializzazione del grafo	70
3.4.3	Costruzione del grafo	71
3.4.4	Aggiornamento dinamico	72

3.4.5	Formalizzazione matematica e iniezione del grafo	74
3.4.6	Rappresentazione del Grafo	74
3.5	Integrazione del grafo nell'architettura	75
3.5.1	Doppia Integrazione del Grafo	75
3.5.2	Motivazione della doppia integrazione del grafo	76
3.5.3	Bias nei Transformer Layers	76
3.5.4	Nudging Grafico sui Logits Finali	79
3.6	Matching tra regioni salienti e nodi clinici	79
3.6.1	Matching probabilistico con softmax	80
3.6.2	Weak supervision con NER	80
3.6.3	Aggiornamento dei nodi segno	81
3.6.4	Formulazione One-Liner riassuntiva	82
3.7	Possibile implementazione alternativa: Vit Classici	82
3.8	Conv2D nei moduli di bias grafico	83
3.9	Estrazione delle mappe di attenzione	85
3.9.1	Metodo di estrazione	85
3.9.2	Scelta del livello di estrazione	85
3.9.3	Pipeline di elaborazione	86
3.9.4	Utilizzo nella pipeline	88
3.9.5	Motivazione della scelta	88
3.9.6	Vantaggi	89
3.9.7	Confronto con Altri Metodi	89
3.10	La Loss	90
3.10.1	Motivazione della funzione di loss composita	90
3.11	Riassunto Architettura	92
4	Analisi preliminare di Med-ViX-Ray	93
4.1	Introduzione	93
4.2	Setup sperimentale	94
4.2.1	Dataset e split	94
4.2.2	Modelli confrontati	94
4.2.3	Metriche di valutazione	95

4.2.4	Motivazioni per la scelta dei modelli di confronto	95
4.2.5	Hardware e risorse computazionali	96
4.3	Risultati quantitativi	97
4.3.1	Presentazione dei risultati	97
4.3.2	Analisi delle metriche su MIMIC	99
4.3.3	Analisi delle metriche su VINDR-CXR	100
4.3.4	Considerazioni sul confronto	101
4.4	Risultati qualitativi	101
4.4.1	Mappe di attenzione	101
4.4.2	Comportamento del grafo clinico	103
4.5	Analisi	104
5	Conclusioni	106
5.1	Discussione	106
5.1.1	Contributi principali del modello Med-ViX-Ray	107
5.1.2	Implicazioni cliniche e interpretabilità	108
5.2	Limiti e Prospettive Future	109
	Bibliografia	111

Elenco delle figure

2.1	Esempi di CXR con rilievi polmonari positivi	16
2.2	Esempi di CXR con rilievi cardio-mediastinici	21
2.3	Esempi di architetture di CNN	30
2.4	Architettura dei Vision Transformer	37
2.5	Architettura di Flamingo. Immagine tratta dal paper originale	55
3.1	Architettura modello Med-ViX-Ray	64
3.2	Schema della loss composita utilizzata nell’addestramento con guida grafica.	92
4.1	Confronto tra le ROC curve dei modelli Swin V2 fine-tuned e Med-ViX-Ray.	98
4.2	Esempio di attention map di Med-Vix-Ray per polmonite	102
4.3	Esempio di attention map di Med-Vix-Ray per cardiomegalia	103

Elenco delle tabelle

2.1	Confronto tra architetture CNN e Vision Transformer (ViT)	39
2.2	Overview moduli di XAI in architetture CNN e ViT	40
2.3	Riassunto delle caratteristiche principali per Grad-CAM, SHAP e CDAM.	45
3.1	Riassunto delle principali caratteristiche statistiche.	73
3.2	Confronto tra metodi di estrazione attenzione	89
4.1	Confronto delle performance sui set di test tra i modelli considerati. .	98
4.2	Confronto AUPRC su test-set di VINDR-CXR	99

CAPITOLO 1

Introduzione

1.1 Contesto Applicativo

L'Intelligenza Artificiale (AI) ha rivoluzionato numerosi ambiti della medicina moderna, in particolare nell'analisi delle immagini radiologiche, dove modelli di deep learning hanno raggiunto performance paragonabili a quelle umane in compiti di classificazione e segmentazione. Tuttavia, questa rapida evoluzione è stata accompagnata da una crescente preoccupazione sulla loro *opacità*: modelli accurati, ma privi di interpretabilità, rischiano di non essere accettati nella pratica clinica. Questo è particolarmente critico nella radiologia toracica, dove la diagnosi può dipendere da segni radiologici sottili, contestuali e spesso ambigui.

1.2 Motivazioni e Obiettivi

Molti dei modelli all'avanguardia nella classificazione automatica delle immagini radiografiche, come CheXNet, Flamingo-CXR o RAD-DINO, ottengono risultati notevoli grazie a grandi corpus di immagini e referti, ma rimangono in larga parte *black-box*, scollegati dal ragionamento clinico strutturato. Inoltre, l'assenza di conoscenza medica esplicita limita la capacità di questi modelli di generalizzare in scenari

fuori distribuzione o fornire giustificazioni clinicamente plausibili. In altri ambiti dell'AI (es. AlphaFold), l'integrazione di conoscenza esperta ha portato a progressi significativi, ma nel contesto radiologico tali approcci sono ancora poco esplorati.

Questa tesi si propone di colmare questa lacuna introducendo **Med-ViX-Ray**, un modello *proof of concept* per la classificazione radiografica che integra conoscenza clinica tramite grafi strutturati e mappe di attenzione estratte direttamente dal backbone visivo. L'obiettivo è duplice: migliorare le performance quantitative, e rendere più trasparente il processo decisionale del modello, favorendo l'adozione in ambito medico.

1.3 Risultati Ottenuti

Il modello Med-ViX-Ray è stato valutato sul dataset MIMIC-CXR in una configurazione di classificazione multi-label. I risultati mostrano un miglioramento delle performance rispetto al fine-tuning diretto di Swin Transformer, con un incremento di F1-score micro e un guadagno netto in AUC-ROC su tutte le patologie critiche. Inoltre, il confronto zero-shot su VINDR-CXR evidenzia una buona capacità di generalizzazione, con risultati competitivi rispetto a modelli più complessi e supervisionati come RAD-DINO.

Dal punto di vista qualitativo, le mappe di attenzione risultano localizzate e coerenti con le regioni patologiche, mentre il grafo clinico consente l'emergere di pattern sintomatici che riflettono una certa forma di "ragionamento clinico indotto" ma presenta ampi margini di miglioramento.

1.4 Struttura della Tesi

Il resto della tesi è articolata come segue:

- Il **Capitolo 2** presenta lo stato dell'arte dei modelli di classificazione radiologica, dei metodi di interpretabilità, e dell'integrazione di conoscenza in modelli neurali.
- Il **Capitolo 3** descrive nel dettaglio l'architettura di Med-ViX-Ray, evidenziando le scelte progettuali, le componenti del grafo clinico e i meccanismi di iniezione dell'informazione.
- Il **Capitolo 4** illustra la sperimentazione effettuata, analizzando i risultati quantitativi e qualitativi, e confrontandoli con modelli noti in letteratura.
- Il **Capitolo 5** discute i contributi principali della tesi, i limiti riscontrati e propone direzioni per futuri sviluppi.

CAPITOLO 2

Background e stato dell'arte

La radiografia del torace (Chest X-Ray, CXR) rappresenta uno degli strumenti diagnostici più diffusi e accessibili nella pratica clinica, grazie al costo relativamente contenuto e alla rapidità di esecuzione. Nonostante la relativa semplicità della procedura, la lettura e l'interpretazione di una CXR può risultare complessa, richiedendo l'esperienza di radiologi e clinici specializzati in grado di individuare segni patologici spesso sottili o sovrapposti ad altre strutture anatomiche. Negli ultimi anni, i rapidi progressi nel campo dell'Intelligenza Artificiale (IA) e, in particolare, dell'Apprendimento Profondo (Deep Learning), hanno aperto nuovi scenari per l'automatizzazione e il supporto alla diagnosi, offrendo la possibilità di analizzare enormi volumi di dati in modo accurato e tempestivo.

Le reti neurali convoluzionali (Convolutional Neural Networks, CNN), ad esempio, hanno dimostrato prestazioni promettenti in diversi contesti clinici, tra cui il rilevamento di patologie polmonari e cardiovascolari su immagini RX [1, 2]. Alcune ricerche si concentrano specificamente su determinate patologie, come la tubercolosi polmonare (TB) [3], mentre altre propongono sistemi in grado di riconoscere più condizioni (ad esempio pneumopatia, cardiomegalia, versamento pleurico e altre ancora) con un singolo modello addestrato su dataset di grandi dimensioni. A riguardo, una meta-analisi recente [4] ha fornito un quadro generale delle prestazioni di vari

modelli di Machine Learning applicati all'interpretazione delle radiografie toraciche, evidenziando sia i risultati positivi sia le sfide legate alla validazione e all'adozione clinica su larga scala.

Oltre all'ambito delle radiografie, l'analisi automatica delle immagini mediche copre anche altre modalità diagnostiche, come la tomografia computerizzata (TC). Sebbene il presente lavoro si focalizzi sulle CXR, risulta utile considerare studi che riguardano la segmentazione e il riconoscimento di strutture anatomiche in TC, in quanto molte delle tecniche di IA e Deep Learning sono trasversali. Ad esempio, la ricerca pubblicata su Nature da Ouyang et al. [5] illustra i progressi nella segmentazione di strutture anatomiche e lesioni in immagini TC, dimostrando la possibilità di sviluppare modelli generalisti che possano essere riadattati o specializzati per varie tipologie di immagini mediche.

In questo capitolo verrà inizialmente presentato lo stato dell'arte relativo all'uso di tecniche di IA per l'analisi delle radiografie del torace, con particolare riferimento ai recenti lavori che integrano metodologie di Deep Learning. Verrà poi esplorato il ruolo delle metodologie di Explainable AI (XAI) in medicina, sottolineando l'importanza della trasparenza e dell'interpretabilità dei risultati quando si tratta di diagnosi e refertazione. A seguire, si discuterà l'evoluzione dei modelli di linguaggio di grandi dimensioni (Large Language Models, LLM) nel contesto medico, soprattutto in relazione alla creazione e validazione di referti. Infine, si fornirà una panoramica di alcuni sistemi completi, come ChatGPT o soluzioni analoghe in fase di sviluppo (ad esempio Google Gemini), che si stanno affacciando nel campo dell'analisi automatica delle immagini e della generazione di output in stile "referto clinico".

2.1 Patologia e Clinica

Le radiografie del torace costituiscono uno strumento diagnostico fondamentale per la valutazione di numerose condizioni cliniche, sia a livello polmonare sia in ambito cardiaco e mediastinico. L'obiettivo di questa sezione è fornire un breve inquadramento delle patologie più comuni e rilevanti ai fini diagnostici, prese in considerazione dal modello di classificazione, raggruppandole per area anatomica di interesse. Una chiara comprensione di tali condizioni e dei loro segni radiologici

caratteristici è essenziale per progettare e addestrare modelli di Intelligenza Artificiale in grado di identificare automaticamente le diverse patologie sulle CXR.

Nel dettaglio, verranno dapprima discusse le patologie polmonari che rappresentano alcune delle indicazioni più frequenti per l'esecuzione di una CXR. Successivamente, verranno presentate le patologie cardiache e mediastiniche, con particolare attenzione a cardiomegalia. Infine, verrà proposto un gruppo eterogeneo di altre condizioni (ad esempio, fratture costali).

La classificazione adottata in questa sezione ha lo scopo di agevolare la descrizione delle patologie e non vuole rappresentare un criterio assoluto; in pratica, molte condizioni possono coesistere o influenzarsi a vicenda.

2.1.1 La radiografia

La radiografia del torace è tra gli esami diagnostici più comunemente utilizzati, grazie al suo basso costo, alla rapidità di esecuzione e alla disponibilità su vasta scala. Questa tecnica impiega un fascio di raggi X che attraversa i tessuti del corpo, i quali assorbono e disperdono i fotoni in misura diversa a seconda della densità e del numero atomico. L'immagine finale, acquisita su un detettore o rilevatore (analogico o digitale), riflette quindi le differenze di attenuazione dei tessuti [6].

In caso di CXR, la proiezione usata più spesso è la postero-anteriore (PA): il paziente si posiziona in piedi, con il torace appoggiato al detettore e le scapole ruotate lateralmente per liberare il campo polmonare. I raggi X attraversano il corpo da dietro (posteriore) verso davanti (anteriore).

Reperti e Artefatti

Nella lettura di una CXR si utilizza principalmente la distinzione tra aree radiotrasparenti (o ipertrasparenti) e aree opache (o radiopache) [7].

Radiotrasparenza: si riferisce alla porzione dell'immagine attraverso la quale i raggi X passano con maggiore facilità. In radiologia toracica, i polmoni sono generalmente considerati "radiotrasparenti" perché contengono aria; appaiono più scuri sull'immagine finale.

Iperdiafania (o ipertrasparenza): è un termine che indica un aumento anomalo della trasparenza. Può dipendere da varie condizioni, come nel caso di un pneumotorace (dove l'aria libera nello spazio pleurico fa apparire una porzione del torace più scura del normale) o di un'iperinflazione polmonare (ad esempio nell'enfisema).

Addensamenti parenchimali: aree opache che indicano consolidamento del tessuto polmonare, come nelle polmoniti o nell'edema polmonare.

Ombra: termine generico usato per descrivere aree di diversa densità che si proiettano sull'immagine radiografica, come l'ombra cardiaca o quella mediastinica.

Opacità (o radiopacità): indica quelle regioni in cui i raggi X vengono maggiormente attenuati, apparendo più chiare sull'immagine. Gli esempi includono il tessuto osseo (come coste, colonna vertebrale), il cuore e i vasi, oltre alle aree polmonari interessate da processi patologici come polmoniti, edema polmonare o consolidamenti di altra natura.

Opacità "a vetro smerigliato": o ground-glass opacification (GGO), indica un'area di aumentata densità del parenchima polmonare nel cui contesto sono riconoscibili le strutture vascolari e bronchiali (broncogramma scuro). Il nome deriva dalla tecnica industriale che prevede l'irruvidimento della superficie del vetro normale mediante molatura il cui risultato è visivamente simile all'opacità osservata. Il termine è specifico di reperti di Tomografia Computerizzata (TC) o più spesso di High Resolution Computed Tomography (HRCT), sebbene molti autori la usino impropriamente per indicare un'opacità a carattere nebuloso anche in RX e che può (sebbene non necessariamente) corrispondere alla stessa lesione visibile in TC.

Radiograficamente la visualizzazione di tale reperto è spesso difficile per l'alta risoluzione richiesta, pertanto l'uso del vocabolo in questa tesi sarà limitato alla descrizione in TC e si parlerà di opacità "a velatura" o sinonimi.

Opacità ad alveare: ombre "ad anello" racchiudenti zone radiotrasparenti. Spesso un'evoluzione di strutture a vetro smerigliato.

Versamento: solitamente riferita al versamento pleurico (pleural effusion) con fluido sieroso, purulento, emorragico, fibrinoso o trasudato o un misto dei precedenti. Le cellule pleuriche raramente proliferano e, in tal caso, il termine **ispessimento pleurico** si riferisce all'ombra causata dall'organizzazione dell'essudato da cui origina.

Nonostante la CXR sia un esame di routine, essa non è esente da artefatti e limitazioni, che possono confondere o alterare l'interpretazione [8].

I principali includono:

Errore di esposizione: la regolazione inadeguata dei parametri di esposizione (kV, mAs) può determinare immagini troppo chiare o troppo scure, riducendo la visibilità delle strutture anatomiche.

Rotazione del paziente: un errato posizionamento può falsare l'ampiezza dell'ombra cardiaca o la simmetria delle emidiaframmi, portando a interpretazioni sbagliate.

Proiezione lordotica involontaria: se il paziente non è in grado di aderire correttamente al detettore, l'immagine subisce una distorsione prospettica (tipica è la lordosi, con un apparente sollevamento o espansione del mediastino).

Artefatti da movimento: respiro o battito cardiaco non controllati possono determinare immagini sfuocate, riducendo il contrasto tra le strutture.

Presenza di dispositivi o corpi estranei: tubi endotracheali, cateteri venosi centrali, pacemaker o aghi per biopsia proiettati sul torace possono generare linee o silhouette anomale, che vanno riconosciute e interpretate correttamente.

Effetto parallasse: avviene quando il soggetto non è centrato in relazione all'asse del raggio; l'immagine derivata può risultare distorta, provocando errori nelle misurazioni.

Altri artefatti particolari: ad esempio, nelle radiografie portatili al letto del paziente, la qualità è spesso inferiore rispetto alle CXR standard in ortostatismo, per via delle limitazioni di posizione e dell'aumento della distanza fuoco-detettore.

La conoscenza di questi artefatti risulta fondamentale per distinguere con precisione i reperti patologici reali dalle anomalie generate dalle condizioni di esame o da errori tecnici. L'adozione di protocolli standardizzati di acquisizione (quali la proiezione postero-anteriore a 180 cm di distanza fuoco-rilevatore, preferibilmente in inspirazione profonda) contribuisce a minimizzare gli artefatti e a migliorare la comparabilità tra studi successivi [9].

Infine, sebbene la CXR fornisca una visione d'insieme su cuore, polmoni e mediastino, la sua natura bidimensionale limita la capacità di rilevare lesioni piccole o localizzate in aree anatomiche difficili da analizzare (come l'apice polmonare o le regioni retrocardiache). Per questi motivi, l'esperienza del radiologo, insieme all'impiego di metodiche di imaging complementari, come RX in proiezione latero-laterale o TC torace, restano essenziali per una diagnosi accurata.

2.1.2 Patologie dell'Apparato Respiratorio

Di seguito sono introdotte le principali patologie dell'apparato respiratorio trattate in questo lavoro.

Atelettasia

La sindrome atelettasica è caratterizzata da condensazione retrattile di un territorio polmonare. Solitamente è evidenza di una patologia primaria associata, come sindrome da distress respiratorio o insufficienza polmonare (anche da trapianto). Si accompagna a dispnea, cianosi, tosse non produttiva, dovuti alla compressione del parenchima polmonare e alla diminuita disponibilità di ossigeno, e dolore toracico per flogosi pleurica. Radiologicamente si evidenzia opacità, riduzione del volume polmonare proporzionale all'estensione atelettasica [10].

Edema

L'edema polmonare è una condizione causata da accumulo di fluido nei polmoni. Può essere interstiziale o alveolare, quest'ultima causa di forte dispnea laddove, invece, la prima forma può lasciare intatto lo scambio gassoso a livello parenchimale.

Nella maggioranza dei casi, la causa è un problema cardiaco (come insufficienza o stenosi mitralica, cardiomiopatia, patologia coronaria) ma può derivare anche da polmoniti, farmaci, traumi al torace, insufficienza renale. Solitamente, l'edema polmonare si sviluppa rapidamente (variante acuta) e necessita di trattamento medico di emergenza [11].

Per la diagnosi di edema, la radiografia toracica è il primo passo effettuato dal medico sulla base del sospetto clinico per differenziare tra le altre cause di dispnea. Altri test sono ECG, ecocardiogramma, ecografia toracica, pulsossimetria [12].

L'aspetto radiologico dell'edema si differenzia in base alla forma e assume alcune specificità in base all'eziologia. La **variante interstiziale** è notevole attraverso l'ispessimento delle pareti polmonari a causa dell'accumulo di fluidi; ciò risulta in una perdita di definizione delle ombre vascolari intrapolmonari e ispessimento dell'interstizio peribroncovascolare. Se sottopleurale, è meglio visibile in proiezione laterale. Il coinvolgimento delle strutture interstiziali può produrre artefatti radiografici conosciuti come linee di Kerley A e B, visibili quanto i setti interlobulari diventano prominenti, rispettivamente perivascolari e sottopleurali [13].

L'**edema alveolare**, invece, produce opacità a carattere nebuloso in RX e "a vetro smerigliato" in TC, dapprima localmente alla zona polmonare colpita (per lo più i lobi inferiori a causa della posizione del paziente e forza di gravità) ma può estendersi a tutto il volume polmonare.

Per la diagnosi differenziale, l'uso di TC o High Resolution TC (HRTC) risulta essere decisamente utile così come rilievi radiografici dovuti non intrinsecamente all'edema quanto alla causa. Un esempio è l'ipertensione polmonare venosa, spesso di origine cardiaca (insufficienza mitralica, insufficienza cardiaca...) dove le vene polmonari risultano ingrossate anche in RX o in caso di ARDS da polmonite, in cui fondamentali sono i reperti evidenziati dalla patologia sottostante.

Nell'ARDS da aumentata permeabilità capillare, invece, le evidenze interstiziali sono per lo più assenti, al contrario dell'evidente edema alveolare. Importante per la diagnosi è anche l'evoluzione temporale: l'RX risulta francamente patologico, con ombre diffuse, a 12-24 ore dalla comparsa di dispnea; le opacità tenderanno a coalescere nei giorni successivi e a produrre rilievi bilaterali per poi creare un pattern reticolare che può scomparire nei mesi successivi con la guarigione del paziente o rimanere invariato, sfociando in fibrosi polmonare irreversibile [14].

Enfisema

Per enfisema polmonare diffuso si intende *"una dilatazione permanente degli spazi aerei distali rispetto ai bronchioli terminali con lesioni distruttive delle loro pareti"*¹.

Si distingue in primitivo e secondario a ostruzione bronchiolare o retrazione parenchimale. La forma primitiva si distingue in centrolobulare e panlobulare.

La forma centrolobulare è una complicazione della bronchite cronica o broncopneumopatia cronico ostruttiva (BPCO) con il paziente che si presenta con tosse, dispnea, torace ipomobile ed iperesteso, per compensare il diminuito volume parenchimale adibito allo scambio gassoso.

Radiologicamente è possibile notare un aumento della trama bronco-alveolare, aree di iperdiafania, per lo più a livello lobare superiore e frequente cardiomegalia associata. Utili per la diagnosi clinica anche i segni di ipercapnia e ipossiemia, con aumento marcato dell'ematocrito a scopo compensativo.

Nell'enfisema panlobulare mancano i precedenti di BPCO ma il paziente può presentare una storia di asma bronchiale, seppur non costantemente. Nelle fasi iniziali può avere una sintomatologia limitata, con una dispnea che va peggiorando. In fase avanzata sono presenti, inoltre, torace globoso, espettorazione, iperfonesi e murmure vescicolare ridotto.

A livello radiologico, al contrario della forma primitiva, il disegno vascolare polmonare tende a essere meno evidente e l'iperdiafania coinvolge l'intero polmone. Sono evidenti anche i segni di modifica dell'aspetto toracico con diametri aumentati e coste orizzontalizzate [15].

¹Fradà, Semeiotica Medica nell'adulto e nell'anziano, 2014, pag. 190

Fibrosi

La fibrosi polmonare è una patologia cronica che interessa il tessuto interstiziale o alveolare polmonare con progressiva formazione di tessuto connettivo cicatriziale. Si distingue in fibrosi idiopatica o secondaria a esposizione continua a sostanze tossiche, radio-chemioterapia, TBC e polmoniti croniche.

Sulle cause che portano a insorgenza di fibrosi polmonare idiopatica sono state fatte diverse ipotesi, e sono state studiate correlazioni con fattori genetici, fumo, infezioni virali come Epatite C o Epstein-Barr ma non vi è nessuna evidenza completa.

Il primo sintomo è la dispnea seguita da tosse, febbre e artralgie. Possono presentarsi anche tachipnea, cianosi da sforzo e crepitii all'auscultazione.

L'approccio diagnostico segue una serie di step in cui, dopo la raccolta di anamnesi ed esame obiettivo, viene valutata la capacità respiratoria con emogasanalisi e spirometria a cui si associa l'RX. Le caratteristiche radiografiche sono diverse a seconda della variante istologica ma sono individuabili due reperti principali:

- *Opacità reticolari* che si concentrano per lo più a livello basale con riduzione volumetrica dei lobi in caso di patologie idiopatiche; possono aggiungersi opacità nodulari in caso di infiltrazione linfonodale.
- *Opacità sfumate o a "velatura"* se accompagnata a fenomeni degenerativi interstiziali.

Di fondamentale importanza è però l'uso di TC o HRCT, in cui le opacità reticolari sono meglio individuate con lesioni "a vetro smerigliato" che possono confluire in zone di "honeycombing" in cui i tessuti fibrotici formano strutture reticolari estese seguendo il connettivo sottopleurico o broncovascolare; possono, inoltre, evidenziarsi bronchiectasie dovute alla trazione esercitata dal tessuto fibrotico [16, 17].

Ispessimento Pleurico

L'**ispessimento pleurico localizzato** è visto come un'opacità dovuta a tessuto molle liscio, regolare e leggermente rialzato, che si estende per uno o due spazi intercostali. Spesso radiologicamente non è notabile in quanto la lesione non attenua

significativamente i raggi x al passaggio. Tuttavia, in caso di calcificazioni, sono visibili densità sottili lineari o curvilinee che tendono a decorrere parallele all'orientamento costale. Pertanto, in caso di lesioni locali più utile risulta l'uso di TC, dove la densità differente le distingue da possibili depositi di grasso subpleurico. L'ispessimento va in diagnosi differenziale anche con l'ispessimento apicale distinto da un carattere regolare, curvilineo, spesso meno di 5 mm, occasionalmente calcificato e come il nome suggerisce presente per lo più nelle posizioni superiori polmonari. Sebbene comune e di non particolare pericolosità, in caso di asimmetrie elevate, distruzione ossea o altri sintomi va sempre effettuata una TC o una risonanza magnetica (RM o RMI) per escludere possibili lesioni neoplastiche apicali.

L'ispessimento pleurico diffuso coinvolge estese porzioni della pleura fino a parlare di fibrotorace, spesso associata a fibrosi polmonare, ad esempio in caso di asbestosi. I segni sono gli stessi della forma localizzata, ma con maggiore estensione creando opacità simili a veli senza margini netti e con evidenze di solchi creati dalle altre strutture a contatto con la parte fibrotica come coste o diaframma. Utile per la diagnosi differenziale l'assenza di opacità da fluidi o effusioni [18].

Pneumotorace

Lo pneumotorace consiste nella presenza di gas nello spazio pleurico. Si definisce spontaneo laddove si verifichi senza alcun trauma antecedente, spesso per rottura di vescicole o cisti nei pressi della pleura viscerale. Può distinguersi in primario se vi è assenza di patologia polmonare sottostante, secondario in caso contrario.

La sintomatologia può variare in base alla dimensione della lesione, ma generalmente si presenta con dolore acuto e trafittivo improvviso accompagnato a dispnea (da lieve a grave) e tosse secca [19].

Radiograficamente, lo pneumotorace si evidenzia da radiotrasparenza parallela alla parete toracica con malposizionamento della linea pleurale viscerale centrale, dovuta alla presenza della camera pneumotoracica che può variare in grandezza e posizione. Il polmone coinvolto può avere dimensioni visibilmente anomale e se la causa è una patologia sottostante, sono evidenziabili segni radiologici della lesione primaria (ad esempio polmonite) o elementi che suggeriscono un trauma come ezi-

logia, quali presenza di coste rotte o corpi estranei. Nella RX del paziente supino, sono visualizzabili anche alcuni reperti come il segno del "solco profondo" dove l'angolo costofrenico è anormalmente approfondito a causa dell'accumulo laterale di aria, il segno del cuscinetto di grasso epicardiale (pneumotorace sinistro) o un inusuale bordo cardiaco reso più netto e visibile dalla lesione. Da notare l'addensamento radiologico della porzione di polmone non coinvolta direttamente nello pneumotorace a causa del raccoglimento del parenchima polmonare in uno spazio ridotto [20].

Polmonite

Le infezioni respiratorie acute, escluse la tubercolosi e il COVID, sono responsabili nel mondo di circa 4,5 milioni di decessi annui, per lo più presso i paesi in via di sviluppo e in comunità, la polmonite è la causa infettiva principalmente responsabile di mortalità con incidenza dal 6 al 20% .

Nella pratica medica, l'identificazione eziologica di una infezione respiratoria non è sempre banale, sia per motivi logistici che per difficoltà delle metodologie batterioscopiche. La radiografia del torace ha un'utilità pratica dovuta alla differenziazione tra polmoniti interstiziali, alveolari e necrotizzanti che favorisce una diagnosi differenziale tra forme virali e batteriche, a cui il diagnosta deve necessariamente aggiungere, tuttavia, informazioni di carattere clinico ed epidemiologico [21].

Alla varietà del quadro eziologico, in cui sono coinvolti batteri sia Gram-positivi che Gram-negativi, virus, miceti e parassiti, con incidenze diverse tra patologie in comunità, nosocomiali o in soggetti immunodepressi, il contesto sintomatologico appare piuttosto omogeneo. Al clinico compete dapprima la diagnosi di polmonite generica e successivamente la distinzione in forma batterica o virale. In assenza di dati batteriologici, la diagnosi si basa su dati clinico-anamnestici e radiologici.

Le polmoniti alveolari, di frequente eziologia batterica, si presentano sul piano radiologico come addensamenti lobari o grossolani focolai bronco-polmonari (Figura 2.1a). Si accompagnano a tosse, spesso produttiva e dolore pleurico.

Le polmoniti interstiziali si accompagnano a scarsi sintomi, per lo più generici come febbre e tosse secca. In RX il quadro osservabile è un generico aumento di densità o opacità poco definibili; più caratteristica è la HRTC con lesioni da opacità a "vetro smerigliato", in quanto sono coinvolti tessuti peribronchiali e perialveolari. L'eziologia è per lo più virale, spicca il Sars-Cov-2 [22], causa del COVID-19, ma anche micoplasmi e clamidie.


Le polmoniti tubercolari hanno caratteristiche peculiari. Nonostante gli sforzi globali per controllarla, la Tubercolosi (TB o TBC) resta una minaccia alla salute umana, rimanendo la prima infezione per mortalità, dopo essere stata superata brevemente dal COVID-19. Ogni anno si registrano più di 10 milioni di nuovi casi di cui 0.5 farmaco-resistenti [23]. La diagnosi inizia tipicamente dall'analisi del quadro clinico, anche se frequenti sono i casi asintomatici, e della radiografica toracica. I rilievi di imaging variano in base allo stadio della malattia [24, 25]:

TBC Primaria Nella TBC primaria, caratterizzata da sintomatologia spesso pseudoinfluenzale, un iniziale focolaio polmonare si evidenzia in RX per lo più come un'ombra nodulare isolata, omogenea, dai limiti netti che può col tempo scomparire o calcificare. Rari sono i coinvolgimenti linfoematogeni o pleurici.

TBC Post-Primaria Si divide in più fasi, non necessariamente possono presentarsi tutte o in sequenza, in base alla risposta del singolo individuo:

- La TBC miliare, dovuta a diffusione ematogena, può presentare un quadro clinico acuto con possibile diffusione meningitica, sub-acuto o cronico, ma radiologicamente presenta sempre ombre miliari fitte e piccole che possono essere circoscritte a livello polmonare, soprattutto nei lobi superiori, o essere sistemiche.
- La TBC essudativa polmonare presenta un quadro infiltrativo con essudati più limitati (tisiogena) o estesi anche all'intero polmone (caseosa), il cui quadro radiologico "a nuvola" può peggiorare fino a evidenziare opacità irregolari e confluenti fra loro.

- La TBC cavitaria, dove le opacità sono simili alla caseosa ma in uno stato di gravità peggiore, a evidenziare i fenomeni di cavitazione polmonare a cui possono unirsi fenomeni di fibrosi.



(a) Opacità in entrambi i polmoni, indicativo di polmonite. (b) CXR con compattazione arrotondata nel polmone sinistro.

Figura 2.1: Esempi di CXR con rilievi polmonari positivi. Fonte Wikimedia Foundation².

Lesioni e noduli tumorali

I tumori polmonari sono la seconda tipologia di tumore più frequente nell'uomo e nella donna (dopo rispettivamente prostata e mammella) e rappresentano una delle principali cause di mortalità per cancro a livello globale, con una prognosi spesso sfavorevole a causa della diagnosi tardiva, quando la malattia è già in fase avanzata [26]. Si distinguono principalmente in tumori primitivi (originati dal tessuto polmonare) e metastasi polmonari (provenienti da neoplasie di altri organi).

Le manifestazioni cliniche dei tumori polmonari possono variare notevolmente a seconda della localizzazione, delle dimensioni e del tipo istologico del tumore ma, in generale, sono subdole e aspecifiche e possono non manifestarsi del tutto nelle fasi iniziali della malattia. I sintomi più comuni includono tosse persistente o modificazione di una tosse cronica preesistente, emottisi (che tra i sintomi è quello

che più frequentemente porta a valutazione radiologica e conseguente diagnosi) dispnea, dolore toracico, calo ponderale non giustificato e astenia [27].

In alcuni casi, possono manifestarsi sindromi paraneoplastiche, ovvero manifestazioni cliniche non direttamente correlate all'invasione o alla crescita del tumore, ma legate alla produzione di sostanze bioattive da parte delle cellule neoplastiche o alla risposta immunitaria dell'organismo [28]. Queste sindromi possono coinvolgere diversi organi e sistemi e includono:

- Ipercalcemia: frequentemente associata al carcinoma a cellule squamose, dovuta alla produzione di peptidi simili al paratormone che aumentano i livelli di calcio nel sangue, causando nausea, confusione mentale e debolezza muscolare.
- Sindrome di Cushing ectopica: tipica del carcinoma a piccole cellule (microcitoma), causata dalla secrezione inappropriata di ACTH, che porta a iperglicemia, ipertensione e debolezza muscolare.
- Sindrome di Lambert-Eaton: una disfunzione neuromuscolare caratterizzata da debolezza muscolare progressiva, spesso associata al carcinoma a piccole cellule.
- Clubbing digitale (ippocratismo digitale): ispessimento e curvatura delle falangi distali delle dita, comune in diverse malattie polmonari, ma particolarmente associato a tumori polmonari.
- Sindromi neurologiche: come neuropatia o mielopatia. La neuropatia periferica è la sindrome neoplastica neurologica più comune. Generalmente, causa una moderata debolezza muscolare, perdita di sensibilità e ridotti riflessi distali.
- Artropatie: come poliartrite reumatica, polimialgia. In caso di tumori polmonari possono verificarsi anche sclerosi sistemiche o lupus eritematoso sistemico.

²<https://commons.wikimedia.org>

Dal punto di vista radiografico [29], le neoplasie polmonari si manifestano principalmente come:

- Noduli polmonari solitari (SPN): opacità ben circoscritte di dimensioni inferiori ai 3 cm, che possono essere di natura benigna o maligna. Un esempio è visibile in Figura 2.1b.
- Masse polmonari: lesioni superiori ai 3 cm, spesso associate a margini irregolari, spiculati o lobulati.
- Segni indiretti: atelettasie (collasso del parenchima polmonare), versamenti pleurici, ingrandimento ilare o mediastinico.
- Cavitazioni: più frequenti nei carcinomi a cellule squamose.

La CXR rappresenta spesso il primo esame eseguito, ma la sua sensibilità è limitata, soprattutto per lesioni di piccole dimensioni o localizzate in aree difficilmente valutabili (come la regione retrocardiaca o gli apici polmonari). La TC torace è l'esame di secondo livello per una valutazione più accurata. I tumori polmonari primitivi si dividono in due grandi categorie istologiche: carcinoma non a piccole cellule (NSCLC) e carcinoma a piccole cellule (SCLC) a cui si aggiungono noduli solitari, tumori rari e metastasi.

Il Nodulo Polmonare Solitario (SPN) è una lesione rotondeggiante, ben definita, con diametro inferiore ai 3 cm, circondata da parenchima polmonare normale e priva di atelettasie, linfadenopatie o versamento pleurico associato. I reperti radiografici evidenziano un' opacità rotondeggiante o ovalare, a margini regolari o irregolari. La presenza di calcificazioni centrali o a "guscio d'uovo" suggerisce una natura benigna. I margini spiculati o lobulati sono più suggestivi per malignità.

Il Carcinoma a Cellule Squamose è il secondo istotipo più frequente, con circa il 23% di tutti i casi di tumore al polmone, ed è associato fortemente al fumo di sigaretta; origina dalle cellule epiteliali bronchiali ed è tipicamente localizzato centralmente, formato una struttura polipoide che cresce nel lume bronchiale e contemporaneamente invade il tessuto sottostante. All'RX si presenta come una massa ilare o perilare con margini irregolari, spesso con necrosi centrale e cavitazione, e può evidenziare calcificazioni occasionali.

Il Carcinoma Non a Piccole Cellule (NSCLC) costituisce circa l'60% di tutti i tumori polmonari. In realtà racchiude in sé diverse tipologie tumorali che si comportano in maniera simile, clinicamente ed epidemiologicamente, e trattati con terapia analoga, a differenza dei tumori a piccole cellule, da cui sono distinti nella classificazione. Il paziente può presentarsi con tosse cronica, dispnea, dolore toracico. L'emottisi o l'emoftoe è più frequente nel tumore squamoso. Si suddivide in diverse istologie:

Adenocarcinoma: è il sottotipo più comune nei non fumatori. Origina dalle cellule epiteliali ghiandolari, spesso localizzato perifericamente e dà precocemente metastasi. Radiograficamente, è un nodulo o massa solida periferica con margini irregolari. È possibile la presenza di pattern "a velatura", a causa della frequente formazione di fibrosi interna e intorno alla massa tumorale, con visibilità di opacità "a vetro smerigliato" in TC, nelle fasi iniziali.

Carcinoma a Grandi Cellule: forma meno differenziata del NSCLC, a rapida crescita, localizzato frequentemente in aree periferiche, tende tuttavia a rimanere localizzata nel torace e dare metastasi a distanza solo nelle fasi avanzate. Si presenta in RX spesso in posizione periferica come una massa solitaria mal definita e, al tempo di diagnosi, spesso già voluminosa.

Il Carcinoma a Piccole Cellule (SCLC o Microcitoma) rappresenta circa il 15% dei tumori polmonari ed è altamente aggressivo, con rapida crescita e metastasi precoci e fortemente associato al fumo.

Tra i sintomi, sono presenti tosse, emottisi, perdita di peso e, a volte, sindromi paraneoplastiche che possono dare sintomi clinici in fase precoce e migliorare la prognosi del paziente che, è spesso infausta a causa della rapida progressione della patologia che spesso porta, al tempo di diagnosi, a un quadro già invasivo e inoperabile. In radiologica è possibile osservare una massa centrale voluminosa, spesso con estensione mediastinica. La rapida metastatizzazione porta a un'ingrandimento ilare bilaterale e linfadenopatie mediastiniche.

Le metastasi polmonari derivano da tumori primari localizzati in altri organi (mammella, colon, rene, melanoma, ecc.) e sono la tipologia di metastasi più frequente, dovuta alla ricca vascolarizzazione del parenchima polmonare, sebbene anche

il trasporto linfatico può avere il suo ruolo, soprattutto in caso di carcinomi alla mammella o stomaco. I reperti radiografici sono molto variabili, sia in base all'origine tumorale che all'adattamento delle cellule al tessuto polmonare. Possono presentarsi noduli unici o, più frequentemente, multipli, bilaterali, distribuiti in modo casuale, ma anche disseminazioni noduliformi, versamento pleurico e linfangite.

I tumori polmonari presentano, quindi, un ampio spettro di manifestazioni cliniche e radiologiche. Sebbene la CXR sia un primo strumento diagnostico utile, la sua sensibilità e specificità sono limitate, rendendo fondamentale l'integrazione con la TC e, in molti casi, con la PET/TC per una migliore stadiazione.

2.1.3 Patologie Cardiaco-Mediastiniche


Le patologie cardiache rappresentano una delle principali cause di morbidità e mortalità a livello globale. Tra le condizioni più frequentemente identificate tramite imaging radiografico del torace vi sono la cardiomegalia e l'allargamento del mediastino, che costituiscono importanti indicatori di malattie cardiovascolari sottostanti. Sebbene questi reperti possano essere asintomatici nelle fasi iniziali, spesso si associano a segni clinici che riflettono la compromissione della funzione cardiaca.

Cardiomegalia


La cardiomegalia non rappresenta una malattia a sé stante, ma un segno radiografico che riflette l'aumento delle dimensioni del cuore, solitamente dovuto a ipertrofia o dilatazione delle camere cardiache. Le cause possono variare da patologie croniche, come l'ipertensione arteriosa e le cardiomiopatie, a condizioni acute come l'infarto miocardico. I sintomi più comuni includono dispnea, dapprima da sforzo poi anche a riposo, edema periferico, con gonfiore agli arti inferiori, affaticamento cronico e ridotta tolleranza all'esercizio fisico, palpitazioni o aritmie e dolore toracico, soprattutto in caso di ischemia miocardica concomitante [30].

Radiograficamente, si evidenzia aumento del rapporto cardiotoracico (CTR): si considera patologico un rapporto superiore al 50% in una proiezione postero-anteriore (PA) [31]. Il CTR viene calcolato misurando la larghezza massima del cuore e confrontandola con la larghezza interna del torace. Notabili, inoltre, alterazioni del profilo cardiaco: bordi arrotondati o "globosi" che suggeriscono una dilatazione delle camere cardiache [32].

Al livello polmonare, possono evidenziarsi segni di congestione, come linee di Kerley B, edema interstiziale e opacità alveolari nei casi di scompenso cardiaco.



(a) Cardiomegalia. Fonte: James Heilman, MD; Wikipedia



(b) Espansione mediastinica. Crediti a Nausheen et al. [33]

Figura 2.2: Esempi di CXR con rilievi cardio-mediastinici. Fonte Wikipedia.

Espansione mediastinica

L'allargamento del mediastino si riferisce all'espansione anomala delle strutture mediastiniche, inclusi cuore, grandi vasi e linfonodi. Questa condizione può derivare da patologie cardiache, come versamenti pericardici o aneurismi aortici, ma anche da cause non cardiache, come linfomi o masse mediastiniche. I sintomi possono sovrapporsi a quelli della cardiomegalia, del quale rappresenta un supergruppo, con l'aggiunta di disfagia, se c'è compressione esofagea, stridore o dispnea intensa, in caso di compressione delle vie aeree; turgore delle vene giugulari e sindrome della vena cava superiore nei casi più gravi.

La radiografia del torace (CXR) rappresenta uno strumento fondamentale per la valutazione iniziale. I reperti più significativi includono un visibile aumento della densità centrale sul film radiografico, dislocazione tracheale o compressione delle vie aeree in caso di masse voluminose [34].

Presenti, inoltre, segni indiretti come deviazione del cuore o dei grandi vasi, che possono suggerire la presenza di una massa o di un aneurisma.

2.1.4 Altre Patologie

Altre condizioni che sono frequentemente riscontrabili nella pratica clinica e rilevabili tramite la CXR sono le ernie e le fratture. Queste patologie, pur non coinvolgendo direttamente il parenchima polmonare o il cuore, possono avere un impatto significativo sulla salute del paziente e influenzare la dinamica respiratoria o la stabilità strutturale della gabbia toracica.

Ernia

Le ernie toraciche più comuni osservabili su una CXR sono le ernie diaframmatiche, che si verificano quando una parte degli organi addominali protrude attraverso un'apertura anomala nel diaframma verso la cavità toracica. Le cause possono essere congenite (ad esempio l'ernia di Morgagni) o acquisite, spesso secondarie a traumi, interventi chirurgici o aumento cronico della pressione intra-addominale.

I sintomi possono variare in base alle dimensioni e alla natura dell'ernia: può essere quasi del tutto asintomatica come presentare dispnea e difficoltà respiratoria, soprattutto se c'è compressione polmonare, dolore toracico o addominale o sintomi gastrointestinali, come reflusso o occlusione intestinale nei casi gravi.

Alla CXR, i segni suggestivi di ernia diaframmatica includono opacità retrocardiche o paracardiache con contorni arrotondati o irregolari, elementi idro-aerei se è presente intestino erniato con contenuto liquido e gas, spostamento delle strutture mediastiniche o sollevamento del diaframma [35];

La conferma diagnostica spesso richiede ulteriori esami, come la TC o uno studio con mezzo di contrasto per definire meglio il contenuto e l'estensione dell'ernia.

Altra ernia possibile è quella gastrica o iatale, che raramente è notabile in CXR, il quale, infatti, non fa parte della routine diagnostica della patologia; tuttavia, in taluni casi, è possibile notare una radiotrasparenza dovuta all'aria nella distensione gastrica erniata e una linea di difetto diaframmatico, per lo spostamento dovuto allo stomaco, occupanti solo una parte del torace [36];

Frattura costale

Le fratture costali rappresentano il tipo di frattura toracica più comune e sono generalmente conseguenza di traumi toracici diretti, come incidenti stradali o cadute. Le fratture possono interessare una o più coste e, nei casi più gravi, coinvolgere anche lo sterno o le vertebre toraciche. In presenza di fratture multiple, si può sviluppare, inoltre, instabilità della parete toracica.

I sintomi tipici includono dolore toracico acuto, peggiorato dalla respirazione profonda, tosse o movimento con difficoltà respiratoria nei casi più gravi. Crepitio sottocutaneo può evidenziarsi se associato a pneumotorace o enfisema sottocutaneo. A livello radiologico si possono notare linee radiotrasparenti che interrompono la continuità dell'osso, indicative di frattura e spostamento dei monconi ossei in caso di frattura scomposta. Possibili anche segni indiretti di complicanze, come pneumotorace, emotorace o contusione polmonare [37, 38].

Tuttavia, alcune fratture, specialmente quelle delle coste anteriori o posteriori, possono essere difficili da visualizzare su una radiografia standard a causa della profondità di risoluzione dei raggi o la sovrapposizione con altre strutture. Alcuni autori, come Bansidhar et al [39], pertanto considerano l'uso della CXR inutile per la sola frattura costale, a cui preferire l'uso di ecografia o TC torace per una valutazione più accurata nei casi più complessi.

2.1.5 Indicazioni Aggiuntive

È importante sottolineare che la radiografia del torace fornisce una valutazione quasi sempre preliminare e che, in presenza di reperti sospetti, sono spesso necessari ulteriori approfondimenti con ecocardiografia, TC o RM toracica per una definizione più accurata della morfologia e della specificità della lesione individuata.

2.2 Ontologie Mediche

L'uso delle ontologie mediche è fondamentale per garantire coerenza, standardizzazione e interoperabilità nell'analisi dei dati in medicina, fornendo una strutturazione della conoscenza clinica. Esse forniscono vocabolari controllati che permettono di codificare diagnosi, patologie, procedure mediche e strutture anatomiche in modo standardizzato, facilitando l'integrazione tra sistemi diversi.

Le principali ontologie utilizzate in ambito radiologico e diagnostico sono UMLS (Unified Medical Language System), ICD-10 (International Classification of Diseases) e RadLex. Ognuna di esse ha obiettivi e strutture specifiche, che ne determinano l'applicabilità in contesti diversi.

2.2.1 Unified Medical Language System

Lo Unified Medical Language System (UMLS) [40] è un sistema sviluppato dal National Library of Medicine (NLM) degli Stati Uniti, progettato per unificare e integrare diversi vocabolari e classificazioni mediche.

Si compone di tre principali componenti:

- Metathesaurus: raccoglie e collega concetti provenienti da oltre 200 vocabolari medici (tra cui SNOMED-CT, LOINC, MeSH e ICD).
- Semantic Network: categorizza i concetti medici in tipologie semantiche (es. "Patologie", "Procedure Mediche").
- Lexicon and Tools: strumenti per il processamento del linguaggio medico.

UMLS non è una classificazione a sé stante, ma un meta-sistema che collega più ontologie e terminologie esistenti, unifica terminologie diverse, consentendo la mappatura tra codifiche eterogenee. Esso include relazioni tra concetti, favorendo l'interoperabilità tra sistemi sanitari ed è ampiamente usato per l'estrazione di informazioni cliniche da testi medici.

2.2.2 International Classification of Diseases

L'International Classification of Diseases (ICD-10) [41, 42] è un sistema di classificazione delle malattie e condizioni di salute sviluppato dall'Organizzazione Mondiale della Sanità (OMS). È il sistema standard internazionale per la codifica delle diagnosi e delle cause di morte.

Presenta una codifica gerarchica in 21 capitoli, che coprono malattie, condizioni patologiche e procedure. Ogni diagnosi ha un codice alfanumerico univoco, composto da una lettera seguita da cifre (es. J18.9 per la polmonite non specificata) in cui le categorie principali presentano tre caratteri, (J18 per la polmonite) e le sottocategorie quattro o più caratteri, (J18.9 per indicare "non specificata").

È obbligatoria per la codifica clinica in molti sistemi sanitari internazionali, utilizzata per fatturazione sanitaria, epidemiologia e ricerca clinica. Va notato che non fornisce relazioni semantiche tra concetti, ma è una classificazione rigida e gerarchica, essendo orientata all'uso clinico e amministrativo, mentre UMLS è una rete concettuale che collega diversi sistemi di codifica.

2.2.3 RadLex

RadLex [43, 44] è un vocabolario strutturato sviluppato dalla Radiological Society of North America (RSNA) per standardizzare la terminologia in radiologia. Contiene oltre 75.000 termini radiologici, inclusi:

- Anatomia (es. polmone destro).
- Patologie (es. nodulo polmonare).
- Procedure di imaging (es. TC torace senza contrasto).
- Descrizioni qualitative (es. opacità a vetro smerigliato).

È organizzato in una gerarchia ontologica, con relazioni tra i concetti per permettere un'interpretazione più avanzata. Essendo specificamente progettato per radiologia e imaging medico, è usato per standardizzare referti e migliorare l'analisi automatizzata delle immagini, pertanto può essere integrato in strumenti di AI per l'elaborazione e il riconoscimento di anomalie nelle immagini medicali.

2.3 Machine Learning e riconoscimento immagini

Negli ultimi anni, lo sviluppo dell'IA e dei metodi di Deep Learning ha introdotto nuove opportunità per l'analisi automatizzata delle immagini mediche, incluse le radiografie del torace. Le reti neurali convoluzionali (CNN), per esempio, hanno dimostrato performance promettenti nell'individuazione di diverse patologie – come polmonite, cardiomegalia, versamento pleurico e pneumotorace – anche se permangono molte sfide legate alla comprensione e validazione di questi modelli in contesti clinici. Di seguito viene fornita una panoramica delle principali tecnologie e il loro uso in ambito clinico.

2.3.1 Machine Learning

Il Machine Learning (ML), o apprendimento automatico, è una branca dell'intelligenza artificiale che si occupa dello sviluppo di algoritmi e modelli capaci di apprendere dai dati e migliorare le proprie prestazioni nel tempo senza essere esplicitamente programmati. Il concetto chiave del machine learning è la capacità dei sistemi di riconoscere pattern complessi e fare previsioni o decisioni basate su dati osservati.

Il machine learning si suddivide principalmente in tre categorie [45]:

Apprendimento Supervisionato: il modello viene addestrato su un dataset etichettato, dove ogni input è associato a un output noto. Esempi includono la classificazione di immagini e la regressione.

Apprendimento Non Supervisionato: il modello lavora su dati non etichettati per identificare pattern nascosti o strutture nei dati, come il clustering e la riduzione della dimensionalità.

Apprendimento per Rinforzo: un agente apprende a compiere azioni in un ambiente per massimizzare una ricompensa cumulativa, utilizzato in ambiti come la robotica e i giochi.

Le Reti Neurali Artificiali (ANN) sono modelli computazionali ispirati alla struttura e al funzionamento del cervello e dei neuroni umani. Una rete neurale è composta da "neuroni artificiali" organizzati in strati (layers), così da simulare, in maniera ancora limitata, una rete di neuroni reali e il loro meccanismo integrativo e decisionale. Pertanto si distinguono:

- **Layer di Input:** riceve i dati grezzi dal mondo esterno.
- **Layer Nascosti (Hidden Layers):** elaborano le informazioni attraverso connessioni pesate e funzioni di attivazione, consentendo la modellazione di relazioni complesse.
- **Layer di Output:** fornisce il risultato finale del processo di elaborazione.

Il neurone artificiale, noto anche come perceptron, è l'elemento fondamentale delle reti neurali artificiali. Ispirato al funzionamento dei neuroni biologici, il neurone artificiale riceve input, li elabora e produce un output. La sua struttura base comprende:

1. **Input:** valori numerici che rappresentano le caratteristiche dei dati in ingresso.
2. **Pesi Sinaptici:** ogni input è associato a un peso che ne determina l'importanza relativa.
3. **Sommatore:** calcola la somma pesata degli input, utile per restituire un valore singolo in output.
4. **Bias:** un termine aggiuntivo che permette al modello di adattare la funzione di attivazione, spostandola a destra o sinistra nel piano cartesiano. Senza il bias, la funzione di attivazione sarebbe vincolata a passare per l'origine del piano cartesiano, limitando la flessibilità del modello. Il bias permette, infatti, di spostare la curva della funzione di attivazione, migliorando la capacità del modello di adattarsi ai dati, e modulare la soglia di attivazione, controllando più precisamente quando un neurone si "attiva".
5. **Funzione di Attivazione:** introduce la non linearità nel modello e determina l'output finale.

Le funzioni di attivazione non lineari sono fondamentali per il funzionamento delle reti neurali. Senza di esse, anche una rete complessa si ridurrebbe a una semplice combinazione lineare degli input, limitandone drasticamente le capacità. Al contrario, grazie al loro uso è possibile modellare relazioni complesse e rappresentare pattern non lineari nei dati e permette di estrarre caratteristiche significative anche in presenza di alta dimensionalità.

Ogni neurone calcola una somma pesata delle sue entrate, aggiunge un bias e applica una funzione di attivazione per introdurre non-linearità nel modello:

$$Output = f(\sum w_i x_i + b) \quad (2.3.1)$$

dove w_i sono i pesi, x_i gli input, b il bias e f la funzione di attivazione [46].

Le reti neurali possono essere di vario tipo, tra cui:

- **Feedforward Neural Networks:** in cui i dati fluiscono in una sola direzione, dall'input all'output.
- **Recurrent Neural Networks (RNN):** progettate per elaborare sequenze di dati, come il testo o il parlato.
- **Convolutional Neural Networks:** specializzate nell'elaborazione di dati strutturati come immagini.

2.3.2 Reti Neurali Convoluzionali

Le Reti Neurali Convoluzionali rappresentano una delle architetture di deep learning più influenti e utilizzate, soprattutto nell'ambito dell'elaborazione delle immagini.

Storia in Breve

Il termine convoluzione fu introdotto nel mondo del machine learning già nel 1988 da Toshiyuki [47] dove la funzione di un neurone venne generalizzata rimpiazzando la moltiplicazione con la convoluzione.

Dopo l'evoluzione prodotta da Yann LeCun negli anni '90 con il modello LeNet-5 [48, 49] per il riconoscimento di caratteri manoscritti, le CNN hanno visto un'esplosione di interesse, soprattutto con l'avvento di modelli quale AlexNet (Figura 2.3b)

che ha rivoluzionato il campo della visione artificiale, vincendo la competizione ImageNet nel 2012, portando il tasso di errore medio dal 25% degli anni precedenti allo 3,5% [50]. Tale competizione, il cui nome completo è ImageNet Large Scale Visual Recognition Challenge (ILSVRC) nasce nel 2010 e si ripete annualmente. In tale occasione, programmi software vengono fatti competere per classificare e rilevare correttamente oggetti e scene contenuti nelle immagini. Nell'ambito della competizione viene impiegata una lista ridotta del dataset chiamato, per l'appunto, ImageNet che, nel completo, contiene più di 14 milioni di immagini labellate [51, 52].

La ResNet (Residual Network) è un'architettura di rete neurale convoluzionale introdotta da He et al. nel 2015 [53]. Il suo principale contributo è stato l'introduzione dei residual blocks, che affrontano il problema della scomparsa del gradiente nelle reti profonde. Invece di apprendere direttamente una trasformazione tra gli strati, la rete apprende una funzione residua rispetto all'input originale. Ogni blocco ha una connessione diretta (skip connection) che permette al segnale di bypassare alcuni strati, facilitando la propagazione del gradiente durante il training.

Successivamente, l'evoluzione di queste architetture ha portato a miglioramenti significativi nella capacità di apprendere rappresentazioni gerarchiche complesse, fondamentali per affrontare compiti di classificazione, segmentazione e rilevamento di oggetti.

2.3.3 Struttura Generale di una CNN

Una CNN è composta da una sequenza di livelli distinti, ciascuno con un ruolo specifico nell'estrazione e trasformazione delle feature dall'immagine di input, come visualizzabile in Figura 2.3a.

La convoluzione è un'operazione matematica che permette di applicare un filtro su una matrice di input, che rappresenta l'immagine, per estrarre caratteristiche significative.

La matrice di input è una rappresentazione numerica dell'immagine, dove ogni elemento corrisponde a un valore di intensità di un pixel. Un filtro (o kernel) è una piccola matrice di pesi che viene fatta scorrere sull'immagine, eseguendo operazioni





Figura 2.3: Esempi di architetture di CNN per la classificazione di immagini. Immagini tratte da Alzubaidi et al. [54]

di prodotto scalare con le regioni locali dell'input. Questo processo evidenzia pattern specifici, come bordi o texture, che vengono utilizzati per costruire rappresentazioni gerarchiche dell'immagine. L'uso della convoluzione consente alle CNN di sfruttare la struttura spaziale dei dati, rendendole più efficienti rispetto alle reti neurali feed-forward tradizionali (FFN), che trattano ogni pixel come un'entità separata senza considerare le relazioni spaziali. A differenza di una rete neurale feed-forward, infatti, in cui ogni neurone è connesso a tutti i neuroni dello strato successivo, una CNN sfrutta connessioni locali e condivisione dei pesi tramite filtri convoluzionali. Questo approccio riduce il numero di parametri da apprendere e migliora l'efficienza computazionale, rendendo le CNN particolarmente adatte all'elaborazione delle immagini.

Livello di Convoluzione

Il livello di convoluzione applica filtri (o kernel) all'immagine di input per estrarre caratteristiche rilevanti come bordi, texture e pattern.

Kernel Un filtro W di dimensione $k \times k$ viene fatto scorrere sull'immagine di input X per produrre una mappa delle feature:

$$Y : Y_{i,j} = \sum_m \sum_n X_{i+m, j+n} W_{m,n} + b \quad (2.3.2)$$

descrive il processo con cui un filtro (o kernel) estrae informazioni da un'area specifica dell'immagine.

- X rappresenta la matrice di input, ovvero l'immagine in forma numerica, in cui ogni elemento corrisponde all'intensità di un pixel.
- W è il filtro convoluzionale, una piccola matrice di pesi che viene appresa durante l'addestramento della rete.
- b è il bias, un valore che aiuta il modello a regolare le attivazioni.
- i, j indicano la posizione del pixel nella mappa delle feature risultante.
- m, n rappresentano gli indici del filtro, che scorre sulla matrice di input per calcolare nuove feature.

L'operazione di convoluzione consiste nel sovrapporre il filtro a una porzione dell'immagine, moltiplicare gli elementi corrispondenti e sommare i risultati. Questo processo viene ripetuto spostando il filtro su tutta l'immagine, generando una nuova matrice (la feature map) che evidenzia le caratteristiche apprese dal filtro, come bordi, texture o pattern più complessi.

Ad esempio, un filtro può essere progettato per rilevare bordi orizzontali, rispondendo con valori alti in corrispondenza delle transizioni di luminosità. Un altro filtro potrebbe individuare pattern più complessi come angoli o curve. Le CNN utilizzano molteplici filtri nei primi strati per estrarre caratteristiche di basso livello, mentre gli strati successivi combinano queste informazioni per riconoscere forme e oggetti più astratti.

I filtri permettono l'estrazione automatica delle feature locali e vengono appresi durante il processo di addestramento.

Ad esempio, supponendo di avere un'immagine in scala di grigi rappresentata da una matrice 5x5 di pixel con valori compresi tra 0 e 255, un filtro 3x3 potrebbe essere progettato per rilevare bordi orizzontali. Applicando la convoluzione, il filtro scorre attraverso l'immagine, moltiplicando i valori dei pixel con i pesi del filtro e sommando i risultati, generando una nuova matrice (feature map) che enfatizza le caratteristiche desiderate. Questo processo consente alla rete di riconoscere schemi e dettagli specifici a diversi livelli di astrazione.

Esistono diversi tipi di kernel comunemente usati nelle CNN, ciascuno progettato per rilevare particolari caratteristiche dell'immagine:

- **Filtro di Sobel:** rileva bordi orizzontali e verticali tramite variazioni di intensità.
- **Filtro Laplaciano:** evidenzia le variazioni rapide di intensità, utile per contorni.
- **Filtro Gaussian Blur:** applica una sfocatura per ridurre il rumore e migliorare la robustezza della rete.
- **Filtro di Sharpening:** enfatizza i dettagli migliorando nitidezza dell'immagine.
- **Filtro di Embossing:** evidenzia le variazioni di profondità e texture simulando un effetto in rilievo.

Questi filtri costituiscono i primi livelli di estrazione delle feature, mentre nei livelli più profondi la rete apprende autonomamente caratteristiche più complesse.

Stride Altro parametro fondamentale è lo stride o passo di avanzamento, fondamentale nelle operazioni di convoluzione e pooling di una CNN. Indica di quanti pixel il filtro deve spostarsi in ogni passaggio mentre scorre sull'immagine di input.

Se lo stride è impostato a 1, il filtro si muove di un pixel alla volta, producendo una mappa delle feature più grande e dettagliata. Se lo stride è 2 o più, il filtro salta alcuni pixel a ogni passaggio, riducendo le dimensioni della feature map risultante.

Uno stride piccolo, quindi si traduce in una maggiore risoluzione nella mappa delle feature, ma più costi computazionali, al contrario, con uno stride più grande, le informazioni sono meno dettagliate, ma la dimensione delle feature map e il numero di parametri sono ridotti, rendendo il modello più efficiente.

In pratica, lo stride permette di controllare il trade-off tra risoluzione spaziale e efficienza computazionale, influenzando direttamente la capacità della rete di catturare dettagli fini o più astratti.

Funzione di Attivazione

Dopo ogni operazione di convoluzione, si applica una funzione di attivazione non lineare, generalmente la ReLU (Rectified Linear Unit); questo aiuta a introdurre non-linearità nel modello, migliorando la capacità della rete di apprendere pattern complessi.

Strato di Pooling

Il pooling riduce la dimensionalità della rappresentazione e aiuta a rendere il modello più robusto alle traslazioni:

- **Max Pooling:** seleziona il valore massimo in una finestra.
- **Average Pooling:** calcola la media dei valori nella finestra.

Lo strato di pooling svolge un ruolo cruciale nella riduzione della dimensionalità della rappresentazione dei dati, diminuendo il numero di parametri e la complessità computazionale. Questo processo contribuisce a migliorare la generalizzazione del modello riducendo il rischio di overfitting, poiché mantiene solo le informazioni più rilevanti. Inoltre, il pooling introduce una certa invarianza alle traslazioni, il che significa che piccole variazioni nella posizione degli oggetti nelle immagini non influenzano drasticamente le prestazioni della rete. Questi vantaggi rendono lo strato di pooling un componente fondamentale nelle architetture CNN moderne.

Strati Fully Connected (FC)

Dopo una serie di livelli convoluzionali e di pooling, la CNN è appiattita e collegata a strati densi (fully connected), che svolgono il ruolo di classificatori.

Il vettore risultante viene moltiplicato per i pesi della rete e processato con una funzione di attivazione **softmax** per ottenere le probabilità di classificazione:

$$P(y_i | X) = \frac{e^{W_i h}}{\sum_j e^{W_j h}} \quad (2.3.3)$$

La funzione trasforma un insieme di valori in una distribuzione di probabilità, assegnando a ogni classe un punteggio normalizzato tra 0 e 1. Questo permette di interpretare l'output del modello come la probabilità che l'input appartenga a ciascuna delle classi previste, garantendo che la somma delle probabilità sia sempre pari a 1. Softmax è particolarmente utile nei problemi di classificazione multiclasse, dove aiuta a determinare la classe più probabile per un determinato input.

2.3.4 Fondamenti dei Transformer e Computer Vision

Storia dei Transformer

I Transformer sono stati introdotti da Vaswani et al. con il famoso paper *Attention is all you need* (2017) [55] per l'elaborazione del linguaggio naturale (NLP). La loro capacità di modellare dipendenze a lungo raggio li ha resi fondamentali in molte applicazioni, inclusa la Computer Vision, dove hanno sostituito progressivamente le CNN in numerosi task.

L'idea chiave alla base dei Transformer è l'uso del meccanismo di self-attention, che consente alla rete di analizzare intere sequenze di dati contemporaneamente, senza dover processare le informazioni in modo sequenziale come nelle RNN. Questo approccio riduce significativamente i problemi legati alla propagazione del gradiente e migliora la capacità del modello di apprendere relazioni a lungo raggio tra elementi di un input.

Funzionamento dei Transformer

Self-Attention Il meccanismo di attenzione è un metodo che permette al modello di pesare l'importanza di diverse parti dell'input durante l'elaborazione di un'informazione. In particolare, la self-attention consente a ciascun elemento dell'input di interagire con gli altri e determinare a quali parti della sequenza prestare maggiore attenzione.

Per spiegare il concetto in modo intuitivo, è possibile paragonarlo a un lettore esperto analizza un testo: invece di leggere ogni parola con la stessa enfasi, il lettore si sofferma sui termini più rilevanti per comprendere il significato complessivo della frase.

Matematicamente, il meccanismo di self-attention è definito come:

$$Attention(Q, K, V) = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (2.3.4)$$

Dove:

- Q (Query) rappresenta la richiesta di attenzione per un particolare elemento della sequenza.
- K (Key) è la chiave che aiuta a determinare la rilevanza di altri elementi rispetto alla query. La T indica la trasposta della matrice K .
- V (Value) contiene le informazioni effettive che devono essere estratte.

L'operazione di self-attention assegna un punteggio di correlazione tra ogni coppia di elementi e, grazie alla funzione softmax, normalizza questi punteggi per generare una ponderazione finale su quali parti del dato di input debbano ricevere più attenzione.

La divisione per $\sqrt{d_k}$ serve a normalizzare i valori per evitare che la softmax produca gradienti estremamente piccoli o grandi, rendendo il training più stabile.

Ogni token viene, quindi, trasformato nei tre vettori Query, Key e Value. Questi vettori non sono calcolati in modo statico, ma dipendono da matrici di pesi che vengono apprese durante l'addestramento:

$$Q = XW^Q; K = XW^K; V = XW^V \quad (2.3.5)$$

con W^Q, W^K, W^V come matrici di pesi che il modello impara nell'addestramento; X , invece, rappresenta l'input.

Multi-Head Attention Un'ulteriore evoluzione del meccanismo di self-attention è la Multi-Head Attention (MHA), che suddivide lo spazio dell'attenzione in più sottospazi, permettendo al modello di apprendere diverse rappresentazioni delle relazioni tra gli elementi dell'input. Questo significa che il modello può analizzare simultaneamente più aspetti dei dati, migliorando la sua capacità di catturare pattern complessi.

La formula per la Multi-Head Attention è:

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W^O \quad (2.3.6)$$

Dopo che le diverse head di self-attention hanno elaborato l'input separatamente, i risultati vengono concatenati in un'unica matrice. Tuttavia, questa concatenazione da sola non avrebbe un significato ottimale dal punto di vista dell'apprendimento.

Per questo motivo, si applica una trasformazione lineare tramite la matrice di pesi W^O appresa quindi, durante il training, che permette di combinare in modo efficace le informazioni apprese dalle diverse teste di attenzione, generando un'unica rappresentazione più ricca e compatta.

2.3.5 Architettura del Vision Transformer (ViT)

Differenze tra Transformer per NLP e Visione

Nei Transformer per visione [56], l'input è un'immagine divisa in piccole porzioni quadrate chiamate **patch**, ognuna delle quali viene trasformata in un token che rappresenta un vettore numerico. Questa suddivisione è analoga alla tokenizzazione di una frase nel NLP, in cui ogni parola viene trattata come un'unità separata.

A differenza delle CNN, che utilizzano convoluzioni per estrarre caratteristiche locali sfruttando la continuità spaziale, i Transformer trattano l'immagine come una sequenza di token indipendenti, come mostrato in Figura 2.4, apprendendo relazioni tra le patch attraverso l'attenzione globale. Questo approccio permette ai Transformer di modellare connessioni a lungo raggio tra le regioni dell'immagine, superando i limiti delle convoluzioni locali e migliorando la capacità di catturare pattern più complessi. Tuttavia, l'assenza di un'induttività spaziale intrinseca richiede l'introduzione di codifiche posizionali per preservare l'ordine spaziale delle informazioni e permettere al modello di comprendere la struttura dell'immagine.

Patch Embedding

L'immagine viene divisa in piccole porzioni quadrate chiamate patch, ciascuna delle quali viene trasformata in un vettore numerico attraverso una proiezione lineare.




Figura 2.4: Architettura dei Vision Transformer. Immagine tratta da Dosovitskiy et al. [56]

Questo processo consente di convertire un'immagine bidimensionale in una sequenza di token, analoga alla tokenizzazione del testo nel NLP. La formula per ottenere il vettore embedding di ciascuna patch è:

$$z_0 = [x_1E; x_2E; \dots; x_NE] + E_{pos} \quad (2.3.7)$$

Dove E rappresenta la matrice dei pesi appresa dal modello e E_{pos} è l'embedding posizionale, fondamentale per mantenere la relazione spaziale tra le patch.

Self-Attention e Multi-Head Attention

Il meccanismo di self-attention consente a ciascuna patch di interagire con le altre per apprendere relazioni globali all'interno dell'immagine. Questo è particolarmente utile nelle immagini mediche, dove le relazioni tra diverse regioni dell'immagine possono essere critiche per la diagnosi. L'MHA migliora ulteriormente questa capacità suddividendo lo spazio dell'attenzione in più sotto-spazi, permettendo al modello di catturare feature a diversi livelli di astrazione.

Feed-Forward Network

Dopo l'applicazione della Multi-Head Attention, il ViT utilizza una rete completamente connessa FFN per elaborare ulteriormente le informazioni estratte. Questa è generalmente composta da due strati lineari con una funzione di attivazione non

lineare intermedia (tipicamente ReLU o GELU). Ogni blocco Transformer include un meccanismo di normalizzazione per stabilizzare l'addestramento e migliorare la convergenza.

Positional Encoding

A differenza delle CNN, che sfruttano le convoluzioni per preservare la struttura spaziale, i Transformer necessitano di un meccanismo esplicito per incorporare la posizione delle patch. Questo viene fatto tramite il Positional Encoding, che introduce una rappresentazione sinusoidale per ciascuna patch, preservando l'ordine e la relazione spaziale tra di esse.

Classification Head

Dopo aver processato tutte le patch attraverso gli strati Transformer, il modello utilizza un token speciale [CLS] per aggregare le informazioni globali dell'immagine. Questo token viene passato attraverso un Multi-Layer Perceptron (MLP) finale, che produce la predizione finale della classe dell'immagine. L'MLP è composto da più strati fully connected con funzioni di attivazione non lineari, ed è ottimizzato per la classificazione.

Questa architettura consente al ViT di apprendere relazioni complesse tra diverse regioni dell'immagine senza le limitazioni imposte dalle convoluzioni locali delle CNN, risultando particolarmente efficace su dataset di grandi dimensioni.

2.4 Explainable AI

L'Explainable AI (XAI) è un insieme di tecniche e metodologie volte a rendere i modelli di intelligenza artificiale più trasparenti e comprensibili per gli esseri umani. Questo aspetto è particolarmente cruciale nell'ambito medico, dove l'interpretabilità delle decisioni è fondamentale per garantire la fiducia e l'adozione clinica dei modelli di deep learning.

Caratteristica	CNN	Vision Transformer (ViT)
Unità base	Filtro convoluzionale	Patch embedding + self-attention
Struttura	Convoluzioni + pooling + fully connected	Self-attention + MLP
Preservazione spaziale	Mantiene relazioni locali	Necessita di Positional Encoding
Dati richiesti	Efficiente su dataset piccoli	Necessita di dataset grandi
Scalabilità	Limitata da convoluzioni locali	Elevata grazie all'attenzione globale
Parallelizzazione	Limitata, elaborazione sequenziale	Alta, per il meccanismo di attenzione
Interpretabilità	Feature maps	Attention maps
Efficienza computazionale	Efficiente su hardware standard	Costosa, richiede risorse elevate

Tabella 2.1: Confronto tra architetture CNN e Vision Transformer (ViT)

2.4.1 Concetti

Una prima distinzione necessaria è la differenza tra interpretabilità e spiegabilità:

Interpretabilità: la capacità di un modello di essere compreso in modo intuitivo da un essere umano senza ulteriori elaborazioni. In letteratura, anche i termini “intelligibility” [57] e “understandability” [58] sono usati come sinonimi intercambiabili con interpretability.

Spiegabilità: l’insieme degli strumenti e delle tecniche che permettono di analizzare e comprendere come un modello prende le sue decisioni.

Nei modelli CNN tradizionali, che lavorano su piccole regioni locali delle immagini, la spiegabilità viene ottenuta principalmente attraverso tecniche, come Grad-CAM, che evidenziano le aree che hanno influenzato maggiormente la decisione del modello. Nei ViT, invece, elaborando le immagini come una sequenza di patch, la spiegabilità si basa sulle attention maps, che mostrano su quali parti dell’immagine il modello ha focalizzato l’attenzione durante l’elaborazione.

Caratteristica	CNN	ViT
Meccanismo di base	Convoluzioni locali	Self-attention globale
Interpretabilità	Feature maps	Attention maps
Spiegabilità	Grad-CAM, SHAP, LIME	Attention Map, Grad-CAM adattato

Tabella 2.2: Overview moduli di XAI in architetture CNN e ViT

Un'altra caratteristica è l'applicabilità del modulo di XAI, che può essere generalizzabile o per singolo input:

- Locale: Mostra su quali pixel o patch il modello si concentra per una singola immagine.
- Globale: Può essere usato per analizzare quali regioni delle immagini in media ricevono più attenzione nel dataset.

2.4.2 Tecniche XAI per CNN

Le reti neurali convoluzionali (CNN) sono ampiamente utilizzate per l'analisi delle immagini mediche, ma la loro natura "black box" ha portato alla necessità di tecniche di Explainable AI (XAI). Diverse strategie sono state sviluppate per comprendere e visualizzare il processo decisionale delle CNN; di seguito sono presentate alcune delle principali.

Grad-CAM (Gradient-weighted Class Activation Mapping) evidenzia le regioni dell'immagine che hanno contribuito maggiormente alla decisione finale del modello, sfruttando i gradienti dei layer convoluzionali [59].

Diversi lavori in letteratura hanno sottolineato come il compromesso migliore per catturare costrutti ad alto livello, regione di interesse e connessioni spaziali sia catturare e analizzare l'output dell'ultimo livello convoluzionale prima del passaggio alla rete completamente connessa tipica di una CNN; Grad-CAM è quindi solitamente applicato per istanziare una heatmap dei pixel più significativi per la scelta a partire da questo livello, seppure sia una tecnica generale applicabile a diversi tipi di reti e layers [60, 61].

Il principio di base è sfruttare il gradiente dei parametri in base al label finale ovvero la misura di quanto cambia questo valore se sono modificate leggermente le attivazioni nei livelli convoluzionali.

$$\frac{\partial y^c}{\partial A_{ij}^k} \quad (2.4.1)$$

Dove:

- y^c è il punteggio della classe c .
- A_{ij}^k è il valore della feature map k nel livello convoluzionale alla posizione (i, j) .

Se un'area di una feature map (risultato dell'applicazione di un filtro convoluzionale a un'immagine) ha un alto gradiente, significa che quella regione è stata molto importante per la decisione del modello.

Siccome possono essere applicate più feature map per ogni livello k si applica un global average pooling (dimostratosi più preciso empiricamente) per ottenere una media α_k dei parametri:

$$\alpha_k = \frac{1}{Z} \sum_{i,j} \frac{\partial y^c}{\partial A_{ij}^k} \quad (2.4.2)$$

Ogni feature map viene quindi moltiplicata per il suo peso, sommate insieme e applicato ReLU in modo da rimuovere i valori che influiscono negativamente sul label scelto, ad esempio se un insieme di pixel propendono più per un label alternativo, avranno un valore negativo per quello scelto alla fine e quindi sono di fatto rimossi dalla heatmap risultante tramite ReLU. Il risultato è:

$$L_{Grad-CAM}^c = ReLU(\sum_K \alpha_k A^k) \quad (2.4.3)$$

Questo assicura che vengano evidenziate solo le regioni che hanno avuto un impatto positivo sulla classe predetta.

La mappa creata viene quindi solitamente ridimensionata per adattarsi alla dimensione dell'immagine originale e viene sovrapposta con una scala di colori per sottolineare l'importanza, in base al gradiente di ogni zona evidenziata.

SHAP Le SHapley Additive ExPlanations sono basate sulla teoria dei giochi, assegnano un valore di contributo a ogni feature dell'input, misurando l'impatto sui risultati [62].

L'obiettivo di SHAP è quello di assegnare un valore numerico a ogni feature, allo scopo di valutare quanto quella particolare feature abbia influenzato la predizione del modello per uno specifico dato. Considerando tutte le possibili combinazioni di feature e contributi, SHAP offre una comprensione estensiva dell'importanza di una feature in un modello [63].

La formula per calcolare il valore SHAP per una feature x_i è:

$$\Phi_i = \sum_{S \subseteq F \setminus \{i\}} \frac{|S|!(|F| - |S| - 1)!}{|F|!} [f(S \cup i) - f(S)] \quad (2.4.4)$$

con i parametri indicanti:

- S è un sottoinsieme delle feature senza la feature x_i ;
- F è l'insieme completo di tutte le feature;
- $f(S)$ è la previsione del modello quando vengono utilizzate solo le feature in S ;
- $f(S \cup i)$ è la previsione del modello quando viene aggiunta la feature x_i ;
- Il coefficiente $\frac{|S|!(|F| - |S| - 1)!}{|F|!}$ è un peso che garantisce che tutte le feature vengano valutate in modo equo.

La computazione dei valori SHAP è impegnativa. Tuttavia, possono essere usati metodi di attribuzioni delle feature additive per approssimare i valori. Esistono varie modalità, un esempio sono il sampling e i Kernel SHAP, proposti già nell'articolo di Lundberg e Lee che descrive SHAP nella sua interezza.

Riassumendo, si calcolano tutte le possibili combinazioni di feature e viene stimato quanto cambia la previsione del modello quando una feature viene aggiunta a un sottoinsieme di feature già presenti, tenendo conto dell'interazione tra feature. Il valore finale di Φ_i rappresenta il contributo medio di quella feature alla previsione del modello.

Altri moduli XAI Numerosi altri moduli sono stati elaborati per comprendere al meglio le decisioni effettuate da modelli di rete neurali. Alcuni dei più importanti ma non approfonditi in questa tesi:

- **Saliency Maps:** Generano mappe di salienza che mostrano quali pixel influenzano maggiormente l'output del modello, fornendo una visione dettagliata delle feature rilevanti.
- **Layer-wise Relevance Propagation (LRP):** Metodo che assegna un punteggio di importanza a ogni pixel dell'immagine basandosi sulla propagazione all'indietro dei valori di attivazione.
- **LIME** (Local Interpretable Model-agnostic Explanations): Applica perturbazioni locali all'input per valutare l'importanza di diverse regioni dell'immagine.

2.4.3 Tecniche XAI per ViT

Per rendere più interpretabili i Vision Transformer, sono state sviluppate diverse tecniche. Alcune sfruttano le caratteristiche proprie dei Transformer e del meccanismo di attenzione, altre sono adattate dalle reti classiche come le CNN.

Attention Map Nel primo gruppo rientrano le attention map. Queste sono rappresentazioni che indicano l'importanza relativa che il modello attribuisce a diverse parti di un'immagine durante l'elaborazione. Queste mappe derivano dal meccanismo di self-attention, che permette al modello di valutare le interazioni tra diverse porzioni dell'immagine, trattate come sequenze di patch.

Nel contesto dei ViT, le mappe sono generate calcolando i pesi di attenzione tra i patch dell'immagine, all'interno del meccanismo di self-attention. Questi pesi indicano quanto ogni patch influisca sulle altre, permettendo al modello di focalizzarsi su regioni specifiche dell'immagine rilevanti per il compito assegnato. È importante notare che, sebbene forniscano intuizioni sulle zone che il modello sta "guardando", l'interpretazione diretta di queste mappe come indicatori di importanza può essere complessa. Pertanto, sono in corso ricerche per sviluppare metodi che le rendano più utili, specialmente in applicazioni critiche come la medicina [64].

Esistono diversi tipi di attention map, una soluzione in particolare sono le **Class-Discriminative Attention Maps** (CDAM) per i ViT introdotte da Brocki et al. [65]. Prima del fine-tuning le mappe non sono discriminative per classi siccome non tengono in conto nessun segnale a valle della pipeline. Le CDAM superano questo limite e si basano sul token [CLS] e sui gradienti computati per la classe risultante nell'ultimo blocco di transformer usato.

CDAM permette di evidenziare le zone di attenzione a partire da una classe conosciuta oppure di svelare un concetto latente. Nel primo caso, lo score di importanza $S_{i,c}$ rispetto al Token T_i si calcola come:

$$S_{i,c} = \sum_j T_{i,j} \frac{\partial f_c}{\partial T_{i,j}} \quad (2.4.5)$$

con $T_{i,j}$ inteso come il j-esimo componente dell'i-esimo token all'ultimo livello di attenzione usato. In caso di concetto latente la formula è simile. L'idea trae origine dalle Saliency Map [66], con il numeratore della frazione sostituito con $\partial g(l, l_c)$ con g che è la misura di similarità scelta (ad esempio cosine similarity), l l'espressione latente di un'immagine X e l_c è un vettore concetto ("*concept vector*") [67] ovvero un vettore derivato dalla media dei valori di l di n immagini scelte per rappresentare il concetto di interesse.

Due varianti sono state, aggiuntivamente, proposte. Anche in questo caso si è preso spunto su lavori precedenti sulla saliency map per nel contesto delle CNN per visualizzare i gradienti di una classe tenendo conto delle feature in input. Invece degli input tuttavia, sono stati modificati i token che entrano nel blocco transformer finale:

- **Smooth CDAM** cerca di rendere l'attention map più morbida aggiungendo del rumore gaussiano ai token.
- **Integrated CDAM** cerca di interpolare dei nuovi token tra una immagine di base (ad esempio una immagine tutta nera) e i token stessi, creando n mappe.

Altre XAI per ViT Altre possibili soluzioni, invece, sono adattamenti dei metodi XAI dalle CNN, in particolare:

- **Grad-CAM per ViT:** Adattamento di Grad-CAM, usato nelle CNN, per evidenziare quali parti dell'immagine hanno avuto maggiore impatto sulla decisione finale. Un esempio è LeGrad [68].
- **SHAP** (Shapley Additive Explanations) adattato per ViT.

Caratteristica	Grad-CAM	SHAP	CDAM
Tipo di Modello	CNN se non adattato	Tutti i modelli	Solo ViT
Calcolo Rilevanza	Gradienti su layer convoluzionali	Teoria dei giochi e contributo marginale	Peso dell'attenzione tra i token (patch)
Output	Heatmap	Importanza numerica o Heatmap	Attention Map
Interpretabilità	Discreta, può evidenziare zone inattese	Molto dettagliato	Utile, a volte non direttamente interpretabile
Applicabilità	Locale	Globale e Locale	Globale e Locale

Tabella 2.3: Riassunto delle caratteristiche principali per Grad-CAM, SHAP e CDAM.

In generale, quindi, la scelta ricade sulle intenzioni dello sviluppatore e sul modello scelto:

- Se si sta lavorando con una CNN è possibile usare Grad-CAM per ottenere una heatmap visiva delle feature attivate.
- Se si vuole un'analisi molto dettagliata dell'importanza delle feature è possibile usare SHAP ma va considerato il costo computazionale.
- In caso di Vision Transformer, le Attention Maps sono la scelta migliore, anche se possono richiedere metodi aggiuntivi per migliorare la spiegabilità come le CDAM.

Integrazione XAI e ViT per la Diagnosi Medica

Nel contesto delle radiografie toraciche, l'integrazione della XAI consente di fornire heatmap di attenzione per mostrare dove il modello sta focalizzando l'analisi e consentire ai radiologi di validare e verificare le decisioni del modello.

Migliorare la fiducia nell'utilizzo clinico dei modelli di AI.

2.5 Large e Small Language Models

Nel panorama dell'intelligenza artificiale, i modelli linguistici hanno assunto un ruolo centrale, evolvendosi in due categorie principali: i Large Language Models (LLM) e gli Small Language Models (SLM). Questi modelli sono progettati per comprendere e generare linguaggio naturale, ma differiscono significativamente per dimensioni, complessità e applicazioni.

2.5.1 Funzionamento in breve

Siccome lo scopo di questa tesi si focalizza maggiormente sull'uso di modelli linguistici piuttosto che sulla loro implementazione, viene fornito qui solo un quadro generale dei meccanismi di funzionamento. Gli LLM si basano anch'essi su architetture di Transformers. Queste architetture utilizzano gli stessi meccanismi di self-attention introdotto precedentemente, che permettono al modello di valutare l'importanza di diverse parti di una sequenza di input rispetto ad altre. Questo approccio consente al modello di catturare le dipendenze a lungo raggio nel testo, migliorando la coerenza e la pertinenza delle risposte generate.

Durante la fase di addestramento, gli LLM analizzano miliardi di frasi e paragrafi, da cui origina il loro nome, apprendendo le strutture sintattiche, le semantiche e le sfumature del linguaggio. Questo processo li rende capaci di generare testi che sono sorprendentemente simili a quelli prodotti dagli esseri umani.

I modelli linguistici basati possono essere suddivisi in tre categorie principali in base alla loro architettura:

- **Modelli Encoder-Only:** Sono specializzati nella comprensione del testo, prendono un input testuale e ne apprendono le rappresentazioni per compiti come classificazione, riconoscimento di entità e recupero di informazioni.
- **Modelli Decoder-Only:** Sono progettati per la generazione di testo. Funzionano in modo auto-regressivo, prevedendo il token successivo basandosi su quelli precedenti. Sono utilizzati per attività come il completamento di frasi, la generazione creativa e il dialogo conversazionale.
- **Modelli Encoder-Decoder (Seq2Seq):** Uniscono entrambi i meccanismi, rendendoli ideali per la traduzione automatica, il riepilogo di testi e il question answering. L'encoder elabora l'input e crea una rappresentazione interna, mentre il decoder genera il testo in output basandosi su questa rappresentazione. Modelli come T5 [69] e UL2 [70] rientrano in questa categoria.

2.5.2 Principali LLM

Tra i principali modelli presenti sul mercato, aggiornati al 2025, è possibile trovare:

- **GPT-4** [71]: Sviluppato da OpenAI, GPT-4 rappresenta una delle evoluzioni più avanzate nella serie dei Generative Pre-trained Transformers. Con oltre un trilione di parametri, è in grado di comprendere e generare testi con un alto grado di coerenza e creatività.
- **Velvet AI** [72]: Sviluppato dall'azienda italiana Almawave, Velvet AI è una famiglia di modelli multilingue progettati per essere sostenibili ed efficienti dal punto di vista energetico. Addestrato su supercomputer europei, supporta diverse lingue, tra cui l'italiano, l'inglese, lo spagnolo e il tedesco.
- **DeepSeek-R1** [73]: Un modello open-source sviluppato in Cina da DeepSeek, noto per le sue prestazioni comparabili a ChatGPT, ma con costi di sviluppo significativamente inferiori. Ha guadagnato rapidamente popolarità, diventando una delle app più scaricate nel 2025.

- **LLaMA (Large Language Model Meta AI)** [74]: Sviluppato da Meta AI, LLaMA è una famiglia di modelli linguistici open-source progettati per fornire elevate prestazioni con un numero di parametri relativamente contenuto. Ad esempio, LLaMA 3.1 8B offre un equilibrio tra potenza ed efficienza, rendendolo adatto per compiti come il question answering e l'analisi del sentiment.
- **BioBERT** [75]: BioBERT è un modello di rappresentazione linguistica pre-addestrato specificamente per il dominio biomedico. Basato sull'architettura BERT, è stato addestrato su grandi corpora biomedici, migliorando le prestazioni in compiti come il riconoscimento di entità nominate, l'estrazione di relazioni e il question answering nel contesto biomedico. L'adozione di BioBERT ha portato a significativi avanzamenti nell'estrazione di informazioni biomediche.

2.5.3 Small Language Models

Gli Small Language Models sono progettati per operare con un numero significativamente inferiore di parametri rispetto ai LLM, spesso variando da pochi milioni ad alcuni miliardi, permettendo una maggiore efficienza energetica e una riduzione dei tempi di risposta. Questa riduzione consente loro di essere implementati su dispositivi con capacità computazionali limitate, come smartphone, tablet o dispositivi IoT, garantendo al contempo prestazioni adeguate per compiti specifici. Nonostante la loro dimensione compatta, gli SLM possono essere addestrati su domini specifici, migliorando la loro efficacia in contesti particolari.

Alcuni esempi sono:

- **Phi-3** [76]: Sviluppato da Microsoft, il Phi-3 è una famiglia di modelli open-source progettati per offrire elevate prestazioni con un numero ridotto di parametri. Questi modelli superano le performance di altri modelli di dimensioni simili e anche superiori in vari benchmark, grazie a innovazioni nell'addestramento. La loro efficienza li rende ideali per applicazioni che richiedono un equilibrio tra capacità computazionale e accuratezza.
- **MobiLlama** [77]: Questo modello open-source da 0,5 miliardi di parametri è stato progettato per dispositivi con risorse limitate. MobiLlama applica uno schema di condivisione dei parametri per ridurre sia i costi di pre-addestramento che quelli di implementazione, mantenendo al contempo elevate prestazioni. La sua trasparenza completa, con accesso al codice di addestramento e ai pesi del modello, lo rende una scelta interessante per sviluppatori e ricercatori.

2.6 Lavori precedenti

L'uso del machine learning in medicina è sempre più oggetto di ricerca in tutti gli aspetti della disciplina come diagnosi, terapia, training, ricerca o gestione paziente e personale.

Nell'ambito di imaging radiologico sono molti gli sforzi per integrare il lavoro di diagnostica con l'AI per migliorare tempi e precisione delle operazioni [78]:

- **Segmentazione immagini:** Tecniche di Deep Learning sono state introdotte per l'analisi delle immagini mediche effettuando segmentazione, studiate per polmoni, tumori e altre strutture, ma anche cellule, membrane e tessuti, per lo più con l'uso di CNN.
- **Labeling automatico:** La generazione di label o didascalie che descrivono le immagini è stata oggetto di ricerca per oggetti comuni per diversi anni, ad esempio Microsoft COCO [79]. La ricerca sul labeling automatico in medicina è molto attiva come CheXpert++ [80], labeler addestrato sull'omonimo dataset radiografico.

- Diagnosi e Computer-Aided Detection (CAD): L'uso di archivi medici digitali, i cosiddetti *picture archiving and communication system* (PACS) [81] ha reso possibile addestrare modelli di rilevamento e diagnosi automatica.
- Medicina di precisione: l'uso di modelli di ML sono sempre più integrati in procedure chirurgiche e valutazione di percorsi terapeutici mirati o per la valutazione di complicazioni post-operatorie, un esempio è l'uso di AI per nella chirurgia oftalmica per migliorare la precisione e ridurre i tempi di recupero a partire, basandosi su un'analisi grafica dell'occhio, in particolare in chirurgia refrattiva (come LASIK) [82, 83] o di flacoemulsione per la cataratta [84].

2.6.1 CXR e Machine Learning

Lo studio di CXR ha subito un notevole contributo e l'aumento di dataset disponibili negli ultimi anni anche a causa dell'esplosione del COVID-19 e della necessità di individuare la patologia e le complicazioni ad esse associate tramite imaging e successivamente con l'uso di ML per migliorare le prestazioni [85, 86].

Un'altra causa che ha portato allo studio in questo campo è l'uso di CXR come test di primo livello in numerose patologie in paesi sviluppati [87, 88] così come in paesi in via di sviluppo, dove la presenza di medici specializzati è di molto minore di quella necessaria a coprire una popolazione crescente [89].

Una review in letteratura

Una meta-analisi di Ahmad et al [90] ha raccolto i principali studi sull'uso di ML per le CXR tra il 2020 e il 2022, rilevando ben 2248 articoli e approfondendone 46. L'obiettivo principale era valutare come i modelli di ML possano assistere i clinici, migliorando l'accuratezza diagnostica e l'efficienza del flusso di lavoro radiologico.

Sono state valutate varie caratteristiche:

- Numero di patologie classificate: La maggior parte dei modelli era in grado di identificare un numero variabile tra 3 e 14 patologie. Tuttavia, tre modelli più avanzati sono stati addestrati rispettivamente con 54, 72 e 124 condizioni diverse.

- Dimensione dei dataset: In media, i modelli sono stati addestrati e validati su dataset pubblici, sebbene alcuni non hanno specificato la fonte e i dataset pubblici più utilizzati includevano MIMIC-CXR [91] (>300k immagini), ChestX-ray14 (>100k)[92] e CheXpert (>200k) [93].
- Confronto con performance umane: Circa il 30% degli studi ha confrontato le prestazioni dei modelli con quelle di clinici, mentre il 19% ha valutato l'impatto dei modelli sull'interpretazione clinica e sulla diagnosi.
- Tipo di modello: ad eccezione di alcuni lavori che non hanno riportato informazioni specifiche sul modello di riferimento creato, tutti gli altri lavori hanno usato come base un modello CNN su cui è stato poi effettuato fine-tuning su immagini radiografiche, in particolare i principali modelli usati sono stati ResNet e DenseNet [94].

Output

Gli studi si sono focalizzati sui seguenti output:

- Classificazione delle patologie: Tutti i modelli sono stati progettati per assegnare etichette specifiche alle immagini, indicando la presenza o l'assenza di determinate condizioni o patologie, dalla dissezione aortica alla polmonite.
- Segmentazione: Alcuni studi hanno implementato tecniche di segmentazione per delineare aree specifiche di interesse, come lesioni o anomalie, fornendo una rappresentazione visiva dettagliata delle regioni affette, come lo studio di Gordienko et al. [95], dove le lesioni polmonari sospette sono state evidenziate dal modello, mentre una segmentazione in input è stata effettuata sui polmoni nel loro insieme.
- Generazione di referti: La review non ha evidenziato studi che generassero anche una refertazione simil-medica usabile da parte del diagnosta, sebbene anche al di fuori della metanalisi un numero limitato di studi ha esplorato la generazione automatica di referti testuali, traducendo le analisi delle immagini in descrizioni cliniche comprensibili [96, 97].

Prestazioni dei modelli

I modelli di ML hanno dimostrato elevate performance, spesso risultando pari o superiori ai radiologi o ad altri clinici nell'interpretazione delle CXR. Inoltre, l'integrazione di questi modelli come strumenti di supporto decisionale ha migliorato la capacità diagnostica dei clinici, aumentando sia l'accuratezza che l'efficienza.

In generale, come metro di paragone per l'accuratezza è stato usato l'AUC che ha registrato valori tra 0.70 e 1.00, sebbene la maggioranza dei modelli abbia ottenuto valori maggiori di 0.90 per buona parte dei label presenti.

Per valutare la qualità degli studi, invece, sono state effettuate analisi con PROBAST [98] tool considerando eventuali carenze o bias tra progettazione, condotta e analisi statistica. Dei 46 studi, 39 sono stati valutati a basso rischio, 6 ad alto rischio, 1 dal significato incerto.

Esempio di rilievo

Uno degli studi più completi è stato condotto da Wu et al. (2020) [99], che hanno valutato le performance di algoritmi di intelligenza artificiale nel contesto reale dei flussi di lavoro radiologici. Utilizzando dataset come CheXpert e MIMIC, hanno analizzato più di 300000 immagini e il loro modello era in grado di classificare 72 diverse patologie, reso possibile da un lavoro di ricostruzione dei label a partire dai referti clinici associati al dataset di immagini con tool automatici e successiva verifica manuale di medici che ha fornito una ground truth iniziale.

Il modello è stato creato a partire da ResNet, con 50 layer, e VGGNet, con 16, i cui output sono stati uniti in successivi layer densi e blocchi convoluzionali dilatati [100] con layer sigmoide finale per la classificazione.

Alla conclusione del test, la sensibilità media è stata di 0.716 per l'algoritmo AI e 0.720 per i medici specializzandi mentre il vero valore predittivo (PPV) è stato di 0.730 e 0.682 rispettivamente.

I risultati hanno evidenziato, quindi, che l'algoritmo non solo eguagliava, ma in alcuni casi superava, l'accuratezza diagnostica dei radiologi in residency, suggerendo un potenziale significativo per l'integrazione dell'IA nella pratica clinica quotidiana.

Conclusione

Questa revisione indica che i sistemi di ML progettati per l'interpretazione delle CXR possono migliorare significativamente l'accuratezza diagnostica e l'efficienza dei clinici. Tuttavia, sono state identificate alcune limitazioni, tra cui la necessità di ulteriori studi prospettici e la valutazione della generalizzabilità dei modelli su diverse popolazioni di pazienti. La collaborazione tra sviluppatori di IA e clinici è comunque cruciale per garantire un'implementazione sicura ed efficace di questi sistemi nel contesto sanitario.

2.6.2 Flamingo-CXR

Flamingo [101] è una famiglia di modelli di intelligenza artificiale sviluppata da DeepMind con l'obiettivo di combinare l'elaborazione del linguaggio naturale e la comprensione visiva in un'unica architettura. Questi modelli sono progettati per affrontare una varietà di compiti multimodali transformer-based, come la descrizione di immagini, il question answering visivo e il dialogo multimodale, utilizzando un approccio di few-shot learning, che consente al modello di adattarsi rapidamente a nuovi compiti con un numero minimo di esempi specifici per il compito.

Architettura di Flamingo

L'architettura di Flamingo (Figura 2.5) si basa sull'integrazione di potenti modelli pre-addestrati per la visione e il linguaggio:

- **Encoder Visivo:** Utilizza un modello di visione pre-addestrato, come NFNet-F6 [102], derivato da ResNet, per estrarre rappresentazioni dalle immagini. Questo encoder produce mappe di caratteristiche che rappresentano informazioni visive rilevanti.
- **Perceiver Resampler:** Questo modulo riceve le mappe di caratteristiche dall'encoder visivo e le trasforma in un numero fisso di token visivi. Questi token sono progettati per essere compatibili con il modello linguistico, facilitando l'integrazione tra dati visivi e testuali.

- **Modello Linguistico:** Flamingo incorpora un modello linguistico di grandi dimensioni, come Chinchilla con 70 miliardi di parametri. Questo modello rimane congelato durante l'addestramento di Flamingo, preservando le conoscenze linguistiche acquisite.
- **Gated Cross-Attention:** Per collegare le rappresentazioni visive e testuali, Flamingo introduce strati di cross-attention con meccanismi di gating, ovvero una struttura che controlla quanto e come un'informazione deve fluire attraverso una parte della rete neurale. Questi strati permettono al modello di focalizzarsi su parti specifiche dell'input visivo in relazione al contesto testuale, modulando l'attenzione attraverso una funzione di attivazione $\tanh$ con parametri di gating appresi.
- **Integrazione dei Moduli:** Le rappresentazioni visive generate dall'encoder vengono ridotte a un set fisso di token tramite il Perceiver Resampler. Questi token sono poi integrati nel modello linguistico attraverso gli strati di Gated Cross-Attention, che modulano l'influenza dei dati visivi sul processo di generazione del linguaggio.
- **Addestramento:** Flamingo è addestrato su grandi quantità di dati multimodali non annotati, utilizzando sequenze intercalate di immagini e testo. L'obiettivo è massimizzare la probabilità del testo successivo dato il contesto precedente, permettendo al modello di apprendere relazioni complesse tra visione e linguaggio.

Applicazione alla Diagnostica Medica

Flamingo-CXR, sviluppata da Tanno et al. [103], rappresenta un'applicazione specifica di Flamingo nel campo della radiologia, focalizzandosi sull'interpretazione delle radiografie toraciche e generazione automatica di referti. Questo modello è stato progettato per assistere i radiologi nella diagnosi di patologie polmonari attraverso l'analisi automatizzata delle immagini radiografiche.

Dei vari modelli di Flamingo presenti, gli autori hanno usato la variante a 400 milioni di parametri nella versione rappresentata nel paper. Gli sviluppatori hanno




Figura 2.5: Architettura di Flamingo. Immagine tratta dal paper originale

effettuato un fine-tuning su due dataset di immagini mediche, ovvero MIMIC-CXR e IND1 [104]. I referti sono stati preprocessati per estrarre solo le sezioni “Findings” e “Impression”, escludendo altri dettagli clinici.

Flamingo-CXR utilizza immagini ridotte a 1 Megapixel per limitare il carico computazionale, rispetto alle immagini originali (4 Megapixel), in particolare tutte le immagini sono state ridotte a 320×320 preservando l’aspect ratio originale, aggiungendo del padding se necessario. Questo è stato fatto per bilanciare la qualità dell’immagine con la capacità del modello di processare più dati contemporaneamente.

Flamingo modella la likelihood di un report radiologico y condizionato da un’immagine di input x con un modello auto-regressivo:

$$p(y|x) = \prod_{l=1}^L p(y_l | y_{<l}, x_{\leq l}) \quad (2.6.1)$$

dove y_l è il l -esimo token del referto in input generato fino a quel momento, $y_{<l}$ rappresenta l’insieme dei token precedenti nella sequenza, x l’immagine radiologica e p è parametrizzato dal modello. In questo modo:

- Il modello genera il referto un token alla volta, basandosi sui token già generati e sull’immagine radiologica, lavorando in maniera simile a GPT-3 [105].
- Ogni parola del referto è generata considerando sia le parole già prodotte sia l’input visivo.

- Il prodotto su tutti i token indica che il modello calcola la probabilità della sequenza complessiva moltiplicando la probabilità di ogni token generato in ordine.

Risultati di Flamingo-CXR

Nei test sui dataset usati, 77.7% dei referti generati da Flamingo-CXR sono stati giudicati equivalenti o superiori a quelli dei radiologi. Nel caso di immagini senza anomalie evidenti, il 94% dei referti di Flamingo-CXR è stato valutato come equivalente o preferibile rispetto ai referti umani. Tuttavia, per condizioni meno comuni come edema polmonare ed cardiomegalia, il modello ha mostrato una precisione inferiore rispetto ai radiologi esperti.

2.6.3 RAD-DINO

L'automazione dell'interpretazione delle immagini mediche tramite deep learning ha mostrato progressi significativi, tuttavia, lo sviluppo di tali modelli richiede tradizionalmente grandi dataset etichettati manualmente, un processo dispendioso in termini di tempo e costi, spesso richiedente profonda conoscenza del dominio o esperienza tecnica. Queste limitazioni hanno spinto la ricerca verso approcci più efficienti in termini di etichettatura, come la pre-formazione auto-supervisionata (self-supervised pre-training), sebbene questi metodi richiedano ancora una fase di fine-tuning supervisionato con dati etichettati. Di conseguenza, sono in grado di prevedere solo le patologie esplicitamente annotate nel dataset di training, limitando la loro applicabilità a patologie non annotate.

In questo contesto, il modello RAD-DINO [106], pubblicato nel gennaio 2025, si presenta come un encoder di immagini biomediche che sfida la dipendenza prevalente dalla supervisione linguistica per l'apprendimento di feature visuali generiche nel dominio biomedico. La sua ipotesi centrale è che la supervisione testuale potrebbe non essere necessaria per apprendere descrittori visuali discriminativi, ma potrebbe addirittura ostacolare l'acquisizione di feature visive ricche.

Architettura in breve L'architettura di RAD-DINO si basa sull'approccio di apprendimento auto-supervisionato (SSL) "image-only" DINOv2. DINOv2 utilizza una rete siamese e due obiettivi di training complementari: il Masked Image Modeling (MIM) e la discriminazione di istanza auto-supervisionata. Questi obiettivi consentono a RAD-DINO di apprendere feature trasferibili per compiti a livello sia globale che locale senza richiedere esplicita supervisione testuale.

Il modello ViT-B/14 (Vision Transformer) viene pre-addestrato su una vasta collezione di dataset di immagini radiologiche del torace, denominata Multi-CXR, che include un'ampia diversità di reperti e dati demografici provenienti da fonti pubbliche e private come MIMIC-CXR, CheXpert, ChestX-ray14 e PadChest per un totale di oltre 800mila immagini.

Risultati I risultati hanno dimostrato che RAD-DINO raggiunge prestazioni simili o superiori rispetto ai modelli biomedici all'avanguardia basati sulla supervisione linguistica in un'ampia gamma di benchmark, inclusi la classificazione delle immagini, la segmentazione semantica e la generazione di referti testuali da immagini. Un vantaggio notevole di RAD-DINO è la sua capacità di estrarre informazioni sui dati demografici dei pazienti (come sesso, età, peso e BMI) con maggiore accuratezza rispetto ai modelli supervisionati dal linguaggio.

Inoltre, RAD-DINO si è dimostrato altamente scalabile con l'aumento della quantità e della diversità dei dati di training di sole immagini, consentendo di sfruttare le vaste quantità di dati di imaging medicale disponibili, superando il problema della scarsità di coppie immagine-testo nei dataset pubblici. Il modello può anche gestire efficacemente sia le scansioni frontali che laterali senza la necessità di associazioni testuali specifiche per ciascuna vista, a differenza dei metodi supervisionati dal linguaggio.

Questa metodologia promette di ridurre significativamente la dipendenza da dataset di immagini mediche densamente annotate, alleviando un importante collo di bottiglia nei workflow di machine learning clinic; tuttavia, RAD-DINO mostra una limitazione nelle applicazioni zero-shot di classificazione e recupero testo-immagine rispetto ad altri modelli in letteratura.

2.7 Approccio della tesi

Flamingo-CXR rappresenta un notevole passo avanti nella generazione automatica di referti radiologici, ottenendo prestazioni superiori rispetto ai modelli precedenti. Tuttavia, presenta ancora limitazioni nella comprensione del contesto clinico e nella spiegabilità delle sue decisioni, aspetti fondamentali per garantire un'effettiva integrazione nell'ambiente medico.

2.7.1 Confronto con la letteratura

Nel confronto con il modello sviluppato, si evidenziano alcune differenze chiave:

- Maggiore spiegabilità nel modello: integrando tecniche di Explainable AI, il sistema offre maggiore trasparenza e giustificazioni visive superiori rispetto a Flamingo-CXR.
- Possibile integrazione con LLM: Il modello mira a essere compatibile per una futura estensione con SLM/LLM in modo da generare referti più dettagliati con maggiore affinità allo stile dei radiologi umani, tramite le tecniche di explainability e attention-map recuperando una feature che altri modelli come RAD-DINO hanno già sviluppato.
- Focus sulla giustificazione delle decisioni: Flamingo-CXR si concentra sull'output del referto, mentre il modello cercherà di giustificare le sue decisioni attraverso un'analisi delle immagini.
- Integrazione dell'ontologia medica radiologica: l'inclusione di terminologie e concetti clinici standardizzati mira a migliorare sia la precisione nella classificazione che fornire uno strumento utile per la fiducia da parte degli operatori.

Di contro, la maggior parte degli altri lavori in letteratura, come evidenziato, si focalizza sulla classificazione delle patologie, ignorando la refertazione e spiegabilità del modello prodotto. Questi sono, inoltre, basati prevalentemente su varianti di CNN ampiamente studiate e sviluppate nel corso degli anni. Al contrario, l'uso dei Vision Transformer risulta ancora limitato essendo un ambito ancora nuovo in cui molta ricerca è tutt'oggi effettuata.

2.7.2 XAI e Medicina

Anche laddove alcuni studi abbiano lavorato sull'explainability, questa si limita a moduli di segmentazione. Tuttavia, diverse ricerche hanno evidenziato come la fiducia di queste tecniche sia limitata sia tra gli operatori sanitari sia tra gli utenti occasionali. In un articolo pubblicato su *The Lancet*, dal titolo significativo *The false hope of current approaches to explainable artificial intelligence in health care*, Ghassemi et al. [107] discutono come le attuali tecniche di XAI non forniscano spiegazioni affidabili sul funzionamento effettivo dei modelli e sulle loro decisioni, suggerendo che il deep learning debba ancora essere trattato come una "black box" dal funzionamento incerto. Inoltre, lo studio sottolinea come heatmap e saliency map non diano sufficiente fiducia ai medici, limitando l'adozione dell'AI in ambito clinico.

A supporto di tale tesi anche altri autori, come Storås et al. hanno evidenziato come le heatmap nell'ambito della valutazione di ECG possano produrre risultati non univoci o focalizzarsi su dettagli diversi da quelli su cui i medici fanno affidamento nelle loro valutazioni cliniche. Sebbene ciò possa rivelarsi una nuova frontiera da esplorare al fine di scoprire correlazioni inaspettate o individuare anomalie non ancora studiate [108], spesso si rileva più uno strumento utile agli sviluppatori come debugging, segnalando un errore nel modello o nel dataset che uno strumento utile agli operatori finali.

D'altra parte, alcuni lavori [109, 110] hanno invece mostrato un aumento della fiducia nei modelli AI tra i radiologi, specialmente quando le heatmap evidenziano con precisione le stesse caratteristiche o aree di interesse che gli operatori utilizzano per effettuare diagnosi. Questo suggerisce che, se integrate in un modello robusto, resilienti ai bias e al rumore negli input nell'uso reale e ottimizzate per l'ambiente clinico, le tecniche di XAI possano effettivamente migliorare la fiducia degli utenti finali.

Migliorare la spiegabilità dei modelli

A tal proposito il lavoro presente in questa tesi intende rafforzare il legame tra le attention map, simili alle saliency map per CNN, l'explainability e le conoscenze mediche tramite metodi di rilevazione statistica delle feature grafiche al fine di

migliorare l'output finale. L'implementazione intra-modello di caratteristiche cliniche tramite grafo, con riferimento all'ontologia medica attuale, ispirata a RadLex e ICD è un ulteriore sforzo nel migliorare la qualità del lavoro svolto.

Questa tesi si propone di rafforzare il legame tra le attention map dei ViT e la generazione di referti esplicativi tramite LLM, affrontando le attuali limitazioni delle heatmap convenzionali e introducendo nuove strategie per migliorare la trasparenza del modello.

Riassumendo, le principali caratteristiche proposte sono:

- **Uso delle Attention Map e Explainability:** Le mappe di attenzione forniscono un'informazione su quali siano le aree critiche dell'immagine, migliorando l'affidabilità del modello nel contesto clinico. Le funzioni di explainability, sono, inoltre, supportate da metodi di rilevazione statistica delle feature grafiche evidenziate, cercando di assicurare una maggiore coerenza medica con le evidenze visive.
- **Iniezione di info mediche nell'attenzione:** Le informazioni mediche, espresse in modello matematico con trasposizione di un grafo e sua matrice di adiacenza, cercano di migliorare la classificazione del modello connettendo da subito segni clinici tra loro e con i rispettivi label.
- **Integrazione di conoscenze mediche strutturate:** L'uso di un grafo che collega segni radiologico-clinici tra loro e con i label del classificatore creato, ispirato all'ontologia specifica per la radiologia, consente di migliorare la precisione delle diagnosi, riducendo la soggettività e facilitando l'adozione clinica del modello.
- **Struttura LLM-ready:** Inizialmente prevista nello sviluppo iniziale, ma non sviluppata per limiti di tempo e risorse, la struttura del modello si adatta all'integrazione in pipeline di un SLM/LLM per la creazione di un referto medico in modo da confrontarsi con i modelli più avanzati come Flamingo-CXR e RAD-DINO.

3.1 Introduzione

In questo capitolo viene presentato **Med-ViX-Ray**, un modello *proof of concept* con approccio *knowledge-guided* per la classificazione multilabel di immagini radiografiche del torace, con particolare riferimento al dataset MIMIC-CXR. Il modello si basa sull'integrazione sinergica tra un backbone neurale di tipo transformer, un grafo clinico rappresentante segni radiografici e patologie, e una pipeline di interpretabilità (XAI) basata sull'analisi delle mappe di attenzione.

Gli approcci knowledge-guided descrivono modelli che sfruttano conoscenze cliniche esplicite per arricchire la rappresentazione visiva e migliorare l'interpretabilità del processo decisionale. In particolare, il grafo clinico funge sia da guida per l'iniezione di bias informativi all'interno delle componenti attention del modello, sia da struttura semantica per il post-processing delle regioni salienti individuate dal modello.

Obiettivi di ricerca Il sistema è stato progettato con l'obiettivo di superare i limiti dei modelli standard basati esclusivamente su apprendimento da immagine, introducendo una componente di ragionamento legata alla semantica radiologica.

Uno degli obiettivi principali è stato esplorare in che misura l'integrazione esplicita di conoscenza clinica possa migliorare non solo le performance, ma anche la trasparenza e l'affidabilità di modelli deep learning per la classificazione multilabel di immagini radiografiche del torace.

Mentre in altri ambiti scientifici l'integrazione di conoscenza simbolica con modelli neurali ha prodotto risultati rilevanti (si pensi, ad esempio, al caso di *AlphaFold* [1] per la predizione di strutture proteiche), in ambito medico, e in particolare nell'analisi automatica di immagini radiografiche, tali approcci sono ancora relativamente poco esplorati.

La maggior parte dei modelli di imaging clinico rimane infatti basata su architetture neurali *black-box*, con meccanismi di interpretabilità post hoc spesso non integrati con la conoscenza clinica sottostante.

Partendo da queste considerazioni, il lavoro qui presentato ha perseguito l'idea di sviluppare una pipeline knowledge-guided che integrasse:

- un modello transformer-based per l'analisi visiva;
- un grafo clinico rappresentante le relazioni semantiche tra segni radiografici e patologie;
- un meccanismo di interpretabilità nativo basato sull'analisi delle mappe di attenzione.

L'obiettivo è stato non solo verificare l'impatto di questa integrazione in termini di performance predittiva, ma anche esplorare la possibilità di ottenere modelli più trasparenti, robusti e allineati con il ragionamento clinico, aprendo la strada a soluzioni più "scientifiche" e affidabili per l'intelligenza artificiale applicata alla radiologia.

Nelle sezioni successive verranno descritti in dettaglio:

- la struttura architeturale del backbone visivo;
- i moduli di attenzione guidata dal grafo;
- la pipeline di estrazione delle regioni salienti e matching con i nodi clinici;
- il meccanismo di nudging che corregge le predizioni in funzione della coerenza semantica;
- la funzione di loss composita e le scelte implementative.

Tutte le componenti sono state implementate in `PyTorch` [112], con il supporto della libreria `timm` [113] per l'inizializzazione della Swin Transformer V2 e l'uso di librerie esterne come `Captum` [114] e `Kornia` [115] per il processamento delle regioni salienti.

3.2 Raccolta e preparazione dei dati

Per l'addestramento e la valutazione del modello è stata utilizzata la versione JPEG del dataset **MIMIC-CXR**, composta da immagini radiografiche del torace annotate con 14 label patologiche.

Sono state selezionate unicamente immagini con proiezione:

- **Antero-Posteriore (AP)**;
- **Postero-Anteriore (PA)**, opportunamente trasformate tramite *flip orizzontale* per uniformare il campo visivo.

Le immagini sono state preprocessate mediante:

- ridimensionamento a risoluzione fissa 256×256 pixel;
- normalizzazione dei pixel;
- data augmentation (rotazioni, trasformazioni affini, jittering di colore, cropping casuale).


Per la costruzione iniziale del grafo clinico, è stata inoltre implementata una pipeline di **Named Entity Recognition (NER)** sui report testuali associati alle immagini, al fine di estrarre segni radiografici e patologie con polarità positiva o negativa. Tali informazioni sono state utilizzate sia per la beta distribuzione dei pesi degli archi del grafo, sia per guidare la fase di *weak supervision* durante il training.

3.3 Visione generale della pipeline

Il modello proposto, denominato **Med-ViX-Ray**, realizza una pipeline end-to-end per la classificazione multilabel di immagini radiografiche del torace, integrando componenti neurali e simboliche in un ciclo di apprendimento guidato dalla conoscenza.

L'architettura, schematizzata in Figura 3.1, si compone di tre elementi principali:

1. un **backbone neurale** basato su *Swin Transformer V2*, che estrae rappresentazioni visive profonde;
2. un **grafo clinico eterogeneo**, modellante la conoscenza a priori su relazioni tra segni radiografici e patologie;
3. una **pipeline di interpretabilità e guida semantica**, che analizza le mappe di attenzione, estrae regioni salienti e corregge le predizioni in modo dinamico.



Legend:

Arrows:

- **Blue Dotted:** Special training/Backward Propagation
- **Black Continuous:** Inference

Symbols

- **BLK:** Freezed Layer
- **FT:** Applied Fine Tuning
- **TR:** Trained layer/model

Figura 3.1: Architettura modello Med-ViX-Ray

Il flusso di elaborazione si articola nelle seguenti fasi:

- Le immagini in ingresso, preprocessate a risoluzione fissa, vengono elaborate dal backbone Swin Transformer V2, i cui ultimi due layer sono modificati tramite l'iniezione di un bias derivato dal grafo clinico.
- Durante il forward pass, vengono salvate le mappe di self-attention. Viene quindi eseguita una procedura di *rollout-like extraction* delle mappe di attenzione, ricostruendo lo spazio globale dell'immagine.
- Le regioni più salienti vengono estratte tramite soglia dinamica e analisi delle componenti connesse, e caratterizzate tramite un set di feature statistiche.
- Le feature estratte vengono associate probabilisticamente ai nodi segno del grafo clinico, con un meccanismo di *matching softmax* che evolve nel corso dell'addestramento.
- A valle della classificazione, viene applicato un *Graph Nudger*, che modula i logits finali in funzione delle regioni salienti individuate e la struttura del grafo.
- L'intero sistema è ottimizzato tramite una funzione di loss composita che bilancia accuratezza predittiva, guida spaziale e semantica.

La pipeline implementa dunque un ciclo chiuso tra:

1. rappresentazioni visive *image-based*;
2. conoscenza a priori *knowledge-based* (grafo);
3. feedback *model-based* (Graph Nudger).

Questa integrazione consente di ottenere un modello non solo più performante su classi sbilanciate e segni rari, ma anche intrinsecamente più interpretabile, in quanto le decisioni del modello possono essere tracciate attraverso il grafo clinico e le mappe di attenzione.

3.3.1 Backbone neurale

Il backbone visivo utilizzato nell'architettura proposta è **Swin Transformer V2**, una variante dei Transformer visivi basata su *window-based attention* e struttura gerarchica.

Swin V2 combina l'efficienza computazionale della self-attention su finestre locali con la capacità di modellare dipendenze globali tramite meccanismi di *shifted windows*. Questa architettura si è dimostrata particolarmente efficace in compiti di visione medica, dove la preservazione della struttura spaziale locale è cruciale.

Nel presente lavoro è stato utilizzato un modello Swin V2 *pre-addestrato su ImageNet*, con successivo fine-tuning sul dataset MIMIC-CXR.

Struttura di Swin Transformer V2 L'architettura di Swin Transformer V2 è organizzata secondo una struttura gerarchica a stadi successivi. Ciascuno stadio riduce progressivamente la risoluzione spaziale e aumenta la dimensione del canale, in modo analogo a una rete convoluzionale.

In dettaglio, la struttura prevede i seguenti componenti principali:

- **Patch Partition:** l'immagine di input viene suddivisa in patch non sovrapposte (tipicamente 4×4 pixel), che costituiscono i token iniziali del Transformer.
- **Linear Embedding:** ciascun patch viene proiettato in uno spazio latente di dimensione C tramite una proiezione lineare.
- **Swin Transformer Layers:** la rete è composta da L layer organizzati in 4 stadi gerarchici:
 - **Stage 1:** $[H/4 \times W/4]$ risoluzione, C canali.
 - **Stage 2:** $[H/8 \times W/8]$ risoluzione, $2C$ canali.
 - **Stage 3:** $[H/16 \times W/16]$ risoluzione, $4C$ canali.
 - **Stage 4:** $[H/32 \times W/32]$ risoluzione, $8C$ canali.

Ogni stadio contiene una sequenza di blocchi Transformer basati su **Window-based Multi-head Self-Attention (W-MSA)** e **Shifted Window-based Multi-head Self-Attention (SW-MSA)**, che permettono di modellare sia dipendenze locali che globali.

- **Scaled Cosine Attention (Attenzione Coseno Scalata)**: Sostituisce il tradizionale calcolo del *dot product attention*. Calcola il logit di attenzione di una coppia di pixel usando una funzione coseno scalata e un termine di bias di posizione relativa. Questo rende il calcolo indipendente rispetto alle ampiezze degli input del blocco e impedisce che i valori di attenzione cadano in valori estremi, contribuendo alla stabilità dell'addestramento e migliorando la precisione, specialmente per i modelli più grandi.
- **Normalization**: dopo ogni stadio, viene applicato un layer di normalizzazione.
- **Global Average Pooling (GAP)**: al termine dei 4 stadi, il feature map viene sottoposto a pooling globale per ottenere un vettore di rappresentazione.
- **Classifier Head**: il vettore globale viene passato a un MLP (Multi-Layer Perceptron), che nel modello originale realizza una classificazione standard. Nel presente lavoro, **questa testa di classificazione è stata modificata** per supportare una classificazione multilabel su 14 patologie, tramite attivazione sigmoid indipendente per ciascuna label.

Altre considerazioni importanti per la scalabilità di Swin Transformer V2:

- La Self-Attention è basata su finestre locali non sovrapposte, per mantenere una complessità computazionale lineare.
- Il Partizionamento a finestre spostate (Shifted Window Partitioning) tra blocchi consecutivi è stato introdotto per permettere connessioni tra finestre adiacenti e migliorare il potere di modellazione.
- Per evitare un aumento del calcolo dovuto alle finestre aggiuntive generate dallo spostamento, viene utilizzato un approccio di spostamento ciclico (cyclic-shifting) verso l'angolo superiore sinistro, mantenendo il numero di finestre batch invariato e impiegando un meccanismo di mascheramento.

Scelta della variante di Swin Transformer e risoluzione di input Nel presente lavoro è stata utilizzata la variante **Swin Transformer V2 Base**, che rappresenta un buon compromesso tra capacità espressiva e complessità computazionale. Tale scelta è stata motivata dal fatto che l'obiettivo del progetto è stato quello di realizzare un *proof of concept* completo di una pipeline knowledge-guided e interpretabile, compatibile con risorse di calcolo limitate.

Per coerenza con questa impostazione, è stato inoltre adottato un formato di input a risoluzione 256×256 pixel. Sebbene le immagini native del dataset presentino risoluzioni molto elevate (da circa 2000 a oltre 3000 pixel, [116]), in letteratura è comune standardizzare tali immagini a risoluzioni inferiori (tipicamente 512×512) per compiti di classificazione automatica, come discusso da Haque et al. in *Effect of image resolution on automated classification of chest X-rays* [117].

Lo stesso studio sottolinea, inoltre, che l'uso di immagini a risoluzione ridotta può in alcuni casi addirittura favorire la generalizzazione e la robustezza del modello, soprattutto per patologie che richiedono un'analisi globale della loro struttura, come può essere per immagini toraciche.

In aggiunta, l'input a 256×256 ha consentito di ridurre sensibilmente i tempi di addestramento e inferenza, rendendo possibile la sperimentazione di architetture più complesse come quella proposta.

Nel complesso, la combinazione tra **Swin Transformer V2 Base** e risoluzione di input moderata si è rivelata adeguata per dimostrare l'efficacia dell'approccio knowledge-guided e della pipeline di interpretabilità sviluppata.

Introduzione alle modifiche Gli ultimi due layer del Transformer (tipicamente il blocco finale di Stage 3 e il blocco finale di Stage 4) sono stati ulteriormente modificati con l'iniezione di un *Graph Attention Bias*, come verrà descritto nella sezione successiva.

Il design gerarchico di Swin Transformer V2 consente di bilanciare in modo efficace la capacità di rappresentare dettagli locali (importanti per la segmentazione di pattern radiologici) e contesto globale (essenziale per inferire patologie che si manifestano su larga scala).

Le immagini radiografiche sono state preprocessate e ridimensionate a risoluzione 256×256 pixel. Sono state selezionate unicamente le proiezioni **antero-posteriori (AP)** e **postero-anteriori (PA)**, con applicazione di *flip orizzontale* per le immagini PA, al fine di omogeneizzare il campo visivo.

Durante l'addestramento è stato applicato un attento schema di *data augmentation*, comprendente rotazioni, trasformazioni affini, jittering di colore e cropping casuale ma con *delta* ridotti al fine di non snaturare la struttura delle immagini radiografiche. Questo approccio ha consentito di aumentare la robustezza del modello alle variazioni tipiche delle acquisizioni radiografiche cliniche.

Nei paragrafi successivi verranno descritte nel dettaglio le modifiche introdotte al backbone Swin V2, con particolare riferimento all'integrazione del grafo clinico e alla pipeline di interpretabilità.

3.4 Modellazione del grafo clinico

3.4.1 Motivazione e obiettivi

Uno degli elementi distintivi dell'architettura proposta è l'integrazione di un **grafo clinico eterogeneo** all'interno del processo di classificazione. L'obiettivo di questo componente è duplice:

- fornire un *bias informativo* che guidi l'attenzione del modello verso pattern visivi in linea con la semantica radiologica;
- abilitare un *meccanismo di interpretabilità* che consenta di tracciare le decisioni del modello attraverso una struttura simbolica comprensibile.

L'uso di un grafo è motivato dal fatto che molte patologie toraciche non si manifestano con pattern visivi univoci, ma attraverso combinazioni di **segni radiografici** che possono essere comuni a più condizioni cliniche. Modellare tali relazioni in modo esplicito consente al modello di apprendere rappresentazioni più robuste e generalizzabili, specialmente per classi rare o sbilanciate.

3.4.2 Preparazione e inizializzazione del grafo

La costruzione iniziale del grafo clinico ha previsto una fase di preparazione basata sull'analisi dei referti testuali associati alle immagini MIMIC-CXR.

In particolare:

- è stata implementata una pipeline di **Named Entity Recognition** (NER) combinando *SciSpacy* [118] e *NegSpacy* [119], al fine di estrarre menzioni di patologie e segni radiografici con polarità positiva o negativa;
- per ciascuna coppia *segno-label*, sono state calcolate correlazioni semantiche empiriche sulla base della co-occorrenza nei referti;
- i pesi degli archi *segno-patologia* sono stati inizializzati come parametri di una **distribuzione beta**, in modo da modellare la probabilità a priori osservata nei dati testuali.

La selezione del set di **segni radiografici** è stata effettuata manualmente, con l'obiettivo di bilanciare:

- la copertura semantica delle principali patologie toraciche;
- la disponibilità di segni descrittivi nella letteratura medica;
- la coerenza con ontologie standard come **RadLex**.

I valori di default per i pesi mancanti sono stati definiti manualmente sulla base della letteratura, laddove disponibile. Questa fase rappresenta un elemento critico del processo, in quanto l'inizializzazione dei pesi può influenzare significativamente la velocità e l'efficacia dell'apprendimento del grafo durante il training.

Il file risultante è stato serializzato in formato **JSON**, contenente la struttura completa del grafo, i nodi, e i pesi iniziali degli archi.

3.4.3 Costruzione del grafo

Il grafo clinico è stato costruito a partire dall'analisi dei referti testuali associati alle immagini MIMIC-CXR. Tramite una pipeline di *Named Entity Recognition (NER)*, sono stati estratti due tipi di entità:

- **Patologie** (*Disease nodes*): corrispondenti alle 14 label ufficiali del dataset MIMIC-CXR.
- **Segni radiografici** (*Sign nodes*): corrispondenti a circa 40 entità semantiche rappresentanti pattern o anomalie osservabili (es. consolidazione, versamento pleurico, noduli, ispessimento interstiziale, ecc.).

Gli archi del grafo rappresentano relazioni semantiche derivate da co-occorrenze osservate nei referti e da conoscenza clinica pregressa. In particolare:

- Archi **patologia-patologia**: modellano correlazioni note tra condizioni cliniche.
- Archi **segno-patologia**: rappresentano la probabilità che un determinato segno sia associato a una specifica patologia.
- Archi **segno-segno**: opzionalmente rappresentabili, ma non modellati esplicitamente in questa versione del grafo.

I pesi degli archi sono inizializzati sulla base di conoscenza clinica (es. linee guida radiologiche e letteratura specialistica) e successivamente aggiornati durante l'addestramento, in funzione delle osservazioni emerse dalle mappe di attenzione.

3.4.4 Aggiornamento dinamico

Il grafo non è statico: durante il training, i nodi segno vengono aggiornati con **feature statistiche aggregate** delle regioni salienti individuate dal modello. Tali feature comprendono:

- intensità media;
- varianza;
- entropia;
- skewness;
- curtosi;
- frattalità;
- dimensione attivata;
- posizione spaziale.

La descrizione e le motivazioni dietro la scelta di ogni parametro sono riassunti nella tabella 3.1.

Il matching tra regioni e nodi segno avviene tramite un meccanismo probabilistico basato su *softmax-weighted assignment*, descritto più in dettaglio nel paragrafo 3.5.

Inoltre, nelle prime fasi dell'addestramento è stata utilizzata una forma di **weak supervision**, in cui il matching è stato vincolato ai segni estratti dai report (tramite NER). Ciò ha consentito di stabilizzare l'aggiornamento del grafo e di inizializzare in modo più robusto le rappresentazioni dei nodi.

Feature	Misura	Utilità
Intensità Media	Densità media della regione attivata nell'heatmap.	Indica quanto un'area RX è "bianca" o opaca (es. consolidazione).
Varianza	Quanto sono distribuiti i valori di intensità.	Se la varianza è bassa → regione uniforme (es. versamento pleurico). Se alta → distribuzione irregolare (es. edema).
Entropia	Quantifica la complessità della regione attivata	Alto valore → pattern complessi (es. fibrosi). Basso valore → pattern uniformi (es. consolidazione).
Dimensione dell'Area Attivata	Percentuale dell'immagine coperta dall'heatmap.	Una polmonite lobare copre un'area più grande rispetto a un nodulo.
Skewness (Asimmetria)	Direzione di distribuzione dell'intensità.	Se > 0 , più pixel chiari (es. versamento). Se < 0 , più pixel scuri (es. enfisema).
Curtosi	Distribuzione dei valori rispetto alla media.	Utile per capire se c'è un unico punto di massima attenzione o se l'attenzione è diffusa.
Frattalità	Quanto la struttura dell'heatmap è simile a scale diverse.	Pattern ripetitivi → tessuto cicatriziale o fibrosi. Pattern irregolari → noduli o tumori.
Posizione	Range di posizione in array $[x_1, x_2, y_1, y_2]$	Utile a individuare le zone più colpite. Anche in caso effetti diffusi (es. polmonite) dà indicazione polmonare rispetto all'intera XR.

Tabella 3.1: Riassunto delle principali caratteristiche statistiche.

3.4.5 Formalizzazione matematica e iniezione del grafo

La formulazione formale del grafo e la sua integrazione nei meccanismi di attenzione del modello sono qui descritte. Il modello **Med-ViX-Ray** integra il modello di base di SwinV2 con conoscenza esterna da un grafo clinico costruito da referti radiologici, iniettandola in due punti chiave:

1. all'interno del meccanismo di self-attention di Swin V2 (*GraphAttentionBias* e *GraphAttentionModule*);
2. dopo la classificazione, come bias additivo sui logits (*GraphNudger*).

3.4.6 Rappresentazione del Grafo

Il grafo è eterogeneo e contiene:

- $D = 14$ nodi di tipo **malattia** (le label MIMIC-CXR);
- $S \approx 40$ nodi di tipo **rilievo radiologico**.

In questa implementazione, d_k , se non diversamente specificato, rappresenta la dimensione dello spazio latente comune per l'interazione tra patologie e segni radiografici, non necessariamente legata ai meccanismi interni dell'attenzione di Swin. Di seguito, le assunzioni e la formulazione matematica per incorporare sia relazioni *correlation* patologia-patologia e *finding*, rilievi-patologia:

- D come nodi malattia (label) e S come nodi di rilievi clinici.
- Logits di base $l_i \in \mathbb{R}^D$ per l'immagine i .
- Collegamenti in $\mathbb{R}^{D \times D}$ tra patologie e in $\mathbb{R}^{D \times S}$ tra patologie e rilievi radiologici.
- Feature estratte $F_i \in \mathbb{R}^{S \times f}$ da attention-map, dove f è il numero di statistiche calcolate (es. intensità, entropia, posizione, ecc.) per ogni rilievo.

- Una matrice di adiacenza eterogenea

$$G = \begin{bmatrix} & \\ G_{dd} & G_{ds} \\ G_{sd} & G_{ss} \end{bmatrix} \in R^{(D+S) \times (D+S)} \quad (3.4.1)$$

dove:

- $G_{dd} \in R^{D \times D}$ proviene dagli archi *correlation* patologia-patologia
- $G_{ds} \in R^{D \times S}$ costruita dagli archi *finding* patologia-segni e scalata di un λ_s minore di 1 per normalizzare i pesi.
- $G_{sd} = G_{ds}^T$ trasposta della precedente dato il grafo non orientato
- $G_{ss} \in R^{S \times S}$ una matrice nulla, siccome non sono modellati archi patologia-patologia.

Da notare che, sebbene semanticamente orientato, il grafo codificato non lo è per favorire la lettura in entrambe le direzioni nelle diverse fasi del forward, sia in training sia in predizione, in cui le informazioni passano alternativamente in una direzione e nell'altra e, l'uso di accorgimenti tecnici evita duplicazione degli archi.

3.5 Integrazione del grafo nell'architettura

3.5.1 Doppia Integrazione del Grafo

Dopo aver definito la struttura e la formalizzazione del grafo clinico, in questa sezione viene descritto come tale conoscenza simbolica venga effettivamente integrata nell'architettura neurale. L'integrazione avviene in due punti distinti:

- a livello di *transformer layers*, attraverso un bias additivo sulle matrici di attenzione;
- a livello di *output*, tramite un modulo di *Nudging* che corregge i logits finali.

3.5.2 Motivazione della doppia integrazione del grafo

L'integrazione della conoscenza simbolica all'interno dell'architettura è stata progettata su due livelli complementari:

- un'integrazione **a priori**, tramite l'iniezione di un *Graph Attention Bias* nei Transformer layers, che guida l'attenzione del modello in fase di encoding delle immagini;
- un'integrazione **a posteriori**, tramite il *Graph Nudger*, che modula i logits finali sulla base della coerenza tra le regioni effettivamente attivate dal modello e la struttura del grafo.

Questa doppia integrazione risponde a due esigenze distinte:

1. favorire l'apprendimento di rappresentazioni visive che riflettano le relazioni semantiche note tra segni e patologie, attraverso il bias a livello di attenzione;
2. aumentare l'interpretabilità e la robustezza delle predizioni finali, sfruttando a posteriori le attention map per correggere o raffinare i logits in funzione della conoscenza clinica.

I pesi utilizzati nel Graph Attention Bias derivano dalla **beta distribuzione** delle correlazioni segno-label calcolate sui referti clinici, mentre il Graph Nudger sfrutta direttamente le mappe di attenzione ottenute durante il forward pass.

Nei paragrafi successivi viene presentata la formalizzazione matematica di questi meccanismi.

3.5.3 Bias nei Transformer Layers

Nei livelli più profondi del backbone Swin V2, le matrici di attenzione vengono modificate sommando un bias appreso dal grafo. In particolare, la matrice di adiacenza G viene:

- adattata via layer convoluzionali $\text{conv}(G)$;
- scalata tramite un coefficiente α_l specifico per ogni layer;
- sommata agli score di attenzione.

Iniezione dell'attenzione

La formula finale degli score di attenzione modificati diventa:

$$S_{ij} = \frac{\cos(q_i, k_j)}{\tau} + B_{ij} + \alpha_l \cdot \text{conv}(G)$$

dove:

- q_i, k_j : query e key dei token;
- τ : temperatura appresa;
- B_{ij} : positional bias;
- α_l : scalare imparabile (gate) per il layer l ;
- $\text{conv}(G)$: grafo adattato da una rete convoluzionale.

L'iniezione del bias nell'attenzione avviene separatamente per ogni livello iniettato (ultimi n livelli, qui usato $n = 2$.) tramite un layer convolutivo costituito da due blocchi *Conv2d* di Torch frammentati a un blocco *ReLU*. In questa implementazione, α_l è diverso per ogni layer in cui viene iniettato il bias dal grafo tale che:

$$\alpha_l = \epsilon + (1 - \epsilon) * \sigma(w_i) \quad (3.5.1)$$

ovvero α_l è un *gate learnable scalar*, con un valore maggiore di 0 e minore o uguale a 1, il cui parametro di learning è w_i per ogni layer; $\sigma(w_i)$ rappresenta il sigmoide del parametro.

Bias nei Transformer Block (**GraphAttentionBias**)

L'obiettivo è arricchire i punteggi di attenzione A del Transformer con informazioni strutturali derivanti dal grafo clinico G . In Swin V2, il grafo è iniettato nei blocchi finali del backbone (ultimi n layer) aggiungendo una componente ai punteggi di attenzione.

Step 1 - Normalizzazione e interpolazione Il grafo è prima interpolato alla dimensione richiesta dai punteggi di attenzione:

$$G_{\text{resized}} = \text{Interpolate}(G, N \times N) \quad (3.5.2)$$

dove N è il numero di token su cui opera il Transformer in un determinato blocco.

Step 2 - Adattamento convoluzionale Per adattare semanticamente i valori di G al contesto dei token e delle attenzioni, viene applicata una rete convoluzionale con attivazione $\tanh$:

$$G_{\text{adapted}} = \tanh(\text{Conv2D}(G_{\text{resized}}))$$

Questa rete è diversa per ciascun layer in cui si inietta il grafo. In pratica, per ogni layer l viene usata una convoluzione diversa f_l .

Step 3 - Modulazione con gate α Il contributo del grafo è scalato da un parametro α_l imparato per ogni layer:

$$\alpha_l = \epsilon + (1 - \epsilon) \cdot \sigma(w_l), \quad \text{con } \epsilon = 0.05$$

Step 4 - Combinazione nei punteggi di attenzione I punteggi di attenzione (di forma $[B, H, N, N]$) vengono modificati così:

$$\text{attn}_{\text{modified}} = \text{attn}_{\text{original}} + \alpha_l \cdot G_{\text{adapted}}$$

dove:

- G_{adapted} viene espanso lungo batch e heads;
- $\text{attn}_{\text{original}}$ è il tensore prodotto dall'originale blocco di attenzione.

Step 5 - Softmax finale Infine, i punteggi modificati vengono normalizzati tramite softmax:

$$A_{ij} = \text{softmax}(\text{attn}_{\text{modified}})_{ij}$$

che diventeranno i pesi per l'aggregazione dei valori nel meccanismo attention.

Questa iniezione è attivata solo nei blocchi a partire da un certo layer (tipicamente gli ultimi 2), per garantire che le informazioni semantiche del grafo influenzino le rappresentazioni più astratte.

3.5.4 Nudging Grafico sui Logits Finali

Bias Post-Classificatore (GraphNudger)

Dopo la classificazione, viene calcolato un **bias additivo** per ogni logit sulla base di:

- similarità tra segni clinici trovati nell'immagine e nodi del grafo;
- pesi degli archi nel grafo (da $\text{findings } s \rightarrow d$);
- gradiente della loss backpropagata.

Per ogni classe d , il bias è dato da:

$$\Delta b_d^{(i)} = \eta \sum_{s \in \mathcal{S}_d} w_{d,s} \cdot \text{sim}_s^{(i)} \cdot \|\nabla L_i\|$$

dove:

- $\text{sim}_s^{(i)}$ è la similarità tra la regione attivata e il nodo segno s ;
- $w_{d,s}$ è il peso dell'arco nel grafo;
- ∇L_i è il gradiente per il sample i .

Ciò avviene per ogni label e il Δ di bias viene vettorizzato affinché la somma finale sia infine aggiunta ai logits di base:

$$\hat{y}_i = \ell_i + \Delta b_i$$

Questo permette al modello di modificare la propria predizione in base a segni osservabili più in linea con quanto codificato nel grafo.

3.6 Matching tra regioni salienti e nodi clinici

Un elemento chiave della pipeline proposta è il meccanismo di **matching tra le regioni salienti individuate nelle mappe di attenzione e i nodi segno del grafo clinico**.

Questo meccanismo consente di:

- aggiornare dinamicamente le rappresentazioni dei nodi segno con feature statistiche derivate dalle immagini;

- modulare i logits finali con l’influsso di evidenza visiva e di conoscenza simbolica;
- migliorare stabilità e generalizzazione del modello durante l’addestramento.

3.6.1 Matching probabilistico con softmax

In un primo momento, si è considerato un approccio *greedy matching*, in cui ogni regione verrebbe assegnata al nodo più simile in base alla similarità coseno: Per ciascun nodo s , si memorizza la massima similarità del coseno trovata, questo equivale a selezionare per ciascun nodo “sign” la regione che meglio lo rappresenta:

$$sim_s^{(i)} = \max_{r=1\dots R_i} \left(\frac{\langle f_{i,r}, f_s \rangle}{\|f_{i,r}\| \cdot \|f_s\|} \right)$$

Tuttavia, è stato poi preferito un approccio **softmax probabilistico**. Quest’ultimo presenta diversi vantaggi:

- evita aggiornamenti troppo *sbilanciati* e sensibili al rumore;
- consente alle regioni ambigue di contribuire a più nodi in modo graduale;
- migliora la stabilità dell’apprendimento del grafo.

Per ciascuna regione attiva r , viene calcolata la similarità coseno $sim(r, s)$ con ciascun nodo segno s . Tali similarità vengono poi trasformate in una distribuzione di probabilità tramite softmax con temperatura T :

$$p(r \rightarrow s) = \frac{\exp\left(\frac{sim(r,s)}{T}\right)}{\sum_{s'} \exp\left(\frac{sim(r,s')}{T}\right)}$$

Successivamente, vengono selezionati i **top- k** nodi segno più probabili, e la loro rappresentazione viene aggiornata in modo *weighted*, ovvero ogni nodo riceve un contributo proporzionale alla probabilità $p(r \rightarrow s)$.

3.6.2 Weak supervision con NER

Durante le prime fasi dell’addestramento, è stata introdotta una forma di **weak supervision** per guidare il matching.

In particolare, per le prime 7 epoche (con l'eccezione di una epoca intermedia di transizione), il matching softmax è stato vincolato ai soli nodi segno presenti nel report testuale dell'immagine, ottenuto tramite NER descritto nei paragrafi precedenti.

Per ciascuna immagine, la lista di segni positivi è stata utilizzata per filtrare i nodi segno considerati dal softmax, riducendo così il rischio di assegnazioni spurie nelle fasi iniziali.

Dopo tale fase, il modello è passato a un **matching softmax completamente libero**, senza vincoli da NER, in modo da permettere al grafo di affinare autonomamente le rappresentazioni dei nodi.

Inoltre, è stato implementato un meccanismo di **annealing della temperatura** per regolare progressivamente la "confidenza" del matching:

- durante le prime 4 epoche, è stata utilizzata una temperatura $T = 0.5$, che produce una distribuzione softmax più "morbida", favorendo l'esplorazione e l'aggiornamento robusto dei nodi segno;
- a partire dalla quinta epoca, la temperatura è stata ridotta a $T = 0.2$, rendendo il matching più selettivo e permettendo al grafo di consolidare le rappresentazioni codificate.

Questa strategia di annealing ha contribuito a migliorare la stabilità dell'aggiornamento del grafo, riducendo il rischio di early overfitting e consentendo un apprendimento progressivo delle associazioni tra regioni salienti e nodi segno.

3.6.3 Aggiornamento dei nodi segno

Per ciascun nodo segno s coinvolto nel matching, la rappresentazione vettoriale viene aggiornata come media pesata delle feature delle regioni assegnate.

In dettaglio, per ciascuna regione r con probabilità $p(r \rightarrow s)$:

- viene calcolato un vettore di feature pesato: $f_r \times p(r \rightarrow s)$;
- tale vettore viene aggregato con le feature correnti del nodo s tramite una media mobile controllata da un parametro di smoothing.

Questo meccanismo consente al grafo di adattarsi progressivamente al dominio visivo, aggiornando i prototipi dei segni radiografici nel tempo.

3.6.4 Formulazione One-Liner riassuntiva

In modelli Swin come quello usato:

$$\hat{y}_i = l_i + W_{\text{out}} \cdot \left\{ \left[\text{softmax} \left(\frac{\cos(Q, K)}{\tau} + B + a_l \cdot \text{conv}(G) \right) \cdot V \right] \right\}_d \quad (3.6.1)$$

con G equivalente a:

$$G = \begin{pmatrix} \begin{bmatrix} G_{dd} & G_{ds} \\ G_{sd} & G_{ss} \end{bmatrix} \end{pmatrix} \quad (3.6.2)$$

con:

- δ_i sono logits generati dal nudging;
- Q, K, V : Query, Key, Value generati dai token di patch nell'Swin block;
- $\cos(Q, K)$ indica un fattore di correzione imparato dal modello applicato tutta-
via solo al layer l ;
- $\text{Conv}(G)$ uscita di due layer convoluzionali con ReLU applicati a G ;
- a_l scala appresa per layer l (via sigmoid su w_l), $a_l \in [0, 1]$;
- W_{cls} proiezione finale della testa di classificazione (MLP);
- $\hat{y}_i$ logits finali usati per calcolo della loss.

Nota: laddove non è applicato il bias dal grafo si assuma $a = 0$.

3.7 Possibile implementazione alternativa: Vit Classici

Questa formulazione alternativa risulta più adatta per i ViT tradizionali che calcolano l'attenzione tramite softmax e non sfruttano l'approccio a finestre tipico di Swin. Pertanto viene qui riportata per confronto teorico, ma non è utilizzata nel modello finale realizzato. Si noti, inoltre, che qui d_k rappresenta la dimensione delle chiavi/queries e viene usato per scalare i prodotti scalari nell'attenzione. Nei modelli Swin V2, il termine corrispondente è appreso implicitamente (es. tramite τ) e non compare esplicitamente nella formula di attenzione.

Un possibile approccio, alternativo all'uso delle convoluzioni per iniettare l'attenzione, prevede la formazione di embedding per introdurre direttamente le informazioni del grafo come parametri dell'attenzione ed eseguirne il prodotto scalare di similarità (usando il fattore di scaling $\sqrt{d_k}$):

$$S_i = \frac{E_i E_i^T}{\sqrt{d_k}} + G \Rightarrow A_i = \text{softmax}(S_i) \Rightarrow R_i = A_i E_i$$

con $E_i E_i^T$ è una moltiplicazione tra matrici (notazione Python @ per tensori 2D, uso di torch.bmm per versioni batched) e G un bias diretto derivante dal grafo (che può essere presente o meno, dato che le informazioni possono essere anche iniettate direttamente negli embeddings).

3.8 Conv2D nei moduli di bias grafico

Le operazioni convolutive (Conv2D) all'interno del modulo di bias grafico sono state applicate per permettere di adattare la matrice di adiacenza alle dimensioni e alla semantica dei pesi nell'attenzione, sfruttando l'autoapprendimento per aggiungere il bias nello stesso spazio vettoriale delle rappresentazioni dei segni nel modello ove presenti.

Dato un input $X \in \mathbf{R}^{C_{in} \times H \times W}$ e un kernel $K \in \mathbf{R}^{C_{out} \times C_{in} \times k_H \times k_W}$, l'output convoluto è:

$$Y_{i,j}^{(c)} = \sum_{c'=1}^{C_{in}} \sum_{m=1}^{k_H} \sum_{n=1}^{k_W} K_{m,n}^{(c,c')} \cdot X_{i+m,j+n}^{(c')} \quad (3.8.1)$$

dove:

- $Y^{(c)}$ è la mappa prodotta dal filtro c -esimo;
- k_H, k_W sono dimensioni del kernel (es. 3×3);
- Il padding zero e lo stride sono controllati nel modulo per allineare input e output;
- Le convoluzioni sono seguite da attivazioni ReLU e normalizzazioni opzionali.

In questo modello, queste convoluzioni operano sulla versione upscalata della matrice G del grafo, generando una mappa strutturalmente compatibile con gli score di attenzione Swin.

Uso della funzione di attivazione $\tanh$ Dopo l'adattamento della matrice del grafo tramite convoluzioni, il risultato viene trasformato tramite funzione $\tanh$, ovvero:

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \in (-1, 1) \quad (3.8.2)$$

Questa scelta è motivata da:

- **Simmetria centrata su zero:** consente sia amplificazione che attenuazione del bias in funzione del contenuto della matrice G adattata;
- **Controllo numerico:** i valori di attenzione rimangono stabili prima di entrare nella somma con gli score S_{ij} originali;
- **Compatibilità con attenzione Swin:** poiché Swin V2 normalizza le attenzioni con softmax su score scalati, limitare il range del bias grafico evita dominance o esplosioni.

Convoluzioni vs. Embedding statici per il bias grafico In architetture alternative considerate ma non implementate (es. ViT classico o GraphFormer), l'integrazione del grafo avveniva tramite embedding statici W_d, W_s per patologie e segni, seguiti da moltiplicazione con i logits/feature:

$$E_d = \ell_i \cdot W_d, \quad E_s = F_i \cdot W_s$$

e successiva attenzione:

$$S = \frac{EE^T}{\sqrt{d_k}} + G$$

Tuttavia, questo approccio presenta due limiti:

- **Gli embedding non si adattano alle strutture topologiche del grafo:** sono condivisi per tutte le immagini e trascurano relazioni locali;
- **Limitata compatibilità con l'attenzione Swin V2,** che opera in dominio spaziale più che semantico globale.

L'approccio attuale, invece, trasforma direttamente la matrice di adiacenza G tramite layer Conv2d, permettendo:

- **Adattamento dinamico:** i pesi convolutivi sono appresi durante l'addestramento e si adattano alla struttura e scala delle mappe di attenzione;

- **Iniezione localizzata:** l'output convolutivo ha la stessa dimensionalità degli score di attenzione per layer, favorendo un'integrazione naturale.

Questo rende l'approccio convolutivo più flessibile e robusto, pur sacrificando una parte della semantica simbolica esplicita che gli embedding statici potevano offrire.

3.9 Estrazione delle mappe di attenzione

Per abilitare un meccanismo di interpretabilità e guida semantica, è stato implementato un processo dedicato di **estrazione delle mappe di attenzione** dalla Swin Transformer V2.

3.9.1 Metodo di estrazione

A differenza di approcci esterni come CDAM o GradCAM, che richiedono modifiche aggiuntive o gradienti, è stato adottato un metodo **rollout-like** basato direttamente sulle *matrici di self-attention* native del Transformer.

In particolare:

- è stato modificato il forward pass della Swin Transformer per salvare i *self-attention weights* del penultimo layer del backbone;
- il penultimo layer è stato scelto perché fornisce **mappe più ricche e diversificate**:
 - l'ultimo layer spesso presenta un'unica finestra globale, che tende a saturare l'attenzione su pochi elementi;
 - il penultimo layer preserva una struttura locale più utile per l'analisi spaziale delle regioni salienti.

3.9.2 Scelta del livello di estrazione

Un aspetto rilevante del processo di estrazione riguarda la scelta del livello della rete da cui prelevare le mappe di attenzione.

Dopo una serie di esperimenti preliminari, è stato deciso di utilizzare il **penultimo layer** della Swin Transformer V2 anziché l'ultimo. Questa scelta è motivata da considerazioni sulla struttura gerarchica della rete e sulla natura della finestratura utilizzata nei diversi stadi.

Il meccanismo Window-based Multi-Head Self-Attention (W-MSA) di Swin suddivide le immagini in finestre locali di dimensione fissa (es. 8×8). A ogni stage, un'operazione di *patch merging* riduce progressivamente la risoluzione spaziale della feature map, mentre il numero di canali aumenta.

Nel layer finale, la feature map è ridotta a 8×8 pixel, e con window size pari a 8, si ottiene una singola finestra che copre l'intera immagine. Di conseguenza, la self-attention in questo stadio tende a essere globale e a riflettere pattern molto compressi, poco utili per l'analisi spaziale fine.

Al contrario, nel penultimo layer, la feature map è di dimensione 16×16 , che corrisponde a 4 finestre (2×2) per immagine. In questo stadio:

- la self-attention è calcolata su finestre locali più piccole, preservando maggiore informazione spaziale;
- le mappe risultanti mostrano un dettaglio maggiore e consentono di individuare con maggiore precisione le regioni salienti.

Il confronto sperimentale ha confermato che l'estrazione dal penultimo layer produce mappe di attenzione più coerenti e interpretabili, rendendole più adatte sia al *matching* con i nodi segno, sia all'integrazione con il modulo *Graph Nudger*.

3.9.3 Pipeline di elaborazione

La strategia adottata estrae direttamente le self-attention diagonali dagli ultimi layer del transformer, considerando per ogni token la quantità di attenzione che esso rivolge a sé stesso. In Swin V2, questi token rappresentano patch locali, quindi il valore riflette il grado di rilevanza spaziale della patch.

Il processo di estrazione delle mappe di attenzione avviene secondo la seguente pipeline:

1. **Forward Pass:** durante il forward pass si salva il tensore di self-attention $A \in \mathbf{R}^{B \times H \times N \times N}$ tramite un *forward hook*, dove B è la batch size, H il numero di heads, N il numero di token.
2. **Self-Attention diagonale:** si estrae la diagonale di ogni mappa di attenzione (self-attention), che rappresenta l'attenzione che ogni token rivolge a sé stesso:

$$\mathbf{A}_{\text{diag}} = \text{diag}(\mathbf{A}) \in \mathbf{R}^{B \times H \times N}$$

3. **Media tra heads:** si calcola la media sui heads, ottenendo una matrice $[N, N]$ per finestra:

$$\mathbf{A}_{\text{mean}}^{(i)} = \frac{1}{H} \sum_{h=1}^H \mathbf{A}_{\text{diag}}^{(i,h,:)} \in \mathbf{R}^N$$

4. **Reshape per finestra:** dato che $N = h_w \cdot w_w$ (es. $64 = 8 \times 8$), la self-attention media viene riorganizzata in una griglia $h_w \times w_w$:

$$\mathbf{A}_{\text{win}}^{(i)} = \text{reshape}(\mathbf{A}_{\text{mean}}^{(i)}, h_w, w_w)$$

5. **Ricostruzione globale via `window_reverse`:** la funzione `window_reverse`, presente nel modulo di Swin V2, ricostruisce la mappa globale dell'immagine a partire dalle finestre locali, ripristinandone la corretta disposizione spaziale:

$$\mathbf{A}_{\text{global}}^{(i)} = \text{window_reverse}(\mathbf{A}_{\text{win}}^{(i)}, w_s, H', W')$$

dove w_s è la dimensione della finestra, e (H', W') sono le dimensioni spaziali della feature map a quel layer.

6. **Upsampling finale:** la mappa globale viene upsamplata tramite interpolazione bicubica alle dimensioni originali dell'immagine $(H_{\text{img}}, W_{\text{img}})$.
7. **Normalizzazione min-max:** la mappa viene, infine, normalizzata tra $[0, 1]$ con una normalizzazione min-max.

$$\mathbf{A}_{\text{norm}}^{(i)} = \frac{\mathbf{A}^{(i)} - \min(\mathbf{A}^{(i)})}{\max(\mathbf{A}^{(i)}) - \min(\mathbf{A}^{(i)}) + \epsilon}$$

3.9.4 Utilizzo nella pipeline

Le mappe di attenzione così ottenute rappresentano una **heatmap interpretabile**, che evidenzia le regioni su cui il modello concentra maggiormente l'attenzione.

Queste mappe vengono successivamente:

- sottoposte a una soglia dinamica (percentile adattivo) per selezionare le regioni più significative;
- elaborate tramite **analisi delle componenti connesse** per estrarre un insieme di regioni attive;
- trasformate in vettori di feature statistiche, che alimentano il meccanismo di matching con i nodi segno del grafo e il modulo Graph Nudger.

3.9.5 Motivazione della scelta

L'adozione di un metodo rollout-like diretto sui self-attention weights presenta diversi vantaggi:

- evita la necessità di calcolare gradienti aggiuntivi, riducendo il costo computazionale;
- sfrutta informazioni native del Transformer, garantendo compatibilità con il processo di forward pass;
- consente di ottenere heatmap interpretabili già durante l'addestramento, senza ulteriori passaggi.

Questa scelta si è rivelata particolarmente efficace nel contesto del progetto, permettendo un'integrazione fluida tra la rappresentazione visiva del modello e la componente simbolica del grafo clinico.

D'altra parte, soluzioni come Grad-CAM richiedono la derivazione rispetto ai feature map spaziali, ma Swin V2 lavora su sequenze di token non facilmente proiettabili in spazio immagine. Inoltre, le attenzioni esplicite sono disponibili direttamente nella rete e più informative rispetto ai gradienti finali.

3.9.6 Vantaggi

- Totalmente compatibile con Swin V2 (usa self-attention reale del Transformer).
- Batch-wise: più veloce e stabile di Grad-CAM e CDAM.
- Non richiede gradienti espliciti: esente da errori di backprop o dipendenze complicate.
- Fornisce mappa interpretabile e normalizzata, adatta a segmentazione soft e estrazione di statistiche regionali.

3.9.7 Confronto con Altri Metodi

Metodo	Compatibile Swin	Gradienti Necessari	Batch-Friendly
Grad-CAM	×	Sì	No
CDAM	~	Sì	No
Metodo Proposto	✓	No	✓

Tabella 3.2: Confronto tra metodi di estrazione attenzione

Nonostante non usi i gradienti per il calcolo dell'importanza, il metodo proposto si dimostra efficace nel generare mappe coerenti con la rilevanza spaziale. La normalizzazione e l'upsampling lo rendono direttamente integrabile nei flussi downstream, inclusa la guida tramite grafo.

Questo processo consente di ottenere una heatmap 2D interpretabile, in cui i valori più alti indicano regioni su cui il modello concentra maggiormente l'attenzione durante il processo di classificazione.

3.10 La Loss

3.10.1 Motivazione della funzione di loss composita

La funzione di loss adottata nel modello Med-ViX-Ray è stata progettata per riflettere le diverse esigenze del sistema knowledge-guided proposto.

In particolare, il modello integra tre componenti principali, schematizzati anche in Figura 3.2:

- una componente di **classification loss**, basata su *Focal Loss*, per ottimizzare la predizione multilabel in presenza di forti sbilanciamenti tra le classi;
- una componente di **attention alignment loss**, per guidare l'attenzione del modello verso regioni salienti in linea con la semantica dei nodi segno;
- una componente di **KL divergence loss**, per regolarizzare la distribuzione delle probabilità sui nodi segno e stabilizzare l'apprendimento del grafo.

I pesi di bilanciamento tra le componenti della loss (λ_{sim} , λ_{KL}) sono stati selezionati empiricamente, in base a un compromesso tra performance predittiva e qualità delle mappe di attenzione osservate.

Funzione di Loss Composita per Addestramento Guidato dal Grafo

Riassumendo, l'idea è che il bias basato sul grafo non causi cambiamenti drastici rispetto alle predizioni del modello base a meno che non ci sia evidenza sufficiente nel grafo stesso. La loss totale diventa quindi:

$$L_{total} = L_{class} + \lambda_{sim} \cdot L_{focus} + \lambda_{KL} \cdot L_{KL} \quad (3.10.1)$$

dove:

- L_{class} è la **loss di classificazione principale**, basata su Focal Loss;
- L_{focus} è una loss di **attenzione guidata**, che incoraggia il modello a concentrare l'attenzione su regioni simili ai segni clinico-radiologici;
- L_{KL} è la **divergenza KL** tra il modello nudged e il modello base (senza guida grafica);
- $\lambda_{sim}, \lambda_{KL}$ sono pesi iperparametrici scelti empiricamente.

(1) Loss di Classificazione: Per la classificazione multilabel è stata utilizzata la **Focal Loss**, adatta a dataset sbilanciati:

$$L_{\text{class}} = - \alpha_t (1 - p_t)^\gamma \log(p_t) \quad (3.10.2)$$

dove p_t è la probabilità predetta per la classe corretta, α_t è un coefficiente che bilancia le classi (tipicamente $\alpha_t = 0.75$ per le classi positive meno frequenti) e γ è il fattore che riduce l'impatto dei campioni "facili" (tipico valore: $\gamma = 2$).

(2) Loss di Attenzione (Focus Guidance): Questa loss guida le mappe di attenzione verso le regioni associate a segni clinici rilevanti:

$$L_{\text{focus}} = \frac{1}{B} \sum_{i=1}^B \left(1 - \frac{1}{K_i} \sum_{j=1}^{K_i} \text{sim}_{ij} \right) \quad (3.10.3)$$

dove sim_{ij} è la similarità coseno tra la regione j della mappa di attenzione dell'immagine i e il segno clinico j nel grafo, con K_i regioni informative. Se non presenti, la loss per quell'immagine è posta a 0.

(3) Loss di Coerenza (KL Divergence): Per evitare che la guida del grafo modifichi in modo eccessivo l'output del modello rispetto alla sua previsione nativa, si aggiunge una regolarizzazione basata sulla divergenza di Kullback-Leibler tra la previsione nudged (p_{adj}) e quella del solo classificatore (p_{base}):

$$L_{\text{KL}} = \text{KL} (p_{\text{adj}} \| p_{\text{base}}) = \sum_{c=1}^C p_{\text{adj}}^{(c)} \log \left(\frac{p_{\text{adj}}^{(c)}}{p_{\text{base}}^{(c)} + \epsilon} \right) \quad (3.10.4)$$

dove C è il numero di classi e ϵ è una costante di stabilizzazione (es. 10^{-6}).

Scelte Iperparametriche:

- $\lambda_{\text{sim}} = 0.4$: peso medio per enfatizzare il ruolo della guida spaziale.
- $\lambda_{\text{KL}} = 0.2$: peso moderato per preservare la stabilità del modello base.




Figura 3.2: Schema della loss composita utilizzata nell'addestramento con guida grafica.

3.11 Riassunto Architettura

In questo capitolo è stata presentata nel dettaglio l'architettura del modello **Med-ViX-Ray** e la pipeline knowledge-guided sviluppata per la classificazione multilabel delle immagini radiografiche del torace.

La progettazione ha integrato elementi neurali e simbolici, combinando:

- un backbone visivo basato su *Swin Transformer V2*;
- un grafo clinico eterogeneo che modella relazioni tra segni radiografici e patologie;
- una pipeline di interpretabilità e guida semantica fondata sull'analisi delle mappe di attenzione;
- un meccanismo di matching probabilistico e un *Graph Nudger* per modulare le predizioni in modo interpretabile.

Tutte le componenti sono state progettate per interagire in un ciclo chiuso tra rappresentazioni visive, conoscenza clinica e feedback del modello, con l'obiettivo di ottenere un sistema più robusto, generalizzabile e interpretabile.

Nel capitolo successivo verranno discussi i risultati sperimentali ottenuti sul dataset MIMIC-CXR, con particolare attenzione:

- alle metriche di classificazione multilabel;
- all'effetto delle componenti knowledge-guided;
- all'analisi qualitativa delle mappe di attenzione generate dal modello.

Analisi preliminare di Med-ViX-Ray

4.1 Introduzione

Dopo aver presentato l’architettura e la pipeline knowledge-guided di Med-ViX-Ray nel capitolo precedente, in questo capitolo vengono discussi i risultati sperimentali ottenuti.

L’obiettivo di questa fase di validazione è duplice:

- valutare l’efficacia predittiva del modello proposto rispetto a una baseline costituita da un backbone Swin Transformer V2 in solo fine-tuning;
- verificare in che misura l’integrazione del grafo clinico e della pipeline di interpretabilità contribuiscano a ottenere predizioni più robuste e coerenti con la semantica radiologica.

La sperimentazione è stata condotta utilizzando il dataset MIMIC-CXR e un setup come descritto nel Capitolo 3. I risultati verranno analizzati sia in termini quantitativi (metriche di classificazione multilabel), sia in termini qualitativi (analisi delle mappe di attenzione e dell’evoluzione del grafo clinico).

Infine, verrà fornita una discussione critica sull’efficacia complessiva dell’approccio proposto e sul raggiungimento degli obiettivi della tesi.

4.2 Setup sperimentale

4.2.1 Dataset e split

Gli esperimenti sono stati condotti utilizzando il dataset **MIMIC-CXR-JPEG version**, un ampio corpus di immagini radiografiche del torace annotate con 14 label patologiche.

Sono state selezionate unicamente immagini con proiezione:

- **Antero-Posteriore (AP)**;
- **Postero-Anteriore (PA)**, opportunamente trasformate tramite *flip orizzontale* per uniformare il campo visivo.

Le immagini con proiezione latero-laterale (LL) sono state escluse. Non è stato imposto un vincolo esplicito sulla presenza del report testuale, anche se praticamente tutte le immagini associate a uno *study_id* disponevano di un report utile per la pipeline NER.

La suddivisione dei dati in **train**, **validation** e **test** ha seguito esattamente gli split ufficiali forniti dai file CSV del dataset su PhysioNet, in modo da seguire il riferimento per MIMIC-CXR.

Il numero di immagini per ciascun set è il seguente:

- **Train pool totale:** ~ 243 000 immagini (147 169 AP + 96 155 PA);
- **Validation:** 1 959 immagini;
- **Test:** 3 403 immagini.

4.2.2 Modelli confrontati

Per valutare l'efficacia dell'approccio proposto, sono stati confrontati i seguenti modelli:

- **Swin Transformer V2 fine-tuned:**
 - backbone pre-addestrato su ImageNet (tramite libreria TIMM);
 - 8 epoche di fine-tuning.

- **Med-ViX-Ray:**

- stesso backbone Swin Transformer V2 pre-addestrato su ImageNet;
- 9 epoche di training complessive;
- **Epoca 1:** grafo clinico disattivato, aggiornamento iniziale dei pesi del grafo tramite informazioni estratte dai report con pipeline NER;
- **Epoche 2+:** iniezione di bias nei layer del Transformer e attivazione del modulo *Graph Nudger*;
- aggiornamento dei pesi da NER effettuato solo nelle prime due epoche, per inizializzare correttamente il grafo.

È stato inoltre eseguito un test preliminare sul modello pre-addestrato senza fine-tuning, ma i risultati di tale variante non sono inclusi tra i confronti principali a causa della limitata disponibilità di metriche comparabili.

4.2.3 Metriche di valutazione

Le metriche principali utilizzate per la valutazione sono:

- **F1 micro:** metrica principale, particolarmente rilevante in contesti multilabel con classi fortemente sbilanciate;
- **F1 macro:** metrica di supporto, per evidenziare il comportamento sulle classi meno rappresentate.

4.2.4 Motivazioni per la scelta dei modelli di confronto

I risultati ottenuti saranno inoltre confrontati con i valori riportati in letteratura per i modelli **Flamingo-CXR** e **Rad-DINO**, al fine di posizionare le performance del modello proposto rispetto agli approcci state-of-the-art.

La scelta di confrontare i risultati di Med-ViX-Ray con i modelli **Flamingo-CXR** e **Rad-DINO**, piuttosto che con altri modelli state-of-the-art con performance assolute superiori, è stata dettata da considerazioni di coerenza architetturale e di allineamento con gli obiettivi originali della tesi. Tuttavia, un parziale confronto è stato effettuato anche con CheXzero [120], classificatore zero-shot con buone qualità discriminative.

Entrambi i modelli selezionati condividono alcune caratteristiche chiave con l'approccio proposto:

- **Architettura Transformer-based:** Rad-DINO è basato su un backbone ViT-B, architettura concettualmente affine a quella di Swin Transformer V2 utilizzata in Med-ViX-Ray.
- **Pipeline orientata alla refertazione:** sia Flamingo-CXR che Rad-DINO integrano, oltre alla componente di classificazione multilabel, meccanismi di generazione di referti clinici. Questa caratteristica è particolarmente rilevante, in quanto uno degli obiettivi iniziali del presente lavoro era proprio la progettazione di un classificatore interpretabile che potesse successivamente essere integrato con modelli linguistici (LLM o SLM) per la generazione di referti.

Per ragioni legate a vincoli di tempo e di risorse computazionali, la componente di refertazione non è stata implementata nella fase attuale del progetto. Tuttavia, la pipeline Med-ViX-Ray è stata concepita fin dall'inizio in modo da poter essere estesa in questa direzione.

In questo contesto, confrontarsi con modelli che già perseguono l'obiettivo di abilitare una classificazione interpretabile e utilizzabile in pipeline di supporto alla refertazione risulta particolarmente significativo, fornendo un benchmark più in linea con la filosofia progettuale di Med-ViX-Ray.

4.2.5 Hardware e risorse computazionali

Il training è stato eseguito sulla piattaforma **Kaggle** e, in parte, su **Colab**, sfruttando un batch size pari a 32.

In aggiunta, è stato effettuato un esperimento anche sulle **Google Research TPU** tramite accesso *SSH* a macchine virtuali in **Google Cloud**. In tale configurazione è stato possibile eseguire il training del modello Swin Transformer V2 fine-tuned, mentre il modello Med-ViX-Ray non è risultato compatibile con l'uso delle TPE per l'implementazione di operazioni fuori dal framework ottimizzato `torch_xla` necessario. Per consentire l'esecuzione, infatti, sono state apportate modifiche specifiche al codice, sviluppate in un branch dedicato (`xla`) del repository GitHub del progetto.

Il tempo complessivo di addestramento *finale* è stato di circa una settimana per singolo modello sulla piattaforma Kaggle:

- 9 epoche per il modello Med-ViX-Ray;
- 8 epoche per il modello Swin Transformer V2 fine-tuned.

Lo scostamento di un'epoca nel numero di training epochs è motivato dalla necessità di consolidare l'apprendimento dopo la disattivazione della weak supervision NER a partire dall'epoca 7, che ha reso necessaria un'ulteriore epoca di affinamento per il modello Med-ViX-Ray.

4.3 Risultati quantitativi

In questa sezione vengono presentati i risultati quantitativi ottenuti dal modello Med-ViX-Ray e confrontati con:

- un modello baseline Swin Transformer V2 fine-tuned;
- i risultati riportati in letteratura per i modelli Flamingo-CXR e Rad-DINO, laddove disponibili.

4.3.1 Presentazione dei risultati

I risultati ottenuti sono riportati nella Tabella 4.1, che confronta le performance di Med-ViX-Ray con la baseline fine-tuned e, in parte, con i modelli Flamingo-CXR e Rad-DINO. Come si evidenzia dalla tabella, infatti, pur essendo addestrati o testati anche su dataset MIMIC, i paper di riferimento non specificano direttamente le metriche necessarie per un paragone efficace. Pertanto i test su MIMIC possono considerarsi utili più per il confronto tra Med-ViX-Ray e la Baseline dove è possibile notare un miglioramento netto di oltre 10 punti percentuali in F1 score e Recall, mentre AUC ROC e Precision hanno valori simili. Un confronto delle AUR-ROC per classe è visibile in Figura 4.1, dove è possibile notare un miglioramento su ogni categoria rispetto al modello base.

Modello	F1 micro	F1 macro	Precision micro	Recall micro	AUC ROC macro
Fine-tuned (baseline)	0.456	0.285	0.529	0.466	0.744
Med-ViX-Ray	0.566	0.385	0.482	0.679	0.790
Flamingo-CXR	0.519 ¹	N/A	N/A	N/A	0.87 ²
Rad-DINO †	N/A	0.319 ³	N/A	N/A	N/A
CheXzero ⁴	0.606	N/A	N/A	N/A	0.889

¹ Chexpert F1 score su report generato su MIMIC-CXR.

² AUC - Nucleus sampling su IND1 Dataset.

³ ViT-B 518x518 su refertazione di MIMIC-CXR, Macro-F1-14.

⁴ Su CheXpert Dataset.

† Dopo 100 epoche di addestramento.

Tabella 4.1: Confronto delle performance sui set di test tra i modelli considerati.




Figura 4.1: Confronto tra le ROC curve dei modelli Swin V2 fine-tuned e Med-ViX-Ray.

Per un confronto più diretto con i modelli presenti in letteratura, è stato effettuato un ulteriore test sul dataset **VINDR-CXR** [121].

In assenza della possibilità di effettuare un fine-tuning dedicato su tale dataset, è stato condotto un test *zero-shot*, utilizzando il modello Med-ViX-Ray pre-addestrato su MIMIC-CXR. Per garantire un confronto il più possibile fedele, le label di VINDR-CXR (28 in totale) sono state aggregate laddove ragionevole alle corrispondenti label di MIMIC-CXR. Ad esempio, le categorie *rib fracture* e *clavicle fracture* di VINDR sono state unite sotto la label *fracture* di MIMIC, evitando così modifiche strutturali al classificatore non riaddestrato.

È importante sottolineare che anche i modelli di confronto in letteratura hanno trattato in modo parziale la label space di VINDR-CXR: nel paper di RAD-DINO, ad esempio, il confronto è stato effettuato su sole 7 delle 28 label disponibili. Inoltre, mentre RAD-DINO e CheXzero riportano l'uso di 1500 immagini di training su VINDR-CXR, il dataset ufficiale riporta 15000 immagini, suggerendo un possibile refuso o errore di trascrizione nel paper.

I risultati di questo confronto, basato su AUPRC, sono riportati nella Tabella 4.2.

Modello	LO	CM	PL-T	PE	Aggregato
Med-ViX-Ray	0.190	0.738	0.482	0.495 ¹	0.476
RAD-DINO ²	0.149	0.699	0.366	0.778	0.498
CheXzero ³	0.111	0.774	0.251	0.602	0.435

¹ Non direttamente presente, usato Pleural Other per confronto.

² RAD-DINO ha usato 1500 immagini di training su VINDR-CXR prima del test.

³ Metriche reperite dal paper di RAD-DINO.

Tabella 4.2: Confronto AUPRC su test-set di VINDR-CXR.

LO: opacità polmonare, CM: cardiomegalia, PL-T: ispessimento pleurico, PE: effusione pleurica,

Aggregato: media macro sui precedenti valori.

4.3.2 Analisi delle metriche su MIMIC

Dall'analisi dei risultati emergono i seguenti punti:

- **Med-ViX-Ray** mostra un miglioramento rispetto al modello baseline Swin V2 fine-tuned in termini di **F1 micro**, suggerendo una maggiore capacità complessiva di classificazione multilabel sul dataset MIMIC-CXR.
- Il miglioramento è più marcato sulle **classi minori**, come evidenziato anche dall'andamento della **F1 macro**.
- A confronto con i modelli state-of-the-art della letteratura, i risultati di Med-ViX-Ray risultano competitivi, considerando che:
 - Flamingo-CXR utilizza un'architettura multimodale avanzata (vision-language model) e training su dataset più ampi;

- Rad-DINO si basa su un pre-training su larga scala mentre in addestramento comprende non solo il dataset di MIMIC ma anche diversi altri dataset radiografici per un totale di oltre 800000 immagini di training.
- È importante sottolineare che, pur non raggiungendo necessariamente le metriche assolute dei modelli più sofisticati, Med-ViX-Ray offre il vantaggio aggiuntivo di una pipeline interpretabile e knowledge-guided, con un design mirato a favorire l'integrazione in contesti clinici reali.

4.3.3 Analisi delle metriche su VINDR-CXR

L'analisi dei risultati su VINDR-CXR evidenzia alcune considerazioni interessanti sul comportamento del modello Med-ViX-Ray in regime di test zero-shot.

Pur non essendo stato eseguito fine-tuning su VINDR-CXR, Med-ViX-Ray mostra performance competitive rispetto ai modelli di riferimento, in particolare:

- ottiene il miglior risultato AUPRC su **LO** (Opacità polmonare) e **PL-T** (Ispessimento pleurale), con valori rispettivamente pari a **0.190** e **0.482**;
- raggiunge un risultato comparabile su **Cardiomegalia** (CM), mantenendosi prossimo ai valori di CheXzero e RAD-DINO;
- su **Versamento pleurico** (PE), pur non raggiungendo il valore di RAD-DINO, presenta un valore discreto considerando la differenza di training e il mancato preciso allineamento di label in questo caso.

Dal punto di vista dell'**Aggregato** (media macro delle label considerate), Med-ViX-Ray ottiene un valore di **0.476**, posizionandosi molto vicino al risultato di RAD-DINO (**0.498**), che ha beneficiato di training supervisionato sul dataset target.

Questi risultati suggeriscono che la pipeline di Med-ViX-Ray, pur senza adattamenti specifici al dominio di VINDR-CXR, riesce a generalizzare in modo robusto. In particolare, l'integrazione del grafo clinico e della guida semantica tramite attention map sembra contribuire a rendere il modello più resistente al domain shift rispetto a modelli puramente neurali.

Va inoltre sottolineato che il confronto è stato effettuato su un sottoinsieme limitato delle label di VINDR-CXR, come avvenuto anche nei confronti di RAD-DINO e CheXzero. La selezione parziale delle label è dovuta alla mancanza di corrispondenze dirette e al diverso focus semantico dei dataset di origine. Questo aspetto rappresenta una limitazione comune nei confronti cross-dataset, ma non invalida l’osservazione della buona capacità di generalizzazione dimostrata da Med-ViX-Ray.

4.3.4 Considerazioni sul confronto

Il confronto con la baseline e con i modelli della letteratura suggerisce che l’integrazione del grafo clinico e della pipeline di interpretabilità consente a Med-ViX-Ray di ottenere un equilibrio interessante tra performance predittiva e trasparenza del modello.

I risultati ottenuti sono in linea con l’obiettivo della tesi, che non era solo quello di massimizzare metriche di accuratezza, ma anche di esplorare approcci knowledge-guided che potessero produrre modelli più robusti, affidabili e comprensibili per l’uso clinico.

4.4 Risultati qualitativi

È stato condotto, inoltre, un approfondimento qualitativo per valutare:

- la coerenza delle mappe di attenzione prodotte dal modello Med-ViX-Ray;
- l’influenza dell’uso del grafo clinico nella predizione dei label prodotti.

4.4.1 Mappe di attenzione

In Figura 4.2 sono riportati alcuni esempi di mappe di attenzione prodotte dal modello Med-ViX-Ray. Dall’analisi delle mappe emergono alcuni punti rilevanti:

- Le mappe di Med-ViX-Ray risultano in generale molto localizzate e coerenti con la semantica clinica delle patologie rappresentate.
- Il matching tra regioni salienti e nodi del grafo favorisce l’attivazione di regioni rilevanti, riducendo l’attivazione spuria su aree non informative.




Figura 4.2: Esempio di attention map generata dal modello Med-ViX-Ray a partire da un'immagine CXR di polmonite tratta da Radiopaedia e usata nel modello addestrato.

In particolare, nell'esempio in figura, il modello ha correttamente indicato "Pneumonia" e "Consolidation" come label finali, individuando correttamente le patologie e i livelli di attenzione sono concentrati principalmente nel lobo destro più colpito da polmonite. In Figura 4.3, invece, il modello ha individuato correttamente la cardiomegalia, aggiungendo anche edema che, tuttavia, seppur spesso collegato alla patologia, non è visibile in questo caso. Questa evidenza qualitativa supporta l'ipotesi che l'integrazione knowledge-guided possa migliorare le metriche quantitative e

renda al contempo il comportamento del modello più interpretabile e allineato al ragionamento clinico ma necessita di ulteriori affinamenti e accorgimenti affinché possa esprimere al meglio il suo potenziale.




Figura 4.3: Esempio di attention map generata dal modello Med-ViX-Ray a partire da un'immagine CXR di cardiomegalia tratta da Radiopaedia.

4.4.2 Comportamento del grafo clinico

Prendendo le precedenti figure come esempio, i segni evidenziati, tramite riferimento diretto al grafo, sono stati per la Figura 4.2 "Ground-glass opacity" non presente ma statisticamente simile a broncogramma aereo citato nel referto dell'immagine; assenti nell'immagine sono anche segno del solco profondo e segno del picco iuxta-frenico evidenziati, invece, dal modello tramite il grafo, seppur con confidenza minore.

In riferimento alla Figura 4.3, i principali segni sono stati "Bone Interruption" e "Deep Sulcus Sign" con similarità di circa 0.5, quindi il modello non è molto sicuro della scelta ed in effetti non trova riscontro nell'immagine; "Ground-glass opacity" e "luftsichel" con confidenza dello 0.8: anche qui i singoli segni non sono presenti nel referto, tuttavia, trovano una certa motivazione nell'opacità diffusa a livello polmonare per il primo, alla cardiomegalia per il secondo, che può aver tratto in inganno il modello sull'angolo formato con il lobo superiore sinistro e il cuore stesso.

Vanno aggiunte, inoltre, alcune osservazioni avvenute durante il training:

- Dopo la fase iniziale di weak supervision, il grafo è stato in grado di affinare le rappresentazioni dei segni più frequentemente associati alle patologie target.
- Il meccanismo di matching probabilistico ha contribuito a evitare aggiornamenti troppo "rigidi", favorendo una rappresentazione più robusta.
- Tuttavia, l'interruzione della weak supervision alla settima epoca ha portato un periodo di assestamento nell'ottava che ha costretto il prolungamento del training di un'ulteriore epoca per riportare i valori delle metriche ai livelli precedenti.

4.5 Analisi

I risultati quantitativi e qualitativi ottenuti nel presente lavoro suggeriscono che l'approccio knowledge-guided proposto con Med-ViX-Ray rappresenta una direzione promettente per la classificazione multilabel di immagini radiografiche del torace.

Dal punto di vista quantitativo, il modello ha mostrato un chiaro miglioramento rispetto al backbone Swin Transformer V2 fine-tuned, con un incremento del **F1 micro** fino a circa **0.41** e una maggiore stabilità nella loss di validazione. In particolare:

- **F1 macro**, **Precision micro** e **Recall micro** risultano più bilanciati, suggerendo una migliore capacità di trattare anche le classi meno rappresentate;
- **AUC ROC macro** evidenzia che l'integrazione knowledge-guided non penalizza la discriminabilità globale del modello.

Il confronto con i modelli di letteratura (Flamingo-CXR e Rad-DINO) evidenzia che, pur non raggiungendo i livelli assoluti di modelli pre-trained multimodali o contrastivi su larga scala, Med-ViX-Ray si posiziona in modo competitivo pur mantenendo una pipeline più leggera e specificamente orientata alla trasparenza clinica.

L'analisi qualitativa condotta evidenzia alcuni spunti importanti sul comportamento del modello Med-ViX-Ray e sulla maturità delle diverse componenti della pipeline.

In particolare, l'iniezione del bias nei layer di attenzione, guidata dal grafo clinico, si è dimostrata efficace nel favorire mappe di attenzione più localizzate e coerenti con il ragionamento clinico. Il caso osservato di associazione tra cardiomegalia ed edema, pur non corretto in senso stretto nell'esempio specifico, suggerisce che il modello ha effettivamente appreso relazioni semantiche tra patologie che possono avere un fondamento fisiopatologico. Questo risultato è in linea con il ruolo previsto per il bias attention-based, ovvero supportare il ragionamento probabilistico all'interno della rete neurale.

Al contrario, il comportamento del modulo di nudging post-classificazione, basato sul matching delle statistiche delle regioni salienti con i nodi del grafo, appare ancora poco maturo. Come evidenziato nei test, i segni suggeriti dal grafo non sempre risultano allineati con l'evidenza radiologica effettiva, e la confidenza associata a tali segni è spesso modesta. È probabile che il meccanismo attuale di calcolo del nudging richieda ulteriori affinamenti o l'adozione di tecniche più raffinate per migliorare la qualità del matching e la coerenza semantica dei suggerimenti prodotti.

Infine, l'interruzione della weak supervision alla settima epoca ha evidenziato la necessità di un periodo di riassetto del grafo, confermando che la fase di supervisione debole è cruciale per guidare correttamente le prime fasi dell'aggiornamento del grafo stesso.

In sintesi, i risultati suggeriscono che l'integrazione knowledge-guided del modello è promettente, in particolare per quanto riguarda l'iniezione del bias attention-based, ma richiede ulteriori sviluppi nella componente di nudging per esprimere appieno il potenziale del paradigma proposto.

5.1 Discussione

Il presente capitolo si propone di analizzare in maniera critica i risultati ottenuti nel corso della sperimentazione, valutando il contributo del modello proposto Med-ViX-Ray rispetto allo stato dell'arte e rispetto agli obiettivi dichiarati in fase iniziale.

Attraverso l'integrazione esplicita della conoscenza clinica tramite un grafo di segni radiologici e l'impiego di una strategia di attenzione guidata, il modello ha mostrato miglioramenti significativi in termini di performance su MIMIC-CXR, mantenendo al contempo buone proprietà di generalizzazione in regime zero-shot su VINDR-CXR.

Tuttavia, alcune componenti della pipeline, in particolare il nudger basato su statistiche regionali, hanno mostrato risultati meno stabili, suggerendo margini di miglioramento. In questa sezione verranno quindi discussi i punti di forza, i limiti, le implicazioni cliniche e le prospettive evolutive del lavoro svolto.

5.1.1 Contributi principali del modello Med-ViX-Ray

Il modello Med-ViX-Ray propone un'integrazione originale tra architetture neurali visive e conoscenza clinica esplicita, con l'obiettivo di migliorare sia la performance che l'interpretabile nei compiti di classificazione radiologica. Tra i principali contributi del modello si segnalano:

- **Integrazione knowledge-guided:** tramite un grafo clinico dei segni radiologici, il modello sfrutta relazioni semantiche tra pattern visivi e diagnosi, integrando conoscenza estratta da referti medici reali.
- **Iniezione guidata dell'attenzione:** i pesi di attenzione tra patch visive vengono influenzati dalle relazioni nel grafo, modulando l'attenzione del backbone visivo in modo più informato e clinicamente motivato.
- **Architettura interpretabile:** la combinazione tra attention map, grafo esplicito e moduli separati per matching e nudging consente di isolare e analizzare il comportamento del modello, offrendo trasparenza sulle decisioni diagnostiche.
- **Robustezza su zero-shot:** i risultati ottenuti su VINDR-CXR in assenza di fine-tuning dimostrano la buona capacità generalizzativa del modello, nonostante la limitata sovrapposizione di labeling con MIMIC-CXR.
- **Pipeline adattabile:** la modularità dell'architettura (matching softmax, nudger, grafo personalizzabile) consente potenzialmente di adattare il modello a nuove patologie, nuovi domini o all'integrazione con modelli di refertazione.

Nel complesso, Med-ViX-Ray si configura come un approccio ibrido, in grado di valorizzare i punti di forza delle architetture neurali e del ragionamento clinico simbolico, offrendo un'alternativa valida rispetto ai metodi completamente end-to-end. Il confronto con modelli recenti evidenzia risultati competitivi: su MIMIC-CXR, Med-ViX-Ray ottiene un F1 micro pari a 0.505 e un AUC ROC macro di 0.788, migliorando le metriche rispetto a un fine-tuning puro dello stesso backbone (0.472 e 0.763, rispettivamente). Anche su VINDR-CXR, in regime zero-shot, il modello si avvicina alle performance di sistemi come RAD-DINO, pur non avendo ricevuto alcuna immagine del dataset in fase di addestramento.

A differenza di modelli come Flamingo-CXR e RAD-DINO, che privilegiano l'integrazione testuale per la generazione dei referti, Med-ViX-Ray adotta una strategia più simbolica e interpretabile, proponendosi come base per futuri sistemi explainable in ambito clinico. Questo lavoro pone quindi le basi per approcci più integrati tra apprendimento profondo, conoscenza medica e trasparenza algoritmica.

5.1.2 Implicazioni cliniche e interpretabilità

L'integrazione di un grafo di segni clinici radiologici nel modello Med-ViX-Ray apre a interessanti prospettive in ambito medico. In particolare, la presenza di una struttura conoscitiva esplicita, che guida sia la fase di attenzione che la decisione finale, consente di avvicinare il comportamento del modello a un ragionamento clinico strutturato.

Le mappe di attenzione, ottenute direttamente dal penultimo layer del backbone visivo e combinate con le attivazioni dei segni nel grafo, offrono una forma di interpretabilità visiva e simbolica: è possibile risalire alle regioni coinvolte nella classificazione e ai pattern visivi che hanno influenzato maggiormente la decisione.

In ambito clinico, questo rappresenta un passo avanti rispetto a modelli "black-box" tradizionali, in quanto:

- consente una verifica a posteriori da parte dello specialista, sia delle regioni salienti sia della motivazione simbolica alla base delle predizioni;
- facilita l'integrazione del modello nei workflow clinici esistenti, in quanto più trasparente e allineato alle logiche diagnostiche;
- permette potenzialmente un'interazione umana più efficace, ad esempio tramite moduli di refertazione basati su LLM guidati dalla struttura del grafo.

Tuttavia, l'interpretabilità ottenuta non è ancora completa né sempre affidabile: la componente di nudging sul grafo ha mostrato in alcuni casi segni spuri o deboli, indicando che ulteriori meccanismi di controllo, verifica e normalizzazione potrebbero essere necessari per un uso in contesti clinici reali.

5.2 Limiti e Prospettive Future

Sebbene i risultati ottenuti dimostrino la validità dell'approccio proposto, il lavoro presenta alcune limitazioni che offrono al contempo spunti concreti per futuri sviluppi.

- **Qualità e granularità del grafo clinico:** la costruzione del grafo, basata su un'aggregazione manuale di concetti da ontologie radiologiche e referti NER, risulta efficace ma ancora approssimativa. La selezione dei segni, la definizione dei pesi iniziali e la validità delle co-occorrenze semantiche possono influenzare fortemente la qualità dell'intervento conoscitivo.
- **Semplicità del nudging:** il meccanismo di nudging finale, basato su combinazioni lineari di predizioni e inferenze dal grafo, è interpretabile ma presenta margini di miglioramento. Approcci più strutturati — ad esempio reti bayesiane, Graph Neural Networks o metodi di energy-based refinement — potrebbero offrire una regolazione più efficace. Un possibile approccio, basato su refinement dei segni previa tokenizzazione ed embedding semantica di modelli come BioBert è in sviluppo al fine di superare i limiti mostrati.
- **Assenza di generazione testuale:** uno degli obiettivi iniziali prevedeva l'estensione del sistema alla generazione automatica di referti. Per limiti computazionali e di tempo, tale componente è rimasta esclusa, ma l'architettura e il grafo sono già predisposti per supportare un eventuale abbinamento con modelli linguistici.
- **Risorse computazionali:** l'intero esperimento è stato condotto con hardware consumer (GPU su Kaggle, TPUs su Google Cloud) e ha richiesto numerose ottimizzazioni per essere eseguito. Un'infrastruttura più solida permetterebbe training più lunghi, tuning di iperparametri, e modelli più ampi.
- **Generalizzazione e adattabilità:** sebbene i risultati su VINDR-CXR siano incoraggianti, l'adattamento a dataset con distribuzioni differenti richiede una gestione più solida della semantica multi-label e un affinamento delle relazioni del grafo.

Nel complesso, Med-ViX-Ray rappresenta un primo passo verso una radiologia computazionale più guidata dalla conoscenza e aperta all'interpretabilità clinica. Il suo sviluppo futuro potrebbe rappresentare un utile ponte tra reti neurali e ragionamento medico assistito, favorendo l'adozione responsabile dell'intelligenza artificiale in ambito medico.

Bibliografia

- [1] G. Litjens, T. Kooi, B. E. Bejnordi, A. A. A. Setio, F. Ciompi, M. Ghafoorian, J. A. van der Laak, B. van Ginneken, and C. I. Sánchez, “A survey on deep learning in medical image analysis,” *Medical Image Analysis*, vol. 42, pp. 60–88, 2017. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S1361841517301135> (Citato a pagina 4)
- [2] P. Rajpurkar, J. Irvin, K. Zhu, B. Yang, H. Mehta, T. Duan, D. Y. Ding, A. Bagul, C. P. Langlotz, K. S. Shpanskaya, M. P. Lungren, and A. Y. Ng, “Chexnet: Radiologist-level pneumonia detection on chest x-rays with deep learning,” *CoRR*, vol. abs/1711.05225, 2017. [Online]. Available: <http://arxiv.org/abs/1711.05225> (Citato a pagina 4)
- [3] J. Diosdado, P. Gilabert, S. Seguí, and H. Borrego, “Lunghist700: A dataset of histological images for deep learning in pulmonary pathology,” *Scientific Data*, vol. 11, no. 1, p. 1088, 2024. (Citato a pagina 4)
- [4] H. Ahmad, M. Milne, Q. Buchlak, N. Ektas, G. Sanderson, H. Chamtie, S. Karunasena, J. Chiang, X. Holt, C. Tang, J. Seah, G. Bottrell, N. Esmaili, P. Brotchie, and C. Jones, “Machine learning augmented interpretation of chest x-rays: A systematic review,” *Diagnostics*, vol. 13, p. 743, 02 2023. (Citato a pagina 4)

- [5] X. Ouyang, D. Gu, X. Li, W. Zhou, Q. Chen, Y. Zhan, X. S. Zhou, F. Shi, Z. Xue, and D. Shen, "Towards a general computed tomography image segmentation model for anatomical structures and lesions," *Communications Engineering*, vol. 3, no. 1, p. 143, 2024. (Citato a pagina 5)
- [6] W. Smith, *Radiology 101: The Basics & Fundamentals of Imaging*. Wolters Kluwer Health, 2013, ch. 1. [Online]. Available: <https://books.google.it/books?id=BwKaAgAAQBAJ> (Citato a pagina 6)
- [7] G. Simon, *Principles of Chest X-ray Diagnosis*, 4th ed. Butterworths, 1978, ch. 1. (Citato a pagina 6)
- [8] G. Brondani Torri, "X-ray artifacts | radiology reference article | radiopaedia.org," 2024, [Accessed 04-02-2025]. [Online]. Available: <https://radiopaedia.org/articles/x-ray-artifacts> (Citato a pagina 8)
- [9] R. Jeffrey, B. Manaster, A. Osborn, M. de Christenson, and P. Woodward, *Diagnostic Imaging: Emergency*, ser. Diagnostic imaging. Amirsys, 2013. [Online]. Available: <https://books.google.it/books?id=YddXmwEACAAJ> (Citato a pagina 9)
- [10] G. Frada, *Semeiotica Medica nell'adulto e nell'anziano: Metodologia Clinica Ed esplorazione morfofunzionale*, V ed. Piccin, 2014, pp. 193-194. (Citato a pagina 9)
- [11] M. C. Staff, "Pulmonary edema symptoms and causes," 2022, [Accessed 05-02-2025]. [Online]. Available: <https://www.mayoclinic.org/diseases-conditions/pulmonary-edema/symptoms-causes/syc-20377009> (Citato a pagina 10)
- [12] —, "Pulmonary edema diagnosis," 2022, [Accessed 05-02-2025]. [Online]. Available: <https://www.mayoclinic.org/diseases-conditions/pulmonary-edema/diagnosis-treatment/drc-20377014> (Citato a pagina 10)
- [13] C. Worsley, "Septal lines in lung, radiopaedia.org," 2024, [Accessed 06-02-2025]. [Online]. Available: <https://radiopaedia.org/articles/septal-lines-in-lung-1> (Citato a pagina 10)

- [14] J. S. Klein, W. E. Brant, C. A. Helms, and E. N. Vinson, *Brant and helms' Fundamentals of Diagnostic Radiology*. Wolters Kluwer, 2019, pp. 816–827. (Citato a pagina 11)
- [15] G. Frada, *Semeiotica Medica nell'adulto e nell'anziano: Metodologia Clinica Ed esplorazione morfofunzionale*, V ed. Piccin, 2014, pp. 190-191. (Citato a pagina 11)
- [16] F. Bariffi, A. Ponticiello, and C. Cecere, *Patologia dell'apparato Respiratorio e Del Mediastino*. Cuzzolin, 2008, pp. 193–208. (Citato a pagina 12)
- [17] F. J. Martinez, H. R. Collard, A. Pardo, G. Raghu, L. Richeldi, M. Selman, J. J. Swigris, H. Taniguchi, and A. U. Wells, "Idiopathic pulmonary fibrosis," *Nature reviews Disease primers*, vol. 3, no. 1, pp. 1–19, 2017. (Citato a pagina 12)
- [18] J. S. Klein, W. E. Brant, C. A. Helms, and E. N. Vinson, *Brant and helms' Fundamentals of Diagnostic Radiology*, ebook ed. Wolters Kluwer, 2019, pp. 734–735. (Citato a pagina 13)
- [19] J. Loscalzo, A. S. Fauci, D. L. Kasper, S. L. Hauser, D. L. Longo, and J. L. Jameson, *Harrison's principles of Internal Medicine*. McGraw Hill, 2022, vol. 1, pp. 2199–2200. (Citato a pagina 13)
- [20] J. S. Klein, W. E. Brant, C. A. Helms, and E. N. Vinson, *Brant and helms' Fundamentals of Diagnostic Radiology*, ebook ed. Wolters Kluwer, 2019, pp. 1157–1165. (Citato a pagina 14)
- [21] F. Bariffi, A. Ponticiello, and C. Cecere, *Patologia dell'apparato Respiratorio e Del Mediastino*. Cuzzolin, 2008, pp. 85-88. (Citato a pagina 14)
- [22] D. Cozzi, E. Cavigli, C. Moroni, O. Smorchkova, G. Zantonelli, S. Pradella, and V. Miele, "Ground-glass opacity (GGO): a review of the differential diagnosis in the era of COVID-19," vol. 39, no. 8, p. 721, 4 2021. (Citato a pagina 15)
- [23] S. Janssen, M. Murphy, C. Upton, B. Allwood, and A. H. Diacon, "Tuberculosis: An Update for the Clinician," vol. n/a, no. n/a, Jan. 2025. (Citato a pagina 15)
- [24] G. Frada, *Semeiotica Medica nell'adulto e nell'anziano: Metodologia Clinica Ed esplorazione morfofunzionale*, V ed. Piccin, 2014, pp. 199–200. (Citato a pagina 15)

- [25] D. Y. K. R. S. L. R. L. I. S. H. S. Marcel A. Behr, Simon Grandjean Lapierre and C. Y. Turenne, "Chapter 3: Diagnosis of tuberculosis disease and drug-resistant tuberculosis," *Canadian Journal of Respiratory, Critical Care, and Sleep Medicine*, vol. 6, no. sup1, pp. 33–48, 2022. [Online]. Available: <https://doi.org/10.1080/24745332.2022.2035638> (Citato a pagina 15)
- [26] K. Chaitanya Thandra, A. Barsouk, K. Saginala, J. Sukumar Aluru, and A. Barsouk, "Epidemiology of lung cancer," *Contemporary Oncology/Współczesna Onkologia*, vol. 25, no. 1, pp. 45–52, 2021. [Online]. Available: <http://dx.doi.org/10.5114/wo.2021.103829> (Citato a pagina 16)
- [27] F. Bariffi, A. Ponticiello, and C. Cecere, *Patologia dell'apparato Respiratorio e Del Mediastino*. Cuzzolin, 2008, pp. 238–246. (Citato a pagina 17)
- [28] R. P. Gale, "Paraneoplastic syndromes," 2024/09 2024, [Accessed 04-02-2025]. [Online]. Available: <https://www.msmanuals.com/professional/hematology-and-oncology/overview-of-cancer/paraneoplastic-syndromes> (Citato a pagina 17)
- [29] J. S. Klein, W. E. Brant, C. A. Helms, and E. N. Vinson, *Brant and helms' Fundamentals of Diagnostic Radiology*, ebook ed. Wolters Kluwer, 2019, pp. 884–914. (Citato a pagina 18)
- [30] J. L. Jefferies and J. A. Towbin, "Dilated cardiomyopathy," *The Lancet*, vol. 375, no. 9716, pp. 752–762, 2010. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0140673609620237> (Citato a pagina 20)
- [31] J. S. Klein, W. E. Brant, C. A. Helms, and E. N. Vinson, *Brant and helms' Fundamentals of Diagnostic Radiology*, ebook ed. Wolters Kluwer, 2019, p. 1513. (Citato a pagina 21)
- [32] T. Sethi, A. P. Singh, V. Singla, and Y. Singh, "Biatrial enlargement: an unusual cause of massive cardiomegaly," vol. 2013, p. bcr2012008320, Jan. 2013. (Citato a pagina 21)

- [33] N. Khan, D. C. Thebe, F. Suleman, and I. v. d. Werke, "Pitfalls and mimics: The many facets of normal paediatric thymus," *South African Journal of Radiology*, vol. 19, no. 11, p. 5, Oct. 2015. (Citato a pagina 21)
- [34] S. Iqbal, "Enlargement of the cardiac silhouette | radiopaedia.org," 2022, [Accessed 08-02-2025]. [Online]. Available: <https://radiopaedia.org/articles/enlargement-of-the-cardiac-silhouette> (Citato a pagina 22)
- [35] J. Belkind-Gerson, "Diaphragmatic hernia," 2023/08 2023, [Accessed 08-02-2025]. [Online]. Available: <https://www.msdmanuals.com/professional/pediatrics/congenital-gastrointestinal-anomalies/diaphragmatic-hernia> (Citato a pagina 22)
- [36] G. Simon, *Principles of Chest X-ray Diagnosis*, 4th ed. Butterworths, 1978, pp. 32–34. (Citato a pagina 23)
- [37] P. Cameron, L. Dziukas, A. Hadj, P. Clark, and S. Hooper, "Rib fractures in major trauma," *Australian and New Zealand journal of surgery*, vol. 66, no. 8, pp. 530–534, 1996. (Citato a pagina 23)
- [38] A.-A. N. Assi and Y. Nazal, "Rib fracture: Different radiographic projections," vol. 77, no. 4, p. 13, Oct. 2012. (Citato a pagina 23)
- [39] B. J. Bansidhar, J. A. Lagares-Garcia, and S. Miller, "Clinical rib fractures: are follow-up chest x-rays a waste of resources?" *The American Surgeon*, vol. 68, no. 5, pp. 449–453, 2002. (Citato a pagina 23)
- [40] O. Bodenreider, "The unified medical language system (umls): integrating biomedical terminology," *Nucleic Acids Research*, vol. 32, no. Database issue, p. D267–D270, Jan. 2004. (Citato a pagina 24)
- [41] WHO, "Icd-10: International statistical classification of diseases and related health problems: Tenth revision," 2003, [Accessed 25-02-2025]. [Online]. Available: <https://iris.who.int/handle/10665/42980> (Citato a pagina 25)

- [42] J. Hirsch, G. Nicola, G. McGinty, R. Liu, R. Barr, M. Chittle, and L. Manchikanti, "Icd-10: History and context," *AJNR: American Journal of Neuroradiology*, vol. 37, no. 4, p. 596–599, Apr. 2016. (Citato a pagina 25)
- [43] C. P. Langlotz, "Radlex: A new method for indexing online educational materials," *RadioGraphics*, vol. 26, no. 6, pp. 1595–1597, 2006, PMID: 17102038. [Online]. Available: <https://doi.org/10.1148/rg.266065168> (Citato a pagina 25)
- [44] J. Jones, "Radlex | radiology reference article | radiopaedia.org," [Accessed 25-02-2025]. [Online]. Available: <https://radiopaedia.org/articles/radlex> (Citato a pagina 25)
- [45] A. Burkov, *The hundred-page machine learning book*. Andriy Burkov, 2020, ch. 1. (Citato a pagina 26)
- [46] —, *The hundred-page machine learning book*. Andriy Burkov, 2020, ch. 6. (Citato a pagina 28)
- [47] L. Atlas, T. Homma, and R. Marks, "An artificial neural network for spatio-temporal bipolar patterns: Application to phoneme classification," in *Neural information processing systems*, 1987. (Citato a pagina 28)
- [48] Y. LeCun, B. Boser, J. S. Denker, D. Henderson, R. E. Howard, W. Hubbard, and L. D. Jackel, "Backpropagation applied to handwritten zip code recognition," *Neural Computation*, vol. 1, no. 4, pp. 541–551, Dec 1989. (Citato a pagina 28)
- [49] Y. Lecun, L. Jackel, C. Cortes, J. Denker, H. Drucker, I. Guyon, U. Muller, E. Sackinger, P. Simard, and V. Vapnik, "Learning algorithms for classification: A comparison on handwritten digit recognition," *The Statistical Mechanics Perspective*, 07 2000. (Citato a pagina 28)
- [50] A. Krizhevsky, I. Sutskever, and G. E. Hinton, "Imagenet classification with deep convolutional neural networks," in *Advances in Neural Information Processing Systems*, F. Pereira, C. Burges, L. Bottou, and K. Weinberger, Eds., vol. 25. Curran Associates, Inc., 2012. [Online]. Available: https://proceedings.neurips.cc/paper_files/paper/2012/file/c399862d3b9d6b76c8436e924a68c45b-Paper.pdf (Citato a pagina 29)

-
- [51] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, and L. Fei-Fei, "ImageNet: A Large-Scale Hierarchical Image Database," in *CVPR09*, 2009. (Citato a pagina 29)
- [52] O. Russakovsky, J. Deng, H. Su, J. Krause, S. Satheesh, S. Ma, Z. Huang, A. Karpathy, A. Khosla, M. Bernstein, A. C. Berg, and L. Fei-Fei, "Imagenet large scale visual recognition challenge," *International Journal of Computer Vision*, vol. 115, no. 3, pp. 211–252, Dec 2015. [Online]. Available: <https://doi.org/10.1007/s11263-015-0816-y> (Citato a pagina 29)
- [53] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," *CoRR*, vol. abs/1512.03385, 2015. [Online]. Available: <http://arxiv.org/abs/1512.03385> (Citato a pagina 29)
- [54] L. Alzubaidi, J. Zhang, A. J. Humaidi, A. Al-Dujaili, Y. Duan, O. Al-Shamma, J. Santamaría, M. A. Fadhel, M. Al-Amidie, and L. Farhan, "Review of deep learning: concepts, cnn architectures, challenges, applications, future directions," *Journal of Big Data*, vol. 8, no. 1, p. 53, Mar 2021. [Online]. Available: <https://doi.org/10.1186/s40537-021-00444-8> (Citato a pagina 30)
- [55] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, "Attention is all you need," *CoRR*, vol. abs/1706.03762, 2017. [Online]. Available: <http://arxiv.org/abs/1706.03762> (Citato a pagina 34)
- [56] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, J. Uszkoreit, and N. Houlsby, "An image is worth 16x16 words: Transformers for image recognition at scale," *CoRR*, vol. abs/2010.11929, 2020. [Online]. Available: <https://arxiv.org/abs/2010.11929> (Citato alle pagine 36 e 37)
- [57] R. Caruana, Y. Lou, J. Gehrke, P. Koch, M. Sturm, and N. Elhadad, "Proceedings on knowledge discovery and data mining, kdd'15," *ACM SIGKDD International Conference*, 2015. (Citato a pagina 39)

- [58] Z. C. Lipton, "The mythos of model interpretability: In machine learning, the concept of interpretability is both important and slippery." *Queue*, vol. 16, no. 3, pp. 31–57, 2018. (Citato a pagina 39)
- [59] R. R. Selvaraju, A. Das, R. Vedantam, M. Cogswell, D. Parikh, and D. Batra, "Grad-cam: Why did you say that? visual explanations from deep networks via gradient-based localization," *CoRR*, vol. abs/1610.02391, 2016. [Online]. Available: <http://arxiv.org/abs/1610.02391> (Citato a pagina 40)
- [60] A. Mahendran and A. Vedaldi, "Visualizing deep convolutional neural networks using natural pre-images," *CoRR*, vol. abs/1512.02017, 2015. [Online]. Available: <http://arxiv.org/abs/1512.02017> (Citato a pagina 40)
- [61] Y. Bengio, A. C. Courville, and P. Vincent, "Unsupervised feature learning and deep learning: A review and new perspectives," *CoRR*, vol. abs/1206.5538, 2012. [Online]. Available: <http://arxiv.org/abs/1206.5538> (Citato a pagina 40)
- [62] S. M. Lundberg and S. Lee, "A unified approach to interpreting model predictions," *CoRR*, vol. abs/1705.07874, 2017. [Online]. Available: <http://arxiv.org/abs/1705.07874> (Citato a pagina 42)
- [63] A. Goel, "Model Explainability using SHAP (SHapley Additive exPlanations) and LIME (Local Interpretable Model-agnostic Explanations)," Dec. 2023, [Accessed 21-02-2025]. [Online]. Available: <https://medium.com/@anshulgoel991/model-exploitability-using-shap-shapley-additive-explanations-and-lime-local-interpretability> (Citato a pagina 42)
- [64] T. Shiraishi, D. Miwa, T. Katsuoka, V. N. L. Duy, K. Taji, and I. Takeuchi, "Statistical test for attention map in vision transformer," 2024. [Online]. Available: <https://arxiv.org/abs/2401.08169> (Citato a pagina 43)
- [65] L. Brocki, J. Binda, and N. C. Chung, "Class-discriminative attention maps for vision transformers," 2024. [Online]. Available: <https://arxiv.org/abs/2312.02364> (Citato a pagina 44)

- [66] K. Simonyan, A. Vedaldi, and A. Zisserman, "Deep inside convolutional networks: Visualising image classification models and saliency maps," *CoRR*, vol. abs/1312.6034, 2013. [Online]. Available: <https://api.semanticscholar.org/CorpusID:1450294> (Citato a pagina 44)
- [67] L. Brocki and N. C. Chung, "Concept saliency maps to visualize relevant features in deep generative models," *CoRR*, vol. abs/1910.13140, 2019. [Online]. Available: <http://arxiv.org/abs/1910.13140> (Citato a pagina 44)
- [68] W. Bousselham, A. Boggust, S. Chaybouti, H. Strobelt, and H. Kuehne, "Legrad: An explainability method for vision transformers via feature formation sensitivity," 2025. [Online]. Available: <https://arxiv.org/abs/2404.03214> (Citato a pagina 45)
- [69] C. Raffel, N. Shazeer, A. Roberts, K. Lee, S. Narang, M. Matena, Y. Zhou, W. Li, and P. J. Liu, "Exploring the limits of transfer learning with a unified text-to-text transformer," *CoRR*, vol. abs/1910.10683, 2019. [Online]. Available: <http://arxiv.org/abs/1910.10683> (Citato a pagina 47)
- [70] Y. Tay, M. Dehghani, V. Q. Tran, X. Garcia, J. Wei, X. Wang, H. W. Chung, S. Shakeri, D. Bahri, T. Schuster, H. S. Zheng, D. Zhou, N. Houlsby, and D. Metzler, "Ul2: Unifying language learning paradigms," *arXiv preprint*, no. arXiv:2205.05131, Feb. 2023, arXiv:2205.05131 [cs]. [Online]. Available: <http://arxiv.org/abs/2205.05131> (Citato a pagina 47)
- [71] OpenAI, J. Achiam, S. Adler, S. Agarwal, L. Ahmad, I. Akkaya, F. L. Aleman, D. Almeida, J. Altschmidt, S. Altman, S. Anadkat, R. Avila, I. Babuschkin, S. Balaji, V. Balcom, P. Baltescu, H. Bao, M. Bavarian, J. Belgum, I. Bello, J. Berdine, G. Bernadett-Shapiro, C. Berner, L. Bogdonoff, O. Boiko, M. Boyd, A.-L. Brakman, G. Brockman, T. Brooks, M. Brundage, K. Button, T. Cai, R. Campbell, A. Cann, B. Carey, C. Carlson, R. Carmichael, B. Chan, C. Chang, F. Chantzis, D. Chen, S. Chen, R. Chen, J. Chen, M. Chen, B. Chess, C. Cho, C. Chu, H. W. Chung, D. Cummings, J. Currier, Y. Dai, C. Decareaux, T. Degry, N. Deutsch, D. Deville, A. Dhar, D. Dohan, S. Dowling, S. Dunning, A. Ecoffet, A. Eleti, T. Eloundou, D. Farhi, L. Fedus, N. Felix, S. P. Fishman, J. Forte,

I. Fulford, L. Gao, E. Georges, C. Gibson, V. Goel, T. Gogineni, G. Goh, R. Gontijo-Lopes, J. Gordon, M. Grafstein, S. Gray, R. Greene, J. Gross, S. S. Gu, Y. Guo, C. Hallacy, J. Han, J. Harris, Y. He, M. Heaton, J. Heidecke, C. Hesse, A. Hickey, W. Hickey, P. Hoeschele, B. Houghton, K. Hsu, S. Hu, X. Hu, J. Huizinga, S. Jain, S. Jain, J. Jang, A. Jiang, R. Jiang, H. Jin, D. Jin, S. Jomoto, B. Jonn, H. Jun, T. Kaftan, Kaiser, A. Kamali, I. Kanitscheider, N. S. Keskar, T. Khan, L. Kilpatrick, J. W. Kim, C. Kim, Y. Kim, J. H. Kirchner, J. Kiros, M. Knight, D. Kokotajlo, Kondraciuk, A. Kondrich, A. Konstantinidis, K. Kosic, G. Krueger, V. Kuo, M. Lampe, I. Lan, T. Lee, J. Leike, J. Leung, D. Levy, C. M. Li, R. Lim, M. Lin, S. Lin, M. Litwin, T. Lopez, R. Lowe, P. Lue, A. Makanju, K. Malfacini, S. Manning, T. Markov, Y. Markovski, B. Martin, K. Mayer, A. Mayne, B. McGrew, S. M. McKinney, C. McLeavey, P. McMillan, J. McNeil, D. Medina, A. Mehta, J. Menick, L. Metz, A. Mishchenko, P. Mishkin, V. Monaco, E. Morikawa, D. Mossing, T. Mu, M. Murati, O. Murk, D. Mély, A. Nair, R. Nakano, R. Nayak, A. Neelakantan, R. Ngo, H. Noh, L. Ouyang, C. O’Keefe, J. Pachocki, A. Paino, J. Palermo, A. Pantuliano, G. Parascandolo, J. Parish, E. Parparita, A. Passos, M. Pavlov, A. Peng, A. Perelman, F. d. A. B. Peres, M. Petrov, H. P. d. O. Pinto, Michael, Pokorny, M. Pokrass, V. H. Pong, T. Powell, A. Power, B. Power, E. Proehl, R. Puri, A. Radford, J. Rae, A. Ramesh, C. Raymond, F. Real, K. Rimbach, C. Ross, B. Rotsted, H. Roussez, N. Ryder, M. Saltarelli, T. Sanders, S. Santurkar, G. Sastry, H. Schmidt, D. Schnurr, J. Schulman, D. Selsam, K. Sheppard, T. Sherbakov, J. Shieh, S. Shoker, P. Shyam, S. Sidor, E. Sigler, M. Simens, J. Sitkin, K. Slama, I. Sohl, B. Sokolowsky, Y. Song, N. Staudacher, F. P. Such, N. Summers, I. Sutskever, J. Tang, N. Tezak, M. B. Thompson, P. Tillet, A. Tootoonchian, E. Tseng, P. Tuggle, N. Turley, J. Tworek, J. F. C. Uribe, A. Vallone, A. Vijayvergiya, C. Voss, C. Wainwright, J. J. Wang, A. Wang, B. Wang, J. Ward, J. Wei, C. J. Weinmann, A. Welihinda, P. Welinder, J. Weng, L. Weng, M. Wiethoff, D. Willner, C. Winter, S. Wolrich, H. Wong, L. Workman, S. Wu, J. Wu, M. Wu, K. Xiao, T. Xu, S. Yoo, K. Yu, Q. Yuan, W. Zaremba, R. Zellers, C. Zhang, M. Zhang, S. Zhao, T. Zheng, J. Zhuang, W. Zhuk, and B. Zoph, “Gpt-4 technical report,” *arXiv preprint*, no. arXiv:2303.08774, Mar. 2024, arXiv:2303.08774 [cs]. [Online]. Available:

<http://arxiv.org/abs/2303.08774> (Citato a pagina 47)

- [72] Y. Ding, S. Suneja, Y. Zheng, J. Laredo, A. Morari, G. Kaiser, and B. Ray, “Velvet: a novel ensemble learning approach to automatically locate vulnerable statements,” in *2022 IEEE International Conference on Software Analysis, Evolution and Reengineering (SANER)*, 2022, pp. 959–970. (Citato a pagina 47)
- [73] DeepSeek-AI, D. Guo, D. Yang, H. Zhang, J. Song, R. Zhang, R. Xu, Q. Zhu, S. Ma, P. Wang, X. Bi, X. Zhang, X. Yu, Y. Wu, Z. F. Wu, Z. Gou, Z. Shao, Z. Li, Z. Gao, A. Liu, B. Xue, B. Wang, B. Wu, B. Feng, C. Lu, C. Zhao, C. Deng, C. Zhang, C. Ruan, D. Dai, D. Chen, D. Ji, E. Li, F. Lin, F. Dai, F. Luo, G. Hao, G. Chen, G. Li, H. Zhang, H. Bao, H. Xu, H. Wang, H. Ding, H. Xin, H. Gao, H. Qu, H. Li, J. Guo, J. Li, J. Wang, J. Chen, J. Yuan, J. Qiu, J. Li, J. L. Cai, J. Ni, J. Liang, J. Chen, K. Dong, K. Hu, K. Gao, K. Guan, K. Huang, K. Yu, L. Wang, L. Zhang, L. Zhao, L. Wang, L. Zhang, L. Xu, L. Xia, M. Zhang, M. Zhang, M. Tang, M. Li, M. Wang, M. Li, N. Tian, P. Huang, P. Zhang, Q. Wang, Q. Chen, Q. Du, R. Ge, R. Zhang, R. Pan, R. Wang, R. J. Chen, R. L. Jin, R. Chen, S. Lu, S. Zhou, S. Chen, S. Ye, S. Wang, S. Yu, S. Zhou, S. Pan, S. S. Li, S. Zhou, S. Wu, S. Ye, T. Yun, T. Pei, T. Sun, T. Wang, W. Zeng, W. Zhao, W. Liu, W. Liang, W. Gao, W. Yu, W. Zhang, W. L. Xiao, W. An, X. Liu, X. Wang, X. Chen, X. Nie, X. Cheng, X. Liu, X. Xie, X. Liu, X. Yang, X. Li, X. Su, X. Lin, X. Q. Li, X. Jin, X. Shen, X. Chen, X. Sun, X. Wang, X. Song, X. Zhou, X. Wang, X. Shan, Y. K. Li, Y. Q. Wang, Y. X. Wei, Y. Zhang, Y. Xu, Y. Li, Y. Zhao, Y. Sun, Y. Wang, Y. Yu, Y. Zhang, Y. Shi, Y. Xiong, Y. He, Y. Piao, Y. Wang, Y. Tan, Y. Ma, Y. Liu, Y. Guo, Y. Ou, Y. Wang, Y. Gong, Y. Zou, Y. He, Y. Xiong, Y. Luo, Y. You, Y. Liu, Y. Zhou, Y. X. Zhu, Y. Xu, Y. Huang, Y. Li, Y. Zheng, Y. Zhu, Y. Ma, Y. Tang, Y. Zha, Y. Yan, Z. Z. Ren, Z. Ren, Z. Sha, Z. Fu, Z. Xu, Z. Xie, Z. Zhang, Z. Hao, Z. Ma, Z. Yan, Z. Wu, Z. Gu, Z. Zhu, Z. Liu, Z. Li, Z. Xie, Z. Song, Z. Pan, Z. Huang, Z. Xu, Z. Zhang, and Z. Zhang, “Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning,” *arXiv preprint*, no. arXiv:2501.12948, Jan. 2025, arXiv:2501.12948 [cs]. [Online]. Available: <http://arxiv.org/abs/2501.12948> (Citato a pagina 47)

- [74] H. Touvron, T. Lavril, G. Izacard, X. Martinet, M.-A. Lachaux, T. Lacroix, B. Rozière, N. Goyal, E. Hambro, F. Azhar, A. Rodriguez, A. Joulin, E. Grave, and G. Lample, "Llama: Open and efficient foundation language models," *arXiv preprint*, no. arXiv:2302.13971, Feb. 2023, arXiv:2302.13971 [cs]. [Online]. Available: <http://arxiv.org/abs/2302.13971> (Citato a pagina 48)
- [75] J. Lee, W. Yoon, S. Kim, D. Kim, S. Kim, C. H. So, and J. Kang, "BioBERT: a pre-trained biomedical language representation model for biomedical text mining," *CoRR*, vol. abs/1901.08746, 2019. [Online]. Available: <http://arxiv.org/abs/1901.08746> (Citato a pagina 48)
- [76] M. Abdin, J. Aneja, H. Awadalla, A. Awadallah, A. A. Awan, N. Bach, A. Bahree, A. Bakhtiari, J. Bao, H. Behl, A. Benhaim, M. Bilenko, J. Bjorck, S. Bubeck, M. Cai, Q. Cai, V. Chaudhary, D. Chen, D. Chen, W. Chen, Y.-C. Chen, Y.-L. Chen, H. Cheng, P. Chopra, X. Dai, M. Dixon, R. Eldan, V. Fragoso, J. Gao, M. Gao, M. Gao, A. Garg, A. D. Giorno, A. Goswami, S. Gunasekar, E. Haider, J. Hao, R. J. Hewett, W. Hu, J. Huynh, D. Iter, S. A. Jacobs, M. Javaheripi, X. Jin, N. Karampatziakis, P. Kauffmann, M. Khademi, D. Kim, Y. J. Kim, L. Kurilenko, J. R. Lee, Y. T. Lee, Y. Li, Y. Li, C. Liang, L. Liden, X. Lin, Z. Lin, C. Liu, L. Liu, M. Liu, W. Liu, X. Liu, C. Luo, P. Madan, A. Mahmoudzadeh, D. Majercak, M. Mazzola, C. C. T. Mendes, A. Mitra, H. Modi, A. Nguyen, B. Norick, B. Patra, D. Perez-Becker, T. Portet, R. Pryzant, H. Qin, M. Radmilac, L. Ren, G. d. Rosa, C. Rosset, S. Roy, O. Ruwase, O. Saarikivi, A. Saied, A. Salim, M. Santacroce, S. Shah, N. Shang, H. Sharma, Y. Shen, S. Shukla, X. Song, M. Tanaka, A. Tupini, P. Vaddamanu, C. Wang, G. Wang, L. Wang, S. Wang, X. Wang, Y. Wang, R. Ward, W. Wen, P. Witte, H. Wu, X. Wu, M. Wyatt, B. Xiao, C. Xu, J. Xu, W. Xu, J. Xue, S. Yadav, F. Yang, J. Yang, Y. Yang, Z. Yang, D. Yu, L. Yuan, C. Zhang, C. Zhang, J. Zhang, L. L. Zhang, Y. Zhang, Y. Zhang, Y. Zhang, and X. Zhou, "Phi-3 technical report: A highly capable language model locally on your phone," *arXiv preprint*, no. arXiv:2404.14219, Aug. 2024, arXiv:2404.14219 [cs]. [Online]. Available: <http://arxiv.org/abs/2404.14219> (Citato a pagina 49)

- [77] —, “Phi-3 technical report: A highly capable language model locally on your phone,” *arXiv preprint*, no. arXiv:2404.14219, Aug. 2024, arXiv:2404.14219 [cs]. [Online]. Available: <http://arxiv.org/abs/2404.14219> (Citato a pagina 49)
- [78] J.-G. Lee, S. Jun, Y.-W. Cho, H. Lee, G. B. Kim, J. B. Seo, and N. Kim, “Deep learning in medical imaging: General overview,” *Korean Journal of Radiology*, vol. 18, no. 4, p. 570, 2017. (Citato a pagina 49)
- [79] T.-Y. Lin, M. Maire, S. Belongie, J. Hays, P. Perona, D. Ramanan, P. Dollár, and C. L. Zitnick, “Microsoft coco: Common objects in context,” in *Computer Vision – ECCV 2014*, D. Fleet, T. Pajdla, B. Schiele, and T. Tuytelaars, Eds. Cham: Springer International Publishing, 2014, p. 740–755. (Citato a pagina 49)
- [80] M. B. A. McDermott, T. H. Hsu, W. Weng, M. Ghassemi, and P. Szolovits, “Chexpert++: Approximating the chexpert labeler for speed, differentiability, and probabilistic output,” *CoRR*, vol. abs/2006.15229, 2020. [Online]. Available: <https://arxiv.org/abs/2006.15229> (Citato a pagina 49)
- [81] L. Bogoni, J. Ko, J. Alpert, V. Anand, J. Fantauzzi, C. Florin, C. Koo, D. Mason, W. Rom, M. Shiau, M. Salganicoff, and D. Naidich, “Impact of a computer-aided detection (cad) system integrated into a picture archiving and communication system (pacs) on reader sensitivity and efficiency for the detection of lung nodules in thoracic ct exams,” *Journal of Digital Imaging*, vol. 25, no. 6, pp. 771–781, Dec. 2012, funding Information: This study was supported by the National Institute of Health/National Cancer Institute-UO-1, CA, 86137 and NYU Biomarker, Clinical and Epidemiologic Center—Early Detection Research Network. (Citato a pagina 50)
- [82] C. Jayadev and R. Shetty, “Artificial intelligence in laser refractive surgery – potential and promise!” *Indian Journal of Ophthalmology*, vol. 68, p. 2650, 12 2020. (Citato a pagina 50)
- [83] Useye, “Lasik in the digital age: Technology revolutionizing vision,” Dec 2024, [Accessed 25-02-2025]. [Online]. Available: <https://centerforsightswfl>.

- com/lasik-in-the-digital-age-technology-revolutionizing-vision/ (Citato a pagina 50)
- [84] M. Nulqiman, M. Xu, Y. Sun, J. Cao, P. Chen, Q. Gao, P. Xu, and J. Ye, "Artificial intelligence in ophthalmic surgery: Current applications and expectations," *Clinical Ophthalmology*, vol. 17, pp. 3499–3511, 11 2023. (Citato a pagina 50)
- [85] B. Garcia Santa Cruz, M. N. Bossa, J. Sölter, and A. D. Husch, "Public covid-19 x-ray datasets and their impact on model bias – a systematic review of a significant problem," *Medical Image Analysis*, vol. 74, p. 102225, Dec. 2021. (Citato a pagina 50)
- [86] S. Bazdar, A. K. A. L. Kwee, L. Houweling, Y. de Wit-van Wijck, F. A. A. Mohamed Hoesein, G. S. Downward, E. J. Nossent, and A. H. Maitland-van der Zee, "A systematic review of chest imaging findings in long covid patients," *Journal of Personalized Medicine*, vol. 13, no. 2, p. 282, Feb. 2023. (Citato a pagina 50)
- [87] J. R. Parikh, D. Wolfman, C. E. Bender, and E. Arleo, "Radiologist burnout according to surveyed radiology practice leaders," *Journal of the American College of Radiology*, vol. 17, no. 1, pp. 78–81, 2020. (Citato a pagina 50)
- [88] A. B. Rosenkrantz, D. R. Hughes, and R. Duszak Jr, "The us radiologist workforce: an analysis of temporal and geographic variation by using large national datasets," *Radiology*, vol. 279, no. 1, pp. 175–184, 2016. (Citato a pagina 50)
- [89] F. S. Ali, S. G. Harrington, S. B. Kennedy, and S. Hussain, "Diagnostic radiology in liberia: a country report," *Journal of Global Radiology*, vol. 1, no. 2, 2015. (Citato a pagina 50)
- [90] H. K. Ahmad, M. R. Milne, Q. D. Buchlak, N. Ektas, G. Sanderson, H. Chamtie, S. Karunasena, J. Chiang, X. Holt, C. H. M. Tang, J. C. Y. Seah, G. Bottrell, N. Esmaili, P. Brotchie, and C. Jones, "Machine learning augmented interpretation of chest x-rays: A systematic review," *Diagnostics*, vol. 13, no. 4, p. 743, Feb. 2023. (Citato a pagina 50)

- [91] P. T. M. R. B. S. . H. S. Johnson, A., "Mimic-cxr database (version 2.1.0)," 2024. (Citato a pagina 51)
- [92] X. Wang, Y. Peng, L. Lu, Z. Lu, M. Bagheri, and R. Summers, "Chestx-ray14: Hospital-scale chest x-ray database and benchmarks on weakly-supervised classification and localization of common thorax diseases," 09 2017. (Citato a pagina 51)
- [93] J. Irvin, P. Rajpurkar, M. Ko, Y. Yu, S. Ciurea-Ilcus, C. Chute, H. Marklund, B. Haghighi, R. L. Ball, K. S. Shpanskaya, J. Seekins, D. A. Mong, S. S. Halabi, J. K. Sandberg, R. Jones, D. B. Larson, C. P. Langlotz, B. N. Patel, M. P. Lungren, and A. Y. Ng, "Chexpert: A large chest radiograph dataset with uncertainty labels and expert comparison," *CoRR*, vol. abs/1901.07031, 2019. [Online]. Available: <http://arxiv.org/abs/1901.07031> (Citato a pagina 51)
- [94] G. Huang, Z. Liu, and K. Q. Weinberger, "Densely connected convolutional networks," *CoRR*, vol. abs/1608.06993, 2016. [Online]. Available: <http://arxiv.org/abs/1608.06993> (Citato a pagina 51)
- [95] Y. G. Gordienko, P. Gang, J. Hui, W. Zeng, Y. Kochura, O. Alienin, O. Rokovyi, and S. G. Stirenko, "Deep learning with lung segmentation and bone shadow exclusion techniques for chest x-ray analysis of lung cancer," *CoRR*, vol. abs/1712.07632, 2017. [Online]. Available: <http://arxiv.org/abs/1712.07632> (Citato a pagina 51)
- [96] J. Huang, L. Neill, M. Wittbrodt, D. Melnick, M. Klug, M. Thompson, J. Bailitz, T. Loftus, S. Malik, A. Phull, V. Weston, J. A. Heller, and M. Etemadi, "Generative artificial intelligence for chest radiograph interpretation in the emergency department," *JAMA Network Open*, vol. 6, no. 10, pp. e2336100–e2336100, 10 2023. [Online]. Available: <https://doi.org/10.1001/jamanetworkopen.2023.36100> (Citato a pagina 51)
- [97] L. L. Plesner, F. C. Müller, J. D. Nybing, L. C. Laustrop, F. Rasmussen, O. W. Nielsen, M. Boesen, and M. B. Andersen, "Autonomous chest radiograph reporting using ai: Estimation of clinical impact," *Radiology*,

- vol. 307, no. 3, p. e222268, 2023, pMID: 36880947. [Online]. Available: <https://doi.org/10.1148/radiol.222268> (Citato a pagina 51)
- [98] R. F. Wolff, K. G. Moons, R. D. Riley, P. F. Whiting, M. Westwood, G. S. Collins, J. B. Reitsma, J. Kleijnen, S. Mallett, and P. Group†, “Probast: a tool to assess the risk of bias and applicability of prediction model studies,” *Annals of internal medicine*, vol. 170, no. 1, pp. 51–58, 2019. (Citato a pagina 52)
- [99] J. T. Wu, K. C. L. Wong, Y. Gur, N. Ansari, A. Karargyris, A. Sharma, M. Morris, B. Saboury, H. Ahmad, O. Boyko, A. Syed, A. Jadhav, H. Wang, A. Pillai, S. Kashyap, M. Moradi, and T. Syeda-Mahmood, “Comparison of chest radiograph interpretations by artificial intelligence algorithm vs radiology residents,” *JAMA Network Open*, vol. 3, no. 10, pp. e2 022 779–e2 022 779, 10 2020. [Online]. Available: <https://doi.org/10.1001/jamanetworkopen.2020.22779> (Citato a pagina 52)
- [100] F. Yu and V. Koltun, “Multi-scale context aggregation by dilated convolutions,” *arXiv preprint*, no. arXiv:1511.07122, Apr. 2016, arXiv:1511.07122 [cs]. [Online]. Available: <http://arxiv.org/abs/1511.07122> (Citato a pagina 52)
- [101] J.-B. Alayrac, J. Donahue, P. Luc, A. Miech, I. Barr, Y. Hasson, K. Lenc, A. Mensch, K. Millican, M. Reynolds, R. Ring, E. Rutherford, S. Cabi, T. Han, Z. Gong, S. Samangooei, M. Monteiro, J. L. Menick, S. Borgeaud, A. Brock, A. Nematzadeh, S. Sharifzadeh, M. Bińkowski, R. Barreira, O. Vinyals, A. Zisserman, and K. Simonyan, “Flamingo: a visual language model for few-shot learning,” *Advances in Neural Information Processing Systems*, vol. 35, p. 23716–23736, Dec. 2022. (Citato a pagina 53)
- [102] A. Brock, S. De, S. L. Smith, and K. Simonyan, “High-performance large-scale image recognition without normalization,” *CoRR*, vol. abs/2102.06171, 2021. [Online]. Available: <https://arxiv.org/abs/2102.06171> (Citato a pagina 53)
- [103] R. Tanno, D. G. T. Barrett, A. Sellaergren, S. Ghaisas, S. Dathathri, A. See, J. Welbl, C. Lau, T. Tu, S. Azizi, K. Singhal, M. Schaeckermann, R. May, R. Lee, S. Man, S. Mahdavi, Z. Ahmed, Y. Matias, J. Barral, S. M. A. Eslami, D. Belgrave, Y. Liu,

- S. R. Kalidindi, S. Shetty, V. Natarajan, P. Kohli, P.-S. Huang, A. Karthikesalingam, and I. Ktena, "Collaboration between clinicians and vision–language models in radiology report generation," *Nature Medicine*, vol. 31, no. 2, p. 599–608, Feb. 2025. (Citato a pagina 54)
- [104] Z. Nabulsi, A. Sellergren, S. Jamsky, C. Lau, E. Santos, A. P. Kiraly, W. Ye, J. Yang, R. Pilgrim, S. Kazemzadeh, J. Yu, S. R. Kalidindi, M. Etemadi, F. Garcia-Vicente, D. Melnick, G. S. Corrado, L. Peng, K. Eswaran, D. Tse, N. Beladia, Y. Liu, P.-H. C. Chen, and S. Shetty, "Deep learning for distinguishing normal versus abnormal chest radiographs and generalization to two unseen diseases tuberculosis and covid-19," *Scientific Reports*, vol. 11, no. 1, p. 15523, Sep. 2021. (Citato a pagina 55)
- [105] T. B. Brown, B. Mann, N. Ryder, M. Subbiah, J. Kaplan, P. Dhariwal, A. Neelakantan, P. Shyam, G. Sastry, A. Askell, S. Agarwal, A. Herbert-Voss, G. Krueger, T. Henighan, R. Child, A. Ramesh, D. M. Ziegler, J. Wu, C. Winter, C. Hesse, M. Chen, E. Sigler, M. Litwin, S. Gray, B. Chess, J. Clark, C. Berner, S. McCandlish, A. Radford, I. Sutskever, and D. Amodei, "Language models are few-shot learners," *CoRR*, vol. abs/2005.14165, 2020. [Online]. Available: <https://arxiv.org/abs/2005.14165> (Citato a pagina 55)
- [106] F. Pérez-García, H. Sharma, S. Bond-Taylor, K. Bouzid, V. Salvatelli, M. Ilse, S. Bannur, D. C. Castro, A. Schwaighofer, M. P. Lungren, M. T. Wetscherek, N. Codella, S. L. Hyland, J. Alvarez-Valle, and O. Oktay, "Exploring scalable medical image encoders beyond text supervision," *Nature Machine Intelligence*, Jan. 2025. [Online]. Available: <https://doi.org/10.1038/s42256-024-00965-w> (Citato a pagina 56)
- [107] M. Ghassemi, L. Oakden-Rayner, and A. L. Beam, "The false hope of current approaches to explainable artificial intelligence in health care," *The Lancet Digital Health*, vol. 3, no. 11, p. e745–e750, Nov. 2021. (Citato a pagina 59)
- [108] W. Saeed and C. Omlin, "Explainable ai (xai): A systematic meta-survey of current challenges and future opportunities," *Knowledge-Based Systems*, vol.

- 263, p. 110273, 2023. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0950705123000230> (Citato a pagina 59)
- [109] E. Tjoa, H. J. Khok, T. Chouhan, and C. Guan, “Enhancing the confidence of deep learning classifiers via interpretable saliency maps,” *Neurocomputing*, vol. 562, p. 126825, 2023. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0925231223009487> (Citato a pagina 59)
- [110] A. Shrikumar, P. Greenside, and A. Kundaje, “Learning important features through propagating activation differences,” in *Proceedings of the 34th International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research, D. Precup and Y. W. Teh, Eds., vol. 70. PMLR, 06–11 Aug 2017, pp. 3145–3153. [Online]. Available: <https://proceedings.mlr.press/v70/shrikumar17a.html> (Citato a pagina 59)
- [111] J. Jumper, R. Evans, A. Pritzel, T. Green, M. Figurnov, O. Ronneberger, K. Tunyasuvunakool, R. Bates, A. Žídek, A. Potapenko, A. Bridgland, C. Meyer, S. A. A. Kohl, A. J. Ballard, A. Cowie, B. Romera-Paredes, S. Nikolov, R. Jain, J. Adler, T. Back, S. Petersen, D. Reiman, E. Clancy, M. Zielinski, M. Steinegger, M. Pacholska, T. Berghammer, S. Bodenstein, D. Silver, O. Vinyals, A. W. Senior, K. Kavukcuoglu, P. Kohli, and D. Hassabis, “Highly accurate protein structure prediction with AlphaFold,” vol. 596, pp. 583–589, Aug. 2021. (Citato a pagina 62)
- [112] A. Paszke, S. Gross, S. Chintala, G. Chanan, E. Yang, Z. DeVito, Z. Lin, A. Desmaison, L. Antiga, and A. Lerer, “Automatic differentiation in pytorch,” 2017. (Citato a pagina 63)
- [113] R. Wightman, “Pytorch image models,” <https://github.com/rwightman/pytorch-image-models>, 2019. (Citato a pagina 63)
- [114] N. Kokhlikyan, V. Miglani, M. Martin, E. Wang, B. Alsallakh, J. Reynolds, A. Melnikov, N. Kliushkina, C. Araya, S. Yan, and O. Reblitz-Richardson,

- “Captum: A unified and generic model interpretability library for pytorch,” 2020. (Citato a pagina 63)
- [115] D. P. E. R. E. Riba, D. Mishkin and G. Bradski, “Kornia: an open source differentiable computer vision library for pytorch,” in *Winter Conference on Applications of Computer Vision*, 2020. [Online]. Available: <https://arxiv.org/pdf/1910.02190.pdf> (Citato a pagina 63)
- [116] W. Huda and R. B. Abrahams, “X-ray-based medical imaging and resolution,” vol. 204, no. 4, pp. 393–397, Apr. 2015. (Citato a pagina 68)
- [117] M. I. U. Haque, A. K. Dubey, I. Danciu, A. C. Justice, O. S. Ovchinnikova, and J. D. Hinkle, “Effect of image resolution on automated classification of chest X-rays,” vol. 10, no. 4, p. 044503., Jul. 2023. (Citato a pagina 68)
- [118] M. Neumann, D. King, I. Beltagy, and W. Ammar, “ScispaCy: Fast and Robust Models for Biomedical Natural Language Processing,” in *Proceedings of the 18th BioNLP Workshop and Shared Task*. Florence, Italy: Association for Computational Linguistics, Aug. 2019, pp. 319–327. [Online]. Available: <https://www.aclweb.org/anthology/W19-5034> (Citato a pagina 70)
- [119] J. Pizarro, L. Reteig, F. Puschner, and L. Murray, “jenojp/negspacy: Spacy 3.3 support,” 2025. (Citato a pagina 70)
- [120] E. Tiu, E. Talius, P. Patel, C. P. Langlotz, A. Y. Ng, and P. Rajpurkar, “Expert-level detection of pathologies from unannotated chest X-ray images via self-supervised learning,” vol. 6, pp. 1399–1406, Dec. 2022. (Citato a pagina 95)
- [121] H. Q. Nguyen, K. Lam, L. T. Le, H. H. Pham, D. Q. Tran, D. B. Nguyen, D. D. Le, C. M. Pham, H. T. T. Tong, D. H. Dinh, C. D. Do, L. T. Doan, C. N. Nguyen, B. T. Nguyen, Q. V. Nguyen, A. D. Hoang, H. N. Phan, A. T. Nguyen, P. H. Ho, D. T. Ngo, N. T. Nguyen, N. T. Nguyen, M. Dao, and V. Vu, “Vindr-cxr: An open dataset of chest x-rays with radiologist’s annotations,” 2020. (Citato a pagina 98)