



UNIVERSITÀ DEGLI STUDI DI SALERNO

Dipartimento di Informatica

Corso di Laurea Triennale in Informatica

TESI DI LAUREA

**Dinamiche sociali nei team
multidisciplinari nello sviluppo di
sistemi software basati su Machine
Learning.**

RELATORE

Prof. Fabio Palomba

Università degli Studi di Salerno

CANDIDATO

Gaetano Vito Faraco

Matricola: 0512114147

Anno Accademico 2024-2025

Questa tesi è stata realizzata nel

sesa^{lab}
SOFTWARE ENGINEERING
SALERNO

Abstract

Lo sviluppo di sistemi software che integrano componenti basate su tecniche di Machine Learning richiede la collaborazione di team multidisciplinari composti da sviluppatori, data scientist, esperti di dominio e stakeholder. In questo contesto emergono numerosi problemi sociali e organizzativi, legati principalmente a barriere comunicative, differenze culturali e difficoltà di allineamento degli obiettivi. Inoltre, l'opacità dei modelli ML genera conflitti decisionali, mentre le preoccupazioni etiche e di fairness condizionano la progettazione e l'accettazione delle soluzioni. Nonostante la crescente attenzione della letteratura, gli studi attuali risultano frammentati e mancano linee guida operative in grado di supportare concretamente i team di sviluppo. Durante il mio lavoro di tesi ho analizzato la letteratura esistente con l'obiettivo di mappare le principali dinamiche sociali nei team ML-intensive e di individuare strategie per ridurre i cosiddetti community smells, ossia schemi ricorrenti di interazioni socio-tecniche subottimali. I risultati mettono in evidenza i pattern più frequenti e suggeriscono pratiche di mitigazione quali team cross-funzionali, strumenti di comunicazione più efficaci, approcci di trasparenza decisionale e audit etici. In conclusione, questa ricerca propone raccomandazioni utili a migliorare la collaborazione e la coesione nei team multidisciplinari, contribuendo a colmare le lacune dello stato dell'arte e offrendo una base per linee guida applicabili anche in contesti industriali.

Indice

Elenco delle Figure	iii
Elenco delle Tabelle	iv
1 Introduzione	1
1.1 Contesto applicativo	1
1.2 Motivazioni e Obiettivi	2
1.3 Risultati ottenuti	2
1.4 Struttura della tesi	3
2 Background e Stato dell'Arte	4
2.1 Sfide collaborative e organizzative	4
2.2 Sfide tecniche	5
2.3 Sfide etiche e di fairness	6
2.4 Approccio integrato	7
2.5 Considerazioni conclusive sullo Stato dell'Arte	7
3 Metodo di Ricerca	8
3.1 Motivazioni e obiettivi	8
3.2 Approccio metodologico	9
3.3 Processo di ricerca	11

3.4	Criteri di selezione	12
3.4.1	Processo di selezione e filtraggio delle fonti	13
3.5	Tecniche di analisi	14
3.6	Output atteso della metodologia	15
4	Analisi dei Risultati	16
4.1	Introduzione	16
4.2	RQ1 - Sfide collaborative e organizzative	16
4.3	RQ2 - Incertezza e opacità dei modelli	18
4.4	RQ3 - Considerazioni etiche e fairness	19
4.5	RQ4 - Pratiche, strategie e strumenti a supporto dei team	20
4.6	Sintesi comparativa dei risultati	22
4.6.1	Differenze tra letteratura accademica e grey literature	23
4.7	Verifica del raggiungimento degli obiettivi	23
5	Conclusioni	24
	Bibliografia	26

Elenco delle figure

3.6	Output atteso della metodologia	15
4.6	Relazione tra sfide e strategie di mitigazione	22

Elenco delle tabelle

3.3	Fasi e descrizione del processo di revisione della letteratura.	11
4.2	Sintesi delle sfide collaborative e organizzative	17
4.3	Strategie di mitigazione delle problematiche etiche nei sistemi ML . .	19
4.4	Strategie di mitigazione delle sfide etiche	20
4.5	Pratiche e strumenti a supporto dei team ML-intensive	21

CAPITOLO 1

Introduzione

1.1 Contesto applicativo

Lo sviluppo software è da sempre un'attività complessa che combina aspetti tecnici e sociali. Con l'introduzione del Machine Learning (ML) nei sistemi software, questa complessità è aumentata, richiedendo la collaborazione di team multidisciplinari composti da sviluppatori, data scientist, esperti di dominio e stakeholder. La natura di tali sistemi porta con sé sfide peculiari: modelli spesso opachi e difficili da interpretare, processi di aggiornamento continui legati ai dati, e una crescente attenzione verso aspetti etici e di fairness. In questi contesti emergono problemi di natura socio-tecnica, come barriere comunicative tra profili professionali differenti, differenze culturali, disallineamenti sugli obiettivi di progetto e resistenze nell'adozione di pratiche innovative. La letteratura ha iniziato a esplorare questi temi, introducendo concetti come *community smells*, ossia schemi ricorrenti di interazioni problematiche che possono compromettere la collaborazione e ridurre l'efficacia dei team. Tuttavia, le ricerche attuali risultano frammentate e mancano di una visione sistematica in grado di fornire linee guida applicabili nei contesti reali.

1.2 Motivazioni e Obiettivi

Le motivazioni di questo lavoro risiedono nella necessità di comprendere in modo approfondito i problemi sociali che ostacolano la collaborazione nei team impegnati nello sviluppo di sistemi ML-intensive. La mancanza di strumenti e raccomandazioni operative espone i progetti al rischio di fallimenti o di scelte progettuali poco trasparenti e difficilmente giustificabili. L'obiettivo principale della tesi è analizzare le dinamiche sociali e organizzative che caratterizzano tali team, con particolare attenzione a:

- barriere comunicative e i conflitti decisionali derivanti dall'opacità dei modelli ML;
- l'impatto delle preoccupazioni etiche e di fairness sui processi decisionali;
- le sfide nella gestione del cambiamento introdotte da nuove pratiche come MLOps e audit etici.

Il fine ultimo è elaborare raccomandazioni e linee guida che possano migliorare la collaborazione e la coesione, contribuendo a una più efficace integrazione del ML nei processi di sviluppo software.

1.3 Risultati ottenuti

L'analisi della letteratura ha permesso di individuare i principali community smells e anti-pattern socio-tecnici ricorrenti nei progetti ML. Tra questi, spiccano i problemi legati ai silos organizzativi, alla mancanza di chiarezza nei ruoli e alla difficoltà di giustificare decisioni basate su modelli opachi. Dallo studio emergono strategie di mitigazione che includono la promozione di team cross-funzionali, pratiche di trasparenza decisionale, strumenti per il monitoraggio della fairness e processi collaborativi per la gestione del cambiamento. I risultati ottenuti costituiscono un quadro organico che integra le evidenze disponibili e fornisce indicazioni pratiche per i team industriali.

1.4 Struttura della tesi

Nel capitolo 2 viene introdotta una rassegna della letteratura esistente, utile a delineare lo stato dell'arte sui problemi sociali e organizzativi che caratterizzano i team impegnati nello sviluppo di sistemi software basati su Machine Learning. Successivamente, viene presentata la metodologia di ricerca adottata per l'analisi, con particolare attenzione ai criteri di selezione degli studi e agli strumenti utilizzati per interpretarne i risultati. All'interno del capitolo 3 viene presentata la metodologia di ricerca adottata per l'analisi, con particolare attenzione ai criteri di selezione degli studi e agli strumenti utilizzati per interpretarne i risultati. Il cuore della tesi è rappresentato dal capitolo 4, che è dedicato alla discussione delle principali evidenze emerse, dove vengono analizzati i community smells più ricorrenti, le loro cause e i loro effetti sulle dinamiche collaborative. A partire da queste osservazioni, il lavoro propone strategie e raccomandazioni per favorire una migliore coesione nei team multidisciplinari. Infine, nel capitolo 5 sono descritte le conclusioni e possibili sviluppi futuri legati a questo studio.

Background e Stato dell'Arte

2.1 Sfide collaborative e organizzative

Lo sviluppo di sistemi software che integrano componenti di Machine Learning si caratterizza per una forte multidisciplinarietà. A differenza del software tradizionale, questi progetti coinvolgono sviluppatori, data scientist, esperti di dominio e stakeholder di business, ciascuno portatore di conoscenze, metodologie e priorità differenti. Questa eterogeneità, se da un lato rappresenta un punto di forza, dall'altro introduce numerose sfide sul piano sociale e organizzativo [1]. Uno dei problemi più ricorrenti riguarda le barriere comunicative. Diversi studi hanno evidenziato come i team ML-intensive faticino a sviluppare un linguaggio condiviso: i data scientist tendono a ragionare in termini di metriche statistiche e modelli probabilistici, mentre gli sviluppatori prediligono concetti legati all'ingegneria del software, e gli stakeholder si focalizzano sull'impatto di business. La mancanza di shared mental models può portare a incomprensioni, ritardi e conflitti decisionali [2, 3]. Un ulteriore ostacolo è rappresentato dall'ambiguità nei ruoli e nelle responsabilità. In molti contesti non è chiaro chi debba assumersi la responsabilità di definire i requisiti, validare i dataset o giustificare le decisioni prese dai modelli. Questa situazione genera sovrapposizioni di compiti o, al contrario, lacune organizzative che compromettono

la coesione del team [1]. La letteratura segnala anche la diffusione di community smells, ossia schemi ricorrenti di interazioni disfunzionali. Alcuni esempi rilevanti nei progetti ML-intensive sono i silos organizzativi, dove i diversi gruppi lavorano in isolamento riducendo lo scambio di conoscenze, e il lupo solitario, che descrive la tendenza di singoli individui a lavorare in modo indipendente senza coordinarsi con il resto del team [1]. Infine, emerge il rischio di groupthink, descritto dal progetto ML in Practice della Carnegie Mellon University. In team eterogenei, la pressione a mantenere l'armonia può portare a minimizzare i conflitti, trascurare alternative o sottovalutare rischi legati a fairness e sicurezza [4].

2.2 Sfide tecniche

Accanto alle difficoltà organizzative, lo sviluppo di sistemi ML-intensive è caratterizzato da numerose sfide di natura tecnica. Queste derivano dalle differenze rispetto al ciclo di vita del software tradizionale, dall'elevata dipendenza dai dati e dalla necessità di integrare modelli non deterministici in contesti produttivi [5]. Un primo tema riguarda i problemi legati ai dati. Dataset incompleti, rumorosi o non rappresentativi compromettono la qualità dei modelli e rallentano i processi di sviluppo. Inoltre, vincoli legali e organizzativi spesso limitano la disponibilità dei dati, generando conflitti tra chi produce i modelli e chi li detiene. La difficoltà di integrare fonti eterogenee porta a soluzioni frammentarie e a costi elevati di gestione [6]. Un'altra sfida centrale è legata al ciclo di vita del software ML. I requisiti nei progetti ML sono più instabili e meno determinabili a priori, poiché dipendono dalla qualità dei dati. Inoltre, il testing dei modelli si discosta dai paradigmi classici: non è possibile garantire risultati deterministici, e metriche come accuratezza o recall non sempre riescono a catturare l'affidabilità del sistema in contesti reali [5]. Ciò alimenta il technical debt e il data debt, dovuto a dataset mal documentati o difficilmente tracciabili. Negli ultimi anni è emersa l'adozione di MLOps, che mira a portare nel mondo ML i principi del DevOps. Tuttavia, l'adozione è tutt'altro che semplice. Le principali difficoltà riguardano l'integrazione di pipeline stabili in un contesto dove i modelli evolvono rapidamente, la mancanza di standard, e la resistenza culturale all'introduzione di nuove pratiche collaborative [7].

2.3 Sfide etiche e di fairness

Oltre agli aspetti organizzativi e tecnici, i sistemi ML sollevano numerose questioni di natura etica. L'adozione di modelli opachi, la dipendenza dai dati e l'impatto diretto sulle decisioni che riguardano persone e organizzazioni rendono inevitabile affrontare i temi di bias, fairness e responsabilità sociale [8]. Il bias algoritmico può manifestarsi a diversi livelli: nei dati, quando i dataset sono non rappresentativi; nei modelli, quando gli algoritmi amplificano distorsioni già presenti; e nell'uso, quando le decisioni degli stakeholder si basano su interpretazioni scorrette dei risultati. Gli effetti concreti includono discriminazioni nei processi di selezione del personale, nell'accesso al credito e nei sistemi di sorveglianza [8]. La gestione della fairness non è soltanto un problema tecnico, ma anche organizzativo. Madaio et al. hanno mostrato come i practitioner abbiano una comprensione frammentaria del concetto: i data scientist lo riducono a metriche di performance, mentre gli stakeholder lo collegano all'impatto sociale delle decisioni [9]. Tra le strategie emergono l'uso parallelo di metriche diverse, la documentazione trasparente dei dataset e il coinvolgimento di audit indipendenti, sebbene la loro adozione resti limitata [9]. Un ulteriore livello di complessità riguarda le implicazioni etiche più ampie dell'IA. Bostrom e Yudkowsky richiamano l'attenzione non solo sui rischi di discriminazione, ma anche su questioni di lungo termine, come i danni esistenziali legati a sistemi superintelligenti [10]. Sebbene possano sembrare distanti dalla pratica quotidiana, queste riflessioni offrono un quadro utile per comprendere la responsabilità intrinseca nello sviluppo di sistemi ML.

2.4 Approccio integrato

In sostanza, le sfide nello sviluppo di sistemi ML-intensive si articolano su tre livelli:

- Collaborative e organizzative, con barriere comunicative, ruoli ambigui e community smells [1, 2, 3];
- Tecniche, legate alla gestione dei dati, all’instabilità dei requisiti e alla difficoltà di testing [5, 6, 7];
- Etiche, che riguardano bias, fairness e responsabilità sociale [10, 9, 8].

Questi aspetti sono strettamente interconnessi: barriere collaborative aggravano i problemi tecnici, lacune tecniche amplificano i rischi etici, e scelte poco trasparenti erodono la fiducia nel team e negli stakeholder. Affrontare tali sfide richiede quindi un approccio integrato che coniughi aspetti tecnici, organizzativi ed etici.

2.5 Considerazioni conclusive sullo Stato dell’Arte

L’analisi della letteratura ha messo in evidenza come le sfide nei team ML-intensive siano affrontate in modo frammentato, spesso limitato a specifiche prospettive (organizzativa, tecnica o etica). Gli studi accademici si concentrano prevalentemente su modelli concettuali e framework teorici, mentre la letteratura industriale propone soluzioni operative ma raramente supportate da evidenze sistematiche. Tale frammentazione indica una mancanza di lavori che integrino i contributi accademici e la grey literature per fornire una visione organica delle problematiche socio-tecniche e delle relative strategie di mitigazione. Da questa lacuna nasce la motivazione del presente lavoro di tesi, che si propone di ricomporre in modo sistematico le evidenze provenienti da fonti scientifiche e professionali, con l’obiettivo di identificare convergenze, differenze e raccomandazioni pratiche per il miglioramento della collaborazione nei team ML-intensive.

Metodo di Ricerca

3.1 Motivazioni e obiettivi

Questo lavoro parte dalla definizione delle domande di ricerca (Research Questions, RQ), che guidano l'intera indagine metodologica e rappresentano i criteri fondamentali per valutare il raggiungimento degli obiettivi della tesi. Esse sono state formulate a partire dalle lacune emerse nello Stato dell'Arte (Cap. 2) e mirano a indagare in profondità le sfide socio-tecniche che caratterizzano i team multidisciplinari impegnati nello sviluppo di sistemi software ML-intensive. Le domande di ricerca sono:

- RQ1. Quali sono le principali sfide collaborative e organizzative che emergono nei team multidisciplinari durante lo sviluppo di sistemi ML-intensive? Questa domanda mira a identificare e classificare le barriere comunicative, l'ambiguità dei ruoli e le dinamiche disfunzionali (es. community smells) che ostacolano la collaborazione tra sviluppatori, data scientist, esperti di dominio e stakeholder.
- RQ2. In che modo l'incertezza e l'opacità dei modelli di Machine Learning influenzano i processi decisionali nei team di sviluppo? L'obiettivo è comprendere come la natura non deterministica e spesso non interpretabile dei modelli

ML influenzi le scelte progettuali, generando problemi tra le diverse figure professionali coinvolte.

- RQ3. Qual è l’impatto delle considerazioni etiche e di fairness sulla progettazione, la valutazione e l’adozione dei sistemi ML? Questa domanda esplora il ruolo delle preoccupazioni etiche, dei rischi di bias e delle strategie di mitigazione nei processi di lavoro, evidenziando come tali aspetti incidano sulla fiducia, sull’accettazione e sulla responsabilità condivisa.
- RQ4. Quali pratiche, strategie o strumenti possono supportare i team nello sviluppo di sistemi ML-intensive, migliorando la collaborazione e la coesione organizzativa? L’intento è raccogliere e analizzare le soluzioni emergenti (ad esempio pratiche di MLOps, audit etici, strumenti di documentazione e comunicazione) per delineare linee guida utili sia a livello operativo che strategico.

Queste domande costituiscono la bussola dell’intera tesi, poiché permettono di tradurre le sfide individuate nello stato dell’arte in obiettivi concreti di analisi e di elaborare, a valle, raccomandazioni pratiche rivolte ai team che operano nello sviluppo di sistemi ML-intensive.

3.2 Approccio metodologico

Per rispondere alle domande di ricerca poste in precedenza, il lavoro adotta un approccio basato sull’analisi della letteratura scientifica, poichè lo studio delle dinamiche socio-tecniche nei team multidisciplinari che sviluppano sistemi ML-intensive è un campo di ricerca emergente, caratterizzato da contributi eterogenei e ancora privi di una sistematizzazione unitaria. Così facendo, una revisione della letteratura strutturata rappresenta lo strumento più efficace per:

- Raccogliere le conoscenze esistenti in modo organico;
- Evidenziare convergenze e divergenze tra i diversi contributi;
- Individuare lacune che aprono nuove prospettive di ricerca;

- Derivare raccomandazioni pratiche a beneficio dei professionisti del settore.

Il metodo scelto si colloca a metà strada tra una Systematic Literature Review (SLR)[11] e una Multivocal Literature Review (MLR) [12]. Da un lato, segue un protocollo rigoroso per garantire integrità dei risultati (SLR), dall'altro accoglie contributi provenienti anche da fonti non strettamente accademiche, quali report industriali, white paper e documentazione tecnica (MLR). Questa combinazione è stata ritenuta opportuna in quanto consente di:

- Integrare la prospettiva accademica con quella industriale;
- Includere evidenze empiriche derivate da casi reali;
- Arricchire l'analisi con spunti di natura pratica difficilmente reperibili nella sola letteratura scientifica.

L'approccio metodologico adottato, dunque, non si limita a una mera raccolta di articoli, ma si configura come un processo iterativo di selezione, codifica e sintesi delle fonti, finalizzato a costruire una mappa coerente delle sfide e delle strategie relative allo sviluppo di sistemi ML-intensive. Tale processo sarà dettagliato nella sezione successiva, insieme alle fasi operative e agli strumenti utilizzati.

3.3 Processo di ricerca

Il processo di ricerca è stato organizzato in fasi sequenziali e iterative, documentate per garantire tracciabilità e replicabilità. Le principali fasi sono:

- Definizione delle domande di ricerca (RQ), che orientano l'intero studio.
- Identificazione delle fonti, includendo database scientifici e report industriali, con strategie basate su parole chiave mirate.
- Selezione degli articoli tramite criteri di inclusione/esclusione per assicurare coerenza con le RQ.
- Analisi e codifica tematica, che ha permesso di classificare i concetti in categorie (collaborative, tecniche, etiche).
- Sintesi e mappatura, attraverso una mappa concettuale delle sfide, delle cause e delle strategie, collegata alle RQ e utile alla definizione delle linee guida.

Tabella 3.3: Fasi e descrizione del processo di revisione della letteratura.

Fase	Descrizione
Definizione RQ	Le domande di ricerca guidano selezione, analisi e interpretazione delle fonti.
Identificazione delle fonti	Consultazione di database scientifici e fonti industriali tramite query basate su parole chiave.
Selezione articoli	Applicazione dei criteri di inclusione/esclusione per garantire la rilevanza delle fonti.
Analisi e codifica	Codifica tematica delle evidenze emerse dagli articoli selezionati.
Sintesi e mappatura	Organizzazione dei risultati in categorie e costruzione di una mappa concettuale delle sfide.

3.4 Criteri di selezione

Il processo di ricerca precedentemente espresso si è basato su combinazioni di parole chiave e tecnica dello snowballing [13], che ha permesso di identificare fonti aggiuntive partendo dalla bibliografia degli articoli selezionati. Inoltre, la scelta delle tecniche di analisi si ispira alle raccomandazioni di Easterbrook et al. [14] sulla selezione dei metodi empirici in ingegneria del software. Detto ciò, un altro fattore da tenere in considerazione riguarda la definizione dei criteri di inclusione ed esclusione per la selezione di tali fonti. Questa fase è necessaria per garantire che il corpus finale di articoli sia coerente con gli obiettivi della tesi e, al contempo, abbastanza ampio da rappresentare la varietà di approcci e prospettive presenti nello stato dell'arte. I criteri di inclusione sono stati:

- articoli peer-reviewed pubblicati in conferenze o riviste scientifiche;
- pubblicazioni comprese tra il 2015 e il 2025, periodo che coincide con la maggiore diffusione di sistemi ML in ambito industriale;
- contributi scritti in lingua inglese o italiana;
- rilevanza diretta rispetto ad almeno una delle RQ (sfide collaborative, tecniche o etiche).

I criteri di esclusione sono stati:

- contributi duplicati o versioni preliminari di articoli già pubblicati in sedi più prestigiose;
- opinion paper o editoriali privi di dati o evidenze empiriche;
- lavori con focus puramente teorico non legato al contesto dei sistemi ML-intensive;
- articoli non accessibili integralmente o con contenuto insufficiente per l'analisi.

L'applicazione di criteri rigorosi di inclusione ed esclusione è in linea con le linee guida per le revisioni sistematiche in ingegneria del software [11].

3.4.1 Processo di selezione e filtraggio delle fonti

L'applicazione dei criteri di inclusione ed esclusione è stata condotta in modo sistematico, garantendo rigore metodologico e trasparenza nel processo di selezione. La ricerca nei principali database accademici (es. Scopus) ha inizialmente restituito 26 risultati preliminari. Dopo l'analisi di titoli e abstract sono stati esclusi i contributi duplicati o non pertinenti rispetto alle domande di ricerca (RQ), riducendo il corpus a 20 studi. La lettura integrale ha portato all'esclusione di ulteriori lavori privi di evidenze empiriche o con focus esclusivamente tecnico, per un totale di 16 articoli accademici inclusi nella revisione.

Parallelamente, la ricerca nella grey literature (white paper, report industriali, blog tecnici e documentazione aziendale) ha prodotto 8 risultati, dei quali solo 2 sono stati mantenuti in base a criteri di autorevolezza, rilevanza e trasparenza. Poiché tali fonti non sono sottoposte a revisione paritaria, sono stati adottati criteri aggiuntivi di valutazione dell'affidabilità, in linea con le linee guida di Garousi et al. (2019) [12]:

- Autorità della fonte: provenienza da istituzioni riconosciute (università, enti di ricerca, aziende leader);
- Scopo e neutralità: contenuto informativo o educativo, non promozionale;
- Tracciabilità e trasparenza: presenza di autori identificabili, riferimenti e data di pubblicazione;
- Rilevanza tematica: coerenza diretta con almeno una RQ.

In totale, il corpus di analisi comprende 18 documenti, utilizzati per la successiva fase di estrazione e codifica delle evidenze. Questo processo ha garantito un equilibrio tra rigore accademico — assicurato dalla revisione sistematica — e rilevanza pratica, derivante dall'inclusione di contributi provenienti dal contesto industriale.

3.5 Tecniche di analisi

Una volta selezionato il corpus di articoli rilevanti, è stata avviata la fase di analisi qualitativa, con l'obiettivo di estrarre, classificare e sintetizzare le informazioni in relazione alle domande di ricerca definite in precedenza. Il processo di analisi ha seguito un approccio tematico e iterativo, articolato nei seguenti passaggi:

- Lettura approfondita delle fonti. Ogni articolo è stato esaminato integralmente per individuare i concetti chiave legati alle sfide collaborative, tecniche ed etiche nello sviluppo di sistemi ML-intensive.
- Codifica iniziale. Le evidenze emerse sono state annotate e associate a etichette (codici) che ne sintetizzassero il contenuto. Ad esempio: barriere comunicative, instabilità dei requisiti, bias nei dati, adozione di MLOps.
- Costruzione di categorie tematiche. I codici sono stati raggruppati in categorie più ampie, corrispondenti ai tre macro-ambiti individuati nel Capitolo 2.
- Analisi comparativa. Le categorie sono state confrontate tra loro per individuare intersezioni (es. come problemi organizzativi possano amplificare i rischi etici) e divergenze (es. diverse strategie di mitigazione proposte in letteratura).
- Validazione interna. Per ridurre il rischio di interpretazioni arbitrarie, i risultati parziali sono stati confrontati con studi simili già presenti in letteratura, in modo da verificare coerenza e solidità dei pattern individuati.

Grazie a questo approccio, è stato possibile trasformare l'eterogeneità della letteratura in un quadro strutturato e coerente, capace di mettere in luce non solo le sfide più ricorrenti, ma anche le connessioni tra i diversi ambiti e le possibili soluzioni. Tali risultati saranno discussi in dettaglio nel Capitolo 4.

3.6 Output atteso della metodologia

L'approccio metodologico descritto nelle sezioni precedenti è finalizzato a produrre un insieme di risultati che rispondano in modo diretto alle domande di ricerca che ci siamo posti. In particolare, l'analisi della letteratura si propone di generare i seguenti output principali:

- Mappature delle sfide. Un quadro sistematico delle sfide socio-tecniche che emergono nello sviluppo di sistemi ML-intensive, organizzato nelle tre macro-categorie identificate (collaborative/organizzative, tecniche, etiche).
- Individuazione delle cause e delle conseguenze. Una descrizione dei fattori che originano tali sfide (es. barriere comunicative, instabilità dei requisiti, bias nei dati) e delle loro ricadute sui team di sviluppo e sugli stakeholder.
- Raccolta delle strategie di mitigazione. Un repertorio delle pratiche e delle soluzioni già proposte in letteratura e in ambito industriale (es. introduzione di pratiche MLOps, audit etici, strumenti di documentazione collaborativa).
- Sintesi comparativa. Un confronto tra le evidenze emerse, utile a individuare pattern ricorrenti, divergenze metodologiche e aree ancora poco esplorate dalla ricerca.
- Linee guida preliminari. La base concettuale per l'elaborazione, nel Capitolo 4, di raccomandazioni concrete volte a migliorare la collaborazione e la coesione nei team multidisciplinari che sviluppano sistemi ML-intensive.




Figura 3.6: Output atteso della metodologia

CAPITOLO 4

Analisi dei Risultati

4.1 Introduzione

Il presente capitolo riporta i risultati dell'analisi condotta sulla base della metodologia descritta nel Capitolo 3. L'obiettivo è rispondere in modo diretto alle quattro domande di ricerca (RQ) definite nella sezione 3.1, fornendo una visione approfondita delle sfide, delle cause, delle strategie e delle pratiche identificate nei team multidisciplinari impegnati nello sviluppo di sistemi software che integrano componenti di Machine Learning (ML).

4.2 RQ1 - Sfide collaborative e organizzative

RQ₁. Quali sono le principali sfide collaborative e organizzative che emergono nei team multidisciplinari durante lo sviluppo di sistemi ML-intensive?

L'analisi della letteratura mostra che i progetti ML-intensive sono fortemente condizionati da barriere comunicative, ruoli ambigui e disallineamenti organizzativi. Busquim et al. [1] e Arpteg et al. [5] evidenziano che tali problemi derivano principalmente da differenze epistemologiche tra sviluppatori software, data scientist e stakeholder di dominio.

Ad esempio, i data scientist tendono a concentrarsi sulla qualità dei dati e sulla precisione dei modelli, mentre gli ingegneri del software privilegiano robustezza, manutenibilità e scalabilità, generando conflitti nelle scelte progettuali e nella pianificazione condivisa.

Le principali cause individuate sono:

- Differenze linguistiche e cognitive, che rendono complessa la traduzione dei requisiti di business in requisiti tecnici.
- Assenza di ruoli formalizzati, con mansioni che si sovrappongono o restano scoperte.
- Community smells, come “lupo solitario” o “scontro organizzativo”, che accentuano la frammentazione sociale nei team.

Tabella 4.2: Sintesi delle sfide collaborative e organizzative

Sfida	Descrizione	Conseguenze
Barriere comunicative	Differenze di linguaggio tecnico tra sviluppatori, data scientist ed esperti di dominio	Incomprensioni, ritardi, scelte subottimali
Ambiguità dei ruoli	Ruoli non chiari o sovrapposti	Conflitti di responsabilità, inefficienze
Community smells	Pattern ricorrenti di interazioni problematiche	Perdita di coesione, aumento del debito sociale

Come riporta Busquim et al. [1], quando la fase di pre-elaborazione dei dati è affidata a un singolo esperto di dominio, , si rischiano dataset poco condivisi e modelli incoerenti. Arpteg et al.[5] mostrano come, nei contesti industriali, la scarsa comunicazione tra i diversi ruoli causa ritardi e inefficienze. Le sfide collaborative non sono un semplice effetto della multidisciplinarietà, ma un problema strutturale che deve essere gestito per garantire la qualità del sistema. Le soluzioni più efficaci proposte in letteratura includono:

- la definizione di ruoli intermedi (es. ML engineer, data steward);
- l’uso di strumenti di comunicazione centralizzati;
- e l’adozione di pratiche MLOps per favorire una collaborazione continua tra i diversi attori.

4.3 RQ2 - Incertezza e opacità dei modelli

RQ2. In che modo l'incertezza e l'opacità dei modelli di Machine Learning influenzano i processi decisionali nei team di sviluppo?

La natura dei modelli di Machine Learning rappresenta un ulteriore elemento di complessità. Le tecniche più performanti, come il deep learning, sono spesso caratterizzate da una scarsa interpretabilità, che rende difficile giustificare le decisioni o prevedere i comportamenti del sistema in contesti critici. Le principali problematiche identificate sono:

- Black-box effect: i modelli ML complessi non consentono di spiegare facilmente perché una predizione è stata fatta.
- Incertezza statistica: la variabilità dei dati di addestramento può alterare significativamente i risultati.
- Responsabilità diffusa: in presenza di decisioni errate, non è chiaro chi debba essere ritenuto responsabile.

Ad esempio, nei sistemi di classificazione per la selezione dei candidati (Hiring ML), Amershi et al.[15] riportano che la mancanza di spiegabilità genera conflitti tra sviluppatori e stakeholder HR, i quali richiedono garanzie sulla correttezza delle decisioni. Per mitigare queste difficoltà, vengono introdotte tecniche di Explainable AI (XAI) come SHAP o LIME, che forniscono spiegazioni locali sulle predizioni del modello. Queste strategie riducono i conflitti interni, ma comportano un compromesso: una maggiore trasparenza spesso implica una minore accuratezza o efficienza. Quindi, l'opacità dei modelli non è solo un problema tecnico, ma una sfida socio-organizzativa. La letteratura concorda sul fatto che la trasparenza deve essere progettata sin dalle prime fasi di sviluppo, integrando strumenti di tracciabilità e documentazione delle decisioni lungo l'intera pipeline ML.

Tabella 4.3: Strategie di mitigazione delle problematiche etiche nei sistemi ML

Strategia	Descrizione	Motivazione	Esempio di Applicazione - Impatto
Metriche di Fairness	Indicatori quantitativi (es. Demographic Parity, Equal Opportunity) utilizzati per misurare la parità di trattamento tra gruppi demografici.	Permettono di identificare bias sistematici nei modelli ML e rendono oggettiva la valutazione dell'equità	In un modello di credit scoring, l'uso di metriche di fairness ha evidenziato una disparità nel tasso di approvazione tra uomini e donne, portando alla ricalibrazione delle soglie decisionali.
Audit etici e Valutazioni indipendenti	Processi di revisione periodica dei sistemi ML, condotti da team esterni o comitati etici	Forniscono una valutazione imparziale dei rischi di bias e delle implicazioni sociali del modello	Nel riconoscimento facciale, audit indipendenti hanno rivelato tassi d'errore più elevati per soggetti con pelle scura, portando all'esclusione di dataset non bilanciati.
Linee Guida e Framework Etici	Documenti o policy promossi da enti pubblici e privati (es. UE, IEEE, Google AI Principles)	Offrono principi di riferimento (trasparenza, accountability, beneficenza) e standard di comportamento.	Le linee guida UE sull'AI Trustworthy hanno portato alla definizione di checklist etiche obbligatorie per i progetti ML ad alto impatto.
Explainable AI (XAI)	Tecniche che rendono interpretabili i modelli complessi (es. SHAP, LIME).	Aumentano la trasparenza e la fiducia da parte di stakeholder non tecnici.	Nei sistemi di selezione automatica del personale, l'uso di LIME ha permesso di mostrare i fattori decisionali per ciascun candidato, migliorando la fiducia dei dipartimenti HR.
Ruoli dedicati all'etica (Ethics Officer, Fairness)	Figure professionali incaricate di monitorare il rispetto dei principi etici e morali.	Rafforzano la responsabilità condivisa e la continuità lavorativa	In progetti di sanità digitale, la presenza di un fairness advocate ha garantito che le scelte sui dati rispettassero principi di integrità etica.

4.4 RQ3 - Considerazioni etiche e fairness

RQ3. Qual è l'impatto delle considerazioni etiche e di fairness sulla progettazione, la valutazione e l'adozione dei sistemi ML?

Gli studi di Madaio et al. [9] mostrano che le preoccupazioni etiche non sono percepite come un compito separato, ma come un problema trasversale che influisce su ogni fase dello sviluppo ML. Le principali sfide individuate riguardano:

- Bias nei dati di addestramento, che riflettono pregiudizi sociali preesistenti.
- Mancanza di strumenti standardizzati per valutare la fairness.
- Scarsa consapevolezza etica nei team tecnici, spesso concentrati solo sulla performance del modello.

Tra le strategie di mitigazione emergono:

1. Metriche di fairness - utilizzate per quantificare la parità di trattamento tra gruppi diversi (es. equal opportunity, demographic parity). Queste metriche emergono perchè forniscono un modo oggettivo per misurare la discriminazione automatizzata. Tuttavia, la loro efficacia è limitata: metriche diverse possono portare a conclusioni contrastanti.

2. Audit etici e valutazioni indipendenti - permettono di identificare bias strutturali non visibili nei test tecnici. Esempio: nei sistemi di riconoscimento facciale, gli audit hanno rivelato tassi d'errore più alti per individui non caucasici, portando a revisioni dei dataset e a una maggiore consapevolezza etica nei team.
3. Linee guida industriali - promosse da enti come Google, IBM o la Commissione Europea, emergono come risposta alla crescente necessità di accountability. Queste linee guida stabiliscono principi di equità e trasparenza, ma la loro applicazione dipende fortemente dal contesto organizzativo.

Detto ciò, le strategie di mitigazione etica non eliminano il problema, ma creano spazi di riflessione strutturali che spingono i team a considerare l'impatto sociale dei propri modelli. La loro efficacia aumenta quando integrate con processi organizzativi trasversali e con ruoli dedicati (es. ethic officer, fairness advocate).

Tabella 4.4: Strategie di mitigazione delle sfide etiche

Strategia	Contesto di applicazione	Limiti
Metriche di fairness	Valutazione quantitativa della non-discriminazione	Difficile copiare tutte le forme di bias
Audit etici	Revisione indipendente dei processi e modelli	Costi elevati, limitata standardizzazione
Linee guida industriali	Best practise condivise	Applicazione non uniforme, enforcement debole

4.5 RQ4 - Pratiche, strategie e strumenti a supporto dei team

RQ4. Qual è l'impatto delle considerazioni etiche e di fairness sulla progettazione, la valutazione e l'adozione dei sistemi ML?

Le pratiche emergenti si collocano in tre aree chiave:

1. MLOps e automazione dei workflow, per integrare le fasi di sviluppo, addestramento e deployment.
2. Strumenti di documentazione e comunicazione: per ridurre le barriere tra ruoli.
3. Audit e accountability, per garantire tracciabilità e trasparenza dei processi.

Definite queste tre aree, gli strumenti e le pratiche che si prendono in considerazione in questo caso sono:

- MLOps (Sculley et al.[16]) permette di ridurre il "technical debt" e il "data debt", standardizzando pipeline e responsabilità .
- Model cards e Datasheets for Datasets (Mitchell et al.[17], Gebru et al.[18]) sono strumenti che migliorano la comunicazione tra data scientist e stakeholder, fornendo una "documentazione leggibile" del comportamento del modello.
- Audit etici integrati nei workflow consentono di anticipare problemi di bias già in fase di progettazione.

Le pratiche organizzative più efficaci non sono meramente tecniche: funzionano perchè rafforzano la trasparenza e la fiducia tra i membri del team, migliorando l'allineamento sugli obiettivi comuni.

Tabella 4.5: Pratiche e strumenti a supporto dei team ML-intensive

Pratica / Strumento	Obiettivo Principale	Benefici Organizzativi	Esempio di Applicazione
MLOps	Integrare sviluppo, training e deployment in pipeline continue.	Migliora la collaborazione tra sviluppatori e data scientist, riduce il debito tecnico.	Implementazione di CI/CD per modelli ML in Google Cloud ML; ha ridotto i tempi di rilascio da settimane a ore.
Datasheets for Datasets	Documentare origine, qualità e scopo dei dataset.	Promuove la trasparenza e la tracciabilità delle scelte sui dati.	IBM ha introdotto datasheet obbligatori per i dataset interni, migliorando la comunicazione tra data scientist e team legali.
Model Cards	Fornire una descrizione leggibile del comportamento del modello e dei limiti di utilizzo.	Supporta la comunicazione verso stakeholder non tecnici.	Google utilizza model cards per illustrare le performance differenziali dei modelli di visione artificiale.
Audit Pipeline Integrati	Automatizzare controlli di conformità etica e bias nei workflow di ML.	Permette una valutazione continua durante l'intero ciclo di vita del modello.	Microsoft ha sperimentato audit pipeline che interrompono automaticamente il training se le metriche di fairness peggiorano.
Documentazione Collaborativa (es. Notion, Confluence, GitHub Issues)	Centralizzare la comunicazione tecnica e gestionale tra team.	Riduce la dispersione informativa e migliora la tracciabilità decisionale.	In team distribuiti, l'uso di issue board condivise ha permesso una gestione coordinata tra ML engineer e product owner.
Cross-role Workshops e Pairing Sessions	Attività collaborative che mettono a confronto ruoli diversi (developer, data scientist, stakeholder).	Favoriscono la comprensione reciproca e riducono i conflitti cognitivi.	Durante progetti finanziari, sessioni congiunte tra data scientist e analisti hanno portato a una riduzione del 30% delle revisioni di modello.

4.6 Sintesi comparativa dei risultati

La seguente figura sintetizza il livello di supporto fornito dalle diverse strategie alle tre principali categorie di sfide emerse: collaborative, tecniche (opacità ML) ed etiche.




Figura 4.6: Relazione tra sfide e strategie di mitigazione

La comparazione mostra che:

- Le pratiche MLOps e la documentazione collaborativa affrontano efficacemente le sfide organizzative.
- Le soluzioni di Explainability mitigano l'opacità, ma non risolvono i problemi di fiducia.
- Gli audit etici e le linee guida industriali rappresentano strumenti fondamentali per le sfide etiche, ma con limiti di costo e scalabilità.

4.6.1 Differenze tra letteratura accademica e grey literature

Dall'analisi comparativa emerge una distinzione significativa tra i contributi provenienti dalla letteratura accademica e quelli della grey literature.

La letteratura accademica (es. Nahar et al., 2021; Madaio et al., 2022; Arpteg et al., 2018) fornisce principalmente analisi empiriche e modelli concettuali, concentrandosi su barriere organizzative, strategie metodologiche e riflessioni teoriche sulle dinamiche socio-tecniche.

La grey literature (Carnegie Mellon University, 2021; Wikipedia, 2023) contribuisce invece con prospettive più pratiche e divulgative, offrendo esempi operativi e linee guida di tipo descrittivo, spesso basate sull'esperienza industriale.

In sintesi, i due insiemi di fonti risultano complementari: gli studi accademici forniscono rigore metodologico e generalizzabilità, mentre la grey literature aggiunge concretezza e attualità, colmando il divario tra ricerca e pratica.

4.7 Verifica del raggiungimento degli obiettivi

Il confronto tra i risultati ottenuti e gli obiettivi iniziali della tesi mostra che:

- E' stata realizzata una mappatura sistematica delle sfide socio-tecniche nei team multidisciplinari.
- Sono state individuate le cause principali e le conseguenze associate a tali sfide.
- Sono state descritte le cause e conseguenze delle problematiche individuate.
- Sono state raccolte e discusse strategie e pratiche per la mitigazione.
- Sono state formulate linee guida preliminari a supporto della collaborazione nei team ML-intensive.

Il lavoro fornisce quindi un quadro coerente e criticamente interpretato delle problematiche sociali nei team ML-intensive, offrendo le basi per la definizione di linee guida future orientate alla collaborazione, alla trasparenza e all'etica dello sviluppo ML.

CAPITOLO 5

Conclusioni

In conclusione, questo studio ha avuto l'obiettivo di analizzare le dinamiche sociali e organizzative che caratterizzano i team multidisciplinari impegnati nello sviluppo di sistemi software basati su tecniche di Machine Learning (ML). L'introduzione di componenti di intelligenza artificiale nei processi di sviluppo tradizionali ha infatti reso evidente la necessità di una collaborazione più stretta tra figure con competenze, linguaggi e priorità differenti, dando origine a sfide di natura socio-tecnica ed etica ancora poco esplorate in modo sistematico.

Attraverso una revisione strutturata della letteratura scientifica e della grey literature, è stato possibile costruire un quadro organico delle principali problematiche e delle pratiche di mitigazione proposte nel tempo. L'analisi ha evidenziato come le barriere comunicative, l'ambiguità dei ruoli e la presenza di community smells rappresentino i fattori più critici sul piano organizzativo. Tali ostacoli compromettono l'allineamento degli obiettivi, la condivisione della conoscenza e la coesione del team, influenzando direttamente la qualità e l'affidabilità dei sistemi sviluppati.

Dal punto di vista tecnico, l'opacità e l'incertezza dei modelli ML aggravano ulteriormente la complessità collaborativa, rendendo difficile giustificare le decisioni algoritmiche e attribuire le responsabilità in caso di errore.

Sul piano etico, emergono infine questioni legate al bias nei dati, alla fairness e alla trasparenza, che richiedono un approccio integrato tra ingegneria del software, scienza dei dati e governance organizzativa.

I risultati ottenuti mostrano che le strategie più efficaci per affrontare tali sfide si basano su pratiche trasversali che uniscono dimensioni tecniche e sociali. In particolare, l'adozione di pratiche MLOps consente di migliorare la collaborazione tra sviluppatori e data scientist, riducendo il technical debt; strumenti come Model Cards e Datasheets for Datasets favoriscono la trasparenza e la comunicazione interfunzionale; mentre audit etici e ruoli dedicati alla fairness rappresentano passi concreti verso una maggiore responsabilità collettiva. L'integrazione di queste pratiche contribuisce a costruire team più consapevoli, coesi e orientati alla qualità socio-tecnica del prodotto.

Sebbene il lavoro abbia raggiunto gli obiettivi prefissati, è importante sottolineare che l'analisi si è concentrata prevalentemente su fonti secondarie, con l'intento di costruire una base teorica e concettuale solida. In prospettiva, l'integrazione di studi empirici (come interviste, casi di studio o osservazioni dirette) potrebbe arricchire ulteriormente la comprensione delle dinamiche socio-tecniche e validare in modo più approfondito le raccomandazioni proposte. Inoltre, la rapida evoluzione delle tecnologie ML e delle pratiche organizzative rappresenta un contesto dinamico, che offre ampie opportunità per estendere e aggiornare i risultati nel tempo.

Per questi motivi, tra i principali sviluppi futuri si individuano:

- la realizzazione di studi empirici sui team industriali per verificare l'efficacia delle pratiche individuate;
- la definizione di metriche socio-tecniche per misurare la qualità della collaborazione nei progetti ML-intensive;
- l'elaborazione di linee guida operative e toolkit a supporto dei project manager e degli stakeholder coinvolti;
- l'approfondimento del legame tra dinamiche etiche e processi di sviluppo software, con particolare attenzione all'integrazione della responsabilità algoritmica nei cicli di vita ML.

Bibliografia

- [1] G. Busquim *et al.*, “Community smells in ml-intensive projects,” in *Research on Socio-Technical Aspects of Software Engineering*. Springer, 2021. (Citato alle pagine 4, 5, 7, 16 e 17)
- [2] N. Nahar *et al.*, “Building machine learning products with interdisciplinary teams,” *Empirical Software Engineering*, vol. 26, no. 5, p. 98, 2021. (Citato alle pagine 4 e 7)
- [3] D. Piorkowski *et al.*, “How ai developers overcome communication challenges in a multidisciplinary team,” *Proceedings of the ACM on Human-Computer Interaction*, vol. 5, no. CSCW1, pp. 1–27, 2021. (Citato alle pagine 4 e 7)
- [4] Carnegie Mellon University, “Interdisciplinary teams,” <https://mlip-cmu.github.io/>, 2021, accessed: 2025-09-17. (Citato a pagina 5)
- [5] A. Arpteg, B. Brinne, L. Crnkovic-Friis, and J. Bosch, “Software engineering challenges of deep learning,” in *Proceedings of the 44th Euromicro Conference on Software Engineering and Advanced Applications (SEAA)*. IEEE, 2018, pp. 50–59. (Citato alle pagine 5, 7, 16 e 17)
- [6] A. Graessner *et al.*, “Dealing with data challenges when delivering data-intensive software solutions,” *IEEE Software*, vol. 39, no. 4, pp. 30–38, 2022. (Citato alle pagine 5 e 7)

-
- [7] C. Amrit and R. Narayanappa, "An analysis of the challenges in the adoption of mlops," *Journal of Innovation and Knowledge*, vol. 10, no. 1, pp. 45–57, 2025. (Citato alle pagine 5 e 7)
- [8] Wikipedia contributors, "Algorithmic bias," https://en.wikipedia.org/wiki/Algorithmic_bias, 2023, accessed: 2025-09-17. (Citato alle pagine 6 e 7)
- [9] M. A. Madaio *et al.*, "Navigating fairness: Practitioners' understanding, challenges, and strategies in ai/ml development," *Empirical Software Engineering*, vol. 27, no. 6, p. 131, 2022. (Citato alle pagine 6, 7 e 19)
- [10] N. Bostrom and E. Yudkowsky, "The ethics of artificial intelligence," in *The Cambridge Handbook of Artificial Intelligence*, K. Frankish and W. M. Ramsey, Eds. Cambridge University Press, 2014, pp. 316–334. (Citato alle pagine 6 e 7)
- [11] B. Kitchenham and S. Charters, "Guidelines for performing systematic literature reviews in software engineering," *EBSE Technical Report*, 2007. (Citato alle pagine 10 e 12)
- [12] V. Garousi, M. Felderer, and M. V. Mäntylä, "Guidelines for including grey literature and conducting multivocal literature reviews in software engineering," *Information and Software Technology*, vol. 106, pp. 101–121, 2019. (Citato alle pagine 10 e 13)
- [13] C. Wohlin, "Guidelines for snowballing in systematic literature studies and a replication in software engineering," *Proceedings of the 18th International Conference on Evaluation and Assessment in Software Engineering*, pp. 1–10, 2014. (Citato a pagina 12)
- [14] S. Easterbrook, J. Singer, M.-A. Storey, and D. Damian, *Selecting Empirical Methods for Software Engineering Research*. Springer, 2008. (Citato a pagina 12)
- [15] S. Amershi, D. Weld, M. Vorvoreanu, A. Fourney, B. Nushi, P. Collisson, J. Suh, V. Sinha, M. L. Khan, S. Gray, and E. Horvitz, "Guidelines for human-ai interaction," in *Proceedings of the 2019 CHI conference on human factors in computing systems*, 2019, pp. 1–13. (Citato a pagina 18)

- [16] D. Sculley, G. Holt, D. Golovin, E. Davydov, T. Phillips, D. Ebner, V. Chaudhary, M. Young, J. Crespo, and D. Dennison, “Hidden technical debt in machine learning systems,” in *Advances in Neural Information Processing Systems*, vol. 28, 2015. (Citato a pagina 21)
- [17] M. Mitchell, S. Wu, A. Zaldivar, P. Barnes, L. Vasserman, B. Hutchinson, E. Spitzer, I. D. Raji, and T. Gebru, “Model cards for model reporting,” in *Proceedings of the Conference on Fairness, Accountability, and Transparency (FAT*)*. ACM, 2019, pp. 220–229. (Citato a pagina 21)
- [18] T. Gebru, J. Morgenstern, B. Vecchione, J. W. Vaughan, H. Wallach, H. Daumé III, and K. Crawford, “Datasheets for datasets,” *Communications of the ACM*, vol. 64, no. 12, pp. 86–92, 2021. (Citato a pagina 21)