



UNIVERSITÀ DEGLI STUDI DI SALERNO

Dipartimento di Informatica

Corso di Laurea Triennale in Informatica

TESI DI LAUREA

Classificazione Multilingua della Tossicità nei Dialoghi: Un Approccio Combinato di Two-Stage Fine-Tuning e Adapter con XLM-RoBERTa

RELATORE

Prof. Fabio Palomba

Università degli Studi di Salerno

CANDIDATO

Gianvincenzo Landolfi

Matricola: 0512114922

Anno Accademico 2024-2025

Questa tesi è stata realizzata nel

sesa^{lab}
SOFTWARE ENGINEERING
SALERNO

"Success in creating AI would be the biggest event in human history. Unfortunately, it might also be the last, unless we learn how to avoid the risks."

Stephen Hawking

Abstract

La classificazione automatica della tossicità nei dialoghi è fondamentale per garantire interazioni sicure nelle piattaforme online. In questa tesi, esploriamo diverse strategie di apprendimento automatico per affrontare la classificazione della tossicità in scenari multilingue, con particolare attenzione alle lingue a bassa risorsa. Utilizzando il dataset `WildChat`, inizialmente sono state estratte sia *feature manuali* che *embedding*, successivamente utilizzati per addestrare modelli di *shallow machine learning*.

In seguito, sono stati effettuati i Fine-Tuning di modelli *Transformer* basati su tokens, come `XLM-RoBERTa`, e confrontati con `Canine`, basato su caratteri. I migliori risultati sono stati ottenuti con il *Two-Stage Fine-Tuning (TSFT)* di `XLM-RoBERTa`, che ha raggiunto un'accuratezza del **92.3%** su 10 lingue ad alta risorsa, seguita da un affinamento su ulteriori 29 lingue a bassa risorsa, su cui ha ottenuto un'accuratezza del **89.3%**. Inoltre, ha ottenuto l'**87.5%** di accuratezza in uno scenario *zero-shot* su ulteriori 21 lingue a bassissima risorsa.

Gli approcci basati su *meta-learning* non hanno superato questi risultati, mentre l'impiego di *Adapters* ha migliorato le performance nel contesto delle 21 lingue a bassissima risorsa, raggiungendo un'accuratezza del **89.3%**. Questi risultati evidenziano come il *Two-Stage Fine-Tuning con XLM-RoBERTa* integrato con *Adapters* rappresenti una strategia efficace per la classificazione della tossicità in contesti multilingue e con dati limitati.

Indice

Elenco delle Tabelle	iii
1 Introduzione	1
1.1 Contesto	1
1.2 Motivazioni e Obiettivi	2
1.3 Risultati	2
1.4 Struttura della Tesi	3
2 Background e Stato dell'Arte	5
2.1 Introduzione	5
2.2 Dai Modelli Tradizionali ai Transformer	6
2.3 Limitazioni dei Modelli di Tossicità Basati su Social Media	6
2.4 Strategie di Adattamento per il Multilingua	7
3 Metodo di Ricerca	9
3.1 Obiettivo della Ricerca	9
3.2 Domande di Ricerca	9
3.3 Dataset e Preprocessing	10
3.3.1 Selezione e Pulizia dei Dati	10
3.3.2 Divisione del Dataset	10
3.4 Modelli e Approcci Metodologici	11

3.4.1	Feature Tradizionali e Shallow ML	11
3.4.2	Embeddings da Transformer per Shallow ML	12
3.4.3	Fine-Tuning di Modelli Transformer	12
3.4.4	Approcci per le Lingue a Bassa Risorsa	12
4	Analisi dei Risultati	16
4.1	Feature Tradizionali e Shallow ML	16
4.1.1	Analisi Feature e Risultati	16
4.2	Embeddings da Transformer per Shallow ML	19
4.3	Fine-Tuning di Modelli Transformer	21
4.3.1	Lingue ad Alta Risorsa	21
4.3.2	Lingue a Bassa Risorsa: Test in Zero-Shot	23
4.4	Approcci per le Lingue a Bassa Risorsa: TSFT, Adapter e Meta-Learning	26
4.4.1	TSFT (Two-Stage Fine-Tuning)	26
4.4.2	Meta-Learning	27
4.4.3	Adapter Standard	28
4.5	Confronto Computazionale: Setup Sperimentale e Analisi dei Modelli	30
4.5.1	Requisiti computazionali e ambienti di esecuzione	30
4.5.2	Confronto tra Modelli Tradizionali (Shallow ML)	30
4.5.3	Confronto tra Modelli di Deep Learning	31
4.5.4	Confronto Approcci per le Lingue a Bassa Risorsa	34
5	Conclusioni	35
	Bibliografia	37

Elenco delle tabelle

4.1	Risultati della classificazione con Gradient Boosting	18
4.2	Confronto delle metriche di accuratezza dei modelli di shallow ml con l'utilizzo di embeddings per lingua ad alta risorsa	20
4.3	Risultati delle metriche per classe dei modelli SVM con diversi embed- dings e dataset.	21
4.4	Confronto metriche per classe del Fine-Tuning di modelli Transformer.	24
4.5	Confronto delle metriche di accuratezza risultanti dal Fine-Tuning sul dataset ad alta risorsa	25
4.6	Confronto delle metriche ottenute testando i migliori modelli in mo- dalità zero-shot.	25
4.7	Confronto tra TSFT, Adapter e Meta-Learning	29
4.8	Confronto tra i modelli per il fine-tuning: accuratezza, tempo di trai- ning e numero di parametri.	32
4.9	Performance dei modelli di shallow ML in relazione all'accuratezza, al tempo di training e alla dimensione del modello salvato.	33
4.10	Confronto tra approcci avanzati: accuratezza, tempo di training e numero di parametri.	34

CAPITOLO 1

Introduzione

1.1 Contesto

L'evoluzione delle interazioni online Negli ultimi anni, la quantità di dati testuali generati sulle piattaforme digitali è cresciuta esponenzialmente, rendendo essenziale l'impiego di strumenti automatici per la moderazione dei contenuti. I social network, i forum e i chatbot basati su intelligenza artificiale hanno evidenziato l'urgenza di individuare e gestire in modo efficace messaggi potenzialmente dannosi, al fine di preservare un ambiente di comunicazione sicuro e rispettoso.

La sfida del multilinguismo Un ulteriore livello di complessità è rappresentato dalla diversità linguistica dei contenuti. Il dataset WildChat [1] analizzato in questo studio comprende 1 milione di conversazioni tra utenti e assistente AI scritte in diverse lingue. Di conseguenza, la classificazione automatica della tossicità non può limitarsi all'inglese, ma deve garantire un'accuratezza adeguata anche in altre lingue, superando le barriere linguistiche e culturali che rendono il problema particolarmente impegnativo.

1.2 Motivazioni e Obiettivi

La ricerca nasce da esigenze di natura pratica e tecnologica. Da un lato, il contrasto ai contenuti tossici rappresenta una priorità: le espressioni offensive e dannose nei contesti digitali hanno un impatto negativo sugli utenti, perciò l’implementazione di sistemi di moderazione automatizzata è cruciale per garantire interazioni online di qualità. Dall’altro, il notevole progresso nelle tecniche di Natural Language Processing, in particolare grazie all’evoluzione dei modelli basati su reti neurali e Transformer [2], ha permesso di ottenere rappresentazioni testuali più precise rispetto ai metodi tradizionali, migliorando l’efficacia della classificazione automatica. Inoltre, le sfide poste dalla diversità linguistica e culturale richiedono l’adozione di modelli avanzati capaci di operare su scala globale, come XLM-RoBERTa [3], per garantire accuratezza anche in presenza di contenuti multilingue.

In questo contesto, gli obiettivi dello studio si articolano in più direzioni: innanzitutto, si intende confrontare diverse tecniche di rappresentazione testuale per la classificazione della tossicità, valutando approcci tradizionali (ad esempio, TF-IDF e feature ingegnerizzate) e embeddings estratti da modelli di deep learning pre-addestrati. Parallelamente, si propone di analizzare le prestazioni di modelli di machine learning, quali le Support Vector Machines (SVM), sfruttando embeddings generati da RoBERTa [4] e XLM-RoBERTa, sia in contesti monolingue (inglese) che multilingue. Un ulteriore obiettivo riguarda il fine-tuning specifico dei modelli: RoBERTa per l’inglese e XLM-RoBERTa per il multilinguismo, con l’integrazione di CANINE [5] – che opera direttamente a livello di caratteri, evitando una tokenizzazione tradizionale – per perfezionare ulteriormente le performance. Infine, lo studio esplora l’utilizzo di algoritmi di Meta-Learning e/o Adapters [6] per il trasferimento cross-lingua, confrontandoli con il Two-Stage Fine-Tuning (TFST) per identificare l’approccio più efficace nelle lingue a bassa risorsa.

1.3 Risultati

Feature Tradizionali L’uso di TF-IDF e feature ingegnerizzate (lunghezza del messaggio, frequenza di parole tossiche, polarità, soggettività) ha prodotto un’accuratez-

za massima del 76% su un dataset monolingua inglese.

Embeddings dai Modelli Transformer per modelli di shallow ML L'impiego di embeddings da modelli transformer ha permesso di migliorare significativamente le performance:

- Con RoBERTa e SVM su dataset monolingua inglese: accuratezza dell'88%.
- Con XML-RoBERTa e SVM su dataset multilingua in 10 lingue ad alte risorse: accuratezza dell'87%.

Fine-Tuning di Modelli Transformer L'impiego di fine-tuning di modelli transformer ha permesso di migliorare ulteriormente le performance:

- Con RoBERTa su dataset monolingua inglese: accuratezza dell'94%.
- Con XML-RoBERTa su dataset multilingua in 10 lingue: accuratezza dell'93.1%.
- Un affinamento (TSFT) su ulteriori 29 lingue a basse risorse ha prodotto un'accuratezza dell'89.3%

Meta-Learning e/o Adapters L'impiego di algoritmi di meta-learning, quali MAML [7] e Reptile [8], non hanno portato miglioramenti rispetto al TSFT. Mentre l'utilizzo di Adapters per le 21 lingue a bassissima risorsa ha portato ad un'accuratezza dell'89.3%

Prestazioni Complessive del Modello Finale Il modello finale ha ottenuto il 92.3% di accuratezza sulle 10 lingue iniziali ad alta risorsa e dell'89.3% sulle 29 lingue a bassa risorsa e le 21 lingue a bassissima risorsa.

1.4 Struttura della Tesi

La tesi è organizzata nei seguenti capitoli:

1. **Background e Stato dell'Arte** – Introduzione al problema della classificazione della tossicità nei testi, con una panoramica sui modelli di NLP, in particolare i transformer, e sulle principali soluzioni adottate nello stato dell'arte.

2. **Metodo di Ricerca** – Descrizione del dataset utilizzato, delle tecniche di pre-processing e feature engineering adottate, e delle strategie di addestramento dei modelli, tra cui fine-tuning, adapters e meta-learning.
3. **Analisi dei Risultati** – Presentazione degli esperimenti condotti, confronto tra le diverse configurazioni testate e analisi dei risultati ottenuti in termini di accuratezza e capacità di generalizzazione su lingue ad alta e bassa risorsa. Un ulteriore confronto per valutare l'utilizzo delle risorse computazionali quali tempo di addestramento, numero di parametri e peso del modello.
4. **Conclusioni** – Sintesi dei risultati principali, discussione delle implicazioni del lavoro e possibili sviluppi futuri per migliorare ulteriormente la classificazione della tossicità nei contesti multilingua.

Background e Stato dell'Arte

2.1 Introduzione

La classificazione automatica della tossicità nei testi è un tema cruciale per la moderazione dei contenuti online e per la sicurezza nelle interazioni tra utenti e intelligenza artificiale. Con la crescente diffusione di chatbot e assistenti virtuali, è fondamentale sviluppare modelli in grado di riconoscere espressioni offensive o dannose in modo accurato ed efficiente.

Negli ultimi anni, l'uso di modelli di apprendimento automatico e, più recentemente, di reti neurali basate su *Transformer* ha portato a significativi progressi nel rilevamento della tossicità. Tuttavia, molte delle soluzioni esistenti si concentrano su contenuti provenienti dai social media [9, 10, 11] e sulla lingua inglese, trascurando contesti conversazionali e scenari multilingua.

In questo capitolo vengono analizzati i principali approcci alla classificazione della tossicità, dai modelli tradizionali ai più recenti modelli basati su deep learning. Verranno inoltre discusse le principali sfide legate alla generalizzazione dei modelli e all'adattamento a lingue con risorse limitate.

2.2 Dai Modelli Tradizionali ai Transformer

Inizialmente, la classificazione della tossicità si basava su metodi di machine learning con feature manuali, come *TF-IDF* e *bag-of-words*, utilizzati in combinazione con modelli come *SVM*, *Logistic Regression* e *Random Forest* [12, 13, 14, 15]. Questi approcci presentavano limiti significativi:

- Dipendenza da feature ingegnerizzate, che non catturano il significato contestuale.
- Vulnerabilità a tecniche di elusione, come l'uso di sarcasmo o la sostituzione di caratteri.

L'avvento dei *Transformer* ha rivoluzionato il settore, con modelli come *Hate-BERT* [16] e *BERTweet* [17], che hanno mostrato prestazioni superiori. Tuttavia, questi modelli presentano due limiti principali:

1. **Scarsa capacità di classificare messaggi in lingue con poche risorse:** molti modelli sono pre-addestrati principalmente sull'inglese o su lingue ad alta disponibilità di dati, risultando meno efficaci su idiomi con dataset limitati.
2. **Difficoltà di generalizzazione:** essendo addestrati principalmente su dati provenienti dai social media, possono avere prestazioni inferiori in contesti conversazionali come le interazioni utente-assistente AI.

La nostra ricerca affronta queste problematiche adottando un approccio innovativo che combina **modelli per conversazioni utente-AI**, **analisi multilingua** e **strategie avanzate di adattamento**.

2.3 Limitazioni dei Modelli di Tossicità Basati su Social Media

La maggior parte dei dataset per la classificazione della tossicità proviene da **social media**, come Twitter e Reddit. Uno studio recente, *ToxicChat* [18], ha dimostrato che i modelli di tossicità addestrati su questi dati non si adattano bene alle interazioni utente-AI, poiché:

- **Le conversazioni con chatbot hanno dinamiche diverse**, con risposte più strutturate e meno rumore testuale rispetto ai social media.
- **Alcune forme di tossicità sono più sottili e contestuali**, rendendo difficile la classificazione con modelli pre-addestrati su dati social.

Tuttavia, *ToxicChat* è limitato alla lingua inglese, mentre la nostra ricerca estende l'analisi a **60 lingue**, inclusi idiomi con risorse limitate, grazie al dataset **WildChat** [1]. Inoltre, esploriamo metodi avanzati per migliorare la generalizzazione in lingue a bassa risorsa.

2.4 Strategie di Adattamento per il Multilingua

Uno dei principali problemi nei modelli di tossicità è la **generalizzazione a lingue con poche risorse**. Per questo, confrontiamo quattro strategie:

1. **Fine-tuning diretto su più lingue**: consente di addestrare un unico modello su un dataset multilingua, ma richiede un'elevata quantità di dati per ogni lingua per garantire buone prestazioni.
2. **Two-Stage Fine-tuning per lingue a bassa risorsa**: prevede un primo addestramento su un ampio dataset multilingua seguito da un fine-tuning su lingue con pochi dati, ma può causare il fenomeno del *catastrophic forgetting*.
3. **Adapter specifici per lingua**: consente di adattare il modello senza modificare i pesi principali, migliorando la generalizzazione e riducendo il rischio di interferenze tra lingue, sebbene introduca un costo computazionale aggiuntivo.
4. **Algoritmi di Meta-learning**: ottimizzano il modello per un rapido adattamento a nuove lingue con pochi dati, bilanciando accuratezza ed efficienza, sebbene siano più complessi da addestrare.

Il meta-learning per l'adattamento a lingue low-resource

L'uso del **meta-learning** in scenari cross-lingua few-shot si basa sull'idea di addestrare un modello in modo che sia in grado di adattarsi rapidamente a nuove lingue

utilizzando pochi esempi. A differenza del fine-tuning tradizionale, che ottimizza i parametri su un singolo task o dominio, il meta-learning ottimizza il processo stesso di apprendimento, mirando a trovare un’inizializzazione che consenta una rapida convergenza anche in condizioni di scarsità di dati.

Nel contesto multilingua, il meta-learning consente di:

- **Imparare a generalizzare** da un insieme di lingue con più risorse, trasferendo la conoscenza verso lingue meno rappresentate.
- **Evitare l’overfitting** nei casi in cui siano disponibili pochissimi esempi di addestramento per una nuova lingua target.

Diversi studi recenti [19, 20, 21, 22] hanno dimostrato l’efficacia del meta-learning per il trasferimento cross-lingua in scenari low-resource, evidenziando come approcci come MAML o i suoi derivati come X-MAML e Proto-MAML possano migliorare significativamente la capacità di generalizzazione rispetto a tecniche più convenzionali.

Nel nostro lavoro, queste considerazioni teoriche hanno motivato l’applicazione di due tecniche meta-apprenditive:

- **MAML con Adapter**, per ottimizzare l’inizializzazione dei moduli linguistici specializzati [23];
- **Reptile**, per un’alternativa più semplice ed efficiente in termini computazionali, ispirandoci al lavoro di Nichol et al. [8].

Metodo di Ricerca

3.1 Obiettivo della Ricerca

© **Our Goal.** L'obiettivo principale di questa ricerca è sviluppare e valutare un sistema di classificazione automatica della tossicità in un contesto multilingua.

3.2 Domande di Ricerca

Le domande di ricerca che guidano il nostro lavoro sono:

1. **Q RQ₁.** *Quanto incide l'uso di embeddings estratti dai modelli Transformer, rispetto alle tecniche tradizionali (come TF-IDF e feature ingegnerizzate), sulla capacità di classificazione della tossicità?*
2. **Q RQ₂.** *Il fine-tuning di modelli Transformer su dati multilingua migliora la capacità di classificazione della tossicità rispetto a metodi basati su embeddings statici?*
3. **Q RQ₃.** *L'uso di adattamenti specializzati, come Adapter e Meta-Learning, può migliorare la generalizzazione del modello in lingue con poche risorse?*

3.3 Dataset e Preprocessing

Per l'addestramento e la valutazione dei modelli, abbiamo utilizzato il dataset **WildChat**, che comprende **1 milione di conversazioni** tra utenti e un assistente AI in diverse lingue.

3.3.1 Selezione e Pulizia dei Dati

Dopo una prima analisi della struttura del dataset, abbiamo individuato la colonna di interesse, denominata `conversation`. Circa il 15% delle conversazioni sono risultate essere etichettate come tossiche. Le operazioni effettuate sono state:

- **Filtraggio dei dati:** estrazione della colonna `conversation`, contenente conversazioni in formato JSON. Ogni messaggio è un oggetto con i campi `content`, `role`, `language` e altri metadati. Sono stati selezionati solo i messaggi con `role = user`, mantenendo le etichette `toxic` e `language` ed eliminando eventuali duplicati.
- **Costruzione di dataset bilanciati:** creazione di dataset monolingua e multilingua bilanciati per le successive fasi di addestramento.

3.3.2 Divisione del Dataset

Sono stati creati dataset bilanciati in base alle risorse linguistiche:

- **Dataset monolingua inglese:** 10k messaggi e un set più ampio con quasi 200k messaggi(`200k_en`).
- **10 lingue ad alta risorsa:** 2k messaggi per lingua(`2k`) e 10k messaggi per lingua, con traduzione delle occorrenze tossiche dall'inglese(`10k_T`).
- **29 lingue a bassa risorsa:** 200 messaggi per lingua (`200_29`) e 1k messaggi per lingua (`1k_T29`), con traduzione delle occorrenze tossiche dall'inglese.
- **21 lingue a bassissima risorsa:** 40 messaggi per lingua (`40_21`).

La data augmentation è stata effettuata con l'utilizzo del modello per le traduzioni: nllb-200-distilled-600M [24].

La suddivisione per l'addestramento prevede:

- **80% train, 10% validation, 10% test** per lingue ad alta e bassa risorsa.
- **50 train, 10% validation, 40% test** per lingue a bassissima risorsa.

La metodologia adottata si basa su diverse strategie che spaziano da metodi tradizionali a tecniche all'avanguardia con modelli Transformer. Di seguito vengono descritti i vari approcci.

3.4 Modelli e Approcci Metodologici

3.4.1 Feature Tradizionali e Shallow ML

- **Feature ingegnerizzate:**
 - Calcolo di feature basate su lunghezza del testo (numero di caratteri, parole e frasi).
 - Analisi statistica tramite test di Pearson, T-test e P-test per valutare correlazioni con la tossicità.
- **Preprocessing del testo:**
 - Normalizzazione (espansione delle contrazioni, conversione in minuscolo, tokenizzazione, rimozione delle stopwords e delle parole non inglesi, lemmatizzazione).
 - Feature Scaling (numero caratteri, parole e frasi) .
- **Calcolo di TF-IDF** e ulteriori feature basate su:
 - Dizionario esterno per il calcolo della frequenza di parole tossiche.
 - Analisi di soggettività e polarità tramite TextBlob.
- **Modelli addestrati:** SVM, Logistic Regression, Random Forest, KNN e Gradient Boosting.

3.4.2 Embeddings da Transformer per Shallow ML

- Estrazione di embeddings da modelli pre-addestrati quali RoBERTa-base/large e XLM-RoBERTa-base/large.
- Utilizzo di questi embeddings in combinazione con modelli di classificazione tradizionali (SVM, Logistic Regression, Random Forest, KNN, XGBoost).

3.4.3 Fine-Tuning di Modelli Transformer

Il **Fine-Tuning** è una tecnica di adattamento di modelli pre-addestrati su grandi quantità di dati generici per specifici compiti di classificazione, come la rilevazione della tossicità nei testi. In questa fase, il modello viene ulteriormente addestrato su un dataset più piccolo e specifico, affinché possa affinare le sue capacità di riconoscere pattern rilevanti per il task target.

- **Modelli utilizzati:**
 - **RoBERTa** (versioni base e large per il dataset monolingua in inglese).
 - **XLM-RoBERTa** (versioni base e large per il contesto multilingua).
 - **CANINE** (versioni S e C, che operano su rappresentazioni basate su caratteri senza necessità di tokenizzazione).

3.4.4 Approcci per le Lingue a Bassa Risorsa

Per gestire le problematiche relative alle lingue con risorse limitate, sono state sperimentate diverse strategie:

Two-Stage Fine-Tuning (TSFT)

- **Primo stadio:** Addestramento iniziale su un sottoinsieme di 10 lingue ad alta risorsa.
- **Secondo stadio:** Successivo fine-tuning su 29 lingue a bassa risorsa o 21 lingue a bassissima risorsa.

Adapter

Gli Adapter [6] sono moduli leggeri e parametrizzati che vengono inseriti all'interno di modelli pre-addestrati per consentire un adattamento specifico a task o domini particolari, senza la necessità di riaddestrare l'intero modello.

Applicazione:

- Implementazione di Adapter specifici per lingue a bassa risorsa, inseriti nelle architetture Transformer uno per ogni singola lingua o per gruppi di lingue.
- Valutazione dell'impatto degli Adapter sul processo di fine-tuning, studiando come il numero di dati di addestramento influenzi la capacità del modello di generalizzare sui dati tossici.

Meta-Learning

Il Meta-Learning consente di ottenere modelli che si adattano rapidamente a nuove lingue o domini con pochi dati, migliorando la capacità di generalizzazione in scenari a bassa risorsa. In questo lavoro, sono stati sperimentati due approcci: MAML e Reptile.

MAML con Adapters L'algoritmo MAML (Model-Agnostic Meta-Learning) [7] mira a trovare una buona inizializzazione dei parametri che possa essere rapidamente adattata a nuove task. In questo contesto, MAML viene utilizzato per ottimizzare specificamente gli adapter inseriti nei modelli Transformer.

Applicazione:

- **Definizione delle Task:** Le task vengono generate a partire da sottoinsiemi di dati provenienti da lingue a bassa risorsa, dove ogni task consiste nel fine-tuning rapido di un adapter su un piccolo set di dati.
- **Procedura di Addestramento:**
 - Per ciascuna task, il modello con gli adapter viene addestrato per pochi passi (inner loop) per adattarsi alla specifica lingua.

- I gradienti ottenuti da ogni task vengono aggregati per aggiornare l’inizializzazione globale degli adapter (outer loop). In questo modo, l’adapter impara a essere più flessibile e a generalizzare meglio a nuove lingue con pochi esempi.
- **Ottimizzazione degli Adapter:** Durante il processo, gli adapter vengono ottimizzati separatamente rispetto ai parametri di base del modello. Questo approccio consente di mantenere invariati i parametri principali del modello Transformer, concentrandosi sull’adattamento delle specifiche caratteristiche linguistiche per ciascuna task.
- **Meta-Training:** Il processo di meta-training viene eseguito su più lingue, con l’algoritmo MAML che ottimizza la capacità del modello di adattarsi rapidamente a ciascuna lingua a bassa risorsa. Gli adapter vengono inizializzati in modo tale da poter essere rapidamente adattati con un numero ridotto di esempi.
- **Sperimentazioni:**
 - Sono stati confrontati approcci in cui gli adapter sono specifici per ogni lingua rispetto a gruppi di lingue condivise.

Reptile Reptile [8] è un algoritmo di meta-learning che, similmente a MAML, punta a trovare una buona inizializzazione dei parametri per consentire un rapido adattamento a nuove task. A differenza di MAML, Reptile non richiede la computazione esplicita di gradienti di secondo ordine.

Applicazione:

- **Definizione delle Task:** Le task vengono create selezionando mini-dataset rappresentativi da lingue a bassa risorsa e a bassissima risorsa, in modo da simulare scenari di adattamento rapido.
- **Procedura di Addestramento:**
 - Il modello viene addestrato su ogni task per un numero limitato di passi.

- Dopo ogni task, i pesi del modello vengono aggiornati in direzione della media dei pesi ottenuti, favorendo un'ottimizzazione che permette un rapido adattamento alle nuove lingue.

- **Ottimizzazione degli Iperparametri:**

- È stata implementata la validazione incrociata per valutare la robustezza del modello.
- L'ottimizzazione degli iperparametri è stata condotta utilizzando Optuna [25], al fine di identificare la configurazione ottimale per il learning rate interno, la dimensione dei task e altri parametri critici.

CAPITOLO 4

Analisi dei Risultati

In questo capitolo vengono presentati e discussi criticamente i risultati ottenuti dalle sperimentazioni descritte nel Capitolo 3. L'analisi è strutturata in quattro sezioni, ognuna focalizzata su un aspetto specifico del metodo, in modo da evidenziare come ciascun esperimento contribuisca a rispondere alle domande di ricerca formulate.

4.1 Feature Tradizionali e Shallow ML

In questa sezione vengono analizzati i risultati ottenuti utilizzando tecniche tradizionali di feature extraction (TF-IDF e feature ingegnerizzate) in combinazione con modelli di shallow machine learning su dataset monolingua inglese.

4.1.1 Analisi Feature e Risultati

Le analisi sono state condotte su feature tradizionali (lunghezza, frequenza di parole tossiche, polarità e soggettività) per valutare la loro relazione con la tossicità dei messaggi.

Feature di Lunghezza

Sono state esaminate tre feature di lunghezza:

- **Numero di caratteri:** correlazione molto debole ($r \approx 0.004$), con medie simili tra messaggi tossici (≈ 1429) e non tossici (≈ 1358) e una differenza non statisticamente significativa ($p > 0.05$).
- **Numero di parole:** correlazione bassa ($r \approx 0.018$), con medie di 238 e 193 rispettivamente, e una t-statistic che non raggiunge la significatività ($p > 0.05$).
- **Numero di frasi:** correlazione leggermente maggiore ($r \approx 0.032$) e differenza significativa ($p \approx 0.0012$), con messaggi tossici che risultano più articolati (media ≈ 14.6 frasi vs. ≈ 9.7).

Questi risultati suggeriscono che, mentre la lunghezza complessiva (caratteri e parole) non è un indicatore chiave, la struttura del discorso, intesa come numero di frasi, è significativamente associata alla tossicità.

Frequenza Parole Tossiche

La feature `toxic_word_frequency`, estratta tramite il dataset *Multilingual Toxic Lexicon* [26], ha mostrato una correlazione moderata con la tossicità ($r \approx 0.33$), indicando che la presenza di parole tossiche è un buon indicatore del livello di tossicità.

Test Combinato e Importanza delle Feature

Sono state valutate combinazioni delle feature di lunghezza e la frequenza di parole tossiche utilizzando modelli di shallow ml, con accuratezza comprese tra il 74% e il 75%. I test di importanza hanno evidenziato che:

- **Random Forest:** la `toxic_word_frequency` risulta la feature più rilevante, seguita dalle misure di lunghezza.
- **Gradient Boosting:** conferma il ruolo preminente della `toxic_word_frequency` (importanza elevata), con contributi minori dalle feature di lunghezza.

Feature di Polarità e Soggettività

Le feature estratte con *textBlob* hanno prodotto correlazioni deboli: la polarità mostra una leggera correlazione negativa ($r \approx -0.10$), mentre la soggettività risulta moderatamente correlata ($r \approx 0.17$) con la tossicità.

Risultati Complessivi

L'addestramento dei modelli su tutte le feature ha portato al miglior risultato con il modello Gradient Boosting, che ha raggiunto un'accuratezza del 75.6%. Ciò ha confermato le limitazioni dei metodi tradizionali nella cattura della complessità semantica e contestuale, costituendo il punto di partenza per valutare l'impatto degli embeddings derivati dai modelli Transformer. Inoltre, come mostrato dalla Tabella 4.1, si possono osservare alcuni aspetti interessanti per le due classi:

- **Non Tossico:** Un **recall** del 90% indica che il modello identifica quasi tutti i campioni non tossici, mentre una **precision** del 70% rivela la presenza di alcuni falsi positivi.
- **Tossico:** Una **precision** dell'86% garantisce predizioni affidabili per i campioni tossici, ma un **recall** del 61% mostra che alcuni campioni tossici non vengono rilevati (falsi negativi).

Da ciò si deduce che il modello ha un forte bias verso la classe non tossica.

Classe	Precision	Recall	F1-score	Supporto
Non Tossico	0.70	0.90	0.79	987
Tossico	0.86	0.61	0.71	960
Accuracy	-	-	0.76	1947
Macro avg	0.78	0.75	0.75	1947
Weighted avg	0.78	0.76	0.75	1947

Tabella 4.1: Risultati della classificazione con Gradient Boosting

4.2 Embeddings da Transformer per Shallow ML

Questa sezione si focalizza sull'utilizzo di embeddings estratti dai modelli Transformer come input per algoritmi di shallow ML. L'impiego degli embeddings ha permesso di catturare in modo più efficace le relazioni semantiche e contestuali, portando a un miglioramento consistente delle prestazioni.

Osservazioni Gli esperimenti hanno registrato un incremento dell'accuratezza, raggiungendo circa l'88%, a conferma dell'efficacia degli embeddings nel migliorare la capacità classificatoria del sistema.

Dettagli Sperimentali Per l'estrazione degli embeddings sono stati utilizzati i modelli *RoBERTa-base* e *RoBERTa-large* applicati a un dataset monolingua contenente quasi 200k messaggi in inglese. Per entrambi i casi, il miglior modello di classificazione è stato SVM, che ha raggiunto rispettivamente l'87.9% e l'87.5% di accuratezza. Questi risultati evidenziano che l'utilizzo di un modello più grande (e quindi con embeddings di dimensione 1024) non ha portato a vantaggi significativi rispetto a quelli ottenuti con embeddings di dimensione 768.

Inoltre, per quanto riguarda la classificazione delle 10 lingue ad alta risorsa, è stato testato sia il modello *XLM-RoBERTa-base* che *XLM-RoBERTa-large* su due dataset: uno con 2k messaggi bilanciati per lingua(2k) e un altro con 10k messaggi bilanciati per lingua ottenuti tramite data augmentation (10k_T). Dai risultati riportati nella Tabella 4.2 emerge che tutte le configurazioni si aggirano attorno all'87% di accuratezza, indicando che in questo contesto né l'utilizzo di un modello più grande né l'impiego di una quantità maggiore di dati apportano benefici significativi.

Prendendo in considerazione le singole lingue, risulta invece che il modello con l'accuracy media più alta nonchè SVM con embeddings estratte con *XLM-RoBERTa-base* dal dataset 2k, ottiene le migliori performance per le lingue: Cinese, Inglese, Giapponese e Russo. Mentre si ottengono migliori risultati nelle lingue: Tedesco, Italiano, Portoghese e Turco andando a utilizzare gli embeddings di *XLM-RoBERTa-large*. Le restanti lingue, Francese e Spagnolo, traggono maggior beneficio nell'utilizzo del dataset più grande (10k_T).

Analizzando le metriche di precision e recall per classe, riferendoci ai risultati riportati nella Tabella 4.3, risultano più bilanciate nell'utilizzo di embeddings con dimensione minore e a parità di dimensione nell'addestramento con più dati.

Mod	Emb	DS	Chi.	Eng.	Fr.	Ger.	Ita.	Jap.	Port.	Rus.	Spa.	Tur.	Avg.
SVM	base	2k	94.0	86.8	83.0	88.8	84.5	89.8	88.0	87.2	84.5	87.0	87.4
SVM	base	10k_T	92.4	85.4	85.9	89.4	85.8	84.2	86.7	86.9	85.8	86.9	86.9
SVM	large	2k	92.5	86.2	81.2	92.5	87.2	87.0	89.0	85.2	83.5	88.0	87.3
SVM	large	10k_T	91.8	84.9	84.6	90.5	86.2	85.8	85.6	86.4	84.5	87.4	86.8

Tabella 4.2: Confronto delle metriche di accuratezza dei modelli di shallow ml con l'utilizzo di embeddings per lingua ad alta risorsa

🔗 **Answer to RQ₁.** L'uso di embeddings estratti dai modelli Transformer si è rivelato significativamente superiore alle tecniche tradizionali, con un incremento dell'accuratezza da circa il 76% fino a valori vicino al 88% su dataset in lingua inglese e con metriche di precision e recall per classe decisamente più bilanciate.

Mod	Emb	DS	Classe	Precision	Recall	F1_Score	Support	Accuracy
SVM	R b	200k_en	Non Tossico	87.59	88.22	87.91	19294	–
			Tossico	88.14	87.50	87.82	19293	–
			macro	87.86	87.86	87.86	38587	87.86
SVM	R l	200k_en	Non Tossico	86.85	88.35	87.60	19294	–
			Tossico	88.15	86.62	87.38	19293	–
			macro	87.50	87.49	87.49	38587	87.49
SVM	XLM-R b	2k	Non Tossico	86.33	88.75	87.52	2000	–
			Tossico	88.43	85.95	87.17	2000	–
			macro	87.38	87.35	87.35	4000	87.35
SVM	XLM-R b	10k_T	Non Tossico	86.13	88.04	87.07	10000	–
			Tossico	87.77	85.82	86.78	10000	–
			macro	86.95	86.93	86.93	20000	86.93
SVM	XLM-R l	2k	Non Tossico	85.34	89.95	87.59	2000	–
			Tossico	89.38	84.55	86.90	2000	–
			macro	87.36	87.25	87.24	4000	87.25
SVM	XLM-R l	10k_T	Non Tossico	85.25	88.92	87.04	10000	–
			Tossico	88.42	84.61	86.47	10000	–
			macro	86.83	86.77	86.76	20000	86.77

Tabella 4.3: Risultati delle metriche per classe dei modelli SVM con diversi embeddings e dataset.

4.3 Fine-Tuning di Modelli Transformer

In questa sezione vengono esaminati i risultati ottenuti attraverso il fine-tuning dei modelli Transformer su dataset multilingua, con particolare attenzione sia alle lingue ad alta risorsa che a quelle a bassa risorsa.

4.3.1 Lingue ad Alta Risorsa

Per le lingue ad alta risorsa sono stati impiegati due approcci:

1. **Dataset monolingua (200k_en):** Da quanto evidenziato nella Tabella 4.4, l'addestramento su questo dataset ha mostrato che, sebbene il modello *RoBERTa-base*

ottenga prestazioni appena superiori rispetto alla versione large, le metriche di precision e recall per classe risultano meno bilanciate rispetto a quelle ottenute con *RoBERTa-large*. Tuttavia in alcuni contesti un valore di recall maggiore per classe "Tossico" in favore della versione base viene prediletto in modo da rilevare al meglio i messaggi tossici anche al costo di accettare più falsi positivi.

2. **Dataset multilingua per 10 lingue ad alta risorsa:** Sono stati testati modelli su due configurazioni di dati:

- **2k messaggi bilanciati per lingua**
- **10k messaggi bilanciati per lingua** (ottenuti tramite data augmentation)

Dai risultati riportati nella Tabella 4.4 emerge che:

- I modelli basati su tokens (XLM-RoBERTa) non mostrano miglioramenti significativi aumentando la quantità di dati.
- I modelli *Canine-S* e *Canine-C*, basati su rappresentazioni a livello di caratteri, registrano un incremento dell'accuratezza rispettivamente del 5.5% e del 4.1%.

Nonostante ciò, il modello che ottiene le performance migliori è *XLM-RoBERTa-base*, con un'accuratezza del 93.1%. Considerando le metriche per classe risulta che, nel caso di *XLM-RoBERTa*, utilizzando la versione base e addestrando su più dati le metriche si bilanciano, mentre utilizzando la versione large con meno dati risulta per la classe "Tossico" il valore minimo di precision al fronte del valore massimo di recall, viceversa per la classe "Non Tossico". Per quanto riguarda i modelli Canine, in tutte le configurazioni testate le metriche per classe rimangono bilanciate. Analizzando la metrica di accuratezza per singola lingua, riportati nella Tabella 4.5, risulta che il modello con la media di accuratezza più alta nonché *XLM-RoBERTa-base* addestrato sul dataset 2k, ottiene le migliori performance per le lingue: Italiano, Giapponese e Turco. Mentre si ottengono migliori risultati nelle lingue: Francese, Tedesco e Spagnolo utilizzando il dataset più grande(10k_T). Le restanti lingue: Cinese, Inglese,

Portoghese e Spagnolo hanno ottenuto performance migliori utilizzando il modello large, le prime due addestrato sul dataset 2k le restanti due su 10k_T.

4.3.2 Lingue a Bassa Risorsa: Test in Zero-Shot

Per le lingue a bassa risorsa, in questa sezione vengono riportati i test in zero-shot, poiché i risultati relativi al TSFT verranno discussi nella sezione successiva. In particolare, sono stati valutati:

- **XLM-RoBERTa-base** addestrato su 2k messaggi per lingua,
- **Canine-S** addestrato su 10k messaggi (con traduzione),
- **RoBERTa-base** addestrato su 200k messaggi monolingua in inglese.

I dataset di test utilizzati riguardano:

- 29 lingue a bassa risorsa,
- 21 lingue a bassissima risorsa.

Da come evidenziato dalla Tabella 4.6, il miglior modello testato in zero-shot è risultato essere *XLM-RoBERTa-base* addestrato su 2k messaggi per lingua, che ha ottenuto un'accuratezza dell'83.9% sulle 29 lingue e dell'81.9% sulle ulteriori 21 lingue.

🔗 **Answer to RQ₂. Il fine-tuning di modelli Transformer su dati multilingua ha significativamente migliorato la capacità di classificazione della tossicità rispetto a metodi basati su embeddings statici, evidenziato dalle alte performance ottenute, fino al 93.1% nelle lingue ad alta risorsa.**

Model	DS	Classe	Precision	Recall	F1_Score	Support	Accuracy
RoBERTa b	200k_en	Non Tossico	95.50	92.95	94.21	9647	–
		Tossico	93.13	95.62	94.36	9647	–
		macro	94.31	94.28	94.28	19294	94.28
RoBERTa l	200k_en	Non Tossico	94.28	94.01	94.15	9647	–
		Tossico	94.03	94.30	94.16	9647	–
		macro	94.15	94.15	94.15	19294	94.15
XLM-R b	10k_T	Non Tossico	93.25	92.80	93.02	5000	–
		Tossico	92.83	93.28	93.06	5000	–
		macro	93.04	93.04	93.04	10000	93.04
XLM-R b	2k	Non Tossico	93.97	92.00	92.98	1000	–
		Tossico	92.16	94.10	93.12	1000	–
		macro	93.07	93.05	93.05	2000	93.05
XLM-R l	10k_T	Non Tossico	92.53	93.46	93.00	5000	–
		Tossico	93.39	92.46	92.92	5000	–
		macro	92.96	92.96	92.96	10000	92.96
XLM-R l	2k	Non Tossico	94.64	88.30	91.36	1000	–
		Tossico	89.03	95.00	91.92	1000	–
		macro	91.84	91.65	91.64	2000	91.65
Canine-c	10k_T	Non Tossico	86.62	90.22	88.38	5000	–
		Tossico	89.80	86.06	87.89	5000	–
		macro	88.21	88.14	88.13	10000	88.14
Canine-c	2k	Non Tossico	82.15	83.30	82.72	1000	–
		Tossico	83.06	81.90	82.48	1000	–
		macro	82.61	82.60	82.60	2000	82.60
Canine-s	10k_T	Non Tossico	89.08	88.08	88.58	5000	–
		Tossico	88.21	89.20	88.70	5000	–
		macro	88.64	88.64	88.64	10000	88.64
Canine-s	2k	Non Tossico	85.29	83.50	84.39	1000	–
		Tossico	83.84	85.60	84.71	1000	–
		macro	84.57	84.55	84.55	2000	84.55

Tabella 4.4: Confronto metriche per classe del Fine-Tuning di modelli Transformer.

Model	Dataset	Chi.	Eng.	Fr.	Ger.	Ita.	Jap.	Port.	Rus.	Spa.	Tur.	AVG
Canine-c	10k_T	93.4	86.2	86.9	91.1	87.6	91.6	87.9	84.7	85.1	86.9	88.1
Canine-c	2k	91.0	80.5	75.5	85.0	84.5	84.0	81.5	79.0	76.5	88.5	82.6
Canine-s	10k_T	94.1	87.5	86.4	92.5	87.5	90.0	88.1	85.2	87.0	87.5	88.6
Canine-s	2k	93.5	82.5	77.5	89.0	87.5	83.5	81.5	85.0	81.0	84.5	84.6
XLM-R b	10k_T	97.0	92.0	92.8	94.9	91.8	93.3	90.8	91.6	93.2	93.0	93.0
XLM-R b	2k	97.5	93.0	91.0	93.5	92.0	94.5	90.5	91.5	91.5	95.5	93.1
XLM-R l	10k_T	96.7	93.3	92.0	94.7	91.7	94.0	92.6	92.2	90.8	91.6	93.0
XLM-R l	2k	98.5	95.0	85.5	93.5	90.0	93.5	89.0	89.5	91.0	91.0	91.6

Tabella 4.5: Confronto delle metriche di accuratezza risultanti dal Fine-Tuning sul dataset ad alta risorsa

Model	DS	Classe	Precision	Recall	F1_Score	Support	Accuracy
XLM-R b_2k	200_29	Non Tossico	82.67	85.86	84.24	2900	–
		Tossico	85.29	82.00	83.61	2900	–
		macro	83.98	83.93	83.93	5800	83.93
Canine-s_10k_T	200_29	Non Tossico	71.78	75.69	73.68	2900	–
		Tossico	74.29	70.24	72.21	2900	–
		macro	73.03	72.97	72.95	5800	72.97
RoBERTa b_200k_en	200_29	Non Tossico	76.02	77.83	76.91	2900	–
		Tossico	77.29	75.45	76.36	2900	–
		macro	76.65	76.64	76.63	5800	76.64

Tabella 4.6: Confronto delle metriche ottenute testando i migliori modelli in modalità zero-shot.

4.4 Approcci per le Lingue a Bassa Risorsa: TSFT, Adapter e Meta-Learning

Questa sezione analizza le strategie adottate per gestire lingue con risorse limitate, confrontando tre approcci: TSFT, Adapter e tecniche di Meta-Learning. L'obiettivo è valutare come questi metodi influenzino la generalizzazione del modello in contesti cross-lingua con dati scarsi.

4.4.1 TSFT (Two-Stage Fine-Tuning)

Il metodo TSFT prevede l'utilizzo di un modello *XLM-RoBERTa-base* precedentemente addestrato su 2k esempi per ciascuna delle 10 lingue ad alta risorsa, che viene poi riaddestrato sulle lingue a bassa risorsa. I risultati evidenziati nella Tabella 4.7 mostrano che:

- Riaddestrare il modello utilizzando 200 esempi per lingua porta ad un'accuratezza del 89.3%, inferiore rispetto all'addestramento su 1k esempi per lingua (92.5%).
- Il riaddestramento con più dati migliora l'adattamento al task nelle nuove lingue, ma, testando nuovamente il modello sul task originale delle lingue ad alta risorsa, si osserva un fenomeno di *catastrophic forgetting*: la perdita di performance è pari al 3% quando si usano 1k esempi, contro una perdita minore (0.8%) con 200 esempi.
- Un fine-tuning diretto, impiegando 1k esempi per lingua sia per le 10 lingue ad alta risorsa che per le 29 lingue a bassa risorsa, ha portato a performance complessive del 90.4%.

Nel casi precedenti le metriche di precisione e recall per classe sono bilanciate. Inoltre, testando il modello in modalità zero-shot sul dataset delle 21 lingue a bassissima risorsa si è osservato che:

- TSFT con 200 esempi per lingua raggiunge un'accuratezza dell'87.5%.

- TSFT con 1k esempi per lingua ottiene un'accuratezza inferiore (84.8%), indicando una perdita nella generalizzazione cross-lingua.

In questi ultimi due casi le metriche di precision e recall per classe sono fortemente sbilanciate. Nel primo caso si ha per la classe "Non Tossico" un alto valore di precision (90%) e un basso valore di recall (84.3%), per la classe "Tossico" vale il viceversa (85.2%/90.7%). Nel secondo caso avviene esattamente l'opposto con classe "Non Tossico" con bassa precision (82.3%) e alta recall (88.6%) e per la classe "Tossico" vale il viceversa (87.6%/81%). Questi risultati fanno del modello basato su *XLM-RoBERTa-base* riaddestrato con 200 esempi per lingua la baseline per i successivi approcci.

4.4.2 Meta-Learning

Sono state effettuate sperimentazioni con approcci di meta-apprendimento, tra cui:

1. MAML con Adapter:

- *Addestramento Base*: il modello viene pre-addestrato su 1k esempi per ciascuna delle 10 lingue ad alta risorsa per apprendere una rappresentazione generale.
- *Meta-Training MAML*: utilizzando un set separato di 1k esempi per le stesse 10 lingue, viene addestrato un "meta_learned_adapter".
- *Fine-Tuning su Lingue a Bassa Risorsa*: l'inizializzazione ottenuta viene usata per addestrare 29 adapter, uno per ciascuna lingua a bassa risorsa, con 200/1k messaggi ciascuno.

I risultati (Tabella 4.7) hanno portato ad un'accuratezza del 84.9%. Raggruppando più lingue in un singolo adapter si è registrato un incremento dell'1.2% di accuratezza, ma le performance restano inferiori rispetto alla baseline TSFT. Le metriche di precision e recall per classe sono bilanciate.

2. Reptile: L'algoritmo Reptile è stato applicato ai seguenti modelli:

- *XLM-RoBERTa-base* addestrato sul dataset 2k, in configurazione per il contesto a **bassa risorsa**;
- Il modello baseline ottenuto dal precedente TSFT, in configurazione per il contesto a **bassissima risorsa**.

L'applicazione di Reptile ha prodotto i seguenti risultati:

- **Dataset a bassa risorsa:** è stata raggiunta un'accuratezza massima del 91.5% (utilizzando il dataset 1k_T29). Le metriche per la classe "Non Tossico" sono risultate pari a 90.4% (precision) e 93% (recall), mentre per la classe "Tossico" rispettivamente 92.8% (precision) e 90.1% (recall).
- **Dataset a bassissima risorsa:** è stata ottenuta un'accuratezza pari all'86.5%, accompagnata da metriche di precision e recall notevolmente sbilanciate. In particolare, per la classe "Non Tossico" si sono registrate precision e recall pari a 92.6% e 79.4%, mentre per la classe "Tossico" 81.9% e 93.7%.

Il secondo risulta superiore al corrispettivo modello baseline TSFT, ma analizzando le metriche per classe risulta molto meno bilanciato.

4.4.3 Adapter Standard

Un ulteriore approccio consiste nell'impiegare adapter specifici per lingua, i quali sono stati applicati agli stessi modelli definiti nella sezione Reptile.

- Per le lingue a bassa risorsa, l'uso di adapter ha portato a performance fino all'87.6% di accuratezza, sebbene inferiori rispetto al modello baseline.
- Per le lingue a bassissima risorsa, gli adapter hanno raggiunto un'accuratezza del **89.3%**, superando il baseline di **1.8%**.
- Sono state sperimentate configurazioni con adapter multi-lingua (un singolo adapter per più lingue), che hanno prodotto risultati ottimi ma non superiori rispetto all'approccio con un adapter per lingua.
- Un ulteriore esperimento con un fine-tuning in tre fasi (three-stage fine-tuning) ha portato a performance inferiori, con una riduzione del 3% nelle lingue a bassissima risorsa.

- Considerando le metriche di precision e recall per classe possiamo concludere che all’aumentare dei dati queste tendono a bilanciarsi nel caso delle lingue a bassa risorsa. Mentre nel caso delle lingue a bassissima risorsa sono sensibilmente sbilanciate con valori rispettivamente del 92.3%/85.7% per la classe "Non Tossico" e di 86.7%/92.9% per la classe "Tossico".

Approccio	Lingue a Bassa Risorsa		Lingue a Bassissima Risorsa		Note
	200 esempi	1k esempi	Fine-Tuning	Zero-Shot	
TSFT	89.3%	92.5%	86.3%	87.5%/84.8%	Baseline migliore
Adapter Standard	84.3%	87.6%	89.3%/88.1%	-	Migliore sulle lingue a bassissima risorsa
MAML con Adapter	79.1%/80.9%	84.9%/86.1%	-	-	Peggior di TSFT
Reptile	87%	91.5%	86.5%	-	Migliore di TSFT lingue a bas.ma risorsa

Effetto del Catastrophic Forgetting per TSFT:

- Accuracy su lingue ad alta risorsa dopo fine-tuning con 200 esempi: 93.1% → 92.3% (-0.8%)
- Accuracy su lingue ad alta risorsa dopo fine-tuning con 1k esempi: 93.1% → 90.1% (-3%)

Tabella 4.7: Confronto tra TSFT, Adapter e Meta-Learning

I valori separati da "/" indicano, nel caso del TSFT, la variazione delle performance in base alla scelta del dataset, mentre per gli approcci basati su Adapter rappresentano il confronto tra l’uso di adapter singoli e multi-lingua. Inoltre i modelli su cui è stato applicato il 1°, 2° o 4° approccio sono *XLM-RoBERTa-base* addestrato sul dataset 2k per il contesto delle lingue a bassa risorsa e il medesimo modello con TSFT sul dataset 200_29 per il contesto delle lingue a bassissima risorsa.

🔗 **Answer to RQ₃.** L’uso di tecniche di meta-learning, come MAML e Reptile, non ha portato a performance superiori rispetto al modello baseline. Tuttavia, l’impiego degli adapter nel contesto delle 21 lingue a bassissima risorsa ha incrementato le performance, confermando l’efficacia di questo approccio in scenari con disponibilità estremamente limitata di dati.

4.5 Confronto Computazionale: Setup Sperimentale e Analisi dei Modelli

4.5.1 Requisiti computazionali e ambienti di esecuzione

Tutti gli esperimenti sono stati condotti in ambiente locale, utilizzando *Anaconda* come gestore di ambienti e *Jupyter Lab* per lo sviluppo e l'esecuzione interattiva del codice.

Le principali librerie impiegate includono:

- `pyarrow` e `pandas` per il preprocessing e la gestione efficiente dei dati;
- `scikit-learn` per l'implementazione dei modelli di apprendimento automatico tradizionale;
- `transformers` di Hugging Face, in combinazione con `PyTorch`, per i modelli basati su architetture Transformer;
- `adapters` per gli esperimenti con Adapter;
- `learn2learn` per gli approcci di meta-apprendimento.

L'intero lavoro è stato eseguito su una workstation riassemblata ad hoc, dotata delle seguenti specifiche:

- Processore: AMD Ryzen 5 5600X (6 core/12 thread, 3.7GHz base, 4.6GHz boost);
- Memoria RAM: 64GB DDR4 a 3600MHz CL18;
- Scheda video: NVIDIA RTX 3090 (24GB GDDR6X, ver. Asus Rog Strix OC).

4.5.2 Confronto tra Modelli Tradizionali (Shallow ML)

In questa sezione vengono confrontati i modelli di apprendimento tradizionale in termini di accuratezza, tempo di addestramento e dimensioni finali del modello.

I modelli *Logistic Regression* (LR) e *Support Vector Machine* (SVM) sono stati eseguiti su un singolo core a 4.6GHz, mentre *Random Forest* (RF) e *K-Nearest Neighbors* (KNN) sono stati eseguiti in modalità multi-core (6C/12T a 4.1GHz). Infine, *XGBoost* (XGB)

è stato eseguito su GPU, sfruttando un hardware significativamente più performante rispetto alla CPU.

Come mostrato nella Tabella 4.9, il modello con la miglior accuratezza in ogni configurazione è risultato essere SVM. Tuttavia, un'analisi più approfondita dei tempi di addestramento e della dimensione finale del modello mostra che:

- SVM presenta un tempo medio di addestramento circa 192 volte superiore rispetto al secondo miglior modello per accuratezza (che risulta essere RF nel 4/6 dei casi e LR nel restante 2/6).
- Il peso del modello SVM è sistematicamente il secondo più elevato.

Considerando il compromesso tra performance, efficienza computazionale e dimensioni, i modelli più vantaggiosi risultano essere LR e XGB. Il primo produce modelli con dimensioni significativamente inferiori (in media circa 15 volte più piccoli rispetto a XGB), mentre il secondo garantisce i migliori tempi di addestramento, grazie all'esecuzione su GPU.

4.5.3 Confronto tra Modelli di Deep Learning

In questa sezione vengono confrontati i modelli di deep learning utilizzati per il fine-tuning in base a tre fattori principali: accuratezza, tempo di addestramento e numero di parametri. Come mostrato nella Tabella 4.8, tutti i modelli Transformer superano ampiamente le performance di accuratezza dei modelli tradizionali.

XLM-RoBERTa-base (XLM-R b) si conferma il modello più bilanciato, raggiungendo un'accuratezza del 93.05% sul dataset multilingua con 2k messaggi per lingua, e mantenendo una performance equivalente anche su dataset più ampio (10k_T), con tempi di addestramento relativamente contenuti (13.3 e 63.76 minuti rispettivamente).

XLM-RoBERTa-large (XLM-R l), pur avendo il numero di parametri doppio rispetto alla versione base (560M), non mostra un miglioramento in termini di accuratezza. Al contrario, risulta meno preciso con 91.65% su 2k e 92.96% su 10k_T, a fronte di tempi di addestramento circa 2-3 volte superiori. Questo indica che l'aumento della capacità del modello non sempre si traduce in un incremento delle performance in scenari con quantità di dati limitata.

RoBERTa-base (125M parametri) e **RoBERTa-large** (355M) mostrano invece le migliori performance assolute sul dataset monolingua inglese (200k_en), con accuratezze rispettivamente di 94.28% e 94.15%. Tuttavia, l'incremento nel tempo di addestramento è notevole per la versione large (387 minuti), rendendo RoBERTa-base una scelta più efficiente a parità di performance.

Infine, i modelli **Canine** (S e C) offrono un'interessante alternativa di tipo token-free. Sebbene le loro performance siano inferiori rispetto a XLM-R, risultano competitive in termini di efficienza. Con soli 132M parametri, Canine-S raggiunge l'88.64% su 10k_T, con tempi di training molto contenuti (circa 36 minuti). Le prestazioni migliorano significativamente all'aumentare dei dati disponibili, suggerendo una buona scalabilità.

Model	Dataset	Accuracy	Training Time (min)	Number of Parameters (M)
XLM-R b	2k	93.05	13.30	278M
XLM-R b	10k_T	93.04	63.76	278M
XLM-R l	2k	91.65	34.59	560M
XLM-R l	10k_T	92.96	196.17	560M
RoBERTa b	200k_en	94.28	117.59	125M
RoBERTa l	200k_en	94.15	387.10	355M
Canine-C	2k	82.60	7.45	132M
Canine-S	2k	84.55	7.55	132M
Canine-C	10k_T	88.14	36.11	132M
Canine-S	10k_T	88.64	36.48	132M

Tabella 4.8: Confronto tra i modelli per il fine-tuning: accuratezza, tempo di training e numero di parametri.

Dataset	Embeddings	Model	Accuracy	Training Time (s)	Model Size (.joblib)
200k_en	R b	KNN	85.49	0.3313	453.4 MB
		LR	87.64	26.025	25.8 KB
		RF	86.16	67.455	171.1 MB
		SVM	87.86	3008.504	280.8 MB
		XGB (GPU)	87.73	4.428	512.2 KB
200k_en	R l	KNN	82.54	0.4434	604.1 MB
		LR	87.44	81.893	35.4 KB
		RF	84.35	80.830	184 MB
		SVM	87.49	9808.476	374.3 MB
		XGB (GPU)	86.36	5.754	520.3 KB
2k	XLM-R b	KNN	81.43	0.0300	47 MB
		LR	86.88	1.5491	28.8 KB
		RF	84.78	4.4716	18.7 MB
		SVM	87.35	32.0046	32.9 MB
		XGB (GPU)	86.48	1.7084	443.2 KB
10k_T	XLM-R b	KNN	84.21	0.1411	235 MB
		LR	86.71	15.7731	28.8 KB
		RF	85.53	31.0553	92.2 MB
		SVM	86.93	820.4223	160.4 MB
		XGB (GPU)	86.91	3.0103	502.2 KB
2k	XLM-R l	KNN	73.55	0.0490	62.7 MB
		LR	86.40	3.6729	39.4 KB
		RF	78.75	6.5302	22.4 MB
		SVM	87.25	43.1691	49.5 MB
		XGB (GPU)	82.35	2.8212	477.3 KB
10k_T	XLM-R l	KNN	78.00	0.1912	313.1 MB
		LR	86.44	28.0760	39.4 KB
		RF	80.24	35.4267	106.7 MB
		SVM	86.77	1329.3530	228.7 MB
		XGB (GPU)	83.82	3.9247	524.4 KB

Tabella 4.9: Performance dei modelli di shallow ML in relazione all'accuratezza, al tempo di training e alla dimensione del modello salvato.

4.5.4 Confronto Approcci per le Lingue a Bassa Risorsa

La Tabella 4.10 confronta diversi approcci per la classificazione della tossicità in lingue a bassa risorsa. L'approccio di TSFT per XLM-RoBERTa-base, preaddestrato su 10 lingue e successivamente addestrato su 29 lingue, raggiunge la migliore accuratezza (89.31%), ma richiede l'intero modello (278M parametri).

Gli adapter offrono un'alternativa più leggera (43M parametri), con una perdita limitata di performance (84.31%), e si dimostrano particolarmente efficaci soprattutto su lingue con appena 40 esempi, raggiungendo un'accuracy di 89.29%, con meno di 34 secondi di addestramento.

Le tecniche di meta-learning mostrano risultati variabili: MAML+Adapters riduce ulteriormente i parametri ma ottiene performance inferiori (79.14%), mentre Reptile mantiene buoni risultati (86.98%) a costo di un tempo di addestramento maggiore.

In conclusione, l'approccio TSFT + Adapters rappresenta il miglior compromesso tra accuratezza, efficienza e scalabilità, risultando ideale per scenari multilingua con dati limitati.

Approccio (Model)	Dataset	Accuracy	Training Time (s)	Number of Parameters (M)
TSFT (XLM-R b 2k)	200_29	89.31	239.02	278M
Adapters (XLM-R b 2k)	200_29	84.31	529.64	43.1M
MAML + Adapters (XLM-R b 1k)	200_29	79.14	83.72 + 358.46	1.5M + 25.9M
Reptile (XLM-R b 2k)	200_29	86.98	1196.54	278M
Adapters (TSFT XLM-R b 2k 200_29)	40_21	89.29	33.76	31.2M

Tabella 4.10: Confronto tra approcci avanzati: accuratezza, tempo di training e numero di parametri.

CAPITOLO 5

Conclusioni

Questo lavoro ha esplorato strategie per migliorare la classificazione della tossicità in contesti multilingua a bassa risorsa, confrontando approcci classici con tecniche basate su modelli Transformer. I risultati evidenziano chiaramente l'efficacia del *Two-Stage Fine-Tuning*, in cui XLM-ROBERTa-base viene prima addestrato su 10 lingue ad alta risorsa e successivamente riaddestrato su 29 lingue a bassa risorsa con soli 200 esempi per lingua. Questo approccio ha raggiunto un'accuratezza del 92.3% nelle lingue ad alta risorsa e circa l'89.3% nelle lingue a bassa risorsa, dimostrandosi superiore ad alternative come l'uso diretto di embeddings o tecniche di meta-learning. Parallelamente, l'integrazione di adapter si è rivelata particolarmente utile per le lingue con risorse estremamente limitate, permettendo buone performance anche con soli 40 esempi per lingua, grazie alla modularità e leggerezza di tali componenti.

Nonostante i risultati promettenti, rimangono alcune sfide aperte. Anzitutto, l'uso del solo messaggio per la classificazione limita la capacità del modello di cogliere contesti complessi come sarcasmo o ambiguità. L'integrazione del contesto conversazionale, come proposto da Baruah et al. [27], potrebbe migliorare significativamente la rilevazione della tossicità.

Sul piano architetturale, l'adozione di modelli basati su caratteri, come Charformer [28], rappresenta un'alternativa promettente rispetto a Canine, soprattutto in

presenza di lingue con sistemi di scrittura non segmentati. Inoltre, un ampliamento della varietà dei dati, ad esempio includendo testi provenienti da social media, trascrizioni orali oppure forum, potrebbe contribuire a rendere i modelli più robusti e meglio aderenti al linguaggio reale.

Un altro aspetto cruciale è l'analisi dei bias presenti nei dati, in particolare quelli legati a dimensioni culturali o linguistiche. Affrontare questi bias è essenziale per garantire equità e inclusività nei modelli NLP, specie in lingue con scarsa rappresentanza.

In prospettiva, sarebbe utile esplorare meccanismi di adattamento continuo che consentano ai modelli di aggiornarsi dinamicamente con nuovi dati, evitando così la necessità di un riaddestramento completo. Infine, l'integrazione di tecniche di topic modeling, come BERTopic [29] oppure LDA multilingue [30], in linea con quanto proposto da Oskouie et al. [31] per dati in lingua inglese, potrebbe migliorare ulteriormente la capacità dei modelli di cogliere pattern tossici legati a contesti culturali specifici.

In sintesi, le strategie proposte si sono dimostrate efficaci per la classificazione della tossicità in ambienti multilingua eterogenei, anche in scenari caratterizzati da una marcata scarsità di dati. I risultati ottenuti pongono solide basi per ricerche future orientate a una maggiore adattabilità, equità e comprensione contestuale nei sistemi di NLP.

Bibliografia

- [1] W. Zhao, X. Ren, J. Hessel, C. Cardie, Y. Choi, and Y. Deng, “Wildchat: 1m chatGPT interaction logs in the wild,” in *The Twelfth International Conference on Learning Representations*, 2024. [Online]. Available: <https://openreview.net/forum?id=Bl8u7ZRlbM> (Citato alle pagine 1 e 7)
- [2] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, “Attention is all you need,” 2023. [Online]. Available: <https://arxiv.org/abs/1706.03762> (Citato a pagina 2)
- [3] A. Conneau, K. Khandelwal, N. Goyal, V. Chaudhary, G. Wenzek, F. Guzmán, E. Grave, M. Ott, L. Zettlemoyer, and V. Stoyanov, “Unsupervised cross-lingual representation learning at scale,” 2020. [Online]. Available: <https://arxiv.org/abs/1911.02116> (Citato a pagina 2)
- [4] Y. Liu, M. Ott, N. Goyal, J. Du, M. Joshi, D. Chen, O. Levy, M. Lewis, L. Zettlemoyer, and V. Stoyanov, “Roberta: A robustly optimized bert pretraining approach,” 2019. [Online]. Available: <https://arxiv.org/abs/1907.11692> (Citato a pagina 2)
- [5] J. H. Clark, D. Garrette, I. Turc, and J. Wieting, “CANINE: Pre-training an efficient tokenization-free encoder for language representation,” *Transactions*

- of the Association for Computational Linguistics*, vol. 10, p. 73–91, 2022. [Online]. Available: http://dx.doi.org/10.1162/tacl_a_00448 (Citato a pagina 2)
- [6] C. Poth, H. Sterz, I. Paul, S. Purkayastha, L. Engländer, T. Imhof, I. Vulić, S. Ruder, I. Gurevych, and J. Pfeiffer, “Adapters: A unified library for parameter-efficient and modular transfer learning,” in *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*. Singapore: Association for Computational Linguistics, Dec. 2023, pp. 149–160. [Online]. Available: <https://aclanthology.org/2023.emnlp-demo.13> (Citato alle pagine 2 e 13)
- [7] C. Finn, P. Abbeel, and S. Levine, “Model-agnostic meta-learning for fast adaptation of deep networks,” 2017. [Online]. Available: <https://arxiv.org/abs/1703.03400> (Citato alle pagine 3 e 13)
- [8] A. Nichol, J. Achiam, and J. Schulman, “On first-order meta-learning algorithms,” 2018. [Online]. Available: <https://arxiv.org/abs/1803.02999> (Citato alle pagine 3, 8 e 14)
- [9] S. G. Roy, U. Narayan, T. Raha, Z. Abid, and V. Varma, “Leveraging multilingual transformers for hate speech detection,” 2021. [Online]. Available: <https://arxiv.org/abs/2101.03207> (Citato a pagina 5)
- [10] K. Poojitha, A. S. Charish, M. A. K. Reddy, and S. Ayyasamy, “Classification of social media toxic comments using machine learning models,” 2023. [Online]. Available: <https://arxiv.org/abs/2304.06934> (Citato a pagina 5)
- [11] B. Wei, J. Li, A. Gupta, H. Umair, A. Vovor, and N. Durzynski, “Offensive language and hate speech detection with deep learning and transfer learning,” 2021. [Online]. Available: <https://arxiv.org/abs/2108.03305> (Citato a pagina 5)
- [12] C. Nobata, J. R. Tetreault, A. O. Thomas, Y. Mehdad, and Y. Chang, “Abusive language detection in online user content,” *Proceedings of the 25th International Conference on World Wide Web*, 2016. [Online]. Available: <https://api.semanticscholar.org/CorpusID:11546523> (Citato a pagina 6)

-
- [13] Z. Waseem and D. Hovy, "Hateful symbols or hateful people? predictive features for hate speech detection on Twitter," in *Proceedings of the NAACL Student Research Workshop*, J. Andreas, E. Choi, and A. Lazaridou, Eds. San Diego, California: Association for Computational Linguistics, Jun. 2016, pp. 88–93. [Online]. Available: <https://aclanthology.org/N16-2013/> (Citato a pagina 6)
- [14] T. Davidson, D. Warmusley, M. Macy, and I. Weber, "Automated hate speech detection and the problem of offensive language," 2017. [Online]. Available: <https://arxiv.org/abs/1703.04009> (Citato a pagina 6)
- [15] D. Androcec, "Machine learning methods for toxic comment classification: a systematic review," *Acta Universitatis Sapientiae, Informatica*, vol. 12, pp. 205–216, 12 2020. (Citato a pagina 6)
- [16] T. Caselli, V. Basile, J. Mitrović, and M. Granitzer, "Hatebert: Retraining bert for abusive language detection in english," 2021. [Online]. Available: <https://arxiv.org/abs/2010.12472> (Citato a pagina 6)
- [17] D. Q. Nguyen, T. Vu, and A. T. Nguyen, "Bertweet: A pre-trained language model for english tweets," 2020. [Online]. Available: <https://arxiv.org/abs/2005.10200> (Citato a pagina 6)
- [18] Z. Lin, Z. Wang, Y. Tong, Y. Wang, Y. Guo, Y. Wang, and J. Shang, "Toxicchat: Unveiling hidden challenges of toxicity detection in real-world user-ai conversation," 2023. [Online]. Available: <https://arxiv.org/abs/2310.17389> (Citato a pagina 6)
- [19] F. Nooralahzadeh, G. Bekoulis, J. Bjerva, and I. Augenstein, "Zero-shot cross-lingual transfer with meta learning," 2020. [Online]. Available: <https://arxiv.org/abs/2003.02739> (Citato a pagina 8)
- [20] A. Roy, R. K. Thakur, I. Sharma, A. Gupta, A. Krishna, S. Sarkar, and P. Goyal, "Does meta-learning help mBERT for few-shot question generation in a cross-lingual transfer setting for indic languages?" in *Proceedings of the 29th International Conference on Computational Linguistics*, N. Calzolari, C.-R.

- Huang, H. Kim, J. Pustejovsky, L. Wanner, K.-S. Choi, P.-M. Ryu, H.-H. Chen, L. Donatelli, H. Ji, S. Kurohashi, P. Paggio, N. Xue, S. Kim, Y. Hahm, Z. He, T. K. Lee, E. Santus, F. Bond, and S.-H. Na, Eds. Gyeongju, Republic of Korea: International Committee on Computational Linguistics, Oct. 2022, pp. 4251–4257. [Online]. Available: <https://aclanthology.org/2022.coling-1.373/> (Citato a pagina 8)
- [21] L. Wu, Z. Guo, B. Cui, H. Tang, and W. Lu, “Good meta-tasks make a better cross-lingual meta-transfer learning for low-resource languages,” in *Findings of the Association for Computational Linguistics: EMNLP 2023*, H. Bouamor, J. Pino, and K. Bali, Eds. Singapore: Association for Computational Linguistics, Dec. 2023, pp. 7431–7446. [Online]. Available: <https://aclanthology.org/2023.findings-emnlp.498/> (Citato a pagina 8)
- [22] M. Mozafari, R. Farahbakhsh, and N. Crespi, “Cross-lingual few-shot hate speech and offensive language detection using meta learning,” *IEEE Access*, vol. 10, pp. 14 880–14 896, Jan. 2022. [Online]. Available: <https://hal.science/hal-03559484> (Citato a pagina 8)
- [23] T. Bansal, S. Alzubi, T. Wang, J.-Y. Lee, and A. McCallum, “Meta-adapters: Parameter efficient few-shot fine-tuning through meta-learning,” in *First Conference on Automated Machine Learning (Main Track)*, 2022. [Online]. Available: <https://openreview.net/forum?id=BCGNf-prLg5> (Citato a pagina 8)
- [24] N. Team, M. R. Costa-jussà, J. Cross, O. Çelebi, M. Elbayad, K. Heafield, K. Heffernan, E. Kalbassi, J. Lam, D. Licht, J. Maillard, A. Sun, S. Wang, G. Wenzek, A. Youngblood, B. Akula, L. Barrault, G. M. Gonzalez, P. Hansanti, J. Hoffman, S. Jarrett, K. R. Sadagopan, D. Rowe, S. Spruit, C. Tran, P. Andrews, N. F. Ayan, S. Bhosale, S. Edunov, A. Fan, C. Gao, V. Goswami, F. Guzmán, P. Koehn, A. Mourachko, C. Ropers, S. Saleem, H. Schwenk, and J. Wang, “No language left behind: Scaling human-centered machine translation,” 2022. [Online]. Available: <https://arxiv.org/abs/2207.04672> (Citato a pagina 11)

- [25] T. Akiba, S. Sano, T. Yanase, T. Ohta, and M. Koyama, "Optuna: A next-generation hyperparameter optimization framework," 2019. [Online]. Available: <https://arxiv.org/abs/1907.10902> (Citato a pagina 15)
- [26] D. Dementieva, D. Moskovskiy, N. Babakov, A. A. Ayele, N. Rizwan, F. Schneider, X. Wang, S. M. Yimam, D. Ustalov, E. Stakovskii, A. Smirnova, A. Elnagar, A. Mukherjee, and A. Panchenko, "Overview of the multilingual text detoxification task at pan 2024," in *Working Notes of CLEF 2024 - Conference and Labs of the Evaluation Forum*, G. Faggioli, N. Ferro, P. Galuščáková, and A. G. S. de Herrera, Eds. CEUR-WS.org, 2024. (Citato a pagina 17)
- [27] A. Baruah, K. Das, F. Barbhuiya, and K. Dey, "Context-aware sarcasm detection using BERT," in *Proceedings of the Second Workshop on Figurative Language Processing*, B. B. Klebanov, E. Shutova, P. Lichtenstein, S. Muresan, C. Wee, A. Feldman, and D. Ghosh, Eds. Online: Association for Computational Linguistics, Jul. 2020, pp. 83–87. [Online]. Available: <https://aclanthology.org/2020.figlang-1.12/> (Citato a pagina 35)
- [28] Y. Tay, V. Q. Tran, S. Ruder, J. Gupta, H. W. Chung, D. Bahri, Z. Qin, S. Baumgartner, C. Yu, and D. Metzler, "Charformer: Fast character transformers via gradient-based subword tokenization," 2022. [Online]. Available: <https://arxiv.org/abs/2106.12672> (Citato a pagina 35)
- [29] M. Grootendorst, "Bertopic: Neural topic modeling with a class-based tf-idf procedure," 2022. [Online]. Available: <https://arxiv.org/abs/2203.05794> (Citato a pagina 36)
- [30] Q. Xie, X. Zhang, Y. Ding, and M. Song, "Monolingual and multilingual topic analysis using lda and bert embeddings," *Journal of Informetrics*, vol. 14, no. 3, p. 101055, 2020. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S1751157719305127> (Citato a pagina 36)
- [31] H. E. Oskouie, C. Chance, C. Huang, M. Capetz, E. Eyeson, and M. Sarrafzadeh, "Leveraging large language models and topic modeling for toxicity classification," 2024. [Online]. Available: <https://arxiv.org/abs/2411.17876> (Citato a pagina 36)

Ringraziamenti

Desidero ringraziare tutte le persone che mi hanno accompagnato e sostenuto in questo percorso universitario. In particolare, voglio rivolgere un ringraziamento speciale al Prof. Fabio Palomba per la sua preziosa guida durante il percorso di tirocinio e la stesura di questa tesi.

Questa tesi ha contribuito a piantare un albero in Haiti tramite il progetto Treedom.

<https://www.treedom.net/it/user/sesalab/event/sesa-random-forest>

<https://www.treedom.net/it/user/gianvincenzo-landolfi-9156/trees/YM3-K9LV>