



Corso di Laurea in Informatica

Analisi del Sentiment nelle Comunicazioni Email tramite Intelligenza Artificiale

Prof. Fabio Palomba


Andrea Ruggiero
Mat.: 0512114732

✉ a.ruggiero150@studenti.unisa.it

🐙 github.com/andrearuggiero150

in [linkedin.com/in/andrea-ruggiero-191443316/](https://www.linkedin.com/in/andrea-ruggiero-191443316/)





Le comunicazioni e-mail rappresentano uno strumento centrale nelle comunicazioni private e lavorative.


comunicazioni
informative o
pubblicitarie



segnalazioni di
disservizi, reclami o
criticità operative




L'obiettivo è quello di realizzare uno strumento in grado di analizzare le e-mail ricevute dall'utente e di stimarne automaticamente il sentiment



Modello di
elaborazione del linguaggio naturale



Interpretando il problema come **regressione** il sentimento delle e-mail viene rappresentato su una scala continua di negatività, permettendo di stimare con maggiore granularità il livello di criticità del messaggio



Lo sviluppo è stato realizzato effettuando **fine-tuning** su dataset specifico di un modello pre-addestrato,

- ✓ Consente di sfruttare la conoscenza linguistica già appresa dal modello di base
- ✓ Adattarla al dominio specifico delle e-mail aziendali e personali



dbmdz/bert-base-italian-xxl-cased
una variante di BERT pre-addestrata su un ampio corpus
testuale in italiano

sviluppata dal gruppo **dbmdz** (Digital Humanities
Group del Munich Center for Machine Learning)



Non potendo, per ragioni di privacy, recuperare dataset di e-mail è stato scelto un dataset di recensioni della piattaforma TripAdvisor.

①

ogni recensione è accompagnata da una valutazione che rappresenta implicitamente un indicatore di sentiment

②

il dominio testuale delle recensioni risulta sufficientemente vicino a quello delle e-mail aziendali




Il dataset è stato ulteriormente pre-processato e adattato al problema di regressione del sentiment

Pulizia delle recensioni da emoji, link, righe vuote o elementi testuali superflui


Parsing delle valutazione espresse da 1 a 5 in soglie del valore continuo da 0 a 1

Downsample delle classi maggioritarie per bilanciare il dataset



Per evitare fenomeni di *data leakage*, il dataset è stato suddiviso in training set, validation set

■ Train set ■ Validation Set ■ Test Set



Una sezione di test set è stata riservata per un'ulteriore valutazione del modello su dati mai visti prima



Il **training set** viene suddiviso in **batch**, ovvero insiemi di elementi elaborati simultaneamente



Il modello lo elabora e produce una predizione del sentiment



La predizione viene confrontata con il valore reale

Per ogni batch



```
graph TD; A[ ] --> B[Vengono calcolati i gradienti per modificare i pesi dei circa 550 milioni di parametri addestrabili di BERT]; B --> C[L'ottimizzatore aggiorna i parametri del modello in base ai gradienti.]; C --> D[viene effettuata la valutazione sul validation set];
```

Vengono calcolati i gradienti per modificare i pesi dei circa 550 milioni di parametri addestrabili di BERT

L'ottimizzatore aggiorna i parametri del modello in base ai gradienti.

Per ogni batch

viene effettuata la valutazione sul validation set



L'addestramento viene eseguito per più epoche, monitorando le prestazioni sul **validation set**

Attraverso un meccanismo di **Early Stopping Callback** l'addestramento si interrompe automaticamente se non si osservano miglioramenti per 2 epoche consecutive



In questo caso l'addestramento si ferma dopo **cinque epoche**



Alla fine dell'addestramento viene caricato il modello inerente all'epoca che ha raggiunto le prestazioni migliori (**la terza**).


Metrica	Validation set	Test set
MSE	0.0279	0.0260
MAE	0.1283	0.1234
R^2	0.7700	0.7810

Le metriche indicano buone prestazioni del modello: un basso **MSE** e **MAE** evidenziano errori contenuti nelle predizioni, mentre R^2 mostra una buona capacità del modello di spiegare la variabilità dei dati, spiegandone circa il 77-78%



Integrazione dell'analisi documentale

- ① Riconoscimento del tipo di documento
(PDF testuale oppure PDF da scansione)
- ② Estrazione del corpo del documento
- ③ Analisi del sentiment tramite modello del corpo del documento



Analisi del Sentiment nelle Comunicazioni Email tramite Intelligenza Artificiale

Grazie dell'attenzione!

Contesto del problema

Le comunicazioni email rappresentano uno strumento centrale nelle comunicazioni private e lavorative.

comunicazione informativa o pubblicitaria

segnalazioni di disservizi, reclami o criticità operative

a.ruggiero150@studenti.unisa.it
github.com/andrearuggiero150
linkedin.com/in/andrea-ruggiero-191443316/

Modello

dbmdz/bert-base-italian-xxl-cased
una variante di BERT pre-addestrato su un ampio corpus testuale in italiano

sviluppata dal gruppo dbmdz (Digital Humanities Group del Munich Center for Machine Learning)

a.ruggiero150@studenti.unisa.it
github.com/andrearuggiero150
linkedin.com/in/andrea-ruggiero-191443316/

Dataset

Il dataset è stato ulteriormente pre-processato e adattato al problema di regressione del sentiment

Pulizia delle recensioni da emoji, link, righe vuote o elementi testuali superflui

Parsing delle valutazioni espresse da 1 a 5 in soglie del valore continuo da 0 a 1

Downsample delle classi maggioritarie per bilanciare il dataset

1.00
0.75
0.50
0.25
0.00

a.ruggiero150@studenti.unisa.it
github.com/andrearuggiero150
linkedin.com/in/andrea-ruggiero-191443316/

Risultati

L'addestramento del modello si stoppa dopo la quinta epoca caricando il modello inerente alla terza epoca

Metrica	Validation set	Test set
MSE	0.0279	0.0260
MAE	0.1283	0.1234
R2	0.7700	0.7810

Le metriche indicano buone prestazioni del modello: un basso MSE e MAE evidenziano errori contenuti nelle predizioni, mentre R² mostra una buona capacità del modello di spiegare la variabilità dei dati, spiegandone circa il 77-78%

a.ruggiero150@studenti.unisa.it
github.com/andrearuggiero150
linkedin.com/in/andrea-ruggiero-191443316/



Questa tesi ha contribuito a
piantare un albero in
Madagascar

Andrea Ruggiero

✉ a.ruggiero150@studenti.unisa.it

🐙 github.com/andrearuggiero150

🌐 linkedin.com/in/andrea-ruggiero-191443316/