



UNIVERSITÀ DEGLI STUDI DI SALERNO

Dipartimento di Informatica

Corso di Laurea Triennale in Informatica

TESI DI LAUREA

# **Analisi dei prompt smells nei prompt per la generazione di immagini: impatto su allineamento e qualità dei risultati**

RELATORE

Prof. Fabio Palomba

Dott. Antonio Della Porta

Università degli Studi di Salerno

CANDIDATO

**Giovanni Paolo Chierchia**

Matricola: 0512117783

Anno Accademico 2024-2025

*Questa tesi è stata realizzata nel*

sesa<sup>lab</sup>  
SOFTWARE ENGINEERING  
SALERNO

*"Si realizzano sempre le cose in cui credi realmente; e il credere in una cosa la rende possibile"*

*Frank Lloyd Wright*

## Abstract

I modelli *text-to-image* hanno raggiunto un'elevata qualità visiva, ma restano sensibili alla formulazione del prompt: difetti non intenzionali nel testo (*prompt smells*) possono degradare la desiderabilità dell'output e ridurre spiegabilità e tracciabilità tra input e output. Lo stato dell'arte discute pratiche di *prompt engineering* e analizza failure case, ma manca una tassonomia operativa e riproducibile di smells per il dominio *text-to-image*, insieme a una quantificazione sistematica del loro impatto sia sulla qualità/allineamento sia sulla stabilità dell'output al variare del seed.

Questa tesi propone una tassonomia organizzata in macrocategorie e tipologie di prompt smells, derivata da baseline *clean* progettate come condizioni di controllo comparabili e un protocollo sperimentale che misura l'effetto delle varianti *smelly* su allineamento testo-immagine, qualità visiva, estetica e preferenza umana condizionata dal prompt. I punteggi sono analizzati tramite *beta mixed-effects model* per stimare contrasti *smelly vs clean*; per la macrocategoria di ambiguità viene inoltre introdotta una *cross analysis* che riduce il confondente dovuto al testo di valutazione. Per studiare la stabilità *intra-prompt*, la tesi analizza anche la variabilità percettiva tra repliche generate con seed diversi tramite LPIPS. I risultati indicano che alcuni smells inducono degradazioni misurabili sulle metriche per immagine e, in specifici casi, aumentano la variabilità percettiva. Nel complesso, la proposta colma il gap di definizione operativa e fornisce evidenza quantitativa riproducibile sul comportamento dei modelli *text-to-image* rispetto a difetti del prompt.



---

# Indice

---

|                                                                  |           |
|------------------------------------------------------------------|-----------|
| <b>Elenco delle Figure</b>                                       | <b>iv</b> |
| <b>Elenco delle Tabelle</b>                                      | <b>v</b>  |
| <b>1 Introduzione</b>                                            | <b>1</b>  |
| 1.1 Contesto applicativo . . . . .                               | 1         |
| 1.2 Motivazione ed Obiettivi . . . . .                           | 2         |
| 1.3 Risultati Ottenuti . . . . .                                 | 3         |
| 1.4 Struttura della tesi . . . . .                               | 3         |
| <b>2 Background e Stato dell'Arte</b>                            | <b>5</b>  |
| 2.1 Modelli text-to-image . . . . .                              | 5         |
| 2.1.1 Diffusion Models . . . . .                                 | 6         |
| 2.1.2 Condizionamento via testo . . . . .                        | 7         |
| 2.2 Valutazione umana delle immagini generate . . . . .          | 8         |
| 2.2.1 Protocolli e dataset principali . . . . .                  | 9         |
| 2.3 Valutazione automatica delle immagini generate . . . . .     | 10        |
| 2.3.1 Metriche di allineamento testo-immagine . . . . .          | 13        |
| 2.3.2 Metriche di qualità visiva (IQA) . . . . .                 | 14        |
| 2.3.3 Metriche di estetica (IAA) . . . . .                       | 16        |
| 2.3.4 Metriche di preferenza umana condizionata dal prompt . . . | 17        |

|          |                                                                                            |           |
|----------|--------------------------------------------------------------------------------------------|-----------|
| 2.3.5    | Similarità e diversità percettiva delle immagini generate . . .                            | 18        |
| 2.4      | Prompt engineering nei modelli text-to-image . . . . .                                     | 18        |
| 2.5      | Prompt smells: definizione e tassonomia . . . . .                                          | 21        |
| 2.5.1    | Ambiguità linguistica e referenziale . . . . .                                             | 23        |
| 2.5.2    | Incoerenza interna . . . . .                                                               | 25        |
| 2.5.3    | Sotto-specificazione . . . . .                                                             | 27        |
| 2.5.4    | Sovra-specificazione / rumore . . . . .                                                    | 28        |
| 2.5.5    | Additivi non visual-grounded . . . . .                                                     | 30        |
| 2.5.6    | Robustezza lessicale e coverage shift . . . . .                                            | 31        |
| 2.5.7    | Format / interaction mismatch . . . . .                                                    | 33        |
| <b>3</b> | <b>Metodologia di ricerca</b>                                                              | <b>36</b> |
| 3.1      | Obiettivi e domande di ricerca . . . . .                                                   | 36        |
| 3.2      | Metodo di ricerca . . . . .                                                                | 37        |
| 3.3      | Setup sperimentale . . . . .                                                               | 38        |
| 3.4      | Tipologie testate e baseline clean . . . . .                                               | 40        |
| 3.4.1    | Baseline clean (condizioni di controllo) . . . . .                                         | 42        |
| 3.4.2    | Tipologie smelly testate: macrocategorie e trasformazioni . . .                            | 43        |
| 3.5      | Workflow A: metriche per immagine e modellazione statistica (RQ1)                          | 47        |
| 3.5.1    | Calcolo delle metriche per immagine . . . . .                                              | 48        |
| 3.5.2    | Preprocessing delle metriche per il beta mixed-effects model .                             | 50        |
| 3.5.3    | Beta mixed-effects model per stimare l'effetto degli smells . .                            | 51        |
| 3.5.4    | Analisi incrociata ( <i>cross analysis</i> ) come verifica di robustezza .                 | 55        |
| 3.6      | Workflow B: variabilità percettiva (LPIPS) (RQ2) . . . . .                                 | 56        |
| 3.6.1    | Misura della variabilità percettiva intra-prompt e aggregazione<br>per tipologia . . . . . | 57        |
| 3.6.2    | Intervalli di confidenza via bootstrap e reporting dei risultati                           | 58        |
| <b>4</b> | <b>Analisi dei risultati</b>                                                               | <b>60</b> |
| 4.1      | Risultati RQ1: impatto degli smells sulle metriche per immagine . . .                      | 60        |
| 4.1.1    | Affidabilità del fit: stabilità numerica e diagnostica DHARMa .                            | 60        |
| 4.1.2    | Contrasti su scala risposta (clean vs smelly): risultati principali                        | 63        |
| 4.1.3    | Cross analysis ( <i>image-swap</i> ) come verifica di robustezza . . . .                   | 69        |

|          |                                                                      |           |
|----------|----------------------------------------------------------------------|-----------|
| 4.2      | Risultati RQ2: variabilità percettiva intra-prompt (LPIPS) . . . . . | 71        |
| 4.3      | Sintesi trasversale e takeaway . . . . .                             | 73        |
| <b>5</b> | <b>Conclusioni</b>                                                   | <b>79</b> |
|          | <b>Bibliografia</b>                                                  | <b>82</b> |

---

## Elenco delle figure

---

|     |                                                                                                                                                                                                             |    |
|-----|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 3.1 | Schema dei workflow sperimentali: analisi delle metriche per immagine (RQ1) e della variabilità percettiva tramite LPIPS (RQ2). . . . .                                                                     | 38 |
| 4.1 | Contrasti <i>smelly vs baseline</i> su scala risposta ( $\Delta\mu$ ) per le metriche di allineamento testo-immagine ( <code>clipscore_unit</code> , <code>geval_align_unit</code> ). . . . .               | 65 |
| 4.2 | Contrasti <i>smelly vs baseline</i> su scala risposta ( $\Delta\mu$ ) per le metriche di qualità visiva ( <code>geval_quality_unit</code> , <code>onealign_quality_unit</code> ). . . . .                   | 66 |
| 4.3 | Contrasti <i>smelly vs baseline</i> su scala risposta ( $\Delta\mu$ ) per preferenza umana condizionata dal prompt ed estetica ( <code>hpsv21_unit</code> , <code>onealign_aesthetic_unit</code> ). . . . . | 67 |
| 4.4 | Esempi qualitativi (stesso <code>seed</code> per ciascuna coppia clean-smelly): baseline clean (sinistra) vs variante smelly (destra). . . . .                                                              | 75 |
| 4.5 | Esempi qualitativi con differenze visive contenute (stesso <code>seed</code> per ciascuna coppia clean-smelly). . . . .                                                                                     | 76 |
| 4.6 | Cross analysis ( <i>image-swap</i> , prompt clean fisso): contrasti su scala risposta $\Delta\mu = \mu(\text{clean prompt, smelly img}) - \mu(\text{clean prompt, clean img})$ . . . . .                    | 77 |
| 4.7 | Variazione della variabilità LPIPS rispetto alla baseline: $\Delta_t$ (mediana delle differenze appaiate per prompt) e IC bootstrap al 95%. . . . .                                                         | 78 |

---

## Elenco delle tabelle

---

|     |                                                                                                                                                |    |
|-----|------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 3.1 | Parametri principali di generazione delle immagini. . . . .                                                                                    | 40 |
| 3.2 | Campi principali e identificativi usati per tracciare prompt e immagini<br>e supportare appaiamenti e raggruppamenti nelle analisi successive. | 41 |
| 4.1 | Sintesi a conteggi dei controlli di affidabilità sui modelli stimati per la<br>RQ1. . . . .                                                    | 61 |

# CAPITOLO 1

---

## Introduzione

---

### 1.1 Contesto applicativo

Sebbene i modelli di generazione di immagini siano oggetto di ricerca da diversi anni, la loro adozione è rimasta a lungo confinata a contesti specialistici, anche a causa di limitazioni in termini di qualità e, soprattutto, di controllabilità del risultato. Una svolta avviene nel 2020 con lo studio di Ho et al. [1], che introduce i *Denoising Diffusion Probabilistic Models* (DDPM), mostrando come i *diffusion models* permettano di ottenere immagini di elevata qualità e stabilità di addestramento, a fronte di un processo di campionamento generalmente più lento rispetto ad approcci alternativi quali GAN ed autoregressivi come mostrato anche dalla survey di Zhang et al. [2].

Nel 2022 si osserva una diffusione su larga scala dei modelli *text-to-image*, favorita dal rilascio di sistemi come DALL·E 2, Midjourney e Stable Diffusion, quest'ultimo rilevante anche per la possibilità di eseguire la generazione localmente su hardware consumer, contribuendo alla democratizzazione di tali tecnologie. Sebbene oggi siano disponibili anche modelli e pipeline che integrano input multimodali (ad esempio testo e immagine) per guidare la generazione, i sistemi *text-to-image* basati esclusivamente su prompt testuali rimangono una delle modalità d'uso più comuni.

Nei modelli *text-to-image* la specifica dell'output desiderato è affidata principalmente a una descrizione in linguaggio naturale. Tuttavia, il linguaggio naturale è intrinsecamente ambiguo e sensibile alla formulazione: come mostrato in letteratura [3, 4, 5, 6], anche variazioni minime del prompt possono produrre cambiamenti significativi nell'immagine generata, con effetti sull'allineamento, sul contenuto e sulle caratteristiche estetiche.

Per migliorare pertinenza e controllabilità dei risultati si è sviluppata la pratica del *prompt engineering*, che mira a progettare e strutturare i prompt in modo più efficace. Quando tale progettazione è imprecisa (spesso in modo involontario), possono emergere i *prompt smells*, nozione introdotta da Ronanki et al. [7], intesi come caratteristiche sintattiche e/o semantiche del prompt che possono compromettere la desiderabilità dell'output, ridurre la spiegabilità del processo generativo e indebolire la tracciabilità tra input e output.

## 1.2 Motivazione ed Obiettivi

Questo lavoro di tesi mira a colmare la mancanza di una tassonomia operativa dei *prompt smells* nel contesto dei modelli *text-to-image* e a studiarne l'impatto sui risultati generati. In letteratura e nella pratica del *prompt engineering* sono riportate diverse criticità ricorrenti nella formulazione dei prompt (ad esempio ambiguità, sotto/sovra-specificazione e incoerenza), ma tali fenomeni non risultano organizzati in modo sistematico in una tassonomia focalizzata sui difetti non intenzionali del prompt e sui loro effetti misurabili.

Per analizzare tali effetti si adotta un'impostazione quantitativa basata su metriche di valutazione automatica. Questo approccio, pur non sostituendo le valutazioni umane, consente di effettuare confronti riproducibili e scalabili tra prompt, misurando aspetti complementari della qualità del risultato. In particolare, viene utilizzato un insieme di sette metriche che copre cinque dimensioni di interesse: allineamento testo-immagine, qualità visiva, estetica percepita, preferenza umana condizionata dal prompt e variabilità percettiva tra immagini generate a partire dallo stesso prompt. Tale scelta permette una valutazione multi-aspetto dei risultati, evitando di ridurre il confronto a una singola dimensione.

Gli obiettivi principali della tesi sono i seguenti:

© **Our Goal.** Definire una tassonomia di *prompt smells* per la generazione *text-to-image*, derivata da problematiche ricorrenti riportate in letteratura e da linee guida/strumenti di prompt engineering, e formalizzata in tipologie riproducibili.

© **Our Goal.** Valutare quantitativamente l’impatto delle diverse tipologie di *prompt smells* confrontando, tramite metriche automatiche, i risultati ottenuti da prompt *clean* (baseline) con quelli prodotti dalle corrispondenti varianti *smelly*.

## 1.3 Risultati Ottenuti

Questo lavoro ha prodotto due risultati principali: (i) una tassonomia operativa di *prompt smells* per il dominio *text-to-image*, formalizzata in tipologie e trasformazioni riproducibili a partire da baseline *clean*; (ii) una valutazione quantitativa del loro impatto su più dimensioni, tramite metriche automatiche calcolate su immagini generate in condizioni controllate.

Dall’analisi sperimentale emerge che i *prompt smells* incidono soprattutto sulla *controllabilità semantica* dell’output: gli effetti sono più evidenti nelle metriche di *allineamento testo-immagine* e nella *preferenza umana condizionata dal prompt*, mentre le metriche di *qualità visiva* risultano in media più stabili. Inoltre, le ambiguità linguistiche e referenziali si confermano problematiche su due piani: possono influenzare direttamente il contenuto generato (scelte interpretative e violazioni intermittenti dei vincoli) e, al contempo, rendere meno affidabile la valutazione automatica basata sul testo quando il prompt è non univoco. Infine, l’analisi della variabilità percettiva intra-prompt (LPIPS) indica che, nella maggior parte dei casi, gli *smells* non modificano in modo sistematico la stabilità dell’output al variare del seed, con poche eccezioni.

## 1.4 Struttura della tesi

La tesi è organizzata come segue. Nel **Capitolo 2** vengono introdotti i concetti di base sui modelli *text-to-image* e sulle metriche di valutazione automatica, e viene



presentata la definizione di *prompt smells* insieme alla tassonomia proposta. Il **Capitolo 3** descrive il metodo di ricerca: costruzione delle baseline e delle tipologie smelly, setup sperimentale, generazione delle immagini, calcolo delle metriche e pipeline di analisi statistica (incluse l'analisi principale e la verifica di robustezza). Nel **Capitolo 4** sono riportati e discussi i risultati della sperimentazione, rispondendo alle domande di ricerca sull'impatto degli smells sulle metriche per immagine e sulla variabilità percettiva intra-prompt. Infine, il **Capitolo 5** riassume i contributi, discute limiti e implicazioni del lavoro e propone possibili sviluppi futuri.

---

### Background e Stato dell'Arte

---

#### 2.1 Modelli text-to-image

La generazione text-to-image è il processo di creazione di un'immagine a partire da una descrizione testuale (prompt) in linguaggio naturale. Un modello text-to-image riceve in input un prompt e produce in output un'immagine che mira a rifletterne i contenuti; tuttavia l'aderenza alla descrizione può variare in funzione della formulazione del testo, del modello e del processo di campionamento. La generazione text-to-image rientra nella categoria più ampia dell'IA generativa e si è diffusa grazie alla rapidità di prototipazione, all'accessibilità anche per utenti non esperti di grafica e al controllo ad alto livello esercitabile tramite il prompt.

Nonostante i vantaggi siano evidenti, questi modelli non sono esenti da criticità:

- **Allineamento testo-immagine imperfetto:** il modello può ignorare dettagli del prompt, confondere attributi (colori, quantità, relazioni spaziali come “a sinistra di ...”) o introdurre elementi non richiesti.
- **Errori strutturali:** artefatti locali o incongruenze geometriche (ad es. mani, pattern ripetitivi, simmetrie innaturali) possono comparire, in particolare in presenza di dettagli fini o strutture complesse [8].

- **Bias nei dati:** essendo addestrati su dati provenienti dal web, i modelli possono riflettere stereotipi (ad es. associazioni tra professioni e genere) o rappresentazioni sbilanciate [2, 9, 10].
- **Questioni di copyright e attribuzione:** la generazione può imitare stili riconoscibili o sollevare dubbi sull'uso dei dati di training e sul riutilizzo commerciale [11].
- **Uso improprio:** possibilità di creare contenuti ingannevoli (ad es. deepfake visivi), disinformazione o manipolazione [12].

In questo lavoro ci si concentra in particolare sulle criticità legate alla formulazione del prompt, analizzando l'impatto di specifiche caratteristiche linguistiche e strutturali sulla qualità e sull'allineamento delle immagini generate.

Negli anni le architetture si sono evolute e, come discusso anche da Zhang et al. [2], i diffusion models si sono affermati come approccio dominante nei sistemi text-to-image moderni. Per questo motivo, nel seguito si farà riferimento principalmente a modelli basati su architetture di diffusione.

### 2.1.1 Diffusion Models

In un diffusion model, il processo generativo viene formulato come l'inversione di una trasformazione graduale che corrompe un dato reale con rumore: durante il training si apprende un modello di denoising in grado di ricostruire progressivamente il campione pulito a partire da una sua versione rumorosa, mentre in inferenza si parte da rumore puro e si applicano iterativamente passi di denoising fino a ottenere l'immagine finale [13].

Un sistema text-to-image basato su diffusion models è tipicamente composto da:

- Un *encoder testuale* che trasforma il prompt in embedding.
- Un modello di *denoising* (ad es. U-Net o Transformer).
- Opzionalmente, un *autoencoder* per lavorare in spazio latente nel caso dei modelli latent diffusion.

- Uno *scheduler/sampler* (nel processo di campionamento) che definisce il noise schedule e i passi di generazione.
- Una strategia di *guidance* (ad es. classifier-free guidance) per controllare l'aderenza al prompt.

Le principali evoluzioni rispetto alla formulazione base sono:

- *Diffusione in pixel space vs diffusione in latent space*, dove l'uso di uno spazio latente (ottenuto tramite un autoencoder) riduce il costo computazionale e facilita la generazione ad alta risoluzione [14].
- *Scelta del backbone di denoising*, con un passaggio progressivo da architetture di tipo U-Net a varianti basate su Transformer, più scalabili [15].
- *Strategia di guidance*, in particolare l'adozione di tecniche come la classifier-free guidance per bilanciare qualità e aderenza al condizionamento [16].
- *Rappresentazione del testo*, che può derivare da encoder pre-addestrati di grandi dimensioni per migliorare la comprensione linguistica [17].

In questo contesto, modelli come GLIDE e Imagen sono esempi di diffusion text-to-image in pixel space [18, 17], mentre Stable Diffusion e DALL-E 2 rappresentano approcci emblematici in latent space [14, 19]. Lavori più recenti esplorano backbone Transformer per il denoising (ad es. DiT, e modelli successivi che ne sviluppano l'impostazione) [15, 20].

### 2.1.2 Condizionamento via testo

Nei diffusion models text-to-image, il prompt viene prima convertito in una rappresentazione numerica tramite un encoder testuale, spesso un modello pre-addestrato, che trasforma il testo in una sequenza di vettori (embedding) associati ai token. Questa rappresentazione viene poi usata come segnale di condizionamento durante la generazione: a ogni passo di denoising, il modello combina l'informazione visiva corrente con l'informazione testuale, in modo da guidare gradualmente l'immagine verso quanto descritto dal prompt [18, 17].

Un meccanismo molto comune per integrare testo e parte visiva è la *cross-attention*. In modo semplificato, il modello “confronta” le caratteristiche interne dell’immagine (nei latenti) con gli embedding del testo e decide a quali parole dare più peso mentre costruisce i dettagli dell’immagine. Questo permette di trasferire nel risultato finale oggetti, attributi e indicazioni di stile presenti nel prompt. Nei modelli in latent space, come Stable Diffusion, il condizionamento opera sui latenti prodotti da un autoencoder, riducendo il costo computazionale e rendendo più efficiente la generazione [14].

Molti sistemi usano anche la *classifier-free guidance*, che combina una generazione condizionata dal testo con una generazione non condizionata, controllando quanto il modello deve “seguire” il prompt. In generale, un valore di guidance più alto aumenta l’aderenza al testo, ma può ridurre la naturalezza dell’immagine o aumentare artefatti, creando un compromesso tra fedeltà e qualità visiva [16].

Nonostante questi meccanismi rendano il prompt uno strumento potente, il condizionamento testuale non garantisce che il modello interpreti sempre il testo in modo completo e univoco. La generazione può essere sensibile ad ambiguità, descrizioni troppo vaghe o vincoli in conflitto, e può avere difficoltà a rispettare correttamente relazioni tra più elementi (ad esempio associare un attributo all’oggetto giusto o seguire relazioni spaziali come “a sinistra di”) [21, 22]. Inoltre, limiti legati alla tokenizzazione e alla lunghezza massima del testo gestibile dall’encoder possono ridurre l’influenza di parti del prompt, soprattutto quando la descrizione è molto lunga o ridondante; un esempio è l’encoder CLIP, che in molte implementazioni opera su input di lunghezza limitata (ad es. 77 token) [23].

Questi aspetti motivano lo studio sistematico di come caratteristiche linguistiche e strutturali del prompt possano influenzare l’allineamento e la qualità delle immagini generate, tema centrale di questa tesi.

## 2.2 Valutazione umana delle immagini generate

La valutazione umana è spesso considerata il gold standard per giudicare le immagini generate da modelli text-to-image, poiché combina comprensione semantica del prompt e percezione visiva (ad es. naturalezza, artefatti, composizione). Tuttavia,

essa presenta costi elevati e limiti di scalabilità, oltre a criticità di riproducibilità se il protocollo non è specificato in modo rigoroso (istruzioni, campionamento, controlli di qualità e reportistica).

### 2.2.1 Protocolli e dataset principali

**Protocolli** Nella letteratura, la valutazione umana viene tipicamente condotta secondo tre schemi:

- **Rating assoluto (Likert/MOS):** i valutatori assegnano un punteggio su una scala discreta (ad es. 1–5) rispetto a criteri quali aderenza al prompt, qualità visiva o estetica. È semplice da implementare, ma soffre di differenze individuali nell’uso della scala e di maggiore varianza.
- **Preferenza a coppie (A/B):** date due immagini generate dallo stesso prompt, si chiede quale sia preferibile (per aderenza, qualità complessiva o estetica).
- **Ranking:** si richiede l’ordinamento di  $N$  immagini rispetto a un criterio. Fornisce informazione più ricca, ma aumenta il carico cognitivo e può introdurre rumore con  $N$  elevato.

Per rendere affidabile la valutazione, sono comunemente adottate misure quali: più annotatori per item, randomizzazione dell’ordine di presentazione, controlli di attenzione, e stima dell’accordo tra annotatori (inter-annotator agreement).

**Dataset** Negli ultimi anni sono stati introdotti dataset su larga scala che raccolgono preferenze umane su immagini generate utilizzando i protocolli sopra indicati:

- **Pick-a-Pic:** dataset ottenuto tramite una web app in cui utenti reali generano immagini ed esprimono un feedback di preferenza su coppie (A/B) per lo stesso prompt, consentendo la raccolta di preferenze in condizioni d’uso realistiche [24].
- **ImageReward:** propone una pipeline di annotazione basata su Likert rating da 1 a 7 su allineamento testo-immagine, qualità visiva e overall; successivamente viene fatto svolgere ai partecipanti un ranking delle immagini, con l’obiettivo

di apprendere un *reward model* che predice preferenze umane e può essere impiegato sia per valutazione sia per ottimizzazione del generatore [25].

- **HPD v2:** introduce un ampio dataset di scelte umane su coppie di immagini (stesso prompt): agli annotatori veniva mostrata una coppia di immagini con un singolo prompt e veniva chiesto loro di indicare quale tra le due preferissero, considerando qualità ed estetica, oltre all'allineamento con il prompt [26].
- **Q-Eval-100K:** introduce un dataset composto da circa 100K istanze (circa 60K immagini + 40K video) con Mean Opinion Scores (MOS) derivati dai rating (1–5) che gli annotatori hanno assegnato a qualità visiva e allineamento prompt-immagine; il lavoro riporta circa 960K annotazioni umane complessive [27].

**Ruolo dei giudizi umani nella valutazione automatica** In molti lavori, i giudizi umani non vengono usati solo come misura finale di qualità, ma anche come *ground truth* per progettare, addestrare e validare metriche automatiche. Una prima linea comprende i *preference/reward models*, che apprendono uno score a partire da confronti tra immagini o da rating/ranking (ad es. ImageReward e HPSv2) [25, 26]. Una seconda linea usa dataset con annotazioni umane (ad es. MOS su qualità e allineamento) come benchmark per verificare la correlazione e l'affidabilità di evaluator automatici (ad es. Q-Eval-100K) [27]. Infine, alcune metriche automatiche vengono validate tramite confronti più *fine-grained* con annotazioni umane su proprietà composizionali o tramite analisi di correlazione con giudizi di fedeltà al testo, come in GenEval e TIFA [28, 29].

## 2.3 Valutazione automatica delle immagini generate

La valutazione automatica delle immagini generate da modelli text-to-image nasce dall'esigenza di affiancare (o, in scenari su larga scala, sostituire) la valutazione umana con misure riproducibili, economiche e facilmente scalabili. In assenza di un riferimento *ground truth* univoco per un prompt scritto da un utente (non esiste un'unica immagine "corretta" per un dato prompt), molte metriche adottate nel text-to-image sono *reference-free*: stimano proprietà dell'immagine (e, in alcuni casi,

della coppia prompt-immagine) senza disporre di un'immagine target. Questo le rende adatte a confronti sistematici tra modelli, configurazioni di campionamento o famiglie di prompt, ma il punteggio dipende dal *valutatore* (ad es. feature extractor, modello multimodale o reward model), che può avere limiti e distorsioni proprie.

Le dimensioni più comuni della valutazione automatica riflettono le stesse categorie considerate nella valutazione umana, ma vengono formalizzate tramite score computabili:

- **Allineamento testo-immagine:** misura quanto il contenuto espresso nel prompt (oggetti, attributi, relazioni) sia coerente con quanto rappresentato nell'immagine.
- **Qualità visiva (IQA, Image Quality Assessment):** l'IQA si concentra principalmente sull'impatto di distorsioni e problemi di qualità (artefatti, incoerenze locali, degradazioni) sulla percezione umana.
- **Estetica (IAA, Image Aesthetic Assessment):** rispetto all'IQA, l'IAA è un compito più complesso; oltre alla qualità visiva, privilegia attributi visivi di livello più alto come contenuto, illuminazione, colore e composizione.
- **Preferenza umana condizionata dal prompt:** un modello apprende uno score che approssima il giudizio umano a partire da confronti (A/B) o rating, con l'obiettivo di predire quale immagine risulti preferibile dato il prompt.
- **Similarità/diversità percettiva:** misura la somiglianza (o variabilità) tra più generazioni dello stesso prompt (ad esempio al variare del seed), utile per quantificare stabilità e variabilità percettiva.

Dal punto di vista dell'unità di analisi, è utile distinguere metriche *per-immagine* (uno score per ciascuna generazione) e metriche *per-coppia* (uno score associato a una coppia di immagini, tipicamente per misurare similarità o diversità percettiva). Esistono inoltre metriche *distribution-level* (ad es. FID e Inception Score) che confrontano insiemi di immagini a livello di distribuzione e sono comunemente usate per valutazioni aggregate [30]. In questo lavoro di tesi si adottano metriche per-immagine e, per la variabilità, una metrica per-coppia successivamente aggregata.



Una distinzione trasversale utile, discussa anche in [31], riguarda il tipo di segnale utilizzato dal valutatore. In questo lavoro si adotta la seguente convenzione: si definiscono *embedding-based* le metriche che derivano uno score a partire da rappresentazioni apprese in uno spazio multimodale condiviso (ad es. modelli CLIP-like), includendo sia misure di similarità tra embedding (come CLIPScore) sia *reward/preference models* che producono uno score direttamente dalla rappresentazione congiunta testo-immagine. Si definiscono invece *content-based* le metriche che scompongono il contenuto del prompt in verifiche esplicite e ne controllano la soddisfazione tramite modelli discriminativi, spesso con pipeline VQA-based o object-centric. Questa distinzione è particolarmente rilevante in scenari compositivi, dove errori di *attribute binding*, conteggio o relazioni spaziali possono non essere catturati adeguatamente da uno score globale. In generale, uno score elevato non implica necessariamente che tutti i vincoli del prompt siano soddisfatti: metriche diverse possono essere sensibili a fattori differenti (ad es. salienza dell'oggetto principale, resa estetica, presenza di artefatti), e i punteggi possono essere influenzati da bias del valutatore o da confondenti non controllati.

Un aspetto chiave è che le metriche automatiche non sono universalmente affidabili: la loro correlazione con giudizi umani varia sensibilmente per categoria compositiva, rendendo critica la scelta della metrica [31]. Per questo motivo, nello studio dei *prompt smells* diventa importante discutere non solo *cosa* misurano le metriche, ma anche *quanto* siano sensibili a trasformazioni linguistiche e strutturali del testo. In generale, studi comparativi mostrano che nessuna metrica è universalmente dominante: le prestazioni variano sensibilmente in funzione del tipo di vincolo da valutare (attributi, conteggio, relazioni), e metriche embedding-based e content-based tendono a fornire segnali complementari. Inoltre, le metriche VQA-based possono manifestare comportamenti di saturazione (score spesso vicini al massimo), mentre metriche embedding-based come CLIPScore e HPSv2 possono avere un range più compresso, riducendo la capacità discriminativa su differenze sottili [31]. Di conseguenza, nello studio sperimentale dei *prompt smells* è opportuno adottare un insieme di metriche complementari, così da coprire sia la fedeltà semantica al testo sia dimensioni human-centric come qualità percettiva, estetica e preferenza, oltre alla stabilità/variabilità delle generazioni.

### 2.3.1 Metriche di allineamento testo–immagine

Le metriche di allineamento testo–immagine mirano a stimare quanto gli elementi semantici espressi nel prompt (entità, attributi e relazioni) siano effettivamente riflessi nell’immagine generata. In linea con la distinzione discussa in [31], si considerano metriche *embedding-based* (similarità in spazi multimodali condivisi) e metriche *content-based* (verifiche esplicite, spesso VQA-based o object-centric). Le due famiglie risultano complementari: le prime sono general-purpose e veloci, ma possono essere meno sensibili a vincoli compositivi; le seconde sono più interpretabili e spesso più adatte a misurare binding e relazioni, ma dipendono dalla qualità e copertura dei modelli ausiliari.

**Metriche embedding-based** Le metriche embedding-based misurano l’allineamento come similarità tra rappresentazioni in uno spazio multimodale condiviso. Un riferimento classico è *CLIPScore* [32], che calcola (tipicamente) la similarità coseno tra embedding del prompt e embedding dell’immagine ottenuti da CLIP [33]. Il vantaggio principale è la semplicità e l’efficienza: lo score è immediato e applicabile a qualsiasi coppia prompt–immagine senza decomposizioni esplicite. Tuttavia, essendo una misura globale, può risultare poco sensibile a errori compositivi localizzati (ad es. l’attributo assegnato all’oggetto sbagliato) o a relazioni complesse.

Per aumentare la granularità interpretativa, sono state proposte varianti che decompongono il prompt e calcolano punteggi separati sulle sue componenti. Un esempio è il *Decomposed CLIPScore* [34], in cui il prompt viene scomposto in frasi nominali e si calcola un CLIPScore per ciascuna, aggregando poi i sottopunteggi. Questo consente di evidenziare quali parti del prompt risultano meno supportate dall’immagine, pur mantenendo la natura embedding-based (e quindi i limiti legati al modello di embedding).

**Metriche content-based** Le metriche content-based trasformano il problema di allineamento in una serie di verifiche esplicite su contenuti e relazioni. *TIFA* [29] adotta un approccio divide-et-impera: un language model genera una collezione di tuple (domanda, opzioni, risposta corretta) per coprire diversi aspetti del prompt; un modello di question answering filtra domande errate o non verificabili; infine un

modello di VQA (Visual Question Answering) risponde alle domande osservando l'immagine. Lo score TIFA corrisponde alla percentuale di risposte corrette e fornisce, oltre a un valore aggregato, un riscontro fine-grained sui vincoli soddisfatti.

*VQAScore* [35] segue una filosofia più semplice: il prompt viene trasformato in una singola domanda binaria del tipo “Does this figure show {prompt}? Please answer yes or no.”, e un modello VQA stima la probabilità che la risposta sia “Yes”. Tale probabilità viene assunta come score di allineamento per la coppia prompt-immagine.

Una linea recente usa modelli multimodali di grandi dimensioni (MLLM) come valutatori generali. *Q-Eval-Score* valuta contenuti *text-to-image* e *text-to-video* lungo due assi separati: qualità visiva (distorsioni e low-level artifacts) e allineamento testo-immagine (consistenza semantica con il prompt). Il backbone MLLM produce giudizi discreti tramite token qualitativi (ad es. *Excellent ... Bad*) e ricava uno score continuo come media pesata delle probabilità dei token. Per i prompt lunghi introduce una strategia *vague-to-specific* che scompone la valutazione dell'allineamento in una parte “vaga” e in più verifiche “specifiche”, poi aggregate.

Altre metriche content-based enfatizzano esplicitamente la composizionalità. *DSG* (Davidsonian Scene Graph) [36] organizza in un grafo un insieme di domande dipendenti, imponendo vincoli di coerenza tra le risposte; un VQA verifica la presenza dei singoli elementi nell'immagine e lo score è ottenuto aggregando le risposte corrette. *GenEval* [28] adotta invece un'impostazione object-focused basata su detector e verifiche di proprietà su prompt con template fisso.

### 2.3.2 Metriche di qualità visiva (IQA)

Le metriche di *Image Quality Assessment* (IQA) mirano a stimare la qualità percettiva di un'immagine, con particolare attenzione a distorsioni e artefatti (ad es. blur, rumore, incoerenze locali). Storicamente, molte metriche IQA sono *full-reference*, ossia richiedono un'immagine di riferimento; un esempio classico è lo *Structural Similarity Index Measure* (SSIM) [37], che quantifica la similarità strutturale tra immagine degradata e riferimento. Nel *text-to-image*, tuttavia, l'assenza di una ground truth univoca

rende meno naturali le metriche full-reference, che risultano invece utili in setting controllati. Anche LPIPS [38] può essere utilizzata in questo modo.

Accanto alle metriche per-immagine, sono diffuse anche metriche *distribution-level* impiegate per confronti aggregati tra insiemi di immagini generate e reali. La *Fréchet Inception Distance* (FID) confronta le statistiche (media e covarianza) delle feature estratte da una rete Inception su due collezioni di immagini, mentre l'*Inception Score* (IS) stima la qualità/diversità a partire dalla distribuzione delle predizioni Inception su una collezione di immagini [30]. Sebbene utili per confronti globali a livello di distribuzione, anche queste metriche richiedono un insieme di immagini e non sono progettate per valutare la fedeltà al prompt.

Una linea recente impiega *MLLM* come valutatori di qualità. Nel caso di *Q-Eval-Score*, lo stesso backbone *MLLM* può essere interrogato con prompt di valutazione diversi per produrre uno score su assi distinti; in questa sezione l'interesse è la componente di *visual quality* [27]. Operativamente, rispetto alla valutazione di allineamento, cambia il *prompt* fornito al valutatore, che richiede esplicitamente un giudizio sulla qualità percettiva (distorsioni e low-level artifacts). In una verifica preliminare, valutando le stesse immagini *con* e *senza* includere il prompt testuale nel contesto di valutazione, si è osservata una variazione dello score; al contempo, ripetendo più run con lo stesso setting (stesso prompt incluso o escluso) il risultato rimaneva stabile. Questo suggerisce che la metrica può tener conto, almeno in parte, dell'informazione testuale quando presente.

Un approccio concettualmente affine è *Q-Align* [39]. Invece di predire direttamente uno score continuo, *Q-Align* insegna a un *LMM* a selezionare tra livelli qualitativi definiti testualmente (rating levels); lo score viene poi ricavato come aggregazione (ad es. valore atteso) delle probabilità associate ai livelli. Con una strategia di apprendimento nello studio si unifica IQA e IAA e la valutazione della qualità video nel modello *OneAlign* [39]. Questa metrica, a differenza di *Q-Eval-Score*, non utilizza il prompt testuale come input.

Infine, oltre alle metriche generali, esistono valutatori *task-specific* mirati a difetti ricorrenti della generazione. Ad esempio, *HADM* (Human Artifact Detection Models) è un modello addestrato per identificare e localizzare anomalie anatomiche umane, fornendo un segnale specifico sui difetti di struttura umana [40]. In modo

complementare, *HandEval* introduce un compito e un valutatore dedicati alla qualità della sola regione delle mani, con l’obiettivo di misurarne severità e realismo delle deformazioni in modo più fine-grained [41]. Questi strumenti non sostituiscono le metriche generali, ma risultano utili quando l’analisi richiede sensibilità verso difetti localizzati e semanticamente ben definiti.

### 2.3.3 Metriche di estetica (IAA)

Le metriche di *Image Aesthetic Assessment* (IAA) mirano a stimare aspetti di livello più alto rispetto all’IQA, come composizione, illuminazione, armonia cromatica e appeal visivo complessivo. L’IAA tende a riflettere preferenze umane più soggettive e può risultare debolmente correlata con l’aderenza al prompt: un’immagine esteticamente gradevole può infatti non rispettare vincoli semantici o compositivi richiesti dal testo.

Tra le metriche recenti, *ArtiMuse* propone una valutazione estetica più *fine-grained* su otto dimensioni estetiche, in cui lo score mira a catturare anche aspetti più articolati dell’estetica, rendendola utile quando l’obiettivo è andare oltre una misura unidimensionale e ottenere un segnale più informativo sulle componenti che contribuiscono all’estetica percepita [42].

Un riferimento molto usato in pipeline pratiche è l’*Aesthetic Score* basato sul *LAION Aesthetic Predictor*, ossia un regressore leggero (embedding-based) addestrato sopra il backbone CLIP per predire un punteggio di gradimento/aesthetic rating. Questo tipo di score viene spesso impiegato come proxy rapido dell’estetica per confronti su larga scala o per filtraggio/curation dei dataset<sup>1</sup>.

Infine, come discusso nella sezione precedente, *Q-Align* (e la sua unificazione in *OneAlign*) può essere utilizzato anche per l’IAA, producendo uno score di estetica a partire da livelli di rating definiti testualmente e aggregati sulla base delle probabilità prodotte dal modello [39].

---

<sup>1</sup><https://laion.ai/blog/laion-aesthetics>; <https://github.com/LAION-AI/aesthetic-predictor>

### 2.3.4 Metriche di preferenza umana condizionata dal prompt

Le metriche di *preferenza umana* mirano a stimare quanto una specifica immagine risulti preferibile per un osservatore umano, *condizionatamente* al prompt. A differenza delle metriche di allineamento puramente semantico o delle metriche di qualità percettiva, queste misure vengono tipicamente addestrate su annotazioni umane e producono uno score che approssima la probabilità che l'immagine venga scelta rispetto ad alternative. Per questo motivo, sono spesso utilizzate come proxy di valutazione human-centric.

Un riferimento largamente adottato è la famiglia *Human Preference Score* (HPS). In *HPSv2* il punteggio è ottenuto fine-tuning di un backbone CLIP su un ampio dataset di scelte umane (HPD v2), producendo uno score per la coppia prompt-immagine che approssima il giudizio di preferenza [26]. Esiste anche *HPSv2.1* che è una variante aggiornata/raffinata dell'implementazione ma che continua a seguire la stessa filosofia di misura<sup>2</sup>. Più recentemente, *HPSv3* estende l'idea a uno scenario *wide-spectrum*, introducendo un dataset di preferenze più ampio e variegato (HPD v3) e un modello di preferenza basato su MLLM con loss di ranking più adatta al confronto fine-grained, con l'obiettivo di aumentare robustezza e copertura della metrica [43].

Un altro reward model di riferimento è *ImageReward*, basato su backbone *BLIP*, addestrato su confronti di preferenza pairwise raccolti tramite una pipeline di annotazione che combina rating e ranking; il modello produce uno score scalare (reward) per una coppia testo-immagine, interpretabile come preferenza prevista. [25]

Su dati di preferenza raccolti in contesti d'uso realistici, *PickScore* è una funzione di scoring *CLIP-based* (ottenuta tramite fine-tuning di *CLIP-H*) addestrata sul dataset *Pick-a-Pic*, costruito tramite una web app in cui utenti reali esprimono scelte A/B tra immagini generate dallo stesso prompt. Il risultato è uno scorer pubblico orientato alle preferenze degli utenti, impiegabile sia per benchmark sia per ranking di campioni generati [24].

Infine, *MPS* apprende la preferenza umana in modo *multi-dimensionale* tramite un unico scorer che, dato un aspetto (estetica, allineamento semantico, qualità dei

<sup>2</sup><https://github.com/tgxs002/HPSv2>

dettagli, overall), applica una *condition mask* al prompt e calcola lo score condizionato integrando la maschera nella cross-attention testo-immagine [44].

### 2.3.5 Similarità e diversità percettiva delle immagini generate

Oltre agli score per-immagine, un aspetto spesso rilevante nella valutazione dei modelli text-to-image è la *variabilità* delle generazioni prodotte a parità di prompt (ad esempio al variare del seed o di altri parametri di sampling). In questo caso l'unità di analisi è tipicamente una *coppia* di immagini, e l'obiettivo è misurare quanto due output risultino percettivamente simili o diversi. Queste misure forniscono un complemento informativo alle metriche di allineamento/qualità: due configurazioni possono avere punteggi medi simili, ma differire in stabilità (bassa variabilità) o in diversità percettiva (alta variabilità).

Una metrica ampiamente usata è *LPIPS* (Learned Perceptual Image Patch Similarity), che calcola una distanza percettiva basata su feature profonde: valori più vicini a zero indicano immagini più simili dal punto di vista percettivo, mentre valori più alti indicano differenze più marcate [38]. In pratica, la similarità/diversità può essere stimata calcolando LPIPS su coppie di immagini generate dallo stesso prompt e aggregando poi i valori (ad es. media o mediana) per ottenere una misura sintetica di variabilità intra-prompt o intra-tipologia. Nel contesto dei *prompt smells*, tali misure sono utili per quantificare in modo operativo la (in)stabilità del processo generativo indotta da ambiguità, vaghezza o rumore lessicale, distinguendo tra degradazione della qualità media e aumento della dispersione tra generazioni.

## 2.4 Prompt engineering nei modelli text-to-image

Nei sistemi *text-to-image*, il prompt costituisce l'interfaccia principale tra l'intento dell'utente e il processo generativo. Con *prompt engineering* si intende l'insieme di pratiche con cui si struttura e si raffina il testo per aumentare controllabilità e qualità dell'output (ad es. specificando contenuto, vincoli compositivi e stile), spesso tramite iterazioni successive. Nella pratica d'uso—in particolare nelle community di *AI art*—si sono storicamente diffusi anche prompt dal formato “telegrafico” (liste

di keyword separate da virgole), arricchiti da riferimenti stilistici e termini estetici ricorrenti (*boosters*) con l’obiettivo di stabilizzare e indirizzare l’output verso rese percepite come più “rifinite” [45, 46].

Un contributo utile a descrivere tali strategie è la tassonomia dei *prompt modifiers* di Oppenlaender, che organizza i modificatori ricorrenti in categorie (ad es. termini di soggetto, modificatori di stile, *quality boosters*, termini ripetuti e *magic terms*) e mostra come molti di essi siano poco intuitivi e difficilmente deducibili osservando la sola immagine generata [45]. In parallelo, studi nell’area *Human–Computer Interaction* (HCI, interazione uomo–computer) evidenziano che la scrittura di prompt efficaci non è una competenza immediata: utenti non esperti tendono a produrre descrizioni plausibili ma incontrano difficoltà nel controllare in modo affidabile stile, composizione e vincoli, con un processo di apprendimento spesso basato su tentativi, esempi e convenzioni d’uso [46]. In questo contesto, nelle community online è frequentemente osservabile il ricorso a repertori condivisi di prompt e a strategie di *copy–paste* di frammenti testuali o keyword ritenute “efficaci”, privilegiando scorciatoie pragmatiche rispetto a una comprensione esplicita del legame tra input e output; ciò può contribuire alla diffusione di modificatori standardizzati e poco interpretabili e ridurre la tracciabilità del processo di generazione [45].

Nonostante i modelli recenti interpretino meglio il linguaggio naturale, rimangono diffuse linee guida pratiche che suggeriscono di separare *contenuto* e *resa* per ridurre omissioni e ambiguità. Ad esempio, lavori sulla riscrittura/ottimizzazione del prompt propongono strutture più “complete” e coerenti con ciò che l’utente intende descrivere, includendo esplicitamente soggetto, dettagli visivi, contesto, atmosfera e specifiche stilistiche [47]. In questo lavoro, per costruire prompt *clean* completi e confrontabili, si adotta un template a blocchi spesso suggerito in guide pratiche per modelli della famiglia Stable Diffusion<sup>3</sup> che organizza gli elementi informativi tipici di un prompt descrittivo:

- **Subject** (soggetto);
- **Detailed imagery** (dettagli visivi rilevanti);

<sup>3</sup><https://blog.segmind.com/prompt-guide-for-stable-diffusion-xl-crafting-textual-conditions>  
<https://stability.ai/learning-hub/stable-diffusion-3-5-prompt-guide>



- **Environment** (contesto/ambientazione);
- **Atmosphere/Mood** (atmosfera);
- **Style** (stile);
- **Style execution** (resa tecnica/medium e indicazioni di esecuzione quando pertinenti).

L'ordine dei blocchi non è vincolante: per descrizioni più articolate può essere necessario riorganizzare gli elementi per mantenere chiarezza e priorità dei vincoli.

Questa organizzazione non implica che il modello operi “per blocchi”, ma rende più espliciti i vincoli e facilita la tracciabilità tra input e output, riducendo la probabilità di omissioni accidentali.

Accanto alla scrittura manuale, una linea di ricerca recente tratta il prompt engineering come *prompt optimization*: il prompt viene riscritto automaticamente per aumentare qualità o preferenza prevista, mantenendo (idealmente) l'intento semantico. Diversi strumenti e framework valutano i prompt candidati attraverso *scorer* automatici, spesso combinando indicatori di allineamento e di gradimento estetico/preferenziale. Lavori come *BeautifulPrompt*, *NeuroPrompts* e *VisualPrompter* utilizzano metriche automatiche (ad es. CLIPScore, Aesthetic Score, PickScore e/o verifiche più composizionali come TIFA/DSG) per misurare l'efficacia delle riscritture e confrontare metodi diversi [48, 49, 50]. Questa tendenza rende esplicito il ruolo delle metriche come “segnale di feedback” e rafforza la necessità di discuterne limiti e sensibilità, poiché l'ottimizzazione rispetto a un valutatore può introdurre dipendenza dalla metrica o *overfitting* allo scorer.

In sintesi, il prompt engineering costituisce sia una pratica d'uso sia un oggetto di ricerca: la presenza di template, repertori condivisi e riscrittori automatici evidenzia quanto la formulazione del prompt sia determinante e, al contempo, quanto sia facile incorrere in difetti non intenzionali del testo. Questo motiva l'introduzione e lo studio sistematico dei *prompt smells*.

## 2.5 Prompt smells: definizione e tassonomia

Nei modelli *text-to-image* la formulazione del prompt incide in modo sostanziale sull'output generato. In questo contesto, Ronanki et al. [7] introducono la nozione di *prompt smells* per descrivere caratteristiche sintattiche e/o semantiche del prompt che emergono da una progettazione imprecisa (spesso involontaria) e che possono compromettere (i) la desiderabilità degli output, (ii) la spiegabilità del processo generativo e/o (iii) la tracciabilità tra input e output. Poiché tale definizione nasce nel contesto dei *Large Language Models*, in questa tesi se ne adotta una lettura adattata al dominio *text-to-image*: uno smell è interpretato come un difetto non intenzionale della formulazione testuale che, interagendo con il condizionamento via testo, può degradare il risultato generato o rendere meno chiaro e controllabile il legame tra prompt e immagine.

Nel seguito, i tre aspetti sopra citati sono considerati *assi distinti*: una tipologia può impattare *anche uno solo* di essi, senza necessariamente comprometterli tutti. In particolare:

- **Desiderabilità:** lo smell tende a peggiorare l'output rispetto all'intento dell'utente, riducendo qualità e/o aderenza al contenuto richiesto (ad es. allineamento testo-immagine), oppure influenzando negativamente estetica e preferenza complessiva.
- **Spiegabilità:** lo smell rende meno interpretabile il processo generativo, perché piccole variazioni del testo producono esiti molto diversi o perché l'effetto di alcuni termini risulta opaco e difficile da razionalizzare.
- **Tracciabilità:** lo smell indebolisce il collegamento tra parti del prompt e parti dell'immagine, ad esempio quando vincoli vengono ignorati o soddisfatti in modo instabile, quando emergono ambiguità di *binding* tra attributi ed entità, o quando rumore lessicale e frammenti copiati riducono la corrispondenza tra input e output.

Individuare e categorizzare i prompt smells è rilevante per almeno tre motivi. Primo, consente di esplicitare fonti ricorrenti di fallimento della generazione *text-to-image* legate non al modello in sé, ma all'interazione tra modello e linguaggio

naturale, che è intrinsecamente ambiguo e sensibile alla formulazione. Secondo, una tassonomia facilita analisi comparabili e riproducibili: senza categorie operative è difficile confrontare studi, misure e tecniche di mitigazione. Terzo, la categorizzazione supporta la progettazione di controlli e baseline, rendendo più chiaro quale trasformazione del prompt stia producendo un certo effetto sulle immagini.

In questa tesi, un fenomeno viene trattato come prompt smell se soddisfa due criteri operativi: (a) deriva plausibilmente da una formulazione non intenzionale o da pratiche d'uso che favoriscono errori ricorrenti (ad es. riuso di template, modificatori poco interpretabili, riscritture parziali); e (b) definisce una trasformazione del prompt per la quale è ragionevole ipotizzare un impatto su almeno una delle dimensioni di valutazione considerate (allineamento, qualità visiva, estetica, preferenza condizionata dal prompt, variabilità percettiva). Tale ipotesi viene poi verificata empiricamente: in alcuni casi l'effetto può risultare debole o nullo sulle metriche adottate, e anche l'assenza di differenze osservabili costituisce un'informazione utile sulla sensibilità delle metriche e sulla robustezza del generatore rispetto a quella trasformazione.

Coerentemente con questi criteri, la tassonomia proposta è stata costruita combinando due fonti principali: da un lato, *problematiche ricorrenti discusse nella letteratura* su robustezza e valutazione della generazione *text-to-image*; dall'altro, evidenze riportate in studi di *Human-Computer Interaction* sull'uso pratico dei sistemi generativi, che mostrano come molti utenti incontrino difficoltà nel formulare prompt controllabili e ricorrano a convenzioni di scrittura (keyword-soup, boosters, frammenti copiati) potenzialmente responsabili di difetti non intenzionali.

Un tema strettamente correlato, ma distinto dagli smells linguistici/strutturali, riguarda i *bias sociali e le proprietà di fairness nelle immagini generate* [10, 9] (ad es. stereotipi associati a professioni o attributi sensibili). Sebbene rilevante, una valutazione sperimentale della fairness richiede scelte normative (quale distribuzione attesa debba essere considerata "corretta") e protocolli dedicati per il campionamento e l'annotazione di attributi sensibili, spesso con supporto di valutazione umana. Per questo motivo, tali aspetti non vengono inclusi nella tassonomia operativa testata in questa tesi e sono considerati come possibile estensione futura.

Sulla base dei criteri sopra indicati, i prompt smells individuati sono organizzati nelle seguenti macrocategorie:

- **Ambiguità linguistica e referenziale**
- **Incoerenza interna / conflitto di vincoli**
- **Sotto-specificazione**
- **Sovra-specificazione / rumore**
- **Additivi non visual-grounded**
- **Robustezza lessicale e coverage shift**
- **Format / interaction mismatch**

In questa tesi si discutono le principali evidenze e i limiti emersi in letteratura per ciascuna macrocategoria, evidenziando il razionale che motiva la loro inclusione nello studio.

### 2.5.1 Ambiguità linguistica e referenziale

**Descrizione del fenomeno** Questa macrocategoria include prompt in cui il testo ammette più interpretazioni plausibili e non contiene indizi sufficienti per fissarne una in modo univoco. Nel dominio *text-to-image* questo è critico perché il modello deve comunque produrre un'immagine: l'ambiguità viene quindi "risolta" implicitamente durante la generazione e può tradursi in output alternativi, instabili tra seed o solo parzialmente allineati. In questa tesi si considerano, in modo coerente con la tassonomia adottata, le seguenti tipologie:

- **Ambiguità sintattica:** ambiguità strutturali (ad es. *PP-attachment*, coordinazioni) che rendono non deterministico il parsing del prompt [51, 10].
- **Ambiguità di negazione:** formulazioni con negazione a *scope* incerto (ad es. "without X and Y"), interpretabili come esclusione di entrambi gli elementi oppure come esclusione del solo primo, con presenza/assenza potenzialmente instabile [51, 10].
- **Polisemia:** termini polisemici/omonimi (ad es. *bat*, *crane*, *glasses*) che possono attivare sensi diversi o combinati nell'immagine [3, 51].

- **Ambiguità figurativa:** espressioni idiomatiche o metaforiche interpretabili in senso letterale o figurato [51].
- **Ambiguità referenziale:** pronomi o ellissi con antecedenti multipli plausibili, che rendono incerto “chi fa cosa” [10].
- **Ambiguità di binding:** attributi non mappati esplicitamente alle entità, con rischio di assegnazione errata (attribute–object binding) [28].
- **Ambiguità spaziale:** relazioni spaziali espresse senza frame di riferimento esplicito o con riferimento ambiguo (ad es. “a sinistra di”), che ammettono interpretazioni alternative [28].

**Perché è un prompt smell** L’ambiguità può ridurre la **desiderabilità** dell’output perché il modello può scegliere un’interpretazione diversa da quella intesa dall’utente (oppure combinare più interpretazioni), producendo immagini solo parzialmente allineate ai vincoli richiesti. Impatta anche la **spiegabilità**: a parità di intento, piccole variazioni testuali o assenza di disambiguazione possono portare a esiti molto diversi, rendendo opaco il processo decisionale che porta a selezionare un senso, un antecedente o un’associazione attributo–entità. Infine, l’ambiguità indebolisce la **tracciabilità** input→output perché diventa difficile attribuire in modo stabile a quali porzioni del prompt corrispondano dettagli specifici dell’immagine (ad es. quali entità “ereditino” certi attributi o quale frame di riferimento sia stato adottato per una relazione spaziale).

**Evidenze e approcci in letteratura** Per la **Polisemia**, è stato osservato che i modelli diffusion possono generare immagini che combinano più sensi del termine (una sorta di “superposizione” semantica), e che interventi sul condizionamento possono orientare verso un senso specifico [3]. Per l’ambiguità più generale, il dataset *TAB* include ambiguità **Ambiguità sintattica** e **Ambiguità referenziale** e mostra che la disambiguazione esplicita(ponendo domande all’utente per disambiguare il prompt) può migliorare la fedeltà all’intento testuale [10]. Studi più recenti analizzano sistematicamente anche **Ambiguità figurativa** e confermano che la risoluzione adottata dal modello può divergere da quella attesa da un umano [51]. Infine, benchmark

object-centric evidenziano limiti persistenti su **Ambiguità di binding** e **Ambiguità spaziale**, che richiedono mappature e relazioni precise [28]. In chiave più pratica, linee guida di prompting suggeriscono di rendere espliciti soggetti, attributi e relazioni per ridurre fallimenti dovuti a formulazioni ambigue.

**Limiti della letteratura e gap** Molti studi sull’ambiguità adottano prompt controllati o template, mentre nei prompt d’uso reale i fenomeni possono co-occorrere (ambiguità + vaghezza + rumore), rendendo difficile attribuire gli effetti a un singolo fattore. Inoltre, per **Ambiguità figurativa** e parte della **Ambiguità referenziale**, l’interpretazione “corretta” dipende spesso dal contesto e dall’intento, limitando l’uso di evaluator automatici come segnale univoco.

### 2.5.2 Incoerenza interna

**Descrizione del fenomeno** Questa macrocategoria include prompt che contengono vincoli *mutuamente incompatibili* o difficilmente conciliabili, introducendo conflitti interni che il modello deve risolvere “scegliendo” quali parti rispettare. In questa tesi si considerano le seguenti tipologie:

- **Contraddizione sul soggetto:** attributi incompatibili assegnati alla stessa entità principale (ad es. caratteristiche fisiche o proprietà materiali in conflitto).
- **Contraddizione ambientale:** vincoli contestuali incoerenti (ad es. illuminazione, meteo, indoor/outdoor, stagione o tempo del giorno non compatibili).
- **Contrasto estetico:** specifiche stilistiche o di esecuzione che entrano in conflitto tra loro oppure con la resa attesa, generando indicazioni estetiche contraddittorie.

**Perché è un prompt smell** L’incoerenza interna compromette la **desiderabilità** perché, in presenza di vincoli incompatibili, l’output non può soddisfare simultaneamente tutte le richieste: il risultato tende quindi a violare (o a “mediare”) una parte dell’intento, con possibili degradazioni di allineamento e/o qualità percepita. Riduce inoltre la **spiegabilità**, poiché non è chiaro a priori quali vincoli verranno privilegiati

dal modello e l'esito può dipendere in modo non intuitivo da dettagli del prompt o da fattori stocastici del sampling. Infine, indebolisce la **tracciabilità** perché la presenza di istruzioni contrastanti rende difficile ricondurre i dettagli finali a specifiche porzioni del testo: alcuni vincoli vengono ignorati o soddisfatti solo parzialmente, e il collegamento tra "richiesta" e "realizzazione" diventa meno deterministico.

**Evidenze e approcci in letteratura** Il problema è particolarmente evidente nella componente stilistica: lavori sulla riscrittura/ottimizzazione del prompt osservano che i modelli (o i riscrittori) riescono spesso a migliorare contenuto e dettagli, ma possono introdurre termini di stile ed esecuzione non coerenti o contrastanti, con ricadute negative sulla fedeltà semantica. *PROMPTIST* sottolinea la difficoltà nel produrre prompt "model-preferred" con stile coerente e segnala che keyword stilistiche improprie o contrastanti possono peggiorare l'output [47]. In modo complementare, *VisualPrompter* discute che tecniche di *prompt decoration* orientate all'estetica possono aggiungere keyword stilistiche eccessive o conflittuali, sacrificando coerenza e semantica, e motiva l'esigenza di meccanismi che evitino conflitti durante la riscrittura [50]. Per le contraddizioni su soggetto e ambiente, l'evidenza deriva soprattutto da pratiche d'uso e linee guida che raccomandano coerenza e specificazione non contraddittoria dei vincoli, poiché aggiunte incrementalmente "per arricchire" possono introdurre conflitti non intenzionali [46].

**Limiti della letteratura e gap** La letteratura discute frequentemente conflitti stilistici (**Contrasto estetico**) nel contesto della riscrittura/ottimizzazione, ma fornisce meno analisi sistematiche e comparabili sui conflitti "di contenuto" (**Contraddizione sul soggetto, Contraddizione ambientale**) in scenari non template-based. Inoltre, l'effetto dei conflitti può dipendere dal generatore e dal valutatore: alcuni modelli possono "risolvere" il conflitto ignorando selettivamente parti del prompt, mentre metriche globali possono non catturare pienamente *quale* vincolo sia stato violato. Questo motiva l'inclusione di tipologie operative che isolano conflitti interni e ne consentono un'analisi comparabile.

### 2.5.3 Sotto-specificazione

**Descrizione del fenomeno** Questa macrocategoria raccoglie prompt in cui l'intento è descritto in modo *incompleto* per omissione di elementi informativi utili al controllo della generazione (ad es. dettagli visivi, contesto, atmosfera, stile). La sotto-specificazione non implica necessariamente "errore" (può essere una scelta deliberata), ma diventa un prompt smell quando l'omissione è *non intenzionale* e riduce la capacità di ottenere output coerenti con l'obiettivo. In questa tesi si considerano le seguenti tipologie:

- **Nessuno stile:** omissione di lessico stilistico/tecnico (medium, riferimenti artistici, indicazioni di esecuzione) che limita il controllo estetico [46].
- **Nessuna keyword:** assenza di *prompt modifiers*/keyword tipiche del prompt engineering, lasciando una descrizione "raw" della scena [52, 49].
- **Solo soggetto+dettagli:** specifica minima centrata sull'entità principale e pochi dettagli, senza vincoli contestuali o di resa.
- **Solo soggetto:** prompt estremamente vago, in cui è specificato solo il soggetto principale.
- **Nessun booster:** rimozione dei soli termini *booster* (quality-enhancers) mantenendo il resto della descrizione, per isolare il contributo dei *boosters* [49].

**Perché è un prompt smell** La sotto-specificazione diventa uno smell quando l'omissione è **non intenzionale** e incide sulla **desiderabilità**: l'output può discostarsi dalle aspettative implicite dell'utente (ad es. stile, contesto o atmosfera desiderati ma non esplicitati), perché il modello completa le parti mancanti facendo affidamento su prior e bias della distribuzione di addestramento. Impatta anche la **spiegabilità**, poiché la mancanza di vincoli rende più difficile prevedere quali scelte "libere" il generatore adotterà e può aumentare la variabilità tra generazioni a parità di prompt. In termini di **tracciabilità**, l'assenza di specifiche riduce la possibilità di collegare componenti dell'immagine a porzioni del testo: molte caratteristiche dell'output non sono giustificabili a partire dall'input perché non sono state vincolate esplicitamente.



**Evidenze e approcci in letteratura** Studi HCI sul prompting per *AI art* riportano che utenti non esperti spesso producono prompt plausibili ma omettono vocaboli specifici di stile/tecnica, con perdita di controllo sull'estetica [46]. In parallelo, lavori che confrontano descrizioni “raw” con varianti arricchite da keyword/modifiers mostrano che l'aggiunta di modificatori tende a migliorare performance o preferenza prevista, suggerendo che l'assenza di tali componenti può costituire una forma di sotto-specificazione rilevante [52]. Coerentemente, diversi framework di *prompt optimization* inseriscono automaticamente modifiers (inclusi booster) per migliorare output secondo scorer automatici, indicando che tali elementi vengono trattati come leve pratiche per aumentare qualità/percezione [49].

**Limiti della letteratura e gap** La sotto-specificazione è difficile da valutare in modo univoco perché dipende dall'intento: un prompt breve può essere una scelta deliberata. Inoltre, l'effetto dell'omissione può variare in funzione del generatore e del contenuto e metriche globali possono avere sensibilità limitata quando la perdita di specifica riguarda aspetti soggettivi (ad es. stile). Questi fattori motivano l'analisi per tipologie distinte, che separano omissioni “mirate” (es. stile o booster) da riduzioni drastiche dei vincoli. In particolare, per i *boosters* l'effetto atteso può essere debole o nullo nei modelli moderni: pratiche nate per compensare limiti di controllabilità/resa di sistemi precedenti possono non trasferirsi in modo lineare a generatori più recenti.

### 2.5.4 Sovra-specificazione / rumore

**Descrizione del fenomeno** Questa macrocategoria include prompt in cui l'utente introduce *più testo del necessario* o aggiunge ridondanze non informative, con il rischio di diluire l'attenzione del modello, aumentare il rumore lessicale e rendere meno stabile il rispetto dei vincoli. In questa tesi si considerano le seguenti tipologie:

- **Prompt troppo lungo:** descrizioni verbose e ridondanti che possono superare i limiti di contesto dell'encoder testuale o comprimere l'informazione in modo poco efficace, riducendo il controllo sui dettagli [33, 23].

- **Ripetizione token:** duplicazioni non informative di parole/attributi, che aumentano rumore e lunghezza senza introdurre nuova semantica; nei prompt reali la ripetizione può emergere come strategia ingenua di “enfasi” [46].
- **Troppi boosters:** eccesso di keyword estetiche general-purpose (*quality boosters*) che mirano a “migliorare” la resa ma possono interferire con la fedeltà semantica o con la priorità dei vincoli [45, 52, 50].

**Perché è un prompt smell** La sovra-specificazione e il rumore lessicale possono ridurre la **desiderabilità** perché la presenza di informazioni ridondanti o di molti modificatori concorrenti può portare a omissioni selettive, interpretazioni parziali o priorità non desiderate (alcuni vincoli vengono rispettati a scapito di altri). Compromettono inoltre la **spiegabilità**: l’effetto di singoli termini diventa difficile da isolare e la relazione causa–effetto tra “aggiunta di testo” e risultato può apparire non lineare, soprattutto quando porzioni del prompt hanno impatto marginale o ambiguo. Infine, peggiorano la **tracciabilità** input→output perché l’aumento di ridondanza e competizione testuale rende meno chiaro quali parti del prompt abbiano determinato specifici dettagli dell’immagine, e può accentuare la difficoltà di attribuire correttamente errori o differenze tra generazioni a componenti testuali precise.

**Evidenze e approcci in letteratura** Una motivazione ricorrente è legata ai limiti degli encoder testuali: molte pipeline text-to-image usano encoder tipo CLIP con finestre di contesto limitate, per cui prompt molto lunghi possono essere troncati o rappresentati in modo compresso, con perdita di informazione e minore influenza di porzioni del testo [33, 23]. Sul versante delle pratiche d’uso, studi su prompting in community di AI art descrivono l’impiego di modificatori estetici e booster come convenzioni diffuse, non sempre trasparenti o necessarie [45, 46]. In particolare, lavori su *prompt optimization* osservano che l’aggiunta aggressiva di keyword estetiche può introdurre rumore o modifiche che sacrificano coerenza e semantica, motivando strategie che controllino l’impatto dei “decoratori” sul contenuto [50]. Infine, confronti tra prompt “raw” e prompt arricchiti suggeriscono che l’effetto dei modificatori dipende dal tipo e dalla quantità: l’aggiunta può aiutare, ma non implica che “più keyword” sia sempre meglio [52].

**Limiti della letteratura e gap** Gli effetti della sovra-specificazione sono fortemente dipendenti da modello, encoder e pipeline: ciò che risulta “troppo lungo” o “troppo decorato” in un sistema può non esserlo in un altro. Inoltre, il confine tra dettaglio utile e rumore non è netto, e le metriche globali possono non catturare bene *quali* vincoli siano stati sacrificati. Questo motiva una trattazione per tipologie distinte (lunghezza, ripetizione, booster), separando fenomeni che possono apparire simili (testo “in eccesso”) ma che hanno meccanismi e implicazioni differenti.

### 2.5.5 Additivi non visual-grounded

**Descrizione del fenomeno** Questa macrocategoria include prompt in cui vengono aggiunti termini o frasi che *non sono direttamente ancorati a contenuti visualizzabili* (oggetti, attributi osservabili, relazioni o vincoli compositivi). Questi additivi possono essere usati per “arricchire” il testo o per imitare convenzioni diffuse nelle community, ma introducono segnali deboli o ambigui per il generatore. In questa tesi si considerano le seguenti tipologie:

- **Termini astratti:** concetti vaghi o altamente concettuali (ad es. intenzioni, stati o qualità difficili da tradurre in vincoli visivi), che possono risultare poco deterministici per il modello [53].
- **Magic terms:** additivi lessicali “poetici” o non letterali inseriti per indurre effetti imprevedibili/surreali o per esplorare comportamenti limite del modello [54].

**Perché è un prompt smell** Gli additivi non visual-grounded tendono a ridurre *spiegabilità* e *tracciabilità*: se un termine non corrisponde a un vincolo visivo verificabile, diventa difficile capire *se* e *come* abbia influenzato l’output. Inoltre possono introdurre rumore semantico che compete con i vincoli “concreti”, aumentando l’instabilità tra generazioni e la probabilità di effetti non interpretabili (ad esempio variazioni stilistiche o contenuti inattesi non riconducibili a parti specifiche del prompt).

**Evidenze e approcci in letteratura** Nel contesto dell’analisi delle *default images*, è stato osservato che alcuni utenti ricorrono a **Magic terms** come additivi lessicali per aumentare casualità e sondare comportamenti limite, ottenendo spesso risultati

altamente imprevedibili o surreali; tali additivi sono descritti come progettati per indurre randomness nel processo generativo [54]. In modo complementare, analisi su log reali di prompt con rating riportano che termini associati a valutazioni più basse risultano frequentemente **più vaghi e più astratti**, suggerendo che la presenza di **Termini astratti** possa essere correlata a intenti meno definiti o a una specificazione insufficiente dei vincoli visivi [53]. Nel complesso, questi risultati supportano l'idea che additivi non ancorati al visivo possano indebolire il controllo e rendere l'output più dipendente da dinamiche implicite del modello.

**Limiti della letteratura e gap** La principale difficoltà è che, per **Termini astratti** e **Magic terms**, manca spesso un criterio oggettivo di “correttezza” visiva: l'effetto atteso non è un vincolo verificabile (come un oggetto o una relazione), e la valutazione dipende dal contesto e dalle aspettative dell'utente. Inoltre, questi fenomeni possono essere confusi con altre fonti di instabilità (prompt lunghi, conflitti stilistici, vaghezza generale). Ciò rende utile trattarli come tipologie separate nella tassonomia, così da poter verificare empiricamente se e quanto introducano rumore o variabilità nelle dimensioni di valutazione adottate.

### 2.5.6 Robustezza lessicale e coverage shift

**Descrizione del fenomeno** Questa macrocategoria include perturbazioni in cui l'informazione del prompt rimane (idealmente) la stessa, ma cambia la *forma lessicale* con cui viene espressa, oppure viene introdotto testo *poco coperto* dalla distribuzione linguistica del modello. In questi casi il rischio è una perdita di ancoraggio semantico (*lexical grounding*): token rari, corrotti, abbreviati o appartenenti a varietà/lingue meno coperte possono essere ignorati, fraintesi o “assorbiti” dal contesto, con una generazione guidata soprattutto dalle parole più comuni. In questa tesi si considerano le seguenti tipologie:

- **Abbreviazioni:** uso di shorthand non standard o poco trasparenti, che può ridurre l'interpretabilità locale del prompt e favorire l'ignoramento dei termini meno riconoscibili [54].

- **Parole corrotte:** inserimento di parole alterate/ortograficamente corrotte, con possibile perdita di ancoraggio e aumento di comportamenti “genericizzati” quando il modello si affida alle parole note circostanti [54].
- **Neologismi:** termini inventati o non stabilizzati, che possono produrre tokenizzazione in sub-token poco informativi e segnali semantici instabili, riducendo controllabilità e tracciabilità input→output.
- **Nomi fantasy:** inserimento di un *nome proprio* raro o sconosciuto che potrebbe non essere rappresentato in modo affidabile nelle conoscenze del modello; di conseguenza, il termine può non vincolare la generazione come previsto e produrre output poco pertinenti rispetto all’intento dell’utente [55].
- **URL aggiunto:** inserimento di un URL non interpretabile come contenuto visuale; può essere ignorato oppure introdurre rumore testuale e, in casi estremi, contribuire a esiti poco informativi [54].
- **Traduzione italiana:** cambio lingua (high-resource) che può comunque introdurre mismatch di coverage e differenze di tokenizzazione, con potenziale calo di robustezza rispetto al baseline in inglese.
- **Traduzione AAVE:** riscrittura in una varietà marcata (African American Vernacular English) che può ridurre la robustezza dell’interpretazione testuale, a causa di grafie non standard e costruzioni morfosintattiche meno frequenti nei dati di addestramento e introdurre effetti collaterali di *subject shift*, poiché alcuni marker dialettali possono essere interpretati come segnali socio-culturali impliciti.
- **Traduzione finlandese:** lingua low-resource che può aumentare il rischio di perdita di ancoraggio e l’emergere di output ricorrenti/non specifici; il finlandese è esplicitamente considerato in studi sulle *default images* come caso di input poco coperto [54].

**Perché è un prompt smell** Queste perturbazioni possono compromettere la desiderabilità dell’output (dettagli ignorati o interpretati in modo errato), ridurre la

spiegabilità (non è chiaro perché il modello “salta” certi vincoli) e indebolire la tracciabilità (parti del prompt non lasciano una firma osservabile nell’immagine). Un comportamento tipico riportato in letteratura è che, in presenza di termini non riconosciuti mescolati a molte parole comuni, il modello tenda a farsi guidare soprattutto dalle componenti note, riducendo drasticamente l’influenza dei token “fuori copertura” [54].

**Evidenze e approcci in letteratura** Nel lavoro sulle *default images*, vengono discusse categorie di input come **Abbreviazioni**, **Parole corrotte**, **URL aggiunto** e termini/lingue poco coperti, mostrando che l’assenza di ancoraggio può portare a immagini genericizzate o ricorrenti e che la presenza di parole note nel prompt può “dominare” la generazione quando coesistono segmenti non interpretabili [54]. In modo complementare, studi orientati a casi d’uso creativi osservano che keyword nuove o nomi “provvisori” (non presenti o non consolidati nel lessico appreso) possono fallire come vincoli, portando a risultati scollegati dall’intenzione: questo motiva la tipologia **Nomi fantasy** come failure mode di coverage/grounding [55].

**Limiti della letteratura e gap** Gli effetti del *coverage shift* dipendono in modo marcato dal generatore e dall’encoder testuale (tokenizzazione, vocabolario, distribuzione linguistica del training): la stessa perturbazione può risultare trascurabile in alcuni sistemi e critica in altri. Per traduzioni e varietà dialettali, inoltre, è difficile isolare l’effetto “lingua” da cambiamenti pragmatici o socio-culturali veicolati dalla forma testuale. Va anche considerato che alcuni modelli più recenti adottano encoder testuali più capaci che possono attenuare le difficoltà con lingue low-resource; tuttavia la robustezza rimane fortemente *model-dependent* e richiederebbe verifica sperimentale caso per caso.

### 2.5.7 Format / interaction mismatch

**Descrizione del fenomeno** Questa macrocategoria include casi in cui il prompt presenta un *mismatch pragmatico o formale* rispetto al formato che i modelli text-to-image trattano tipicamente come descrizione dell’immagine. Il contenuto informativo può anche rimanere simile, ma la forma (tono istruzionale, ordine non canonico,

wrapper conversazionale, keyword-soup) può cambiare il modo in cui l’encoder e il modello distribuiscono attenzione e priorità ai vincoli. In questa tesi si considerano le seguenti tipologie:

- **Prompt istruzionale:** formulazione imperativa/stepwise (es. “Generate... Make the mood... Render with...”), più simile a un comando che a una caption descrittiva [46].
- **Mismatch template:** contenuto invariato ma organizzato in un ordine disorganizzato o non conforme a pattern/strutture consolidate, simulando la mancata adozione di un template [46].
- **Prompt conversazionale:** formulazione in stile chat (ad es. saluto e richiesta cortese) espressa come domanda (“Could you...?”), che incapsula la descrizione in una pragmatica dialogica invece che in una caption diretta [46].
- **Formato legacy:** prompt in formato keyword-soup telegrafico (frammenti separati da virgole, sintassi minima) tipica di convenzioni storiche o workflow precedenti, potenzialmente non ottimale per modelli contemporanei.

**Perché è un prompt smell** Il format mismatch può ridurre la desiderabilità dell’output quando la forma del testo introduce segnali non utili al grounding visivo (saluti, cortesia, istruzioni meta), o quando altera la struttura informativa in modo da rendere meno chiaro quali vincoli siano prioritari. Può inoltre ridurre la spiegabilità: piccoli cambiamenti di forma (descrizione vs comando vs domanda) possono produrre variazioni non intuitive. Infine, indebolisce la tracciabilità input→output perché frammenti non visual-grounded (preamboli conversazionali) o riordini disorganizzati possono rendere più difficile collegare porzioni del prompt ai dettagli dell’immagine.

**Evidenze e approcci in letteratura** Studi HCI sul prompting per AI art riportano che utenti non esperti spesso interagiscono con sistemi di generazione come se fossero chat, producendo richieste conversazionali o prompt istruzionali invece di descrizioni dirette, e tendono a non seguire template ricorrenti adottati nelle community [46].

Queste osservazioni supportano la rilevanza di tipologie che isolano la variazione di forma pragmatica (**Prompt conversazionale**) e di struttura (**Mismatch template**). Inoltre, la coesistenza di formati “storici” (keyword-soup) e linee guida moderne basate su linguaggio naturale suggerisce che un **Formato legacy** possa introdurre mismatch di compatibilità/robustezza: a parità di contenuto dichiarato, la diversa segmentazione in frammenti e la minore coesione sintattica possono modificare la distribuzione dell’attenzione e la forza dei vincoli.

**Limiti della letteratura e gap** La letteratura HCI evidenzia pattern d’uso e difficoltà degli utenti, ma raramente quantifica in modo sistematico l’effetto di singole trasformazioni formali a contenuto controllato. Inoltre, l’impatto del formato dipende dal modello e dall’encoder: alcuni sistemi possono essere quasi invarianti a preamboli conversazionali, altri possono risentirne. Questo motiva la definizione di tipologie operative che modificano *solo la forma* del prompt (istruzioni, ordine, wrapper conversazionale, keyword-soup) mantenendo per quanto possibile la copertura informativa, così da verificare empiricamente se e quanto la pragmatica del testo influenzi allineamento, qualità e stabilità degli output. Nel caso del **Formato legacy**, la struttura a frammenti telegrafici può inoltre attenuare i segnali di composizionalità del linguaggio naturale (ad es. relazioni sintattiche e dipendenze tra elementi), rendendo meno evidenti i legami tra soggetto, attributi e contesto e quindi potenzialmente indebolendo la tracciabilità tra parti del prompt e parti dell’output.



---

### Metodologia di ricerca

---

#### 3.1 Obiettivi e domande di ricerca

Come discusso nello Stato dell'Arte, la formulazione del prompt nei sistemi *text-to-image* può influenzare in modo significativo il risultato della generazione. In particolare, difetti non intenzionali del testo (*prompt smells*) possono degradare la desiderabilità dell'output e ridurre spiegabilità e tracciabilità tra input e output. A fronte della mancanza di una tassonomia operativa focalizzata sui *prompt smells* nel contesto *text-to-image*, questa tesi mira a definire tipologie riproducibili di *smells* e a quantificarne l'impatto in modo sistematico tramite metriche automatiche che valutano più fattori.

Per perseguire tale obiettivo, sono state formulate le seguenti domande di ricerca:

- **Q RQ<sub>1</sub>.** *In che misura i prompt smells impattano sulle metriche di allineamento testo-immagine, qualità visiva, estetica e preferenza umana condizionata dal prompt?*
- **Q RQ<sub>2</sub>.** *I prompt smells influenzano la variabilità percettiva intra-prompt delle immagini generate al variare del seed?*

## 3.2 Metodo di ricerca

La Figura 3.1 riassume i due workflow sperimentali adottati. Entrambi condividono una prima fase comune di costruzione dei prompt, generazione delle immagini e calcolo delle metriche; successivamente il flusso si biforca in (i) un workflow dedicato alla variabilità percettiva (LPIPS) e (ii) un workflow dedicato alla modellazione statistica delle metriche per immagine.

### Fase comune (clean vs smelly)


1. **Definizione delle baseline clean:** costruzione di prompt di controllo progettati per essere riproducibili e comparabili.
2. **Applicazione degli smells:** generazione delle varianti *smelly* tramite trasformazioni mirate che istanziano le tipologie di prompt smells.
3. **Generazione delle immagini:** produzione delle immagini per prompt clean e smelly in condizioni controllate (stesso modello e configurazione), includendo repliche al variare del seed.
4. **Calcolo delle metriche:** estrazione dei punteggi automatici per ciascuna immagine.

**Metriche per immagine** Per ogni immagine vengono calcolate sei metriche automatiche che coprono più dimensioni: *allineamento testo-immagine* (CLIPScore, Q-Eval Image Alignment), *qualità visiva* (Q-Eval Image Quality, OneAlign Quality), *estetica* (OneAlign Aesthetic) e *preferenza umana condizionata dal prompt* (HPSv2.1).

**Workflow A: modellazione statistica (sei metriche)** Nel workflow delle metriche per immagine, i punteggi vengono sottoposti a preprocessing (ricondotti al dominio  $(0, 1)$ ) e quindi analizzati con un *beta mixed-effects model* in `glmmTMB`, con l'obiettivo di quantificare l'effetto degli smells sulle metriche e rispondere alla RQ1.

**Workflow B: variabilità percettiva (LPIPS)** Nel workflow LPIPS, la variabilità percettiva *intra-prompt* (repliche a seed diversi) è misurata tramite distanza LPIPS e poi

aggregata a livello di tipologia (`prompt_typology`) per confronti *smelly vs baseline*. L'incertezza delle stime è quantificata con intervalli di confidenza via bootstrap, al fine di rispondere alla RQ2. I dettagli operativi dei due workflow sono presentati nelle sezioni successive.



**Figura 3.1:** Schema dei workflow sperimentali: analisi delle metriche per immagine (RQ1) e della variabilità percettiva tramite LPIPS (RQ2).

### 3.3 Setup sperimentale

**Ambiente di esecuzione e risorse** Gli esperimenti di generazione sono stati eseguiti in un notebook Kaggle dotato di GPU NVIDIA T4 (16 GB VRAM). Per rientrare nei vincoli di memoria mantenendo al contempo tempi di inferenza contenuti, è stato adottato un setup di inferenza ottimizzato tramite quantizzazione selettiva e tecniche di *memory saving*.

**Modello text-to-image** Per la generazione delle immagini è stato utilizzato `stabilityai/stable-diffusion-3.5-large-turbo` tramite la libreria `diffusers`. Il modello è stato selezionato perché combina buona qualità visiva e robustezza generale con un impiego di VRAM compatibile con l'hardware disponibile. In particolare, è

stata applicata una quantizzazione a 4 bit (NF4) al solo modulo denoiser basato su Transformer (`SD3Transformer2DModel`), mantenendo gli altri componenti della pipeline in FP16. Questo compromesso consente di ridurre l'occupazione di memoria senza introdurre una quantizzazione pesante sull'intera pipeline. Modelli alternativi più onerosi in termini di memoria (ad es. famiglie come FLUX) sono stati scartati poiché, a meno di quantizzazioni più aggressive, non risultavano compatibili con i limiti di memoria dell'ambiente di esecuzione.

**Ottimizzazioni di memoria** Per ridurre ulteriormente l'uso di VRAM durante l'inferenza, la pipeline è stata configurata con *CPU offload* del modello, *VAE slicing/tiling* e *attention slicing*. Inoltre, il controllo di sicurezza è stato disabilitato in fase di generazione al fine di evitare filtraggi automatici e mantenere una valutazione consistente sugli output prodotti.

**Parametri di generazione** Le immagini sono state generate con risoluzione  $768 \times 768$ , 6 step di inferenza e `guidance_scale` pari a 0.0 per rispettare la configurazione raccomandata per la variante turbo e massimizzare stabilità. Per garantire confronti riproducibili tra tipologie e condizioni (clean vs smelly), sono stati impiegati seed deterministici e prefissati, identici per tutti i prompt: {101, 202, 303, 404, 505, 606, 707, 808}. Con questa configurazione, il tempo di generazione osservato è stato in media dell'ordine di  $\sim 30$  s per immagine, corrispondenti a circa  $\sim 1$  ora per tipologia. I parametri principali di generazione sono riassunti in Tabella 3.1.

**Struttura dei prompt e dimensione del campione** Ogni tipologia di prompt (`prompt_typology`) contiene 14 prompt, organizzati in 7 famiglie semantiche (`prompt_family`): *Human Portrait*, *Single Object*, *Indoor Scene*, *Outdoor Scene*, *Artistic Style*, *Animals*, *Action Scene*. Per ciascuna famiglia sono state definite 2 varianti (`prompt_variant`), ottenendo così 14 prompt per tipologia. Per ogni prompt sono state generate 8 repliche (una per seed), per un totale di  $14 \times 8 = 112$  immagini per tipologia. Considerando tutte le tipologie testate (6 baseline clean e 32 tipologie smelly, per un totale di 38 `prompt_typology`), il dataset complessivo comprende  $38 \times 112 = 4256$  immagini generate.

**Tabella 3.1:** Parametri principali di generazione delle immagini.

| Parametro              | Valore                                   |
|------------------------|------------------------------------------|
| Risoluzione            | 768 × 768                                |
| Numero di step         | 6                                        |
| Guidance scale         | 0.0                                      |
| Seed                   | {101, 202, 303, 404, 505, 606, 707, 808} |
| Repliche per prompt    | 8 (una per seed)                         |
| Immagini per tipologia | 112 (14 × 8)                             |
| Formato output         | PNG                                      |

**Tracciamento e organizzazione dei dati** Per ciascuna immagine generata sono stati salvati (i) l’output in formato PNG e (ii) una riga di tracciamento in un file CSV associato alla tipologia, contenente il testo del prompt e un insieme di identificativi sperimentali. Oltre ai campi direttamente disponibili in fase di generazione, sono stati inclusi anche identificativi costruiti per rendere espliciti gli appaiamenti e i raggruppamenti necessari nelle fasi di analisi successive. La Tabella 3.2 riassume i campi principali e il loro ruolo nel mantenere un mapping univoco e verificabile tra input (prompt) e output (immagini), nonché nel supportare confronti tra tipologie.

### 3.4 Tipologie testate e baseline clean

Questa sezione descrive le tipologie di prompt incluse nello studio, distinguendo tra (i) *baseline clean* impiegate come condizioni di controllo e (ii) tipologie *smelly* ottenute applicando trasformazioni testuali riproducibili. Le baseline clean sono state progettate per rendere il confronto *clean vs smelly* quanto più possibile controllato: ciascuna baseline elimina (o disinnesca) una specifica fonte di ambiguità o confondimento, così che la variante *smelly* possa differire per una modifica minimale e attribuibile. In coerenza con il workflow riassunto in Figura 3.1, le baseline clean costituiscono il punto di partenza da cui sono derivate sistematicamente le tipologie *smelly* analizzate nelle sezioni successive.

**Tabella 3.2:** Campi principali e identificativi usati per tracciare prompt e immagini e supportare appaiamenti e raggruppamenti nelle analisi successive.

| Campo           | Descrizione                                                                                                                                                                                           |
|-----------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| prompt          | Testo del prompt effettivamente passato al modello generativo.                                                                                                                                        |
| prompt_family   | Famiglia semantica del prompt (7 livelli: <i>Human Portrait</i> , <i>Single Object</i> , <i>Indoor Scene</i> , <i>Outdoor Scene</i> , <i>Artistic Style</i> , <i>Animals</i> , <i>Action Scene</i> ). |
| prompt_variant  | Variante del prompt all'interno della famiglia ({1,2}); consente di avere due prompt distinti per ciascuna prompt_family.                                                                             |
| prompt_typology | Tipologia (baseline clean o smelly) a cui appartiene il prompt; identifica la trasformazione applicata (se presente).                                                                                 |
| seed            | Seed deterministico usato per la generazione dell'immagine.                                                                                                                                           |
| base_prompt_id  | Identificativo della baseline del prompt, usato per appaiare prompt semanticamente corrispondenti tra tipologie diverse; definito come combinazione di prompt_family e prompt_variant.                |
| prompt_id       | Identificativo univoco del prompt nella tipologia; definito come combinazione di prompt_family, prompt_variant e prompt_typology.                                                                     |
| pair_id         | Identificativo per raggruppare immagini semanticamente corrispondenti generate con lo stesso seed su tipologie diverse; definito come combinazione di prompt_family, prompt_variant e seed.           |
| image_path      | Percorso relativo univoco dell'immagine salvata su disco, che include tipologia e identificativi del prompt/seed (es.:aave_translation/human_portrait_1_aave_translation_101.png).                    |

### 3.4.1 Baseline clean (condizioni di controllo)

Le baseline clean rappresentano condizioni di controllo progettate per essere comparabili tra loro e accoppiabili in modo stabile con le varianti smelly. Tutte le baseline clean condividono due invarianti di progetto: (a) una struttura a sei blocchi concettuali [1] **Subject**, [2] **Detailed Imagery**, [3] **Environment Description**, [4] **Mood/Atmosphere**, [5] **Style**, [6] **Style Execution**; (b) copertura delle stesse sette famiglie semantiche (*human\_portrait*, *single\_object*, *indoor\_scene*, *outdoor\_scene*, *artistic\_style*, *animals*, *action\_scene*), con 2 varianti per famiglia (14 prompt totali per tipologia). All'interno di questo schema comune, ciascuna baseline introduce vincoli mirati per eliminare ambiguità o confondenti nella dimensione controllata, consentendo confronti *clean vs smelly* attribuibili a una modifica minimale.

**clean1 (baseline generica)** *clean1* è la baseline di riferimento generale, usata come base pulita per smells che non richiedono prerequisiti sintattici o semantici specifici. Le istanze sono state generate a partire da un meta-prompt dedicato, con l'obiettivo di mantenere coerenza interna e variabilità controllata tra famiglie.

**clean\_syntax\_base (controllo per sintassi)** Questa baseline è stata introdotta per testare lo smell *syntactic\_ambiguity* evitando che l'ambiguità sia già presente nel controllo. In particolare, si controlla l'ambiguità legata alle frasi introdotte da una preposizione, rendendo univoco a quale elemento della descrizione esse si riferiscano. Ciò è ottenuto tramite formulazioni esplicite (ad es. clausole del tipo "the X has Y"), che eliminano interpretazioni sintattiche alternative.

**clean\_polysemy\_base (controllo per polisemia)** Questa baseline rappresenta la condizione disambiguata necessaria a isolare lo smell *polysemy*. La disambiguazione è inserita *esclusivamente nel Subject* tramite specificatori lessicali che selezionano un singolo senso del termine polisemico, mentre *Detailed Imagery* ed *Environment* restano intenzionalmente neutri per evitare disambiguazione indiretta.

**clean\_figurative\_base (controllo per figuratività)** Questa baseline è stata introdotta per testare l'effetto delle espressioni figurative separandolo da altri fattori. Il Subject descrive lo stato/condizione in forma *letterale e disambiguata* (senza idiomi o metafore ambigue), mantenendo brevi e stabili le specifiche di stile ed esecuzione per limitare confondenti estetici.

**clean\_negation\_base (controllo per negazione)** Questa baseline consente di testare la negazione evitando il confondente “negazione presente vs assente”. La negazione è formulata con scope non ambiguo tramite schemi del tipo “*with Y, without X*” (o equivalenti), dove Y è esplicitamente presente e X esplicitamente assente.

**clean\_relation\_base (controllo per relazioni e binding)** `clean_relation_base` è progettata per includere prerequisiti necessari a smells relazionali: due entità distinguibili (E1, E2), due attributi scambiabili (A1, A2) assegnati in modo esplicito, e una relazione spaziale disambiguata tramite frame esplicito (ad es. riferimento al punto di vista). È inoltre inclusa un'interazione breve tra E1 ed E2; stile ed execution restano compatti e il più possibile costanti per ridurre confondenti.

#### **Mappatura baseline → tipologie smelly derivate**

- Da `clean_relation_base` derivano `referential_ambiguity`, `attribute_binding_ambiguity` e `spatial_relation_ambiguity`.
- Da `clean_figurative_base` deriva `figurative_ambiguity`.
- Da `clean_polysemy_base` deriva `polysemy`.
- Da `clean_negation_base` deriva `negation_scope_ambiguity`.
- Da `clean_syntax_base` deriva `syntactic_ambiguity`.
- Tutte le restanti tipologie smelly sono derivate da `clean1`.

### **3.4.2 Tipologie smelly testate: macrocategorie e trasformazioni**

Riprendendo definizioni e rationale discussi nella Sezione 2.5, questa sezione elenca le tipologie di *prompt smells* effettivamente testate negli esperimenti e ne



sintetizza l'operazionalizzazione. Ciascuna tipologia è implementata come trasformazione *minimale* e il più possibile *controllata* rispetto alla baseline di provenienza (si veda la Sezione 3.4.1), così da attribuire gli effetti osservati principalmente allo smell introdotto.

### (1) Ambiguità linguistica e referenziale

- `syntactic_ambiguity` (*Ambiguità sintattica*, da `clean_syntax_base`): sostituzione di formulazioni disambiguate con una struttura a PP-attachment non deterministico.
- `negation_scope_ambiguity` (*Ambiguità di negazione*, da `clean_negation_base`): riscrittura della negazione in forma a scope ambiguo (stessi elementi X/Y).
- `polysemy` (*Polisemia*, da `clean_polysemy_base`): rimozione degli specificatori disambiguanti nel Subject, mantenendo invariati gli altri blocchi.
- `figurative_ambiguity` (*Ambiguità figurativa*, da `clean_figurative_base`): sostituzione dello slot letterale con un'espressione idiomatica/metaforica non disambiguata.
- `referential_ambiguity` (*Ambiguità referenziale*, da `clean_relation_base`): introduzione di pronomi/dimostrativi con antecedente multiplo plausibile, mantenendo invariati binding e frame spaziale.
- `attribute_binding_ambiguity` (*Ambiguità di binding*, da `clean_relation_base`): riscrittura dell'assegnazione attributo→entità in forma non mappata esplicitamente.
- `spatial_relation_ambiguity` (*Ambiguità spaziale*, da `clean_relation_base`): rimozione del frame di riferimento esplicito nelle relazioni spaziali.

### (2) Incoerenza interna / conflitto di vincoli

- `subject_contradiction` (*Contraddizione sul soggetto*, da `clean1`): inserimento di un singolo frammento con attributo incompatibile riferito alla stessa entità principale.
- `environment_contradiction` (*Contraddizione ambientale*, da `clean1`): inserimento di un singolo vincolo contestuale incoerente (tempo/meteo/indoor-outdoor/illuminazione).
- `keyword_aesthetic_contrast` (*Contrasto estetico*, da `clean1`): aggiunta mirata di keyword estetiche contrastanti rispetto a *Style* e *Style Execution*, evitando degradazioni triviali della qualità.

### (3) Sotto-specificazione (vaghezza per omissione)

- `no_style` (*Nessuno stile*, da `clean1`): rimozione dei blocchi *Style* e *Style Execution*.
- `no_keyword` (*Nessuna keyword*, da `clean1`): rimozione di *Mood*, *Style* e *Style Execution*, mantenendo solo descrizione della scena e contesto.
- `no_keyword_boosters` (*Nessun booster*, da `clean1`): rimozione dei soli booster (ablation mirata dei quality-enhancers), mantenendo intatti gli altri blocchi.
- `subject_plus_details` (*Solo soggetto+dettagli*, da `clean1`): mantenimento dei soli blocchi *Subject* e *Detailed Imagery*.
- `only_subject` (*Solo soggetto*, da `clean1`): mantenimento del solo *Subject* (prompt estremamente vago).

### (4) Sovra-specificazione / rumore

- `too_long` (*Prompt troppo lungo*, da `clean1`): espansione controllata del testo tramite ridondanze/parafrasi senza introdurre nuovi contenuti semantici.
- `token_repetition` (*Ripetizione token*, da `clean1`): duplicazione deterministica di token salienti per introdurre ridondanza non informativa.
- `keyword_boosters` (*Troppi boosters*, da `clean1`): aggiunta di un set fisso di booster estetici “general-purpose” per simulare overload di modifiers.

**(5) Additivi non visual-grounded**

- `abstract_terms` (*Termini astratti*, da `clean1`): inserimento di termini astratti/vaghi debolmente coerenti con mood/scena, non direttamente visualizzabili.
- `magic_terms` (*Magic terms*, da `clean1`): inserimento di un additivo “poetico”/non letterale volto a indurre effetti poco interpretabili.

**(6) Robustezza lessicale e coverage shift**

- `abbreviations` (*Abbreviazioni*, da `clean1`): sostituzione di termini con shorthand/abbreviazioni non standard (intervento distribuito su più blocchi).
- `corrupted_words` (*Parole corrotte*, da `clean1`): corruzione ortografica di termini selezionati secondo una regola uniforme, mantenendo invariato il contenuto globale.
- `neologisms` (*Neologismi*, da `clean1`): sostituzione “semantic-preserving” di descrittori con neologismi plausibili, senza introdurre nuovi concetti.
- `fantasy_names` (*Nomi fantasy*, da `clean1`): inserimento di un proper noun raro accanto al soggetto per testare named entities potenzialmente non coperte.
- `add_url` (*URL aggiunto*, da `clean1`): aggiunta di un URL di “reference image” non accessibile come artefatto non interpretabile.
- `italian_translation` (*Traduzione italiana*, da `clean1`): traduzione integrale in italiano preservando struttura e copertura informativa.
- `aave_translation` (*Traduzione AAVE*, da `clean1`): riscrittura in AAVE preservando contenuto e struttura dei blocchi, introducendo un dialect-shift controllato.
- `finnish_translation` (*Traduzione finlandese*, da `clean1`): traduzione in finlandese (low-resource) con regole uniformi per i termini tecnici/stilistici.

#### (7) Format / interaction mismatch

- `instruction` (*Prompt istruzionale*, da `clean1`): conversione del prompt in forma imperativa/stepwise (“Generate... Make the mood... Render...”).
- `template_mismatch` (*Mismatch template*, da `clean1`): riordino deterministico dei blocchi in ordine non canonico, a contenuto invariato.
- `chitchat_question` (*Prompt conversazionale*, da `clean1`): incapsulamento del prompt in un wrapper conversazionale (saluto + richiesta).
- `legacy_prompt_format` (*Formato legacy*, da `clean1`): conversione in formato keyword-soup telegrafico preservando, per quanto possibile, la copertura informativa.

Nel seguito, le tipologie sono indicate con il codice `prompt_typology` e, alla prima occorrenza, con l’etichetta descrittiva in italiano (es. `syntactic_ambiguity`, *Ambiguità sintattica*).

### 3.5 Workflow A: metriche per immagine e modellazione statistica (RQ1)

Questa sezione descrive il workflow utilizzato per rispondere alla RQ1, finalizzato a quantificare in modo sistematico l’impatto delle tipologie *smelly* sulle metriche per immagine. Il flusso operativo parte dai prompt (baseline clean e varianti smelly) e dalle immagini generate in condizioni controllate, e si articola in quattro passaggi principali:

1. Calcolo delle sei metriche per ciascuna coppia immagine–prompt.
2. Preprocessing dei punteggi per ricondurli nel dominio (0,1) e renderli compatibili con la modellazione beta.
3. Stima degli effetti degli smells mediante *beta mixed-effects model* (`glmmTMB`), tenendo conto della struttura a osservazioni ripetute e degli appaiamenti sperimentali.

4. Sintesi e reporting dei risultati attraverso stime su scala risposta e intervalli di confidenza, utilizzate poi nel capitolo dei risultati.

Oltre all'analisi principale *clean vs smelly*, viene condotta anche un'analisi incrociata (*cross analysis*) come verifica di robustezza, limitata alla macrocategoria *Ambiguità linguistica e referenziale*. In questa variante, la *cross analysis* è applicata alle sole metriche che utilizzano esplicitamente il prompt come input, ovvero **CLIPScore**, **Q-Eval Image Alignment** e **HPSv2.1**. Operativamente, le metriche sono ricalcolate utilizzando il *prompt clean* in associazione all'immagine generata dalla corrispondente variante *smelly* (accoppiamento controllato tramite `pair_id`). L'obiettivo è ridurre l'effetto dell'ambiguità del testo sulla valutazione automatica e stimare i punteggi rispetto a una descrizione disambiguata, mantenendo invariata l'immagine prodotta dallo *smell*. Le metriche *image-only* (**OneAlign Quality** e **OneAlign Aesthetic**) non sono incluse poiché non dipendono dal prompt, mentre **Q-Eval Image Quality** non è stata considerata nella *cross analysis* perché, nel setup adottato, la dipendenza dal testo è risultata marginale (variazioni dell'ordine del  $\sim 2\%$ ).

### 3.5.1 Calcolo delle metriche per immagine

Come discusso nello Stato dell'Arte, i valutatori automatici possono essere sensibili a segnali diversi e non esiste una metrica universalmente dominante, soprattutto in scenari compositivi [31]. Per questo motivo, l'analisi della RQ1 utilizza un insieme di sei metriche *per-immagine* calcolate sulle generazioni ottenute, con l'obiettivo di coprire dimensioni complementari: allineamento testo-immagine, qualità visiva, estetica e preferenza umana condizionata dal prompt.

#### Allineamento testo-immagine (2 metriche)

- **CLIPScore**. È una metrica *embedding-based* che stima l'allineamento come similarità tra embedding del prompt e dell'immagine calcolati con un backbone CLIP [32, 33]. È stata scelta perché leggera, semplice da calcolare e ampiamente utilizzata come baseline in letteratura. Tuttavia, trattandosi di uno score globale, può risultare poco sensibile a vincoli compositivi o a legami fini tra termini

del prompt; nel contesto di questa tesi tale limite è rilevante soprattutto quando lo smell altera struttura e interpretabilità del testo.

- **Q-Eval Image Alignment.** È una metrica basata su valutatore MLLM che produce uno score di allineamento in  $[0, 1]$  a partire dalla coppia prompt-immagine [27]. È stata affiancata a CLIPScore per ottenere un segnale più *content-aware* su oggetti, attributi e relazioni. Nel setup non è stata adottata la strategia *vague-to-specific* (V2S) poiché non risultava disponibile nell’implementazione riutilizzata durante gli esperimenti.

#### Qualità visiva (IQA) (2 metriche)

- **Q-Eval Image Quality.** È uno score di qualità in  $[0, 1]$  stimato da valutatore MLLM, mirato a catturare distorsioni e artefatti percettivi [27]. Nel setup utilizzato, includere vs escludere il prompt nel contesto di valutazione ha prodotto variazioni contenute dello score (circa 2%), mentre a parità di configurazione lo score è risultato stabile tra run ripetute. Si è deciso infine di includere anche il prompt nel contesto di valutazione per diversificare la valutazione da OneAlign Quality.
- **OneAlign Quality.** È una metrica di IQA su scala  $[1, 5]$  calcolata senza utilizzare il prompt testuale [39]. È stata inclusa per affiancare a Q-Eval un segnale di qualità non dipendente dal testo, utile quando le trasformazioni smelly modificano la forma linguistica del prompt.

**Estetica (IAA) (1 metrica)** Per l’estetica è stata adottata **OneAlign Aesthetic** (scala  $[1, 5]$ ), che fornisce una stima human-centric di livello alto (composizione, illuminazione, appeal complessivo) e non richiede il prompt come input [39]. In fase esplorativa è stata considerata anche una metrica alternativa (ad es. ArtiMuse [42]), ma non è stata inclusa negli esperimenti finali perché non eseguibile in modo affidabile sull’hardware disponibile (OOM su GPU NVIDIA T4).

**Preferenza umana condizionata dal prompt (1 metrica)** La preferenza umana condizionata dal prompt è stimata tramite **HPSv2.1**, che produce uno score per

la coppia prompt-immagine e approssima il giudizio di preferenza [26]. È stata scelta per disponibilità e stabilità d'uso nel setup sperimentale. Una versione più recente (HPSv3 [43]) non è stata utilizzata perché non eseguibile in modo affidabile nell'ambiente Kaggle adottato a causa di vincoli di memoria (OOM).

**Output e tracciamento** I punteggi delle sei metriche vengono salvati nel CSV associato alla tipologia, preservando il mapping tra `prompt`, `image_path` e identificativi sperimentali (Sezione 3.3). Questi valori costituiscono l'input per il preprocessing e la successiva modellazione beta mixed-effects descritti nelle sottosezioni seguenti.

### 3.5.2 Preprocessing delle metriche per il beta mixed-effects model

Il modello adottato per la RQ1 è un *beta mixed-effects model*, che richiede una variabile risposta continua definita sul dominio  $(0, 1)$ . Le metriche considerate presentano range eterogenei (ad es.  $[1, 5]$  per OneAlign, valori non normalizzati per CLIPScore) e, in generale, possono produrre punteggi molto vicini agli estremi. Per rendere i punteggi confrontabili e compatibili con l'assunzione di supporto beta, è stato applicato un preprocessing in due fasi: (i) ricondurre tutte le metriche nel range  $[0, 1]$  tramite trasformazioni deterministiche per metrica; (ii) applicare una trasformazione standard per ottenere valori strettamente interni a  $(0, 1)$  e rendere la pipeline robusta e riusabile.

**Ricondurre le metriche in  $[0, 1]$**  Sia  $m$  il punteggio grezzo della metrica. Le trasformazioni adottate sono:

- **CLIPScore.** Il punteggio è calcolato come  $2.5 \cdot \max(0, \cos(\cdot))$  e quindi non può assumere valori negativi [32]. Per garantire un supporto in  $[0, 1]$  si applica la normalizzazione  $m' = m/2.5$ . Tale scelta evita che, nei rari casi in cui lo score ecceda 1, la variabile risposta esca dal range richiesto.
- **Q-Eval Image Alignment e Q-Eval Image Quality.** I punteggi sono definiti in  $[0, 1]$ ; viene applicata la sola normalizzazione identità  $m' = m$ .
- **OneAlign Quality e OneAlign Aesthetic.** Gli score sono continui nel range  $[1, 5]$  e vengono mappati in  $[0, 1]$  tramite trasformazione lineare  $m' = (m - 1)/4$ .

- **HPSv2.1.** Poiché la metrica può assumere valori negativi, i valori  $m < 0$  vengono troncati a 0; successivamente si considera  $m' = m$  come score in  $[0, 1]$ .

**Clipping di sicurezza** Nel dataset utilizzato non sono stati osservati valori  $\leq 0$  o  $\geq 1$  dopo le trasformazioni di scala descritte sopra. Ciononostante, è stato applicato un clipping di sicurezza in  $[0, 1]$  a tutte le metriche normalizzate, per (i) uniformare la pipeline tra metriche con scale diverse, (ii) rendere l'intero preprocessing facilmente estendibile a future tipologie o configurazioni in cui possano emergere valori fuori range a causa di artefatti numerici o cambiamenti nei valutatori.

**Trasformazione Smithson–Verkuilen** Per ottenere risposte strettamente interne a  $(0, 1)$  è stata applicata la trasformazione di Smithson–Verkuilen [56] a ciascuna metrica normalizzata  $y \in [0, 1]$ :

$$y^* = \frac{(n-1)y + 0.5}{n},$$

dove  $n$  è la numerosità del campione utilizzato per la trasformazione. Anche in assenza di valori esattamente pari a 0 o 1, tale mappatura riduce l'influenza di punteggi molto prossimi agli estremi (in particolare vicino al limite superiore), stabilizzando la stima del modello beta e mantenendo una pipeline coerente tra metriche.

**Output del preprocessing** Le sei variabili di risposta utilizzate nel beta mixed-effects model sono: `clipscore_unit`, `qeval_align_unit`, `qeval_quality_unit`, `onealign_quality_unit`, `onealign_aesthetic_unit`, `hpsv21_unit`. Queste variabili costituiscono l'input della modellazione descritta nella sottosezione successiva.

### 3.5.3 Beta mixed-effects model per stimare l'effetto degli smells

Per rispondere alla RQ1, ciascuna metrica preprocessata (Sezione 3.5.2) è stata modellata con un *beta mixed-effects model* tramite `glmmTMB`. Oltre all'adeguatezza statistica (risposte continue in  $(0, 1)$  e presenza di dipendenze tra osservazioni), la scelta



di `glmmTMB` è stata motivata da considerazioni pratiche: rispetto a un’implementazione bayesiana in Python (ad es. `bambi`), ha mostrato tempi di stima inferiori nel setup sperimentale adottato, permettendo di esplorare rapidamente più specificazioni e convergere su una struttura finale stabile e supportata dai dati.

**Analisi *pooled per baseline*** L’analisi è condotta separatamente per ciascuna baseline clean: fissata una baseline  $B$ , viene costruito un dataset che include  $B$  e tutte le tipologie smelly derivate da  $B$ , e su tale dataset viene stimato un unico modello per ciascuna metrica. Questa strategia (*pooled per baseline*) consente di:

- Confrontare ciascuna tipologia smelly con la baseline clean da cui deriva, così che il confronto *smelly vs baseline* sia attribuibile principalmente alla trasformazione introdotta e non a differenze strutturali tra baseline diverse.
- Aumentare stabilità delle stime, sfruttando congiuntamente tutte le osservazioni disponibili all’interno dello stesso blocco sperimentale.
- Ottenere contrasti *smelly vs baseline* e correzioni per confronti multipli in modo coerente all’interno di ciascuna baseline e metrica. In particolare, stimare un unico modello per baseline consente di calcolare, per ciascuna tipologia, il contrasto  $\Delta\mu = \mu(\text{smelly}) - \mu(\text{baseline})$  su scala risposta all’interno dello stesso modello, rendendo direttamente confrontabili tra loro i diversi  $\Delta\mu$  (entro la stessa metrica e baseline) e facilitandone la sintesi in figure di confronto.

**Specificazione del modello** Sia  $y_i$  il punteggio (in  $(0, 1)$ ) associato all’immagine  $i$  per una data metrica. Si assume:

$$y_i \sim \text{Beta}(\mu_i, \phi_i), \quad g(\mu_i) = \eta_i,$$

dove  $g(\cdot)$  è il link logit e  $\phi_i$  è un parametro di precisione. La parte fissa del modello include `prompt_typology` (fattore; baseline come livello di riferimento). Le quantità riportate nel capitolo dei risultati—medie marginali  $\hat{\mu}$  per tipologia e contrasti tra tipologie—sono ottenute su *scala risposta* (dominio  $(0, 1)$ ) tramite medie marginali stimate e trasformazione inversa del link (`emmeans` con `regrid`).

**Struttura random e razionale** Le osservazioni (immagini) non sono indipendenti perché più tipologie condividono lo stesso *contenuto base* (`base_prompt_id`), le condizioni clean e smelly sono accoppiate a seed fissato (`pair_id`) e ogni prompt realizzato è replicato su più seed (`prompt_id`). Per catturare tali dipendenze, è stata definita come specificazione di riferimento la seguente struttura random (M2):

$$(1|base\_prompt\_id) + (1|pair\_id) + (1|prompt\_id)$$

dove  $(1|base\_prompt\_id)$  assorbe l’eterogeneità legata al contenuto base,  $(1|pair\_id)$  controlla l’appaiamento clean–smelly a seed fissato, e  $(1|prompt\_id)$  cattura clustering addizionale specifico del prompt realizzato. Nella pratica, l’inclusione di `prompt_id` è risultata spesso informativa in termini di fit e di stima delle varianze; tuttavia, nei casi in cui tale componente non fosse supportata dai dati o non apportasse un miglioramento informativo, è stata adottata una struttura più parsimoniosa (M1), descritta di seguito.

**Criterio di selezione e fallback** Per robustezza è stata definita una strategia di fallback alla struttura più parsimoniosa (M1):

$$(1|base\_prompt\_id) + (1|pair\_id)$$

da utilizzare quando la struttura completa (M2) non è supportata dai dati o introduce instabilità (fit fallito, Hessiano non positivo-definito, varianza di `prompt_id` prossima a zero). Quando entrambi i modelli risultano stimabili e identificabili, la scelta è guidata da parsimonia informativa: definendo  $\Delta AIC = AIC(M2) - AIC(M1)$ , la struttura completa (M2) è mantenuta solo se migliora l’AIC di almeno 2 punti, cioè se  $\Delta AIC \leq -2$ ; in caso contrario si preferisce M1. In questo modo, la complessità addizionale introdotta da  $(1|prompt\_id)$  viene mantenuta solo quando giustificata dai dati.

**Random slopes non adottati** Sono stati considerati random slopes (ad es. slope di `prompt_typology` per `base_prompt_id`), ma non adottati nel modello finale perché causavano problemi di convergenza e identificabilità (Hessiano non positivo-definito). Inoltre, la stima di slope casuali a livello di `base_prompt_id` è sfavorita

dal numero limitato di livelli (14) rispetto alla complessità introdotta. È stata quindi privilegiata una specificazione parsimoniosa basata su random intercepts.

**Scelta della specifica di dispersione** Per tenere conto di eteroschedasticità tra tipologie, la componente di dispersione è stata modellata nel beta mixed-effects model e sono state confrontate tre alternative ( $\text{dispformula}=\sim 1$ ,  $\sim \text{prompt\_typology}$ ,  $\sim 0 + \text{prompt\_typology}$ ) mantenendo invariata la parte media del modello. In tutte le metriche, l'ipotesi di dispersione costante ( $\sim 1$ ) è risultata non supportata, mentre le specifiche dipendenti da `prompt_typology` hanno fornito un fit nettamente migliore. Poiché  $\sim \text{prompt\_typology}$  e  $\sim 0 + \text{prompt\_typology}$  sono equivalenti dal punto di vista del fit (differiscono solo per parametrizzazione), è stata adottata  $\text{dispformula}=\sim 0 + \text{prompt\_typology}$  per rendere esplicita una stima della dispersione per ciascun livello di tipologia e semplificare l'interpretazione e il reporting.

**Diagnostica e reporting** Per ciascuna metrica e baseline, la qualità del fit è stata verificata con controlli di stabilità numerica (convergenza, Hessiano positivo-definito e assenza di warning critici) e con diagnostica basata su residui simulati (DHARMA;  $n = 1000$  simulazioni), includendo test di uniformità, dispersione e outlier. Sono state inoltre monitorate le varianze dei random intercepts per verificare che i termini casuali fossero supportati dai dati.

Per il reporting, le quantità di interesse sono state riportate su *scala risposta* (dominio  $(0, 1)$ ). In particolare, per ogni tipologia è stata stimata la media marginale  $\hat{\mu}$  con IC al 95%; per rispondere alla RQ1 sono stati calcolati i contrasti *smelly vs baseline* come differenze di medie su scala risposta:

$$\Delta\mu = \mu(\text{smelly}) - \mu(\text{baseline})$$

dove  $\mu(\cdot)$  indica la media attesa del punteggio (post-preprocessing) per una data tipologia. Poiché per ciascuna metrica e baseline vengono effettuati più confronti, i p-value dei contrasti sono stati corretti con procedura di Holm all'interno della stessa metrica e baseline.

### 3.5.4 Analisi incrociata (*cross analysis*) come verifica di robustezza

Oltre al confronto principale *clean vs smelly*, è stata condotta una *cross analysis* come verifica di robustezza, limitata alla macrocategoria *Ambiguità linguistica e referenziale*. L'idea è valutare le metriche testo-immagine rispetto a una descrizione disambiguata, mantenendo invariata l'immagine generata dallo *smell*. In pratica, per ciascuna baseline  $B$  e per ciascuno *smell*  $s$  della macrocategoria, si considera la coppia (*prompt clean*, *immagine smelly*) e la si confronta con la coppia di riferimento (*prompt clean*, *immagine clean*).

**Dataset e accoppiamento** Per una baseline  $B$ , il dataset include il livello `prompt_typology` corrispondente a  $B$  e i livelli `cross_<s>` per ciascuno *smell*  $s$  derivato da  $B$ . L'accoppiamento è controllato tramite `pair_id`, che garantisce il confronto a seed fissato tra l'immagine *clean* e l'immagine *smelly* semanticamente corrispondenti.

**Modello statistico** Analogamente all'analisi principale, per ciascuna delle tre metriche *prompt-immagine* (`clipscore_unit`, `qeval_align_unit`, `hpsv21_unit`) preprocessata in  $(0,1)$  viene stimato un *beta mixed-effects model pooled per baseline* con link logit. La parte fissa del modello include `prompt_typology` e consente di stimare le medie attese per la baseline  $B$  e per ciascuna variante `cross_<s>`. Per rispondere alla *cross analysis*,  $B$  è trattata come condizione di controllo nel calcolo dei contrasti `cross_<s>` vs  $B$ , riportati su *scala risposta*.

Per catturare le dipendenze indotte dall'appaiamento a seed fissato e dall'eterogeneità del contenuto base, la struttura random adottata è:

$$(1|base\_prompt\_id) + (1|pair\_id)$$

dove  $(1|base\_prompt\_id)$  assorbe la variabilità legata al contenuto semantico del *prompt* e  $(1|pair\_id)$  controlla l'appaiamento *clean-cross* a seed fissato (*immagine clean* vs *immagine smelly* valutate rispetto allo stesso *prompt clean*).

**Modello di dispersione** Per modellare eteroschedasticità tra livelli di tipologia anche nella *cross analysis*, la componente di dispersione è parametrizzata come:

$$dispformula \sim 0 + prompt\_typology$$

ottenendo una stima della dispersione per ciascun livello (baseline e `cross_<s>`).

**Contrasti e reporting** Anche per la cross analysis, i risultati sono riportati su *scala risposta* (dominio (0, 1)). Per ciascuna delle tre metriche (`clip_score_unit`, `qeval_align_unit`, `hpsv21_unit`) e baseline  $B$  vengono stimate le medie marginali  $\hat{\mu}$  con IC al 95% per tutti i livelli di `prompt_typology` nel dataset  $\{ B, \text{cross\_<s>} \}$ . Il contrasto è definito come differenza di medie attese su scala risposta:

$$\Delta\mu = \mu(\text{clean prompt, smelly img}) - \mu(\text{clean prompt, clean img})$$

dove  $\mu(\text{clean prompt, smelly img})$  corrisponde alla tipologia `cross_<s>` e  $\mu(\text{clean prompt, clean img})$  alla baseline  $B$ . Poiché per ciascuna *metrica e baseline* vengono effettuati più confronti (`cross_<s>` vs  $B$ ), i p-value dei contrasti sono corretti con correzione di Holm all'interno della stessa metrica e baseline. I risultati della cross analysis sono riportati come evidenza complementare (robustness check) e discussi separatamente dall'analisi principale.

### 3.6 Workflow B: variabilità percettiva (LPIPS) (RQ2)

Questa sezione descrive il workflow adottato per rispondere alla RQ2, che indaga se i *prompt smells* influenzino la variabilità percettiva *intra-prompt* delle immagini generate al variare del seed. L'obiettivo non è valutare la qualità o l'allineamento rispetto al testo (come nel workflow A), ma stimare la *stabilità* dell'output generativo quando il prompt è mantenuto fisso e varia unicamente il seed.

Il workflow si basa su LPIPS [38] che calcola la variabilità percettiva visiva tra repliche. Per ciascun prompt vengono considerate le otto immagini generate con seed diversi e viene calcolata LPIPS su tutte le coppie di repliche, ottenendo una distribuzione di distanze intra-prompt. Tale informazione viene quindi sintetizzata con una statistica robusta a livello di prompt e successivamente aggregata a livello di tipologia (`prompt_typology`), così da confrontare in modo coerente baseline clean e varianti smelly. Infine, l'incertezza delle stime (sia assolute sia come differenze rispetto alla baseline corrispondente) è quantificata tramite intervalli di confidenza

stimati via bootstrap, che costituiscono l’input per il reporting nel capitolo di Analisi dei Risultati.

### 3.6.1 Misura della variabilità percettiva intra-prompt e aggregazione per tipologia

La variabilità percettiva viene operazionalizzata come variabilità visiva tra repliche generate dallo stesso prompt al variare del seed. Per ciascun `prompt_id` sono disponibili otto immagini ( $S = \{101, 202, 303, 404, 505, 606, 707, 808\}$ ) prodotte in condizioni di generazione controllata (Sezione 3.3). A partire da tali repliche, la variabilità intra-prompt viene misurata tramite LPIPS, una distanza percettiva basata su feature profonde.

**Calcolo pairwise su tutte le coppie di seed** Dato un prompt con  $k = 8$  repliche, vengono calcolate le distanze LPIPS su tutte le coppie non ordinate  $(i, j)$  con  $i < j$ , ottenendo  $\binom{k}{2} = 28$  confronti per prompt. Le distanze vengono calcolate in batch utilizzando l’implementazione di riferimento LPIPS con backbone `alex` ed esecuzione su CPU nell’ambiente Kaggle. I risultati sono salvati in file `lpips_<prompt_typology>.csv`, con una riga per coppia di seed e campi di tracciamento (`prompt_family`, `prompt_variant`, `prompt_typology`, `prompt_id`).

**Sintesi robusta a livello di prompt** Per ottenere una misura robusta della variabilità associata a ciascun prompt, le 28 distanze pairwise vengono riassunte tramite la mediana:

$$v_p = \text{median}\left(\text{LPIPS}(I_{p,s_i}, I_{p,s_j})\right) \quad \forall s_i < s_j$$

dove  $I_{p,s}$  indica l’immagine generata dal prompt  $p$  con seed  $s$ .

**Aggregazione a livello di tipologia e confronto con la baseline** I valori  $v_p$  vengono quindi aggregati a livello di tipologia (`prompt_typology`). Poiché ciascuna tipologia include 14 prompt (7 famiglie semantiche  $\times$  2 varianti), la variabilità tipologica è definita come:

$$V_t = \text{median}(\{v_p : p \in t\})$$

Per confrontare una tipologia smelly  $t$  con la baseline clean corrispondente  $B$ , si calcolano differenze appaiate per prompt:

$$\delta_p = v_p^{(t)} - v_p^{(B)}$$

dove l'appaiamento è definito sul contenuto semantico tramite `prompt_family` e `prompt_variant`. L'effetto complessivo della tipologia rispetto alla baseline è sintetizzato come:

$$\Delta_t = \text{median}(\{\delta_p\})$$

### 3.6.2 Intervalli di confidenza via bootstrap e reporting dei risultati

Per quantificare l'incertezza delle stime di variabilità e confrontare le tipologie, sono stati stimati intervalli di confidenza (IC) tramite bootstrap percentile. La scelta è motivata dal numero contenuto di prompt per tipologia (14) e dall'assenza di garanzie di normalità per statistiche come la mediana.

**Unità di bootstrap** Il bootstrap è eseguito a livello di prompt, campionando con reinserimento i 14 valori per-prompt. Questa scelta preserva la struttura gerarchica dell'esperimento ed evita di trattare come indipendenti le distanze pairwise all'interno dello stesso prompt.

**IC per la variabilità assoluta ( $V_t$ )** Per ciascuna tipologia  $t$ , si generano  $B = 5000$  campioni bootstrap dei 14 valori  $v_p$  e si ricalcola  $V_t$  su ciascun campione; l'IC al 95% è ottenuto come intervallo tra i quantili 2.5% e 97.5% della distribuzione bootstrap.

**IC per la differenza rispetto alla baseline ( $\Delta_t$ )** Per ciascuna tipologia smelly  $t$  e baseline  $B$ , si costruiscono le 14 differenze appaiate  $\delta_p$  e si generano  $B = 5000$  campioni bootstrap campionando con reinserimento tali differenze; per ogni campione si ricalcola  $\Delta_t$  e si ottiene l'IC al 95% tramite i quantili 2.5% e 97.5%.

**Sintesi grafica e convenzioni di visualizzazione** I risultati sono sintetizzati tramite tabelle e forest plot. Nei forest plot viene riportata, per ciascuna tipologia, la stima  $\Delta_t$  insieme al relativo IC al 95%. Per facilitare la lettura, i marker distinguono i casi in cui

l'IC include lo zero da quelli in cui lo esclude; tale convenzione ha scopo descrittivo e l'interpretazione è discussa nel capitolo dei risultati.



---

### Analisi dei risultati

---

#### 4.1 Risultati RQ1: impatto degli smells sulle metriche per immagine

**Q RQ<sub>1</sub>.** *In che misura i prompt smells impattano sulle metriche di allineamento testo-immagine, qualità visiva, estetica e preferenza umana condizionata dal prompt?*

L'obiettivo di questa RQ è quantificare l'effetto delle tipologie *smelly* sui punteggi delle sei metriche per immagine considerate nello studio. Come descritto nella Sezione 3.5, i punteggi (preprocessati nel dominio  $(0, 1)$ ) sono stati analizzati tramite *beta mixed-effects model* (`glmmTMB`) per stimare contrasti *smelly vs baseline* su scala risposta.

##### 4.1.1 Affidabilità del fit: stabilità numerica e diagnostica DHARMA

Prima di discutere i contrasti *smelly vs baseline* su scala risposta (Sottosezione 4.1.2), è stata valutata l'affidabilità dei modelli stimati per la RQ1. Poiché l'analisi *pooled per baseline* prevede un modello per ciascuna combinazione *baseline*  $\times$  *metrica*, la diagnostica è stata analizzata complessivamente su 36 modelli (6 metriche  $\times$  6 baseline). La Tabella 4.1 riassume i principali esiti dei controlli.

**Tabella 4.1:** Sintesi a conteggi dei controlli di affidabilità sui modelli stimati per la RQ1.

| Indicatore                                  | Valore |
|---------------------------------------------|--------|
| Modelli stimati (baseline $\times$ metrica) | 36     |
| Struttura random completa (M2)              | 27     |
| Fallback (M1)                               | 9      |
| Hessiano positivo-definito (pdHess=TRUE)    | 36     |
| Warning critici in fase di stima            | 0      |
| DHARMA: uniformità ( $p < 0.05$ )           | 17     |
| DHARMA: outlier ( $p < 0.05$ )              | 4      |
| DHARMA: dispersione ( $p < 0.05$ )          | 0      |

**Struttura random scelta (M2 vs fallback M1)** La selezione tra struttura completa (M2:  $(1|base\_prompt\_id) + (1|pair\_id) + (1|prompt\_id)$ ) e fallback (M1:  $(1|base\_prompt\_id) + (1|pair\_id)$ ) segue il criterio definito nella Sezione 3.5. In particolare, M1 è stato utilizzato quando l’aggiunta di  $(1|prompt\_id)$  non era supportata dai dati (miglioramento informativo insufficiente e/o varianza addizionale trascurabile). L’uso di M1 è concentrato soprattutto in `clean_syntax_base` (5/6 metriche), `clean_relation_base` (3/6 metriche) e, in misura minore, `clean_negation_base` (1/6 metriche).

**Stabilità numerica** Tutti i modelli risultano numericamente stabili: convergenza completata, Hessiano positivo-definito (pdHess=TRUE) e assenza di warning critici. Le varianze dei random intercepts sono risultate finite; nei casi stimati con M1, l’esclusione di `prompt_id` è coerente con una componente addizionale non necessaria ai fini del fit.

**Controllo dei valori ai limiti (boundary check)** Dopo il preprocessing e la trasformazione Smithson–Verkuilen (Sottosezione 3.5.2), non sono stati osservati valori estremamente prossimi al limite inferiore ( $< 0.01$ : 0% in tutti i modelli). Una quota di osservazioni prossime al limite superiore ( $> 0.99$ ) è presente in alcune metriche:

in particolare `onealign_quality_unit` (fino a circa 6.9% per i dati relativi alla baseline `clean1`) e, più raramente, `qeval_align_unit` (fino a circa 0.55%). Questo è coerente con distribuzioni concentrate verso punteggi elevati e può aumentare la sensibilità dei test diagnostici basati su residui simulati.

**Diagnostica DHARMA (residui simulati)** La diagnostica è stata effettuata con DHARMA utilizzando 1000 simulazioni per modello.

Il test di uniformità di DHARMA risulta significativo in 17/36 modelli. Le segnalazioni sono concentrate soprattutto nella baseline `clean1` (6/6 metriche) e, in misura minore, in `clean_relation_base` (4/6) e `clean_negation_base` (3/6). Questo pattern è plausibile perché `clean1` è la baseline con la numerosità più elevata ( $n = 2912$ , contro  $n = 224\text{--}448$  nelle altre baseline): in campioni grandi, i test di questo tipo diventano molto sensibili e possono evidenziare come “significative” anche deviazioni lievi dal comportamento atteso dei residui simulati. Inoltre, alcune metriche mostrano distribuzioni fortemente concentrate verso valori alti (risposte bounded e vicine al limite superiore), condizione che può amplificare ulteriormente la sensibilità del test.

Il test di dispersione non segnala criticità (0/36), coerentemente con la scelta di modellare eteroschedasticità tramite una dispersione dipendente da `prompt_typology`.

Il test outlier risulta significativo in 4/36 modelli (tre in `clean1` e uno in `clean_relation_base`).

Nel seguito, per rendere la discussione sintetica e direttamente interpretabile, i risultati sono riportati come contrasti *smelly vs baseline* su scala risposta, cioè come differenze tra medie marginali attese nel dominio  $(0, 1)$  ( $\Delta\mu$ ) con IC al 95%. La diagnostica DHARMA è utilizzata come controllo qualitativo del fit (possibili segnali di lieve mis-specificazione residua), ma non come criterio esclusivo per validare l’interpretazione delle stime.

### 4.1.2 Contrasti su scala risposta (clean vs smelly): risultati principali

I risultati della RQ1 sono sintetizzati tramite forest plot dei contrasti su scala risposta

$$\Delta\mu = \mu(\text{smelly}) - \mu(\text{baseline})$$

dove  $\mu(\cdot)$  indica la media marginale attesa nel dominio  $(0, 1)$  (Sezione 3.5). Per tutte le metriche, valori più alti indicano performance migliore; dunque  $\Delta\mu < 0$  indica un peggioramento rispetto alla baseline. Nei grafici, i segmenti rappresentano l'IC al 95% e i marker pieni indicano contrasti significativi dopo correzione di Holm (baseline  $\times$  metrica). La Figura 4.1 riporta l'allineamento testo-immagine, la Figura 4.2 la qualità visiva e la Figura 4.3 preferenza umana ed estetica.

**Sintesi dei risultati principali** I pattern più rilevanti osservati nei contrasti possono essere riassunti come segue:

- **Coverage shift / lingua:** le traduzioni sono l'intervento con impatto più ampio e sistematico, soprattutto su `qeval_align_unit` e `hpsv21_unit`. In particolare, `finnish_translation` mostra il peggioramento più marcato (ordine di  $\Delta\mu \approx -0.63$  su `qeval_align_unit`), mentre `italian_translation` produce un calo moderato (ordine di  $\Delta\mu \approx -0.18$  su `qeval_align_unit`). La degradazione è compatibile non solo con la sensibilità dei *valutatori* al language shift, ma anche con una ridotta robustezza del *modello generativo* nel seguire vincoli testuali in lingue meno supportate, con conseguente perdita di controllo sull'output.
- **Conflitto di vincoli:** `keyword_aesthetic_contrast`, `environment_contradiction` e `subject_contradiction` riducono in modo consistente l'allineamento `qeval_align_unit` (cali tipici nell'intervallo  $\Delta\mu \approx [-0.14, -0.11]$ ). Il risultato è coerente con prompt che contengono vincoli mutuamente incompatibili: il modello tende a soddisfare solo una parte della specifica e il valutatore penalizza la mancata coerenza.
- **Sotto-specificazione estrema:** `only_subject` e `subject_plus_details` mostrano un comportamento biforcuto: aumentano `qeval_align_unit` (or-


dine di  $\Delta\mu \approx +0.13$  e  $\Delta\mu \approx +0.06$ ), ma peggiorano `onealign_aesthetic_unit` (ordine di  $\Delta\mu \approx -0.11$ ) e riducono `clipscore_unit`. Questo è coerente con il fatto che un prompt molto meno vincolante rende più facile ottenere un output compatibile con il prompt sotto-specificato (e quindi un punteggio di allineamento più alto), ma porta a immagini più generiche e meno curate sul piano estetico.

- **Formato legacy:** `legacy_prompt_format` mostra un calo moderato su `geval_align_unit` (ordine di  $\Delta\mu \approx -0.09$ ), coerente con il fatto che una struttura “keyword-soup” rende meno espliciti i legami tra elementi e penalizza un valutatore *content-aware*.

**(A) Allineamento testo–immagine (Figura 4.1).** La metrica più sensibile ai prompt smells è `geval_align_unit`. Oltre ai casi di traduzione e conflitto di vincoli, un risultato rilevante riguarda la sotto-specificazione estrema (`only_subject`, `subject_plus_details`), che aumenta lo score di allineamento, suggerendo che la metrica beneficia di prompt meno restrittivi. `clipscore_unit` mostra effetti più contenuti e si riduce soprattutto in presenza di traduzioni e di sotto-specificazione (prompt più poveri di dettagli e stile).

**(B) Qualità visiva (Figura 4.2)** Le metriche di qualità visiva risultano complessivamente stabili: per la maggior parte delle tipologie i contrasti sono vicini a zero e gli IC includono lo zero. Gli effetti più evidenti si osservano in presenza di language shift forte: `finnish_translation` riduce `geval_quality_unit` (ordine di  $\Delta\mu \approx -0.12$ ) e, più debolmente, `onealign_quality_unit` (ordine di  $\Delta\mu \approx -0.04$ ). Un ulteriore segnale (di piccola ampiezza) riguarda `negation_scope_ambiguity` su `onealign_quality_unit` (ordine di  $\Delta\mu \approx -0.01$ ). Nel complesso, questi risultati indicano che molti smells agiscono principalmente sul contenuto e sulla tracciabilità prompt–immagine più che sulla qualità percettiva “low-level”.

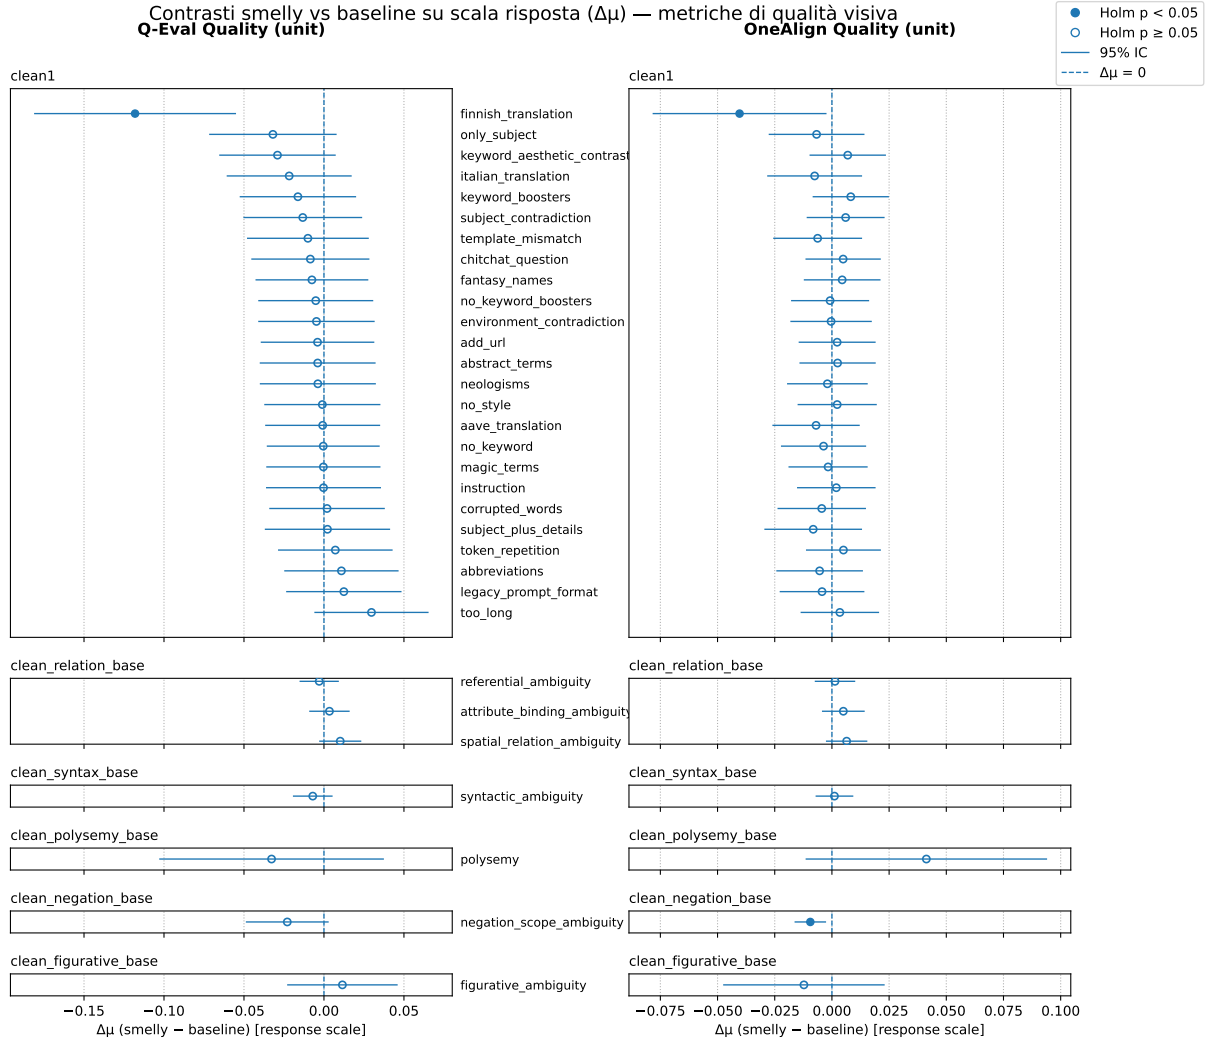
**(C) Preferenza umana ed estetica (Figura 4.3).** Per `hpsv21_unit`, i cali principali riguardano le traduzioni (`finnish_translation` e `italian_translation`), mentre le altre tipologie mostrano differenze più contenute. Per `onealign_aesthetic_`



**Figura 4.1:** Contrasti *smelly* vs *baseline* su scala risposta ( $\Delta\mu$ ) per le metriche di allineamento testo-immagine (`clipscore_unit`, `qeval_align_unit`).

unit, due risultati risultano più informativi: (i) la sotto-specificazione estrema (`only_subject`, `subject_plus_details`) peggiora l'estetica, coerentemente con output più generici; (ii) `polysemy` (da `clean_polysemy_base`) mostra un incremento estetico, indicando che la perdita di vincoli semantici può lasciare maggiore libertà al generatore, con possibile beneficio estetico, pur riducendo controllabilità e allineamento.

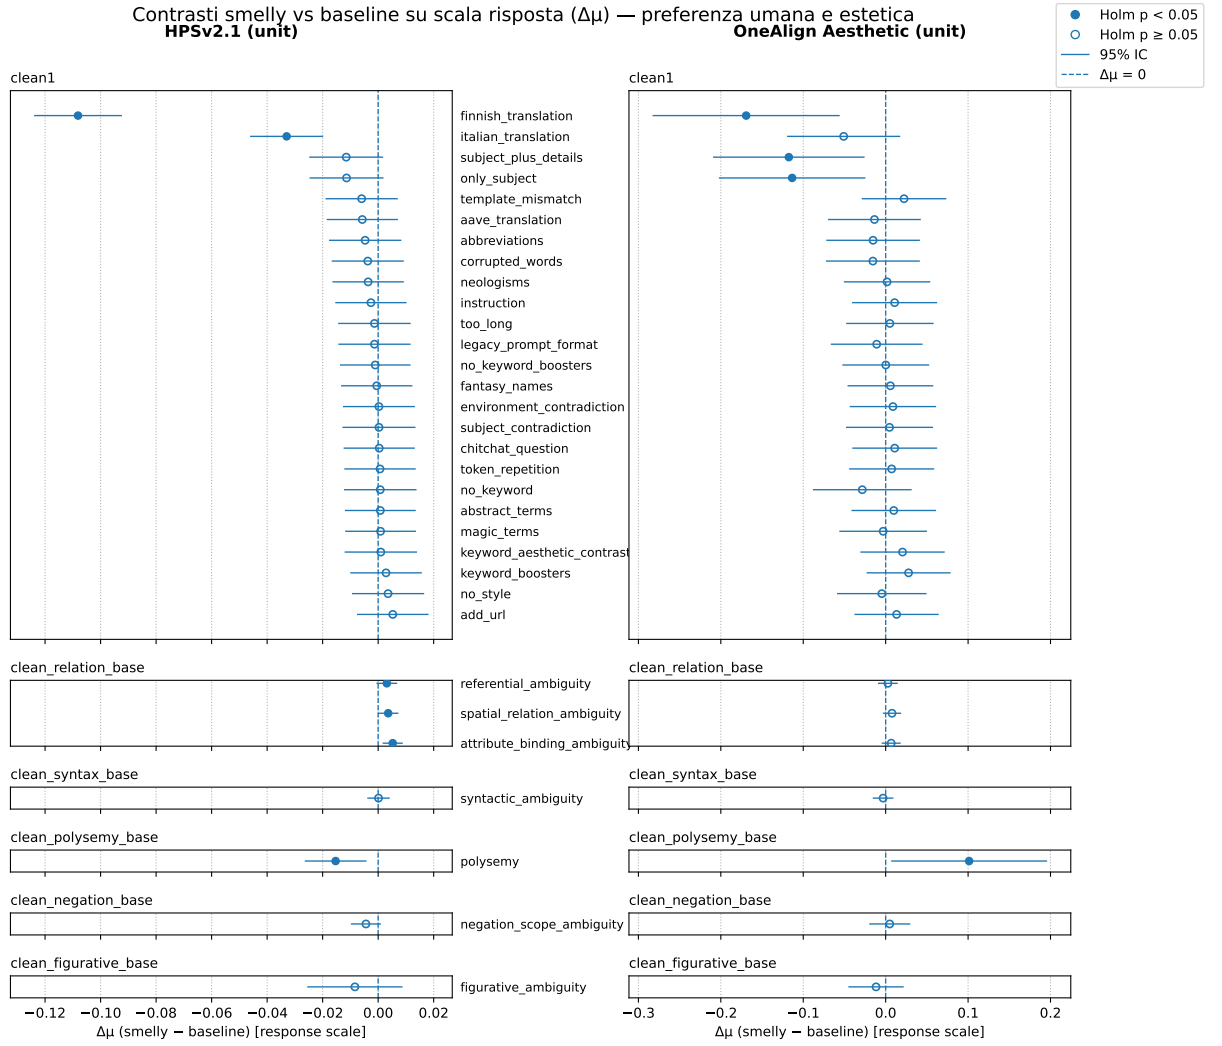
**Evidenza qualitativa: esempi rappresentativi dalla macrocategoria *Ambiguità linguistica e referenziale*** Oltre ai risultati quantitativi, è stato condotto un controllo qualitativo su coppie *clean* vs *smelly* per verificare se, a parità di configurazione di generazione, alcune ambiguità producano interpretazioni errate o instabili. Le Figu-



**Figura 4.2:** Contrasti *smelly* vs *baseline* su scala risposta ( $\Delta\mu$ ) per le metriche di qualità visiva (qeval\_quality\_unit, onealign\_quality\_unit).

re 4.4 e 4.5 riportano esempi selezionati a **parità di seed** (stesso seed per ciascuna coppia clean–smelly), così da attribuire le differenze osservate alla sola trasformazione testuale. Per mantenere la discussione sintetica, nel testo vengono riportati solo gli *snippet* del prompt che introducono lo smell; i prompt completi e gli identificativi di tracciamento (base\_prompt\_id, seed, image\_path) sono riportati in appendice/materiale supplementare.

- **polysemy (da clean\_polysemy\_base).** Nel primo esempio (Figura 4.4, riga 1), la rimozione del disambiguatore nel Subject porta a un cambio di senso del termine *seal*. Con il prompt clean (“A *wax seal*, ...”) il modello genera correttamente un sigillo di cera (Figura 4.4a), mentre con la variante smelly (“A



**Figura 4.3:** Contrasti *smelly vs baseline* su scala risposta ( $\Delta\mu$ ) per preferenza umana condizionata dal prompt ed estetica (hpsv21\_unit, onealign\_aesthetic\_unit).

*seal, ...*) l’output viene reinterpretato come animale (foca), nonostante il resto del prompt suggerisca proprietà più compatibili con un oggetto (*intricate pattern, surface texture, photorealistic close-up*) (Figura 4.4b). Questo caso evidenzia come una polisemia non disambiguata possa dominare il contesto e indurre *subject shift*.

- **negation\_scope\_ambiguity (da clean\_negation\_base).** Nel secondo esempio (Figura 4.4, riga 2), la negazione con scope non ambiguo produce un comportamento stabile: con la baseline (*“with sunglasses, without a hat”*) l’output rispetta in modo consistente la presenza degli occhiali e l’assenza del cappello (Figura 4.4c). Con la variante smelly (*“without a hat and sunglasses”*), invece,



l’assenza degli attributi non è più deterministica: il modello può generare immagini in cui compaiono entrambi, o uno solo dei due (Figura 4.4d). Questo comportamento è coerente con un’interpretazione incerta dello scope della negazione e suggerisce che parte dell’effetto dello smell si manifesti come *violazione intermittente* dei vincoli.

- **figurative\_ambiguity (da clean\_figurative\_base).** Nel terzo esempio (Figura 4.4, riga 3), un’espressione idiomatica viene interpretata letteralmente. Nella baseline (“*about to do something unpleasant*”) la scena rimane coerente con un contesto clinico e un mood teso (Figura 4.4e). Nella variante smelly (“*about to bite the bullet*”), l’output può includere un proiettile come oggetto fisico (Figura 4.4f). Pur essendo meno frequente rispetto a polisemia e negazione, l’esempio illustra come l’ambiguità figurativa possa introdurre contenuti non previsti dall’intento del prompt.

**Casi meno frequenti: output simili ma legami input–output indeboliti** Per altre tipologie della stessa macrocategoria (`syntactic_ambiguity` e le tre tipologie derivate da `clean_relation_base`: `referential_ambiguity`, `attribute_binding_ambiguity`, `spatial_relation_ambiguity`) le differenze visive tra immagini clean e smelly sono spesso ridotte. In diversi casi il modello sembra applicare euristiche di interpretazione (ad es. assegnazione per *prossimità* tra sintagmi o default composizionali), producendo output molto simili anche quando la formulazione smelly è ambigua. La Figura 4.5 mostra due esempi rappresentativi: (i) `attribute_binding_ambiguity`, dove la scena è rispettata ma l’associazione attributo→entità può non essere verificabile con certezza; (ii) `syntactic_ambiguity` (PP-attachment), dove il modello tende a interpretare l’attributo come riferito all’oggetto più vicino. In questi casi la tracciabilità rimane compromessa perché l’ambiguità può portare, su altri prompt o seed, a scelte alternative (binding errati o interpretazioni diverse), rendendo meno verificabile quale vincolo testuale abbia guidato l’output.

**Motivazione della cross analysis** Le Figure 4.4–4.5 mostrano che, nella macrocategoria *Ambiguità linguistica e referenziale*, l’ambiguità può agire su due livelli: può in-

fluenzare la generazione (scelta interpretativa e possibili violazioni dei vincoli) e può influenzare le metriche testo-immagine, che valutano una coppia prompt-immagine partendo da un testo ambiguo. Coerentemente, l'analisi qualitativa evidenzia casi di instabilità, mentre l'analisi quantitativa *clean vs smelly* restituisce spesso contrasti medi piccoli e non significativi dopo correzione multipla.

Questa discrepanza è plausibile perché gli effetti dell'ambiguità possono essere sporadici (limitati a specifici prompt/seed) e quindi diluiti nella media di tipologia; inoltre, i valutatori possono mascherare differenze quando devono interpretare un prompt ambiguo. Per controllare questo confondente, introduciamo la *cross analysis*: le metriche testo-immagine sono calcolate usando il *prompt clean* insieme alle immagini generate dalla variante *smelly*, mantenendo fisso il testo di valutazione e isolando più direttamente l'effetto sull'immagine.

#### 4.1.3 Cross analysis (*image-swap*) come verifica di robustezza

Come anticipato nella Sottosezione 4.1.2, nella macrocategoria *Ambiguità linguistica e referenziale* una parte dell'effetto osservato nei contrasti *clean vs smelly* può dipendere non solo dall'immagine generata, ma anche dal fatto che i valutatori testo-immagine operano su un *testo ambiguo*. Per ridurre questo confondente e separare l'impatto dello smell sul contenuto visivo dall'impatto dovuto alla formulazione testuale, è stata condotta una *cross analysis (image-swap)* in cui il *prompt* di valutazione è mantenuto **clean** e viene “scambiata” solo l'immagine: la coppia (*prompt clean, immagine smelly*) viene confrontata con (*prompt clean, immagine clean*) a seed fissato.

Formalmente, per ciascuna baseline  $B$  e smell  $s$  della macrocategoria, è stato stimato il contrasto su scala risposta:

$$\Delta\mu = \mu(\text{clean prompt, smelly img}) - \mu(\text{clean prompt, clean img}),$$

dove  $\Delta\mu < 0$  indica che, a parità di prompt clean, l'immagine generata dallo smell ottiene un punteggio inferiore rispetto all'immagine clean. L'analisi è stata limitata alle metriche prompt-immagine (*clipscore\_unit*, *geval\_align\_unit*, *hpsv21\_unit*), per le quali l'ambiguità testuale può influenzare direttamente il processo di valutazione.

**Risultati principali e differenze rispetto a *clean vs smelly*** La Figura 4.6 evidenzia tre pattern informativi.

- **Polisemia: effetto ampio e persistente anche a prompt clean.** Per `polysemy` (`baseline clean_polysemy_base`) i contrasti risultano fortemente negativi, soprattutto su `qeval_align_unit`. Ciò indica che l'effetto osservato non è spiegato solo da ambiguità del testo nel valutatore: lo smell altera frequentemente *l'immagine prodotta* (ad es. *subject shift*), che risulta meno compatibile con l'intento disambiguato del prompt clean.
- **Negazione e sintassi: effetti moderati e dipendenti dalla metrica.** Per `negation_scope_ambiguity` (`baseline clean_negation_base`) e `syntactic_ambiguity` (`baseline clean_syntax_base`), i contrasti sono di ampiezza ridotta rispetto ai casi più estremi e possono mostrare andamenti non uniformi tra metriche (ad es. variazioni contenute su `clipscore_unit` e segnali più leggibili su `qeval_align_unit` e/o `hpsv21_unit`). Questo è coerente con uno smell che, in media, non forza sempre un cambiamento drastico del contenuto visivo, ma può introdurre instabilità episodica (violazioni intermittenti dei vincoli) che emerge in modo più chiaro quando l'immagine viene valutata rispetto a un testo disambiguato.
- **Ambiguità figurativa: effetto in media contenuto ma potenzialmente episodico.** Per `figurative_ambiguity` (`baseline clean_figurative_base`) i contrasti risultano generalmente più piccoli rispetto a `polysemy`. Questo è coerente con un comportamento *non deterministico*: l'idioma può essere interpretato correttamente (quindi l'immagine resta simile alla clean) oppure letteralmente (introducendo oggetti/contenuti spuri). In cross analysis, fissare il prompt clean rende più evidente tale dinamica, perché eventuali deviazioni visive vengono valutate rispetto a una descrizione letterale e disambiguata.
- **Relazioni/binding: segnali piccoli ma non nulli.** Nelle tipologie derivate da `clean_relation_base` (`referential_ambiguity`, `attribute_binding_ambiguity`, `spatial_relation_ambiguity`) i contrasti risultano generalmente più piccoli rispetto a `polysemy`, ma alcuni risultano comunque distin-

guibili da zero, soprattutto su `qeval_align_unit` e `hpsv21_unit`. In questi casi l’immagine può rimanere qualitativamente simile, ma l’*allocazione* di attributi/relazioni o la resa della scena può divergere in modo sufficiente da ridurre la compatibilità con la specifica clean, rendendo più evidente la perdita di tracciabilità tra vincoli e output.

**Interpretazione complessiva** Nel complesso, la cross analysis fornisce evidenza complementare rispetto ai contrasti *clean vs smelly*: quando il peggioramento è **presente anche con prompt clean fisso** (caso tipico: `polysemy`), l’effetto è attribuibile principalmente a cambiamenti nel contenuto visivo generato dallo smell; quando invece l’effetto è **contenuto o metric-dipendente**, è plausibile che nel confronto principale una parte della variabilità sia dovuta anche all’ambiguità del testo nel processo di valutazione. Per questo motivo, i risultati della cross analysis sono interpretati come *robustness check* mirato alla macrocategoria di ambiguità e discussi separatamente dall’analisi principale.

## 4.2 Risultati RQ2: variabilità percettiva intra-prompt (LPIPS)

**Q RQ2.** *I prompt smells influenzano la variabilità percettiva intra-prompt delle immagini generate al variare del seed?*

L’obiettivo di questa RQ è valutare se le tipologie *smelly* modificano la *stabilità* dell’output generativo quando il prompt è mantenuto fisso e varia solo il seed. Come descritto nella Sezione 3.6, la variabilità percettiva è misurata tramite LPIPS e riassunta, per ciascuna tipologia, come differenza rispetto alla baseline clean corrispondente:

$$\Delta_t = \text{median}(\delta_p) \quad \text{con} \quad \delta_p = v_p^{(t)} - v_p^{(B)}.$$

Valori  $\Delta_t > 0$  indicano **maggiore variabilità** (output meno stabile) nella tipologia *smelly* rispetto alla baseline, mentre  $\Delta_t < 0$  indica **minore variabilità** (output più stabile). L’incertezza è quantificata tramite IC bootstrap al 95% (percentile,  $B = 5000$ ) campionando a livello di prompt ( $n = 14$  per tipologia).

**Risultato complessivo: effetti tipicamente piccoli** La Figura 4.7 mostra che, nella maggior parte delle tipologie,  $\Delta_t$  è vicino a zero e l'IC include lo zero, suggerendo che molti prompt smells *non alterano in modo sistematico* la variabilità intra-prompt indotta dal seed. In termini di ampiezza, il 95% delle tipologie (escludendo casi estremi) presenta variazioni entro circa  $\pm 0.01$ – $0.02$ , indicando un impatto generalmente contenuto sulla stabilità percettiva.

**Casi con evidenza di variazione non nulla (IC 95% non include 0)** Solo quattro tipologie mostrano IC al 95% che non include lo zero, e dunque un cambiamento coerente della variabilità rispetto alla baseline:

- **finnish\_translation (da clean1)**: incremento marcato della variabilità ( $\Delta_t \approx +0.089$ ,  $IC_{95\%} \approx [0.051, 0.119]$ ). Questo risultato è coerente con un *coverage shift* forte (lingua low-resource) che può ridurre il controllo del modello sul contenuto e aumentare l'instabilità tra seed, producendo output più eterogenei.
- **subject\_plus\_details (da clean1)**: riduzione della variabilità ( $\Delta_t \approx -0.031$ ,  $IC_{95\%} \approx [-0.101, -0.0003]$ ). L'effetto è moderato ma con IC ampio, suggerendo eterogeneità tra prompt; in media, rimuovere contesto/mood/stile può portare a generazioni più *conservative* e simili tra seed.
- **referential\_ambiguity e spatial\_relation\_ambiguity (da clean\_relation\_base)**: riduzioni piccole ma coerenti della variabilità (rispettivamente  $\Delta_t \approx -0.005$  con  $IC_{95\%} \approx [-0.014, -0.0001]$  e  $\Delta_t \approx -0.007$  con  $IC_{95\%} \approx [-0.016, -0.0008]$ ). Pur con ampiezza limitata, il segnale è compatibile con un comportamento in cui ambiguità su riferimenti/relazioni spaziali induce il generatore ad adottare configurazioni più *standardizzate* e ripetibili tra seed.

**Interpretazione e collegamento con la RQ1** Nel complesso, i risultati indicano che i prompt smells tendono a incidere più sulla *correttezza/controllabilità* del contenuto rispetto al testo (RQ1) che non sulla *stabilità percettiva* intra-prompt (RQ2). Le eccezioni sono informative: (i) un forte language shift (finlandese) aumenta nettamente

l'instabilità tra seed; (ii) alcune forme di sotto-specificazione o ambiguità relazionale possono invece ridurre la variabilità, plausibilmente per effetto di “defaulting” compositazionale.

### 4.3 Sintesi trasversale e takeaway

**Q RQ<sub>1</sub>.** *In che misura i prompt smells impattano sulle metriche di allineamento testo-immagine, qualità visiva, estetica e preferenza umana condizionata dal prompt?*

**🔗 Answer to RQ<sub>1</sub>.** I prompt smells impattano soprattutto su *allineamento testo-immagine* e *preferenza umana condizionata dal prompt*, mentre l'effetto sulla *qualità visiva* è generalmente contenuto. Gli effetti più evidenti emergono quando il prompt introduce conflitti tra vincoli, riduce drasticamente la specificazione, oppure contiene ambiguità: in quest'ultimo caso lo smell è problematico sia perché può alterare l'immagine generata, sia perché può rendere meno affidabile la valutazione automatica basata sul testo.

**Q RQ<sub>2</sub>.** *I prompt smells influenzano la variabilità percettiva intra-prompt delle immagini generate al variare del seed?*

**🔗 Answer to RQ<sub>2</sub>.** La maggior parte dei prompt smells non modifica in modo sistematico la variabilità percettiva intra-prompt (LPIPS): le variazioni rispetto alla baseline sono tipicamente piccole e spesso compatibili con zero. Solo pochi casi mostrano effetti coerenti, suggerendo che gli smells alterano più la controllabilità semantica dell'output che la stabilità al variare del seed.

**Rassegna riassuntiva** Nel complesso, le metriche di *allineamento* risultano più sensibili alle trasformazioni smelly rispetto a CLIPScore, mentre le metriche di *qualità visiva* mostrano contrasti spesso prossimi a zero: molti smells agiscono quindi principalmente sulla corrispondenza tra vincoli testuali e contenuto generato, più che su artefatti percettivi. Un pattern ricorrente è il trade-off della sotto-specificazione: prompt meno vincolanti possono risultare più facili da soddisfare (migliorando l'allineamento), ma tendono a produrre immagini più generiche e meno curate sul piano estetico.

Per le tipologie basate su ambiguità linguistica e referenziale, i risultati indicano un duplice canale di impatto: (i) l'ambiguità può influenzare direttamente la generazione, inducendo scelte interpretative diverse e talvolta violazioni intermittenti dei vincoli; (ii) l'ambiguità può influenzare anche le metriche prompt-immagine, perché il valutatore deve interpretare un testo non univoco. In questo senso, la cross analysis (prompt clean fisso) fornisce evidenza complementare: fissare un testo disambiguato in valutazione aiuta a isolare l'effetto sul contenuto visivo e a rendere più interpretabili eventuali degradazioni.

### Takeaway

- Gli smells emergono soprattutto su **allineamento** e **preferenza**, più che sulla **qualità visiva**.
- Alcune trasformazioni introducono **trade-off** tra controllabilità semantica e qualità estetica.
- Le **ambiguità** sono critiche perché possono compromettere sia il **risultato generativo** sia la **misurazione automatica** basata sul testo.
- La **stabilità** intra-prompt (LPIPS) è per lo più invariata, con poche eccezioni.



(a) clean\_polysemy\_base



(b) polysemy




(c) clean\_negation\_base



(d) negation\_scope\_ambi.



(e) clean\_figurative\_base



(f) figurative\_ambiguity

**Figura 4.4:** Esempi qualitativi (stesso seed per ciascuna coppia clean-smelly): baseline clean (sinistra) vs variante smelly (destra).





(a) clean\_relation\_base


(b) attribute\_binding\_ambi.




(c) clean\_syntax\_base

(d) syntactic\_ambiguity

**Figura 4.5:** Esempi qualitativi con differenze visive contenute (stesso seed per ciascuna coppia clean-smelly).



**Figura 4.6:** Cross analysis (*image-swap*, prompt clean fisso): contrasti su scala risposta  $\Delta\mu = \mu(\text{clean prompt, smelly img}) - \mu(\text{clean prompt, clean img})$ .



**Figura 4.7:** Variazione della variabilità LPIPS rispetto alla baseline:  $\Delta_t$  (mediana delle differenze appaiate per prompt) e IC bootstrap al 95%.

## CAPITOLO 5

---

### Conclusioni

---

Questo lavoro di tesi ha avuto come obiettivo l'analisi sistematica dei *prompt smells* nei sistemi *text-to-image*, ovvero difetti non intenzionali nella formulazione del prompt che possono ridurre la desiderabilità dell'output e compromettere spiegabilità e tracciabilità tra input e output. A fronte della mancanza di una tassonomia operativa focalizzata su questo contesto, la tesi ha definito un insieme di tipologie riproducibili di prompt smells e ne ha quantificato l'impatto tramite una sperimentazione controllata supportata da metriche automatiche.

Per rendere l'analisi comparabile e ripetibile, sono state progettate baseline clean come condizioni di controllo e sono state generate varianti smelly tramite trasformazioni testuali mirate. Le immagini sono state prodotte con un modello *text-to-image* in condizioni controllate, mantenendo costanti configurazione di generazione e seed deterministici, così da ottenere repliche confrontabili per ciascun prompt. Su ciascuna immagine sono state calcolate metriche automatiche che coprono più dimensioni: allineamento testo-immagine, qualità visiva, estetica e preferenza umana condizionata dal prompt. I punteggi sono stati quindi analizzati con un *beta mixed-effects model* per stimare, su scala risposta, l'effetto delle tipologie smelly rispetto alle baseline corrispondenti, tenendo conto della struttura a osservazioni ripetute e degli appaiamenti sperimentali. In parallelo, per valutare la stabilità percettiva dell'output al variare del

seed, è stata condotta un’analisi dedicata basata su LPIPS con intervalli di confidenza bootstrap.

I risultati principali mostrano che l’impatto dei prompt smells emerge soprattutto sulle dimensioni legate alla *controllabilità semantica* dell’output. In particolare, le metriche di allineamento testo–immagine risultano le più sensibili alle trasformazioni smelly, evidenziando che difetti nel prompt possono ridurre la corrispondenza tra vincoli espressi nel testo e contenuto effettivamente generato. Al contrario, le metriche di qualità visiva mostrano nel complesso variazioni più contenute, suggerendo che molti smells non degradano sistematicamente l’immagine sul piano percettivo *low-level*, ma agiscono principalmente sul contenuto e sulla tracciabilità dei vincoli. Un ulteriore risultato rilevante è la presenza di trade-off in scenari di forte sotto-specificazione: prompt meno vincolanti possono risultare più facili da “soddisfare” per i valutatori di allineamento, ma tendono a produrre output più generici e meno curati sul piano estetico.

Per le tipologie basate su ambiguità linguistica e referenziale, è emerso un aspetto particolarmente critico: l’ambiguità può essere problematica sia per il risultato finale sia per la misurazione automatica. Da un lato può indurre scelte interpretative diverse e, in alcuni casi, violazioni intermittenti dei vincoli; dall’altro lato può rendere meno affidabile la valutazione prompt–immagine quando i valutatori devono interpretare un testo non univoco. In questo contesto, la *cross analysis* ha fornito evidenza complementare utile a separare l’effetto dello smell sull’immagine dall’effetto dovuto alla formulazione del prompt nel processo di scoring.

Per quanto riguarda la RQ2, l’analisi della variabilità percettiva intra-prompt tramite LPIPS indica che, nella maggior parte dei casi, i prompt smells non modificano in modo sistematico la stabilità dell’output al variare del seed. Le variazioni osservate risultano generalmente piccole e spesso compatibili con zero, con poche eccezioni che suggeriscono come alcune trasformazioni possano portare a output più eterogenei oppure, al contrario, a generazioni più “standardizzate” e ripetibili. Nel complesso, i risultati indicano che gli smells influenzano più *cosa* viene generato e quanto tale contenuto sia controllabile rispetto al testo, piuttosto che *quanto* l’output vari tra seed.

L’impatto del lavoro è duplice. Da un lato, la tesi propone una tassonomia operativa e riproducibile di prompt smells per il dominio *text-to-image*, utile come riferimento

per studi futuri e per costruire benchmark controllati. Dall’altro lato, i risultati sperimentali forniscono indicazioni pratiche su quali famiglie di difetti testuali tendono a compromettere maggiormente l’allineamento e la tracciabilità tra input e output, evidenziando anche limiti e possibili distorsioni della valutazione automatica in presenza di ambiguità.

Nonostante i risultati ottenuti, il lavoro presenta alcuni limiti. In primo luogo, gli esperimenti sono stati condotti utilizzando un singolo modello generativo e una specifica configurazione di inferenza, quindi la generalizzabilità dei risultati ad altri modelli e setting deve essere verificata. In secondo luogo, la valutazione è stata basata su metriche automatiche, che pur coprendo dimensioni diverse possono presentare sensibilità differenti e non sostituiscono completamente la valutazione umana. Infine, la tassonomia implementata, pur ampia, rappresenta una selezione di tipologie e non esaurisce tutte le possibili forme di difetti non intenzionali nei prompt.

Come sviluppi futuri, un primo passo naturale consiste nel replicare lo studio su modelli *text-to-image* differenti e su configurazioni di generazione più varie (ad es. diversi numeri di step, guidance, risoluzioni), per valutare la stabilità dei pattern osservati. Un secondo sviluppo riguarda l’estensione della valutazione includendo esperimenti con giudizi umani, utili sia per validare i trend rilevati dalle metriche sia per misurare direttamente percezioni di desiderabilità e controllabilità. Un’ulteriore direzione consiste nel progettare strategie di mitigazione dei prompt smells, ad esempio tramite riscritture automatiche o template disambiguanti, e misurarne l’efficacia in termini di miglioramento dell’allineamento e della tracciabilità. Infine, sarebbe utile ampliare il set di tipologie e studiare in modo più approfondito il ruolo di ambiguità e sotto-specificazione su scenari compositivi più complessi, dove il binding di attributi e relazioni tende a essere più difficile e l’impatto dei difetti del prompt potrebbe risultare ancora più marcato.

---

## Bibliografia

---

- [1] J. Ho, A. Jain, and P. Abbeel, “Denoising diffusion probabilistic models,” *CoRR*, vol. abs/2006.11239, 2020. [Online]. Available: <https://arxiv.org/abs/2006.11239> (Citato a pagina 1)
- [2] C. Zhang, C. Zhang, M. Zhang, I. S. Kweon, and J. Kim, “Text-to-image diffusion models in generative ai: A survey,” 2024. [Online]. Available: <https://arxiv.org/abs/2303.07909> (Citato alle pagine 1 e 6)
- [3] J. C. White and R. Cotterell, “Schrödinger’s bat: Diffusion models sometimes generate polysemous words in superposition,” 2022. [Online]. Available: <https://arxiv.org/abs/2211.13095> (Citato alle pagine 2, 23 e 24)
- [4] H. Gao, H. Zhang, Y. Dong, and Z. Deng, “Evaluating the robustness of text-to-image diffusion models against real-world attacks,” 2023. [Online]. Available: <https://arxiv.org/abs/2306.13103> (Citato a pagina 2)
- [5] M. A. H. Khan, Y. Jain, S. Bhattacharyya, and V. Vineet, “Test-time prompt refinement for text-to-image models,” 2025. [Online]. Available: <https://arxiv.org/abs/2507.22076> (Citato a pagina 2)
- [6] A. Hertz, R. Mokady, J. Tenenbaum, K. Aberman, Y. Pritch, and D. Cohen-Or, “Prompt-to-prompt image editing with cross attention control,” 2022. [Online]. Available: <https://arxiv.org/abs/2208.01626> (Citato a pagina 2)

- [7] K. Ronanki, B. Cabrero-Daniel, and C. Berger, "Prompt smells: An omen for undesirable generative AI outputs," in *Proceedings of the IEEE/ACM 3rd International Conference on AI Engineering – Software Engineering for AI (CAIN '24)*. New York, NY, USA: Association for Computing Machinery, 2024, pp. 286–287, lisbon, Portugal. [Online]. Available: <https://doi.org/10.1145/3644815.3644982> (Citato alle pagine 2 e 21)
- [8] A. Borji, "Qualitative failures of image generation models and their application in detecting deepfakes," 2024. [Online]. Available: <https://arxiv.org/abs/2304.06470> (Citato a pagina 5)
- [9] P. W. Shin, J. J. Ahn, W. Yin, J. Sampson, and V. Narayanan, "Can prompt modifiers control bias? a comparative analysis of text-to-image generative models," 2024. [Online]. Available: <https://arxiv.org/abs/2406.05602> (Citato alle pagine 6 e 22)
- [10] N. Mehrabi, P. Goyal, A. Verma, J. Dhamala, V. Kumar, Q. Hu, K.-W. Chang, R. Zemel, A. Galstyan, and R. Gupta, "Is the elephant flying? resolving ambiguities in text-to-image generative models," 2022. [Online]. Available: <https://arxiv.org/abs/2211.12503> (Citato alle pagine 6, 22, 23 e 24)
- [11] Y. Zhang, T. T. Tzun, L. W. Hern, H. Wang, and K. Kawaguchi, "On copyright risks of text-to-image diffusion models," 2024. [Online]. Available: <https://arxiv.org/abs/2311.12803> (Citato a pagina 6)
- [12] International Telecommunication Union (ITU), "Standards and policy considerations for multimedia authenticity," Online, 2025. (Citato a pagina 6)
- [13] J. Ho, A. Jain, and P. Abbeel, "Denoising diffusion probabilistic models," *CoRR*, vol. abs/2006.11239, 2020. [Online]. Available: <https://arxiv.org/abs/2006.11239> (Citato a pagina 6)
- [14] R. Rombach, A. Blattmann, D. Lorenz, P. Esser, and B. Ommer, "High-resolution image synthesis with latent diffusion models," *CoRR*, vol. abs/2112.10752, 2021. [Online]. Available: <https://arxiv.org/abs/2112.10752> (Citato alle pagine 7 e 8)



- [15] W. Peebles and S. Xie, "Scalable diffusion models with transformers," 2023. [Online]. Available: <https://arxiv.org/abs/2212.09748> (Citato a pagina 7)
- [16] J. Ho and T. Salimans, "Classifier-free diffusion guidance," 2022. [Online]. Available: <https://arxiv.org/abs/2207.12598> (Citato alle pagine 7 e 8)
- [17] C. Saharia, W. Chan, S. Saxena, L. Li, J. Whang, E. Denton, S. K. S. Ghasemipour, B. K. Ayan, S. S. Mahdavi, R. G. Lopes, T. Salimans, J. Ho, D. J. Fleet, and M. Norouzi, "Photorealistic text-to-image diffusion models with deep language understanding," 2022. [Online]. Available: <https://arxiv.org/abs/2205.11487> (Citato a pagina 7)
- [18] A. Nichol, P. Dhariwal, A. Ramesh, P. Shyam, P. Mishkin, B. McGrew, I. Sutskever, and M. Chen, "Glide: Towards photorealistic image generation and editing with text-guided diffusion models," 2022. [Online]. Available: <https://arxiv.org/abs/2112.10741> (Citato a pagina 7)
- [19] A. Ramesh, P. Dhariwal, A. Nichol, C. Chu, and M. Chen, "Hierarchical text-conditional image generation with clip latents," 2022. [Online]. Available: <https://arxiv.org/abs/2204.06125> (Citato a pagina 7)
- [20] J. Chen, J. Yu, C. Ge, L. Yao, E. Xie, Y. Wu, Z. Wang, J. Kwok, P. Luo, H. Lu, and Z. Li, "Pixart- $\alpha$ : Fast training of diffusion transformer for photorealistic text-to-image synthesis," 2023. [Online]. Available: <https://arxiv.org/abs/2310.00426> (Citato a pagina 7)
- [21] K. Huang, C. Duan, K. Sun, E. Xie, Z. Li, and X. Liu, "T2i-compbench++: An enhanced and comprehensive benchmark for compositional text-to-image generation," 2025. [Online]. Available: <https://arxiv.org/abs/2307.06350> (Citato a pagina 8)
- [22] M. M. Trusca, W. Nuyts, J. Thomm, R. Honig, T. Hofmann, T. Tuytelaars, and M.-F. Moens, "Object-attribute binding in text-to-image generation: Evaluation and control," 2024. [Online]. Available: <https://arxiv.org/abs/2404.13766> (Citato a pagina 8)

- 
- [23] B. Zhang, P. Zhang, X. Dong, Y. Zang, and J. Wang, "Long-clip: Unlocking the long-text capability of clip," 2024. [Online]. Available: <https://arxiv.org/abs/2403.15378> (Citato alle pagine 8, 28 e 29)
- [24] Y. Kirstain, A. Polyak, U. Singer, S. Matiana, J. Penna, and O. Levy, "Pick-a-pic: An open dataset of user preferences for text-to-image generation," 2023. [Online]. Available: <https://arxiv.org/abs/2305.01569> (Citato alle pagine 9 e 17)
- [25] J. Xu, X. Liu, Y. Wu, Y. Tong, Q. Li, M. Ding, J. Tang, and Y. Dong, "Imagereward: Learning and evaluating human preferences for text-to-image generation," 2023. [Online]. Available: <https://arxiv.org/abs/2304.05977> (Citato alle pagine 10 e 17)
- [26] X. Wu, Y. Hao, K. Sun, Y. Chen, F. Zhu, R. Zhao, and H. Li, "Human preference score v2: A solid benchmark for evaluating human preferences of text-to-image synthesis," 2023. [Online]. Available: <https://arxiv.org/abs/2306.09341> (Citato alle pagine 10, 17 e 50)
- [27] Z. Zhang, T. Kou, S. Wang, C. Li, W. Sun, W. Wang, X. Li, Z. Wang, X. Cao, X. Min, X. Liu, and G. Zhai, "Q-eval-100k: Evaluating visual quality and alignment level for text-to-vision content," 2025. [Online]. Available: <https://arxiv.org/abs/2503.02357> (Citato alle pagine 10, 15 e 49)
- [28] D. Ghosh, H. Hajishirzi, and L. Schmidt, "Geneval: An object-focused framework for evaluating text-to-image alignment," 2023. [Online]. Available: <https://arxiv.org/abs/2310.11513> (Citato alle pagine 10, 14, 24 e 25)
- [29] Y. Hu, B. Liu, J. Kasai, Y. Wang, M. Ostendorf, R. Krishna, and N. A. Smith, "Tifa: Accurate and interpretable text-to-image faithfulness evaluation with question answering," 2023. [Online]. Available: <https://arxiv.org/abs/2303.11897> (Citato alle pagine 10 e 13)
- [30] M. Heusel, H. Ramsauer, T. Unterthiner, B. Nessler, and S. Hochreiter, "Gans trained by a two time-scale update rule converge to a local nash equilibrium," 2018. [Online]. Available: <https://arxiv.org/abs/1706.08500> (Citato alle pagine 11 e 15)

- [31] S. A. Kasaei, A. Aghayari, A. Marioriyad, N. Sepasian, M. Fazli, M. S. Baghshah, and M. H. Rohban, "Evaluating the evaluators: Metrics for compositional text-to-image generation," 2025. [Online]. Available: <https://arxiv.org/abs/2509.21227> (Citato alle pagine 12, 13 e 48)
- [32] J. Hessel, A. Holtzman, M. Forbes, R. L. Bras, and Y. Choi, "Clipscore: A reference-free evaluation metric for image captioning," 2022. [Online]. Available: <https://arxiv.org/abs/2104.08718> (Citato alle pagine 13, 48 e 50)
- [33] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, G. Krueger, and I. Sutskever, "Learning transferable visual models from natural language supervision," 2021. [Online]. Available: <https://arxiv.org/abs/2103.00020> (Citato alle pagine 13, 28, 29 e 48)
- [34] O. Mañas, P. Astolfi, M. Hall, C. Ross, J. Urbanek, A. Williams, A. Agrawal, A. Romero-Soriano, and M. Drozdal, "Improving text-to-image consistency via automatic prompt optimization," 2024. [Online]. Available: <https://arxiv.org/abs/2403.17804> (Citato a pagina 13)
- [35] Z. Lin, D. Pathak, B. Li, J. Li, X. Xia, G. Neubig, P. Zhang, and D. Ramanan, "Evaluating text-to-visual generation with image-to-text generation," 2024. [Online]. Available: <https://arxiv.org/abs/2404.01291> (Citato a pagina 14)
- [36] J. Cho, Y. Hu, R. Garg, P. Anderson, R. Krishna, J. Baldridge, M. Bansal, J. Pont-Tuset, and S. Wang, "Davidsonian scene graph: Improving reliability in fine-grained evaluation for text-to-image generation," 2024. [Online]. Available: <https://arxiv.org/abs/2310.18235> (Citato a pagina 14)
- [37] Z. Wang, A. Bovik, H. Sheikh, and E. Simoncelli, "Image quality assessment: from error visibility to structural similarity," *IEEE Transactions on Image Processing*, vol. 13, no. 4, pp. 600–612, 2004. (Citato a pagina 14)
- [38] R. Zhang, P. Isola, A. A. Efros, E. Shechtman, and O. Wang, "The unreasonable effectiveness of deep features as a perceptual metric," 2018. [Online]. Available: <https://arxiv.org/abs/1801.03924> (Citato alle pagine 15, 18 e 56)

- [39] H. Wu, Z. Zhang, W. Zhang, C. Chen, L. Liao, C. Li, Y. Gao, A. Wang, E. Zhang, W. Sun, Q. Yan, X. Min, G. Zhai, and W. Lin, "Q-align: Teaching lmms for visual scoring via discrete text-defined levels," 2023. [Online]. Available: <https://arxiv.org/abs/2312.17090> (Citato alle pagine 15, 16 e 49)
- [40] K. Wang, L. Zhang, and J. Zhang, "Detecting human artifacts from text-to-image models," 2025. [Online]. Available: <https://arxiv.org/abs/2411.13842> (Citato a pagina 15)
- [41] Z. Wang, B. Peng, S. Yang, Z. Tang, and J. Dong, "Handeval: Taking the first step towards hand quality evaluation in generated images," 2025. [Online]. Available: <https://arxiv.org/abs/2510.08978> (Citato a pagina 16)
- [42] S. Cao, N. Ma, J. Li, X. Li, L. Shao, K. Zhu, Y. Zhou, Y. Pu, J. Wu, J. Wang, B. Qu, W. Wang, Y. Qiao, D. Yao, and Y. Liu, "Artimuse: Fine-grained image aesthetics assessment with joint scoring and expert-level understanding," 2025. [Online]. Available: <https://arxiv.org/abs/2507.14533> (Citato alle pagine 16 e 49)
- [43] Y. Ma, Y. Shui, X. Wu, K. Sun, and H. Li, "Hpsv3: Towards wide-spectrum human preference score," 2025. [Online]. Available: <https://arxiv.org/abs/2508.03789> (Citato alle pagine 17 e 50)
- [44] S. Zhang, B. Wang, J. Wu, Y. Li, T. Gao, D. Zhang, and Z. Wang, "Learning multi-dimensional human preference for text-to-image generation," 2024. [Online]. Available: <https://arxiv.org/abs/2405.14705> (Citato a pagina 18)
- [45] J. Oppenlaender, "A taxonomy of prompt modifiers for text-to-image generation," *Behaviour amp; Information Technology*, vol. 43, no. 15, p. 3763–3776, Nov. 2023. [Online]. Available: <http://dx.doi.org/10.1080/0144929X.2023.2286532> (Citato alle pagine 19 e 29)
- [46] J. Oppenlaender, R. Linder, and J. Silvennoinen, "Prompting ai art: An investigation into the creative skill of prompt engineering," 2024. [Online]. Available: <https://arxiv.org/abs/2303.13534> (Citato alle pagine 19, 26, 27, 28, 29 e 34)

- [47] W. Li, J. Wang, and X. Zhang, "Promptist: Automated prompt optimization for text-to-image synthesis," in *Natural Language Processing and Chinese Computing*, D. F. Wong, Z. Wei, and M. Yang, Eds. Singapore: Springer Nature Singapore, 2025, pp. 295–306. (Citato alle pagine 19 e 26)
- [48] T. Cao, C. Wang, B. Liu, Z. Wu, J. Zhu, and J. Huang, "Beautifulprompt: Towards automatic prompt engineering for text-to-image synthesis," 2023. [Online]. Available: <https://arxiv.org/abs/2311.06752> (Citato a pagina 20)
- [49] S. Rosenman, V. Lal, and P. Howard, "Neuroprompts: An adaptive framework to optimize prompts for text-to-image generation," 2024. [Online]. Available: <https://arxiv.org/abs/2311.12229> (Citato alle pagine 20, 27 e 28)
- [50] S. Wu, M. Sun, W. Wang, Y. Wang, and J. Liu, "Visualprompter: Prompt optimization with visual feedback for text-to-image synthesis," 2025. [Online]. Available: <https://arxiv.org/abs/2506.23138> (Citato alle pagine 20, 26 e 29)
- [51] W. Elsharif, M. Alzubaidi, J. She, and M. Agus, "Visualizing ambiguity: Analyzing linguistic ambiguity resolution in text-to-image models," *Computers*, vol. 14, no. 1, 2025. [Online]. Available: <https://www.mdpi.com/2073-431X/14/1/19> (Citato alle pagine 23 e 24)
- [52] N. Pavlichenko and D. Ustalov, "Best prompts for text-to-image models and how to find them," in *Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval*, ser. SIGIR '23. ACM, Jul. 2023, p. 2067–2071. [Online]. Available: <http://dx.doi.org/10.1145/3539618.3592000> (Citato alle pagine 27, 28 e 29)
- [53] Y. Xie, Z. Pan, J. Ma, L. Jie, and Q. Mei, "A prompt log analysis of text-to-image generation systems," in *Proceedings of the ACM Web Conference 2023*, ser. WWW '23. ACM, Apr. 2023, p. 3892–3902. [Online]. Available: <http://dx.doi.org/10.1145/3543507.3587430> (Citato alle pagine 30 e 31)
- [54] H. Simonen, A. Kiviniemi, H. Johnston, H. Barranha, and J. Oppenlaender, "An exploration of default images in text-to-image generation," 2026. [Online]. Available: <https://arxiv.org/abs/2505.09166> (Citato alle pagine 30, 31, 32 e 33)

- [55] H.-K. Ko, G. Park, H. Jeon, J. Jo, J. Kim, and J. Seo, "Large-scale text-to-image generation models for visual artists' creative works," in *Proceedings of the 28th International Conference on Intelligent User Interfaces*, ser. IUI '23. ACM, Mar. 2023, p. 919–933. [Online]. Available: <http://dx.doi.org/10.1145/3581641.3584078> (Citato alle pagine 32 e 33)
- [56] M. Smithson and J. Verkuilen, "A better lemon squeezer? maximum-likelihood regression with beta-distributed dependent variables," *Psychological Methods*, vol. 11, pp. 54–71, 03 2006. (Citato a pagina 51)