



UNIVERSITÀ DEGLI STUDI DI SALERNO

Dipartimento di Informatica

Corso di Laurea Triennale in Informatica

TESI DI LAUREA

Selezione di Scenari di Test per Sistemi ADS tramite Algoritmo Greedy

RELATORE

Prof. Nome Dario Di Nucci

Dott. Nome Antonio Trovato

Università degli Studi di Salerno

CANDIDATO

Mancino Renato

Matricola: 0512117090

Anno Accademico 2024–2025

Questa tesi è stata realizzata nel

sesa^{lab}
SOFTWARE ENGINEERING
SALERNO

Abstract

Negli ultimi anni, gli Automated Driving Systems sono diventati un elemento centrale nello sviluppo delle automobili di nuova generazione, con l'obiettivo di migliorare la sicurezza stradale, ridurre il numero di incidenti e aumentare il comfort di guida. La validazione di tali sistemi in scenari critici è essenziale, ma i test su strada presentano costi elevati, tempi lunghi e rischi per la sicurezza. L'impiego di simulatori open-source come CARLA consente di ricreare scenari complessi in ambienti sicuri e controllati; tuttavia, l'esecuzione indiscriminata di un elevato numero di scenari può risultare inefficiente, includendo test ridondanti o poco informativi. Questa tesi propone un approccio basato su un algoritmo greedy per la selezione automatica di scenari di test, mirato a massimizzare la copertura di casi critici, aumentare la diversità delle condizioni simulate e ridurre il tempo totale di esecuzione. I risultati dimostrano una significativa riduzione dei tempi di test, il mantenimento del 100% della copertura degli scenari critici presenti nella suite iniziale e una maggiore varietà delle condizioni simulate, confermando l'efficacia dell'approccio proposto e ponendo le basi per futuri sviluppi verso scenari più complessi e realistici.

Indice

Elenco delle Tabelle	iii
1 Introduzione	1
1.1 Contesto Applicativo	1
1.2 Motivazioni e Obiettivi	2
1.3 Risultati	3
1.4 Struttura della Tesi	4
2 Background e Stato dell'arte	5
2.1 Automated Driving Systems	5
2.1.1 Simulazione per la Validazione degli ADS	6
2.1.2 Test Case Selection tramite l'Approccio Greedy	6
2.2 Stato dell'arte	7
3 Metodologia	9
3.1 Ambiente di Simulazione e Dataset	10
3.2 Metriche di Valutazione	10
3.2.1 Copertura degli Scenari Critici / Diversità (f_1)	11
3.2.2 Collision Coverage (f_2)	11
3.2.3 Tempo di Esecuzione (f_3)	11
3.3 Pre-processing dei Dati	11

3.4	Formulazione del Problema e Funzione di Utilità	12
3.4.1	Configurazione dei Pesi	12
3.5	Processo di Selezione Additional Greedy	13
4	Analisi Sperimentale e Risultati	14
4.1	Configurazione di Riferimento	14
4.1.1	Dati di Input (Suite Completa Baseline)	14
4.1.2	Risultati di Ottimizzazione con Taratura di Riferimento	15
4.2	Analisi dei Trade-off e Bontà dell'Approccio	15
4.3	Analisi di Sensibilità e Flessibilità delle Variabili α	17
4.4	Conclusioni del Capitolo	17
5	Limiti dello Studio	18
6	Conclusioni e Sviluppi Futuri	20
	Bibliografia	22

Elenco delle tabelle

4.1	Dati di Riferimento della Suite Completa (Baseline)	15
4.2	Confronto tra Suite Completa e Suite Ottimizzata	15
4.3	Confronto sulla Metrica di Copertura degli Scenari Critici (f_1)	16
4.4	Analisi di Sensibilità dei Coefficienti α	17

CAPITOLO 1

Introduzione

1.1 Contesto Applicativo

Gli Autonomous Driving Systems (ADS) sono una componente fondamentale delle automobili di nuova generazione. Questi sistemi combinano sensori, telecamere, radar e algoritmi avanzati per monitorare l'ambiente circostante e assistere il conducente in compiti complessi, come il mantenimento di corsia, la frenata automatica di emergenza, il rilevamento di pedoni o il controllo adattivo della velocità [1, 2].

L'obiettivo degli ADS è duplice: aumentare la sicurezza stradale, riducendo il più possibile situazioni pericolose, ed al contempo migliorare comfort e l'esperienza di guida. Per raggiungere tali obiettivi, questi sistemi devono essere progettati per funzionare in una vasta gamma di condizioni operative, dalle situazioni di traffico quotidiane a scenari critici caratterizzati da eventi rari o comportamenti imprevedibili di altri utenti della strada.

Esempi di scenari complessi includono: manovre improvvise di veicoli adiacenti, attraversamenti inattesi di pedoni, ostacoli statici imprevisti o condizioni meteorologiche estreme. Garantire prestazioni affidabili in tali circostanze è una sfida notevole, che richiede test approfonditi e metodologie di validazione capaci di coprire una molteplicità di casi e variabili.

Le tecnologie di simulazione rappresentano uno strumento sempre più utilizzato per ricreare ambienti di guida realistici e controllati, riducendo i rischi e i costi associati ai test su strada e permettendo di esplorare situazioni difficilmente replicabili nella realtà. Simulatori open-source come CARLA [3] e BeamNG.tech [4] consentono di modellare scenari di traffico complessi, includendo diversi tipi di strade, condizioni meteorologiche, livelli di traffico e comportamenti dei veicoli, offrendo così un contesto applicativo ideale per la validazione di sistemi ADAS.

1.2 Motivazioni e Obiettivi

La validazione dei sistemi di guida autonoma e dei Sistemi Avanzati di Assistenza alla Guida (ADAS) rappresenta una sfida complessa a causa dei costi elevati, dei tempi lunghi e della difficoltà di riprodurre scenari critici nel mondo reale. Le strategie tradizionali, come l'approccio *retest-all*, risultano spesso impraticabili poiché richiedono l'esecuzione di tutte le suite di test su ogni nuova versione del sistema, con un notevole dispendio di risorse [5]. Inoltre, gli ADAS sono sistemi software complessi ed in continua evoluzione, per cui è necessario un processo di test continuo, che amplifica ulteriormente i costi [1].

Inoltre, i metodi tradizionali tendono a considerare un singolo obiettivo (ad esempio la copertura degli scenari critici), mentre nella pratica reale il processo di testing deve bilanciare molteplici criteri tra loro conflittuali: massimizzare la copertura degli scenari critici, ridurre il tempo di esecuzione e scartare test troppo simili fra loro per evitare ridondanze. In questo contesto, approcci di ottimizzazione multi-obiettivo basati su algoritmi greedy o evolutivi risultano particolarmente promettenti, poiché consentono di selezionare sotto-suite efficienti mantenendo il valore informativo dei test e riducendo le risorse necessarie.

L'obiettivo generale del progetto è affrontare le limitazioni delle suite di test tradizionali per sistemi ADAS tramite l'applicazione di una strategia di *test case selection*. Tale strategia consiste nella selezione automatica di un sottoinsieme rappresentativo di casi di test a partire da una suite più ampia, con l'obiettivo di ridurre i costi computazionali del processo di validazione mantenendo un'elevata capacità di individuare scenari critici e comportamenti anomali del sistema. . Sono stati raggiunti obiettivi

principali quali l'automazione della selezione degli scenari di test attraverso un algoritmo greedy che, analizzando un'ampia suite di scenari di simulazione, seleziona in automatico un sottoinsieme ottimizzato. L'algoritmo opera sulla base di tre metriche chiave:

Copertura dei fallimenti. Priorità agli scenari che generano collisioni o altri malfunzionamenti.

Diversità. Punteggio calcolato sulla base della distanza tra caratteristiche come tipologia di strada, condizioni meteo e layout della città.

Tempo di esecuzione. Riduzione del tempo totale della suite eliminando scenari ridondanti o poco informativi.

Il sistema genera infine un report in formato JSON che consente di confrontare facilmente i risultati della suite eseguita con e senza algoritmo, garantendo una selezione automatica e non manuale, mirata a massimizzare il valore informativo di ogni scenario eseguito.

1.3 Risultati

L'applicazione dell'algoritmo greedy alla selezione degli scenari di test ha portato a miglioramenti significativi rispetto all'esecuzione completa della suite originale. In particolare, i risultati ottenuti evidenziano:

- **Riduzione del tempo totale di esecuzione**, resa possibile dall'eliminazione di scenari ridondanti o poco informativi.
- **Aumento della diversità degli scenari eseguiti**, grazie all'inclusione di condizioni di traffico, meteo e tipologie di strada eterogenee.

Complessivamente, l'algoritmo ha permesso di mantenere o migliorare la capacità di individuare comportamenti anomali del sistema, riducendo al contempo i tempi e i costi computazionali. Questi risultati dimostrano l'efficacia di approcci di selezione intelligente degli scenari nella validazione di sistemi ADAS, ponendo le basi per sviluppi futuri orientati a scenari più complessi e realistici.

1.4 Struttura della Tesi

Il presente elaborato è strutturato in cinque capitoli, ciascuno dei quali affronta un aspetto specifico del lavoro svolto:

- **Capitolo 2 – Background e Stato dell’arte:** Fornisce una panoramica sulle tecnologie e i concetti chiave alla base degli ADAS, sulle metodologie di validazione e sui simulatori open-source, con un focus sui metodi di selezione degli scenari.
- **Capitolo 3 – Metodologia proposta:** Illustra l’architettura e l’implementazione del sistema sviluppato, descrivendo l’algoritmo greedy e le metriche utilizzate.
- **Capitolo 4 – Sperimentazione e analisi dei risultati:** Riporta il setup sperimentale, i dataset e gli scenari utilizzati, e confronta le prestazioni tra esecuzione completa e ottimizzata.
- **Capitolo 5 – Conclusioni e sviluppi futuri:** Riassume i contributi principali, discute i limiti dell’approccio proposto e suggerisce possibili evoluzioni future.

Background e Stato dell'arte

2.1 Automated Driving Systems

Gli *ADS* sono sistemi che consentono a un veicolo di gestire in autonomia alcuni compiti di guida, riducendo o eliminando l'intervento umano. Tra le funzionalità tipiche rientrano il mantenimento automatico della corsia, le manovre di sorpasso assistite e la frenata di emergenza, tutte finalizzate ad aumentare la sicurezza e a ridurre gli incidenti stradali causati dall'errore umano. La validazione degli ADS su strada risulta però estremamente complessa e costosa: riprodurre un numero elevato di scenari di guida richiede risorse economiche e temporali molto elevate, oltre a comportare rischi per la sicurezza degli utenti coinvolti [1, 6].

Per superare tali limiti si ricorre sempre più spesso alla **co-simulazione**, che consente di ricreare scenari realistici attraverso l'utilizzo di simulatori avanzati, come ad esempio *CARLA*, in grado di modellare condizioni di traffico, ambienti urbani e situazioni critiche difficilmente replicabili nel mondo reale.

2.1.1 Simulazione per la Validazione degli ADS

Per affrontare le difficoltà e i rischi dei test su strada, la comunità scientifica e industriale ricorre sempre più alla simulazione, che consente di ricreare ambienti realistici in modo sicuro e controllato. Tra gli strumenti più utilizzati vi è CARLA (Car Learning to Act)¹, un simulatore open-source progettato specificamente per la ricerca e lo sviluppo di sistemi di guida autonoma.

CARLA permette di modellare scenari complessi includendo diversi tipi di strade, condizioni meteorologiche variabili, traffico dinamico e interazioni con altri utenti della strada. Questo lo rende ideale per validare gli ADS, in quanto consente di testare il comportamento del veicolo in una vasta gamma di situazioni, comprese quelle critiche e rare che sarebbero difficilmente replicabili nel mondo reale.

Tuttavia, anche l'uso della simulazione comporta costi significativi: l'esecuzione di una singola suite di scenari può richiedere tempi di calcolo elevati e un notevole consumo di risorse computazionali, specialmente quando il numero di test è elevato e le condizioni ambientali sono variabili [1, 2, 6].

Diventa quindi fondamentale adottare tecniche di selezione e prioritizzazione degli scenari, che permettano di ridurre il numero di test mantenendo al tempo stesso un'elevata capacità di individuare malfunzionamenti e situazioni critiche.

2.1.2 Test Case Selection tramite l'Approccio Greedy

Nel contesto dello sviluppo software, il *regression testing* ha l'obiettivo di verificare che le funzionalità già validate continuino a comportarsi correttamente dopo modifiche o aggiornamenti del sistema. In linea teorica, tale attività richiederebbe la riesecuzione dell'intera suite di test a ogni nuova versione del software; tuttavia, nei sistemi complessi questo approccio risulta spesso impraticabile a causa dei costi computazionali e dei tempi di esecuzione elevati.

Per rendere il processo di regression testing sostenibile, una delle strategie più diffuse è la *test case selection*, che consiste nella selezione automatica di un sottoinsieme di casi di test a partire da una suite completa, con l'obiettivo di ridurre il

¹<https://carla.org/>

costo del processo di validazione mantenendo al contempo un'adeguata capacità di individuare regressioni e malfunzionamenti.

Nel caso dei sistemi di guida autonoma (ADS), la selezione dei casi di test può essere vista come un problema di **ottimizzazione multi-obiettivo**, in cui è necessario bilanciare criteri diversi e spesso in conflitto, quali la copertura dei malfunzionamenti, la diversità degli scenari simulati e l'efficienza temporale del processo di testing [7].

Tra i vari approcci disponibili, gli algoritmi greedy offrono una soluzione euristica rapida e semplice [5]. Essi costruiscono la soluzione passo dopo passo, scegliendo a ogni iterazione l'opzione localmente migliore. Pur non garantendo l'ottimalità globale, risultano particolarmente efficaci nel produrre soluzioni approssimate in tempi contenuti.

In questo lavoro si adotta una variante chiamata *Additional Greedy*, proposta da Yoo e Harman [5], che seleziona progressivamente gli scenari in base a una funzione di utilità che combina copertura dei fallimenti, diversità ed efficienza temporale. Questo approccio permette di ridurre il numero complessivo di test mantenendo alta la capacità di individuare scenari critici.

2.2 Stato dell'arte

Lo stato dell'arte sulla selezione dei casi di test negli ADS evidenzia come negli ultimi anni la ricerca si sia concentrata soprattutto su metodi complessi, basati sull'ottimizzazione multi-obiettivo e apprendimento automatico [1, 2, 5, 6]. Questi approcci hanno portato a risultati interessanti, in particolare nella riduzione dei costi di validazione e nell'aumento dell'efficacia, ma presentano anche limiti importanti legati alla complessità e alla necessità di grandi quantità di dati.

Il lavoro presentato in questa tesi si colloca in continuità con queste ricerche ma si differenzia per la scelta dell'approccio. Invece di puntare su modelli molto sofisticati, è stato adottato un algoritmo *Additional Greedy*. La forza di questa scelta sta nella semplicità: l'algoritmo è rapido da eseguire, facile da interpretare e al tempo stesso permette di bilanciare tre criteri fondamentali – copertura dei fallimenti, diversità ed efficienza temporale.

In questo contesto, il contributo rappresenta una soluzione complementare agli approcci esistenti per la validazione degli ADS, dimostrando che, accanto a metodi complessi, è possibile adottare strategie più leggere e immediate, comunque in grado di produrre risultati utili.

CAPITOLO 3

Metodologia

Questo capitolo descrive la metodologia proposta per la selezione degli scenari di test utilizzati nella validazione dei Sistemi di Guida Autonoma (ADS).

L'obiettivo principale è **massimizzare la copertura del dominio operativo**, garantendo che il sistema venga testato in una vasta gamma di condizioni e scenari critici, **minimizzando al contempo i tempi di esecuzione complessivi** e quindi il costo computazionale del processo di validazione.

Per raggiungere tale equilibrio è stato adottato un approccio *Additional Greedy*, una variante del classico algoritmo greedy [8], che costruisce progressivamente la soluzione selezionando, a ogni iterazione, lo scenario con il miglior contributo marginale rispetto a una funzione di utilità aggregata. Questo approccio, introdotto da Yoo e Harman [5] nel contesto della *test case selection*, è stato scelto per la sua semplicità, trasparenza e rapidità di calcolo, caratteristiche particolarmente adatte alla validazione di sistemi complessi come gli ADS. La metodologia proposta si articola in tre elementi fondamentali:

- **definizione delle metriche di valutazione**, che quantificano copertura, fault history e costo computazionale;

- **formulazione di una funzione di utilità multi-obiettivo**, che integra le metriche in un singolo punteggio;
- **processo iterativo di selezione greedy**, che guida la costruzione incrementale della suite di test ottimizzata.

Il capitolo descrive dapprima l'ambiente di simulazione e le metriche adottate, per poi illustrare la formulazione del problema, la funzione di utilità e l'implementazione pratica dell'algoritmo.

3.1 Ambiente di Simulazione e Dataset

La metodologia è stata progettata e validata in un ambiente di simulazione basato su **CARLA (Car Learning to Act)** e **ScenarioRunner**, strumenti open-source ampiamente impiegati nella ricerca sui sistemi di guida autonoma [3].

Il dataset utilizzato è stato generato tramite simulazioni automatiche di scenari di guida, ottenute variando parametri ambientali, veicolari e di traffico, al fine di esplorare una porzione ampia e diversificata del dominio operativo degli ADS. In particolare, ciascuno scenario è definito dalla combinazione di:

- mappa e layout stradale;
- condizioni meteorologiche;
- configurazione del traffico e degli attori presenti;
- parametri dinamici del veicolo EGO.

Per ogni scenario eseguito, CARLA e ScenarioRunner producono dati grezzi relativi a eventi di collisione, durata della simulazione, parametri cinematici e caratteristiche contestuali che dati costituiscono l'input del processo di ottimizzazione.

3.2 Metriche di Valutazione

A partire dai dati di simulazione, sono state definite tre metriche che rappresentano i criteri di valutazione per la selezione automatica degli scenari.

3.2.1 Copertura degli Scenari Critici / Diversità (f_1)

La metrica di diversità misura quanto uno scenario differisce dagli altri in termini di condizioni ambientali, veicolari e contestuali. Essa è calcolata mediante la **distanza di Manhattan (norma L1)** applicata ai vettori di feature degli scenari. Formalmente:

$$f_1(i) = \frac{1}{N-1} \sum_{j \neq i}^N D_{\text{Manhattan}}(\text{Scenario}_i, \text{Scenario}_j)$$

Un valore elevato di f_1 indica che lo scenario contribuisce in modo significativo alla copertura del dominio operativo.

3.2.2 Collision Coverage (f_2)

La metrica f_2 indica la presenza di una collisione del veicolo EGO durante l'esecuzione di uno scenario ed è definita in modo binario come:

$$f_2(i) = \begin{cases} 1, & \text{se nello scenario } i \text{ è stata rilevata una collisione;} \\ 0, & \text{altrimenti.} \end{cases}$$

Essa viene utilizzata come proxy semplificato della criticità dello scenario e come indicatore di fault history.

3.2.3 Tempo di Esecuzione (f_3)

Il tempo di esecuzione rappresenta il costo computazionale di ciascun scenario. Nel contesto sperimentale considerato, la durata della simulazione viene normalizzata rispetto al tempo massimo osservato nell'intera suite, ottenendo $f_3 \in [0, 1]$. Questo termine agisce come fattore penalizzante implicito nella funzione di utilità.

3.3 Pre-processing dei Dati

Prima del calcolo delle metriche di selezione, i dati di simulazione vengono sottoposti a una fase di pre-processing finalizzata a costruire una rappresentazione vettoriale omogenea degli scenari.

Le variabili numeriche comprendono il tempo di esecuzione della simulazione, , il valore binario di collision coverage e la metrica di diversità . Tali variabili vengono normalizzate nell'intervallo $[0, 1]$ mediante Min-Max Normalization:

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$$

Le variabili categoriche descrivono invece il contesto dello scenario e includono la mappa e il layout stradale, le condizioni meteorologiche, la configurazione del traffico, la tipologia di attori presenti e il tipo di scenario simulato. Queste variabili vengono trasformate tramite One-Hot Encoding, evitando l'introduzione di relazioni ordinali artificiali [?].

Il risultato di questa fase è una matrice delle feature X , in cui ogni riga rappresenta uno scenario e ogni colonna una feature numerica o binaria.

3.4 Formulazione del Problema e Funzione di Utilità

La selezione automatica degli scenari è formalizzata come un problema di ottimizzazione in cui si vogliono massimizzare $\{f_1(x), f_2(x)\}$ e minimizzare $\{f_3(x)\}$; i criteri vengono quindi aggregati in una funzione di utilità a obiettivo singolo.

$$U_i = \frac{\alpha_1 \cdot f_1(i) + \alpha_2 \cdot f_2(i)}{f_3(i)}$$

I coefficienti α_1 e α_2 regolano l'importanza relativa di diversità e fault history, mentre il tempo di esecuzione agisce come termine penalizzante.

3.4.1 Configurazione dei Pesi

Negli esperimenti di base sono stati adottati $\alpha_1 = 0.5$ e $\alpha_2 = 0.5$.

Questa configurazione bilanciata consente di ottenere una suite compatta ma rappresentativa, mantenendo un compromesso tra copertura, capacità diagnostica ed efficienza computazionale.

3.5 Processo di Selezione Additional Greedy

L'algoritmo *Additional Greedy* costruisce iterativamente la suite di test selezionando, a ogni iterazione, lo scenario con il valore di utilità marginale più elevato rispetto alla suite corrente.

Questo approccio consente di ottenere una soluzione computazionalmente efficiente e ben bilanciata anche in presenza di grandi quantità di scenari, mantenendo coerenza tra formulazione teorica e implementazione pratica.

Analisi Sperimentale e Risultati

Il presente capitolo è dedicato alla presentazione e alla discussione dei risultati sperimentali ottenuti applicando l'algoritmo di selezione **Additional Greedy** basato su una funzione di utilità aggregata a obiettivo singolo U_i .

L'obiettivo primario è la convalida empirica della metodologia proposta, dimostrando la sua capacità di generare una suite di test ottimizzata che bilanci efficacemente la diversità degli scenari (f_1), la copertura delle collisioni (f_2) e il costo computazionale associato al tempo di esecuzione (f_3).

L'analisi è strutturata per valutare la bontà dell'approccio attraverso un confronto tra le metriche della **Baseline** (suite completa) e quelle della **Suite Ottimizzata** ottenuta mediante simulazione in ambiente CARLA.

4.1 Configurazione di Riferimento

4.1.1 Dati di Input (Suite Completa Baseline)

L'esperimento è stato condotto su un dataset iniziale di **493** scenari analizzati. Questa **Suite Completa** rappresenta il riferimento baseline in termini di costo computazionale, rispetto al quale valutare l'efficacia del processo di ottimizzazione.

Tabella 4.1: Dati di Riferimento della Suite Completa (Baseline)

Metrica	Valore
Numero totale di scenari	493
Tempo totale di esecuzione	29 580 s ($\approx$ 8.22 ore)
Numero di collisioni rilevate (Collision Coverage)	311

4.1.2 Risultati di Ottimizzazione con Taratura di Riferimento

Tabella 4.2: Confronto tra Suite Completa e Suite Ottimizzata

Metrica	Suite Completa	Suite Ottimizzata	Variazione
Scenari selezionati (N)	493	396	−19.7%
Tempo totale di esecuzione	8.22 h	5.01 h	−39.1%
Copertura delle collisioni (f_2)	311/311 (100%)	311/311 (100%)	Copertura mantenuta

I risultati mostrano una riduzione significativa del costo computazionale complessivo. Il tempo totale di esecuzione risulta ridotto di circa il 39.1%, a fronte dell'eliminazione di quasi il 20% degli scenari, pur mantenendo la copertura completa delle collisioni osservate nella suite di partenza.

4.2 Analisi dei Trade-off e Bontà dell'Approccio

La bontà scientifica dell'approccio risiede nel modo in cui l'algoritmo *Additional Greedy* gestisce il compromesso tra i criteri integrati nella funzione di utilità, in particolare tra la copertura degli scenari critici (f_1), la copertura delle collisioni (f_2) e il costo computazionale associato al tempo di esecuzione (f_3).

La metrica f_1 misura la diversità degli scenari selezionati, favorendo la scelta di test che esplorano porzioni tra loro distanti dello spazio dei parametri e riducendo la ridondanza informativa all'interno della suite finale.

Tabella 4.3: Confronto sulla Metrica di Copertura degli Scenari Critici (f_1)

Metrica di Copertura	Suite Completa	Suite Ottimizzata	Variazione
Somma della Diversità Totale	3,276.237	3,103.111	−5.3%
Diversità Media per Scenario (f_1)	6.645	7.836	+17.9%

Sebbene la somma totale della diversità si sia ridotta a seguito della rimozione del 19.7% degli scenari, la diversità media per scenario è aumentata del 17.9%.

Questo incremento indica che l'algoritmo ha eliminato principalmente scenari ridondanti (basso contributo a f_1), concentrando la selezione su casi più distintivi e informativi, migliorando l'efficacia esplorativa della suite ottimizzata.

La metrica di copertura delle collisioni (f_2) rappresenta un indicatore fondamentale della capacità diagnostica della suite di test selezionata. I risultati sperimentali mostrano che la suite ottimizzata mantiene il **100% della copertura delle collisioni** osservate nella suite completa di partenza, nonostante una riduzione significativa del numero di scenari eseguiti e del tempo totale di simulazione.

Questo risultato evidenzia che l'algoritmo *Additional Greedy* è stato in grado di preservare tutti gli scenari associati a comportamenti critici del sistema, eliminando prevalentemente test ridondanti o poco informativi.

La conservazione integrale della copertura delle collisioni conferma che la riduzione della suite non ha compromesso la capacità di individuare situazioni potenzialmente pericolose, rafforzando la validità dell'approccio proposto nel contesto della validazione dei sistemi di guida autonoma.

La riduzione significativa del tempo totale di esecuzione (39.1%) non è stata casuale, ma rappresenta il risultato diretto dell'inclusione del termine f_3 (tempo di esecuzione normalizzato) al denominatore della funzione di utilità U_i .

Questo meccanismo ha guidato l'algoritmo *Additional Greedy* a privilegiare scenari con un contributo informativo elevato a fronte di un costo computazionale contenuto, penalizzando implicitamente scenari caratterizzati da tempi di esecuzione elevati.

Di conseguenza, il processo di selezione ha favorito una riduzione complessiva del costo computazionale, mantenendo un compromesso efficace tra efficienza del processo di validazione e qualità diagnostica della suite di test.

4.3 Analisi di Sensibilità e Flessibilità delle Variabili α

Al fine di valutare l'impatto dei coefficienti di ponderazione α_1 e α_2 sul comportamento dell'algoritmo *Additional Greedy*, è stata condotta un'analisi di sensibilità basata su esecuzioni multiple dell'algoritmo, ciascuna caratterizzata da una diversa configurazione dei pesi all'interno della funzione di utilità.

In particolare, l'intero processo di selezione greedy è stato rieseguito tre volte sul medesimo dataset di input, variando sistematicamente i valori di α_1 e α_2 , mentre il termine relativo al tempo di esecuzione (f_3) è stato mantenuto invariato in tutte le configurazioni, continuando ad agire come fattore penalizzante implicito al denominatore della funzione di utilità.

Tabella 4.4: Analisi di Sensibilità dei Coefficienti α

Configurazione α_1 / α_2	Criterio prevalente	Scenari (N)	Tempo Totale (h)	Diversità Totale ($\sum f_1$)
0.01 / 0.98	Copertura delle collisioni (f_2)	396	5.01	3103.111
0.30 / 0.30	Configurazione di riferimento	396	5.01	3103.111
0.98 / 0.01	Copertura degli scenari critici (f_1)	403	5.14	3169.191

4.4 Conclusioni del Capitolo

Gli esperimenti hanno convalidato in modo robusto la metodologia **Additional Greedy** basata sulla funzione di utilità U_i . L'approccio ha garantito la piena copertura delle collisioni osservate nella suite di partenza e ha prodotto una riduzione significativa del costo computazionale, mantenendo al contempo un'elevata diversità degli scenari selezionati e confermando la validità scientifica e applicativa dell'approccio proposto per la selezione automatica di scenari di test nei sistemi ADS.

CAPITOLO 5

Limiti dello Studio

Nonostante i risultati sperimentali ottenuti mostrino chiaramente l'efficacia dell'approccio proposto, è importante evidenziare alcuni limiti del lavoro svolto per inquadrare correttamente il contesto in cui la metodologia può essere applicata.

Il primo limite riguarda l'ambiente di validazione. L'analisi è stata condotta su un dataset di 493 scenari generati interamente in simulazione, utilizzando CARLA e ScenarioRunner. Sebbene questi strumenti siano ampiamente utilizzati nella ricerca sui sistemi di guida autonoma e permettano di riprodurre scenari complessi in modo controllato e sicuro, i risultati dipendono comunque dalla fedeltà del simulatore e dalla varietà degli scenari considerati. Testare l'approccio su un numero maggiore di scenari, su mappe diverse o con configurazioni di traffico più eterogenee consentirebbe di valutare meglio la generalità e la scalabilità del metodo.

Un secondo limite è legato alla modellazione del costo computazionale. In questo lavoro, il tempo di esecuzione degli scenari è stato considerato in forma normalizzata ed è stato utilizzato come fattore penalizzante all'interno della funzione di utilità. Questa scelta rende il metodo semplice ed efficace, ma non tiene conto di aspetti più realistici, come le differenze di carico hardware, l'esecuzione parallela delle simulazioni o specifici vincoli temporali tipici di contesti industriali reali.

Infine, l'algoritmo *Additional Greedy* produce una singola suite di test ottimiz-

zata, costruita in modo incrementale scegliendo di volta in volta lo scenario più conveniente. Questo approccio è veloce e facilmente interpretabile, ma non consente di esplorare soluzioni alternative con diversi compromessi tra copertura, diversità e costo computazionale. In particolare, non viene analizzato l'intero insieme delle soluzioni possibili, come con metodi di ottimizzazione multi-obiettivo espliciti.

Nel complesso, questi limiti non riducono la validità dei risultati ottenuti, ma aiutano a definire chiaramente il campo di applicazione del lavoro e rappresentano una base concreta per eventuali estensioni e miglioramenti futuri.

Conclusioni e Sviluppi Futuri

In questa tesi è stato affrontato il problema della selezione automatica degli scenari di test per la validazione dei sistemi di guida autonoma, con l'obiettivo di ridurre i costi computazionali del processo di testing senza compromettere la capacità di individuare comportamenti critici del sistema.

La metodologia proposta si basa sull'algoritmo *Additional Greedy*, combinato con una funzione di utilità aggregata che tiene conto di tre aspetti fondamentali: la copertura degli scenari critici, la presenza di collisioni e il tempo di esecuzione degli scenari. L'idea centrale è stata quella di integrare il costo computazionale direttamente nel processo decisionale, in modo da favorire la selezione di scenari informativi ma meno onerosi dal punto di vista temporale.

I risultati sperimentali ottenuti in ambiente CARLA mostrano che questo approccio consente di ridurre in modo significativo sia il numero di scenari da eseguire sia il tempo totale di simulazione. Allo stesso tempo, la copertura delle collisioni osservate nella suite originale viene mantenuta e la diversità media degli scenari selezionati aumenta. I risultati indicano che una strategia di selezione guidata da metriche semplici e ben definite, se opportunamente calibrata, può rappresentare una soluzione efficace e pratica per il problema della Test Case Selection nei sistemi ADS.

A partire da quanto emerso, è possibile individuare diverse direzioni di sviluppo futuro. Una prima estensione naturale riguarda l'adozione di approcci di ottimizzazione multi-obiettivo espliciti, che permettano di analizzare più soluzioni alternative e di studiare diversi compromessi per adattare la selezione degli scenari a differenti fasi del ciclo di sviluppo.

Un ulteriore possibile sviluppo consiste nell'arricchire le metriche utilizzate nel processo di selezione. In particolare, l'introduzione di misure di rischio o di severità delle collisioni potrebbe consentire una valutazione più fine della criticità degli scenari, orientando la selezione verso i casi potenzialmente più rilevanti dal punto di vista della sicurezza. Allo stesso modo, considerare relazioni o correlazioni tra scenari potrebbe contribuire a ridurre ulteriormente la ridondanza all'interno della suite ottimizzata.

Infine, l'applicazione dell'approccio a contesti più realistici rappresenta un passaggio importante per valutarne l'effettiva trasferibilità. L'integrazione in pipeline di validazione industriali, l'utilizzo in ambienti hardware-in-the-loop o l'estensione a domini affini potrebbero fornire ulteriori conferme della validità del metodo. In questo senso, la semplicità, la modularità e la facilità di interpretazione dell'approccio proposto costituiscono un punto di forza per una possibile adozione pratica.

Nel complesso, il lavoro svolto dimostra che l'approccio *Additional Greedy*, basato su una strategia di selezione leggera e trasparente e su metriche interpretabili, può contribuire a rendere più efficiente il processo di validazione dei sistemi di guida autonoma, offrendo una base solida per sviluppi futuri e applicazioni reali.

Bibliografia

- [1] C. Lu, H. Zhang, T. Yue, and S. Ali, "Search-based selection and prioritization of test scenarios for autonomous driving systems," in *Search-Based Software Engineering*, ser. LNCS, vol. 12914. Springer, 2021, pp. 41–55. (Citato alle pagine 1, 2, 5, 6 e 7)
- [2] C. Birchler, N. Ganz, S. Khatiri, A. Gambi, and S. Panichella, "Cost-effective simulation-based test selection in self-driving cars software," *Science of Computer Programming*, vol. 226, p. 102926, 2023. (Citato alle pagine 1, 6 e 7)
- [3] A. Dosovitskiy *et al.*, "Carla: An open urban driving simulator," *Proceedings of the Conference on Robot Learning (CoRL)*, 2017. (Citato alle pagine 2 e 10)
- [4] "Beamng.tech," <https://beamng.tech>, 2021. (Citato a pagina 2)
- [5] S. Yoo and M. Harman, "Pareto efficient multi-objective test case selection," in *Proceedings of the International Symposium on Software Testing and Analysis (ISSTA)*. ACM, 2007, pp. 140–150. (Citato alle pagine 2, 7 e 9)
- [6] C. Birchler, S. Khatiri, B. Bosshard, A. Gambi, and S. Panichella, "Machine learning-based test selection for simulation-based testing of self-driving cars software," *Empirical Software Engineering*, vol. 28, no. 71, 2023. (Citato alle pagine 5, 6 e 7)

- [7] A. Trovato, M. De Stefano, F. Pecorelli, D. Di Nucci, and A. De Lucia, "Reformulating regression test suite optimization using quantum annealing: an empirical study," *Empirical Software Engineering*, 2024. (Citato a pagina 7)
- [8] T. H. Cormen, C. E. Leiserson, R. L. Rivest, and C. Stein, *Introduction to Algorithms*, 3rd ed. MIT Press, 2009. (Citato a pagina 9)

Ringraziamenti

Ringraziamenti qui...