



UNIVERSITÀ DEGLI STUDI DI SALERNO

Dipartimento di Informatica

Corso di Laurea Triennale in Informatica

TESI DI LAUREA

Riconoscimento delle emozioni in tempo reale basato su segnali audio in ambienti virtuali

RELATORE

Prof. Fabio Palomba

Dott.ssa Viviana Pentangelo

Università degli Studi di Salerno

CANDIDATO

Michele Quaglia

Matricola: 0512118399

Anno Accademico 2024-2025

Questa tesi è stata realizzata nel

sesa^{lab}
SOFTWARE ENGINEERING
SALERNO

Ai miei genitori, mamma Rachele e papà Domenico

Abstract

Negli ultimi anni, l'integrazione tra riconoscimento emotivo e ambienti virtuali ha suscitato grande interesse in ambiti quali il gaming interattivo, la telemedicina e la formazione a distanza. Nonostante il crescente interesse, le soluzioni specifiche per il riconoscimento emotivo in scenari immersivi risultano ancora limitate e poco consolidate, rendendo necessarie ulteriori ricerche in questo campo. L'obiettivo di questo studio è sviluppare un sistema capace di identificare in tempo reale lo stato emotivo dell'utente a partire da segnali audio, per renderlo parte attiva di uno scenario virtuale dinamico e reattivo. L'approccio proposto si basa sull'analisi di caratteristiche estratte dalla voce e sull'impiego di tecniche di machine learning. In particolare vengono applicati approcci basati su grafi di visibilità e grafi statistici, combinati con algoritmi di classificazione come Random Forest. Il sistema consente di rilevare lo stato emotivo dell'utente e di proiettarlo in uno scenario virtuale

Indice

Elenco delle Figure	iii
Elenco delle Tabelle	iv
1 Introduzione	1
1.1 Contesto applicativo	1
1.2 Obiettivo di ricerca	1
1.3 Risultati ottenuti	2
1.4 Struttura della tesi	2
2 Background	4
2.1 Emotion Recognition	4
2.1.1 Facial Expression Recognition	5
2.1.2 Skeleton-based Emotion Recognition	5
2.1.3 Speech Emotion Recognition	6
2.2 Metaverso	7
2.2.1 Realtà Virtuale	7
2.2.2 Realtà Aumentata	7
2.2.3 Emotion Recognition nel Metaverso	8
3 Obiettivi, Metodologia e Implementazione	9

3.1	Obiettivi	9
3.2	Metodologia	10
3.2.1	Strumenti utilizzati	10
3.2.2	Dataset	11
3.2.3	Approccio Strutturale	12
3.2.4	Approccio Statistico	13
3.2.5	Estrazione dei valori	14
3.2.6	Creazione e addestramento del modello	15
3.3	Sviluppo dell'ambiente virtuale	16
3.3.1	Architettura e funzionamento dell'applicazione	16
3.3.2	Interfaccia utente e visualizzazione delle predizioni	17
4	Analisi dei risultati	18
4.1	Classification Report	18
4.2	Matrice di confusione	19
4.3	Confronto con un modello di rete neurale convoluzionale	20
4.3.1	Costruzione del nuovo modello	20
4.3.2	Classification Report	21
4.3.3	Matrice di confusione	21
4.3.4	Conclusioni del confronto	22
4.4	Confronto con i risultati ottenuti in letteratura	23
5	Conclusioni	24
5.1	Limitazioni e sviluppi futuri	25
	Bibliografia	26

Elenco delle figure

2.1	Estrazione landmark, Facial Expression Recognition [1]	5
2.2	Costruzione dello skeleton [2]	6
2.3	Classificazione segnali audio [3]	6
2.4	Riunione lavorativa nel Metaverso [4]	7
3.1	Esempio di grafo di visibilità e costruzione della matrice di adiacenza [5]	13
3.2	Importanza delle feature	16
3.3	Visualizzazione dell'ambiente	17
3.4	Pannello dell'interfaccia utente prima della fase di registrazione audio	17

Elenco delle tabelle

4.1	Classification Report del modello Random Forest	19
4.2	Matrice di confusione	20
4.3	Classification Report del modello CNN	22
4.4	Matrice di confusione del modello CNN	23

CAPITOLO 1

Introduzione

1.1 Contesto applicativo

Negli ultimi anni il progresso tecnologico ha favorito la diffusione di tecnologie legate agli ambienti immersivi, con particolare riferimento al concetto di metaverso. Questo ha suscitato interesse nello sviluppo di strumenti che possano riconoscere e interpretare le emozioni degli utenti, con l'obiettivo di creare esperienze più coinvolgenti e personalizzate, che si adattino alle emozioni percepite in modo naturale e intuitivo. Tra i diversi metodi utilizzati per il riconoscimento delle emozioni, i segnali vocali rappresentano quello più espressivo e più facilmente accessibile, soprattutto nel contesto degli ambienti immersivi, questo rende la voce il mezzo comunicativo ideale per il riconoscimento delle emozioni in tempo reale. Tuttavia, la complessità del linguaggio vocale rende ancora oggi questo compito una sfida aperta.

1.2 Obiettivo di ricerca

Il presente lavoro si basa sulla ricerca di Pentari et al. [5], dalla quale è stato ripreso l'approccio al riconoscimento delle emozioni vocali basato su rappresentazioni grafiche dei segnali audio. Il lavoro svolto nasce dalla volontà di implementare un

sistema di riconoscimento delle emozioni in tempo reale all'interno di un ambiente immersivo, con lo scopo di adattare l'esperienza dell'utente in base alle emozioni rilevate. L'obiettivo principale è stato quello di costruire un pipeline completa, capace di elaborare segnali audio vocali, estrarre caratteristiche rilevanti, classificare l'emozione corrispondente, e infine integrare tale classificazione in un'interfaccia immersiva sviluppata su visore Meta Quest. In questo progetto, abbiamo esplorato alcuni approcci basati su tecniche di machine learning supervisionato, confrontando i risultati di un modello di Random Forest e una rete neurale convoluzionale. L'obiettivo è dimostrare che è possibile sviluppare una soluzione praticabile per il riconoscimento vocale delle emozioni, che funzioni in tempo reale in ambienti virtuali.

1.3 Risultati ottenuti

I risultati ottenuti hanno evidenziato performance migliori nel modello Random Forest, con un Unweighted Average Recall (UAR) del 58% contro il 17% della rete neurale. Nonostante i risultati non abbiano raggiunto lo stesso livello della ricerca di Pentari et al. [5], il sistema ha mostrato prestazioni complessivamente accettabili nelle attività di classificazione, considerando le differenze nei dataset utilizzati e nell'ambiente di sviluppo. Inoltre è stato correttamente integrato all'interno dell'ambiente virtuale sviluppato ed è in grado di ricevere in tempo reale frammenti vocali registrati dall'utente e restituire l'emozione stimata attraverso un'interfaccia grafica intuitiva.

1.4 Struttura della tesi

La tesi è strutturata come segue:

Capitolo 2. Presenta il contesto teorico e le tecniche principali utilizzate per riconoscere le emozioni dai segnali audio..

Capitolo 3. Illustra nel dettaglio la metodologia impiegata, dalla preparazione dei dati alla creazione del modello di Random Forest, passando dallo sviluppo dell'ambiente virtuale e all'integrazione del modello stesso.

Capitolo 4. Analizza i risultati sperimentali, confrontandoli con quelli ottenuti da un modello di rete neurale convoluzionale e discutendo le metriche di valutazione.

Capitolo 5. Conclude il lavoro evidenziando le limitazioni e proponendo possibili direzioni per ricerche future.

CAPITOLO 2

Background

Le emozioni rappresentano lo stato mentale di un individuo e influenzano il suo comportamento e la sua percezione del mondo esterno. In campo tecnologico, riuscire a riconoscere le emozioni degli utenti può portare a vari vantaggi da parte di chi fornisce i servizi, ad esempio la personalizzazione dell'esperienza per l'utente, inoltre queste informazioni possono essere sfruttate anche nell'ambito della Realtà Virtuale. Nel corso della storia, filosofi, psicologi e neuroscienziati hanno cercato di classificare le emozioni umane. Le ricerche classiche hanno identificato un insieme di emozioni universali, fra cui gioia, tristezza, rabbia, paura, sorpresa e disgusto, riconosciute e manifestate in maniera coerente in culture diverse. [6]

2.1 Emotion Recognition

L'Emotion Recognition [7] è un campo di ricerca che ha come obiettivo l'identificazione delle emozioni espresse da un individuo, partendo da diversi input come segnali vocali, espressioni facciali, movimenti del corpo, o segnali fisiologici (ad esempio, battito cardiaco). Per classificare questi segnali si utilizzano tecniche di machine learning o deep learning che consentono di lavorare con grandi quantità di dati, acquisiti tramite sensori (come videocamere o microfoni) e che vengono

successivamente pre-processati, analizzati e classificati. In questo ambito sono molto utilizzate rete neurali convoluzionali (CNN) per via della loro capacità di apprendere direttamente dai dati grezzi, quindi senza il bisogno di estrarre manualmente le caratteristiche. L'Emotion Recognition può essere suddivisa in sotto-campi, in base alle diverse tecniche utilizzate per estrarre ed elaborare le informazioni.

2.1.1 Facial Expression Recognition

La Facial Expression Recognition (FER) [8] si concentra sull'analisi dei dati provenienti da espressioni facciali, con l'obiettivo di identificare l'emozione espressa dall'individuo. Il processo comincia con la rilevazione del volto all'interno di un immagine (face detection)(Fig. 2.1), seguita dall'identificazione di punti chiave, detti landmark, ad esempio gli angoli della bocca e le estremità delle sopracciglia. Una volta estratti i dati, questi vengono codificati, elaborati e successivamente classificati.




Figura 2.1: Estrazione landmark, Facial Expression Recognition [1]

2.1.2 Skeleton-based Emotion Recognition

La Skeleton-based Emotion Recognition [9] si pone l'obiettivo di identificare l'emozione espressa da un individuo utilizzando dati estratti dall'analisi dei movimenti e dalla postura del corpo umano, che vengono rappresentati da uno scheletro digitale detto skeleton(Fig. 2.2). Lo skeleton è costituito da un'insieme di punti articolari collegati da segmenti. I punti includono testa, collo, spalle, gomiti, polsi, caviglie ecc. Il processo comincia con l'identificazione delle articolazioni e la costruzione dello skeleton, dopodichè vengono calcolate le caratteristiche posturali e dinamiche, come

gli angoli tra le articolazioni e la distanza tra i punti. Infine i dati vengono codificati ed elaborati e successivamente classificati.




Figura 2.2: Costruzione dello skeleton [2]

2.1.3 Speech Emotion Recognition

La Speech Emotion Recognition [?] si focalizza sul parlato di un individuo, analizzandone le caratteristiche dei segnali audio. Esse infatti rappresentano un grande strumento per identificare l'emozione espressa da un individuo, considerando il fatto che variano naturalmente a seconda dell'emozione provata. Il processo comincia con la registrazione del segnale vocale tramite un microfono e la successiva estrazione dei valori, come intensità, intonazione, velocità del parlato ecc. In seguito i dati vengono pre-processati, rimuovendo eventuale rumore che potrebbe comprometterne l'efficienza, e altri tipi di operazioni come normalizzazione e segmentazione. Conclusa tutta la fase di pre-processing, i dati vengono elaborati e successivamente classificati (Fig. 2.3).



Figura 2.3: Classificazione segnali audio [3]

2.2 Metaverso

Il Metaverso [10] è un ambiente virtuale in cui le persone possono interagire tra di loro senza essere fisicamente presenti. Ogni utente nel Metaverso è rappresentato da un avatar personalizzato, visibile agli altri utenti connessi, con i quali è possibile svolgere diversi tipi di attività di tipo sociale, lavorativa (Fig. 2.4), creativa o ludica. Per entrare nel Metaverso è necessario essere muniti di specifici dispositivi hardware come visori, questi sono dotati di tecnologie di Realtà Aumentata e Realtà Virtuale. Tra i dispositivi utilizzabili per accedere al Metaverso vi sono i visori della serie Meta Quest [11], realizzati da Meta.



Figura 2.4: Riunione lavorativa nel Metaverso [4]

2.2.1 Realtà Virtuale

La Realtà Virtuale (VR) [12] è una tecnologia capace di immergere l'utente in un mondo virtuale tridimensionale, in cui ha la possibilità di interagire con oggetti e persone. L'utente risulta totalmente coinvolto nell'ambiente poichè i dispositivi utilizzati sono dotati di sensori di movimento, che permettono di tracciare i movimenti del corpo e delle mani, inoltre alcuni dispositivi possono essere accompagnati anche da controller che migliorano l'esperienza di utilizzo.

2.2.2 Realtà Aumentata

La Realtà Aumentata (AR) [13] è una tecnologia in cui l'utente si ritrova immerso in un'ampliamento del mondo che lo circonda, composto da elementi reali ed ele-

menti virtuali, creando quindi una fusione tra reale e digitale. L'AR viene generata grazie a varie fotocamere presenti sul dispositivo utilizzato e a sensori di profondità, che riescono a percepire il mondo circostante e ad ampliarlo.

2.2.3 Emotion Recognition nel Metaverso

In ambito Metaverso, l'Emotion Recognition consente di aggiungere le emozioni agli avatar, rendendo quindi l'interazione con gli utenti più umana. Attraverso segnali come movimenti del corpo, espressioni facciali oppure la voce, le emozioni provate da un individuo possono essere visualizzate sugli avatar e facilitare quindi la comunicazione virtuale nel Metaverso. Inoltre, l'Emotion Recognition può essere applicata ad agenti intelligenti, in modo da renderli capaci di interpretare lo stato emotivo dell'individuo e personalizzare il tipo di risposta, creando quindi un ambiente più interattivo. [14]

Obiettivi, Metodologia e Implementazione

In questo capitolo verranno descritti gli obiettivi principali del lavoro, l'approccio utilizzato per raggiungerli e l'ambiente virtuale sviluppato per implementare il sistema proposto.

3.1 Obiettivi

Nel Metaverso, come introdotto nella sezione 2.2, gli utenti sono totalmente coinvolti nell'ambiente, nonostante ciò risulta difficile simulare l'interazione umana attraverso un dispositivo. Una delle principali sfide riguarda la difficoltà nel riprodurre una comunicazione emotiva. Le emozioni svolgono un ruolo importante nella comunicazione poichè ci consentono di interpretare le sensazioni dell'interlocutore, esse sono ovviamente assenti nelle macchine e questo ci differenzia principalmente con esse. L'obiettivo principale del lavoro svolto era quello di sviluppare un sistema capace di riconoscere in tempo reale l'emozione provata da un utente in un ambiente virtuale, utilizzando tecnologie di Speech Emotion Recognition. Il lavoro è basato sulla ricerca scientifica "Speech emotion recognition via graph-based representations" [5]

3.2 Metodologia

L'approccio utilizzato si basa sull'analisi dei segnali vocali, su cui è stato eseguito un accurato pre-processing suddiviso in un approccio strutturale e un approccio statistico, grazie ai quali è stata creata una rappresentazione compatta dei dati, utilizzata infine per l'addestramento e la classificazione di un modello di Machine Learning. Il modello è stato integrato in un ambiente virtuale.

3.2.1 Strumenti utilizzati

Per lo sviluppo del progetto di riconoscimento delle emozioni vocali e la sua integrazione in ambiente immersivo sono stati utilizzati diversi strumenti software, suddivisi secondo le principali fasi operative:

- **Python 3.10:** linguaggio principale per la costruzione del modello di classificazione, la gestione dei dataset e l'analisi dei risultati.
- **Librerie Python:**
 - `pandas`, `numpy`: per la manipolazione e l'analisi dei dati.
 - `scikit-learn`: per l'addestramento del modello Random Forest e il calcolo delle metriche di valutazione.
 - `imblearn`: per l'applicazione della tecnica SMOTE al fine di bilanciare il dataset.
 - `tensorflow` e `keras`: per la creazione e il training della rete neurale convoluzionale (CNN 1D).
 - `joblib`: per il salvataggio e il caricamento del modello e dell'encoder delle etichette.
- **Flask:** micro-framework web utilizzato per implementare il server Python che gestisce le richieste di classificazione provenienti dall'ambiente virtuale.
- **Unity (versione 2022 o successiva):** motore grafico utilizzato per la creazione dell'ambiente virtuale interattivo in cui l'utente si muove e visualizza le emozioni rilevate.

- **C#**: linguaggio di scripting utilizzato all'interno di Unity per gestire la logica di registrazione dell'audio, invio delle richieste al server e visualizzazione dei risultati.
- **Meta Quest 3s (visore VR)**: dispositivo utilizzato per testare l'integrazione in ambiente immersivo e per la raccolta vocale in tempo reale.
- **Visual Studio Code / PyCharm**: editor utilizzati per lo sviluppo e il debugging del codice Python.
- **Git**: sistema di controllo versione utilizzato per la gestione del codice sorgente.

L'utilizzo congiunto di questi strumenti ha permesso di sviluppare un sistema completo, che combina tecniche di machine learning con un'interfaccia immersiva, garantendo il riconoscimento in tempo reale delle emozioni vocali.

3.2.2 Dataset

È stato utilizzato il dataset pubblico Emozionalmente¹, un archivio di 6902 segnali audio registrati da 431 attori, in cui compaiono 18 frasi diverse per esprimere 7 diverse emozioni: rabbia, disgusto, paura, gioia, tristezza, sorpresa e neutralità. Ogni registrazione è un file di tipo .wav, con una durata media di 3,81 secondi e una frequenza di campionamento di 16.000 Hz. Il dataset è composto dalle righe che corrispondono ai segnali audio e da 4 colonne in cui sono indicati rispettivamente:

- **filepath**: indica il percorso del segnale audio all'interno del progetto
- **sentence**: frase pronunciata all'interno del segnale
- **speaker id**: codice identificativo dell'attore
- **emotion**: emozione espressa all'interno del segnale

¹<https://zenodo.org/records/12616095>

3.2.3 Approccio Strutturale

Durante questa fase è stato seguito l'approccio descritto da Pentari et al. [5], applicando un primo preprocessing ai dati con lo scopo di creare un grafo di visibilità e una matrice di adiacenza, da cui saranno estratte delle informazioni riguardanti la struttura geometrica dei segnali utili alla costruzione del modello. Ogni segnale audio appartenente al dataset viene diviso in segmenti utilizzando l'algoritmo di edge detection Canny, il quale permette di individuare variazioni improvvise del segnale, utilizzate per spezzarlo e individuare i confini tra un segmento e l'altro. I segmenti con un numero di campioni basso vengono eliminati, per ogni segnale restante viene calcolato il valore medio dei singoli campioni in ogni segmento, ossia l'ampiezza media del segnale in quel segmento, e vengono inseriti tutti in un'unica lista. La lista creata è composta quindi dai valori medi dei segmenti di ogni segnale, su di essa viene applicata una finestra scorrevole con sovrapposizione, in cui viene calcolata la deviazione standard per ogni finestra, in modo da calcolare quanto si discostano tra di loro i valori tra una finestra e l'altra. I valori scelti per la lunghezza della finestra e per la sovrapposizione vengono esplorati e viene scelta la coppia che genera una media di 10 segmenti e una deviazione standard più bassa. Il risultato finale è una serie temporale per ogni segnale, composta dalle deviazioni standard di ogni finestra, con le quali, per ogni segnale la cui serie temporale contenga almeno 2 segmenti, viene creato un grafo di visibilità e una matrice di adiacenza (Fig. 3.1). I nodi del grafo rappresentano le deviazioni standard, mentre gli archi indicano se due nodi sono collegati, in questo caso due nodi sono collegati se graficamente non esistono dei picchi compresi tra due punti. La matrice di adiacenza A_1 è una rappresentazione binaria del grafo di visibilità, quindi indica i collegamenti tra i nodi

$$A_1[i, j] = \begin{cases} 1, & \text{se i nodi } i \text{ e } j \text{ sono collegati,} \\ 0, & \text{altrimenti.} \end{cases}$$




Figura 3.1: Esempio di grafo di visibilità e costruzione della matrice di adiacenza [5]

3.2.4 Approccio Statistico

Nell'approccio statistico, anch'esso ispirato al lavoro di Pentari et al. [5], viene eseguito un secondo processamento sui dati, con lo scopo di creare una nuova matrice e un nuovo grafo da cui estrarre informazioni che sintetizzano la struttura statistica dei segnali, utilizzate nella successiva fase di modellazione. In questa fase viene nuovamente utilizzata la lista contenente per ogni segnale i valori medi di ogni segmento, ottenuta durante la fase di approccio strutturale. Su di essa è stata applicata una nuova finestra scorrevole, i cui parametri vengono esplorati e viene scelta la coppia che minimizza la varianza tra le finestre, ottenendo un numero totale di finestre M pari a:

$$M = 1 + \left\lfloor \frac{L - W}{S} \right\rfloor$$

dove:

- L =lunghezza totale della lista su cui è applicata la finestra scorrevole
- W =numero totale di elementi presenti in ogni finestra
- S =numero di elementi che si sovrappongono per ogni finestra

Una volta ottenute le finestre, viene creata una matrice $M \times W$, dove ogni riga è una finestra, e per ogni coppia di righe viene calcolato il coefficiente di correlazione di Pearson, riempiendo eventuali valori nulli con 0, ottenendo in output la matrice

A_2 di dimensione $M \times M$, dove il valore di ogni elemento è compreso tra -1 e 1. Il coefficiente di correlazione di Pearson permette di misurare la forza e la direzione di una relazione lineare tra due serie di dati, in questo caso specifico permette di quantificare la similarità lineare tra due finestre, in modo da comprendere se variano insieme (valore prossimo a 1), hanno andamento opposto (valore prossimo a -1) oppure non condividono un andamento lineare (valore prossimo a 0). Alla fine di questo processo viene creato un grafo basato sulla matrice A_2 ottenuta, dove ogni nodo corrisponde a una finestra i ed esiste un arco (i, j) se e solo se $A_2[i, j] > 0$.

3.2.5 Estrazione dei valori

Conclusa la fase di pre-processing, vengono estratte dalle matrici A_1 e A_2 le caratteristiche descritte da Pentari et al. [5], che sintetizzano la struttura geometrica e statistica dei segnali, per un totale di 6 valori per A_1 e 5 valori per A_2 . Per ogni segnale nel dataset viene creato un array contenente le seguenti informazioni: ID dello speaker, l'emozione espressa e un nuovo array che include i valori calcolati durante le operazioni precedenti (le feature strutturali e statistiche estratte dal segnale audio). Sugli array contenenti i segnali viene eseguita una fase di bilanciamento per evitare il rischio di overfitting. In particolare, vengono eliminati i segnali per cui la coppia (ID dello speaker, emozione) appare meno di tre volte, per evitare che il modello venga influenzato da dati troppo rari che non sarebbero sufficientemente rappresentativi. Per risolvere il problema delle classi sbilanciate viene applicato SMOTE, che consente al modello di apprendere in modo equilibrato anche per le classi meno presenti nel dataset. SMOTE è una tecnica di oversampling che crea esempi sintetici per le classi minoritarie, nello specifico seleziona un punto dalla classe minoritaria e per ogni punto scelto, trova i vicini più prossimi. Vengono creati nuovi campioni sintetici combinando il campione originale con i suoi vicini. La combinazione avviene prendendo la distanza tra i punti e aggiungendo una piccola variazione casuale per generare nuovi esempi, che aggiunti a quelli già esistenti danno vita al dataset definitivo, utilizzato in fase di addestramento.

3.2.6 Creazione e addestramento del modello

Il modello di Machine Learning utilizzato è il Random Forest, un modello di apprendimento supervisionato che utilizza una combinazione di alberi decisionali per fare delle previsioni [15]. Il compito del modello è di assegnare un'etichetta (un'emozione) a ciascun segnale audio che riceve come input. Ogni albero decisionale viene addestrato su una sottoselezione casuale del dataset, la previsione finale è il risultato della media dei singoli alberi. È stato utilizzato un modello composto da 500 alberi decisionali ed è stato addestrato sul dataset generato successivamente all'applicazione dello SMOTE per il bilanciamento delle classi. Il dataset è stato suddiviso in due parti: il 70% è stato utilizzato per l'addestramento del modello, mentre il restante 30% è stato riservato alla fase di valutazione. Questa divisione consente di verificare le prestazioni del modello su dati mai visti, riducendo il rischio di overfitting. L'addestramento crea un modello di Random Forest che apprende la relazione tra le feature (caratteristiche audio estratte) e le etichette delle emozioni. Una delle caratteristiche chiave di Random Forest è la possibilità di calcolare l'importanza delle feature, questo permette di capire quali caratteristiche del segnale audio sono più rilevanti per il riconoscimento delle emozioni. Le feature con alta importanza avranno un impatto maggiore sulle decisioni dell'albero decisionale, esse vengono scelte in base a quanto migliora la qualità (o purezza) delle suddivisioni (splits) nei nodi dell'albero. Le feature più significative sono quelle che contribuiscono maggiormente a ridurre l'impurità (misurata tramite Gini impurity o entropia) nelle suddivisioni degli alberi. In particolare, l'importanza di una feature viene calcolata come la media dell'abbassamento dell'impurità (della Gini impurity o entropia) che si verifica ogni volta che la feature viene utilizzata per fare una divisione nel modello, se una feature viene utilizzata molto spesso e contribuisce significativamente a migliorare la qualità delle divisioni, avrà un'alta importanza. Nel grafico in Fig. 3.2 è rappresentata l'importanza di ciascuna feature nel modello creato, dove l'asse delle ordinate mostra il nome di ciascuna feature, mentre l'asse delle ascisse mostra un valore associato ad esse compreso tra 0 e 1, un valore alto indica un forte impatto sulle predizioni. Una volta che il modello è stato addestrato, viene salvato su disco in modo da poter essere caricato in seguito, evitando di doverlo ri-addestrare ad ogni

utilizzo.




Figura 3.2: Importanza delle feature

3.3 Sviluppo dell’ambiente virtuale

Il modello sviluppato è stato integrato all’interno di un’applicazione di realtà virtuale progettata per il visore Meta Quest, con l’obiettivo di rilevare in tempo reale le emozioni dell’utente a partire dalla sua voce.

3.3.1 Architettura e funzionamento dell’applicazione

L’utente si ritrova immerso in un ambiente semplice, raffigurante una camera arredata, in cui può muoversi liberamente ed utilizzare le mani per interagire con gli oggetti circostanti (Fig. 3.3). Durante l’esperienza, la voce dell’utente viene registrata ad intervalli di 6 secondi tramite il microfono del visore Meta Quest e viene convertita in formato .wav e inviata, tramite richiesta HTTP POST, a un server esterno sviluppato appositamente per la comunicazione con l’ambiente virtuale. Il modello di classificazione, residente su questo server, elabora i file ricevuti e restituisce l’emozione predetta in formato JSON. L’ambiente virtuale, una volta ricevuta la risposta, mostra graficamente l’emozione all’utente in tempo reale, arricchendo l’esperienza immersiva con un feedback emotivo continuo.



Figura 3.3: Visualizzazione dell'ambiente

3.3.2 Interfaccia utente e visualizzazione delle predizioni

All'interno dell'ambiente virtuale, l'utente può visualizzare un pannello che riporta lo stato della registrazione audio e l'emozione rilevata in tempo reale. Le emozioni vengono mostrate tramite un componente testuale TextMeshPro, posizionato in modo visibile nella scena. Durante la registrazione, viene indicato un conto alla rovescia per informare l'utente dell'imminente rilevazione (Fig. 3.4). Successivamente, il sistema mostra l'etichetta dell'emozione riconosciuta durante la registrazione (es. *felicità*, *tristezza*, *rabbia*) e aggiorna il contenuto a intervalli regolari di 6 secondi. Questa scelta di interfaccia garantisce all'utente un feedback immediato e continuo sull'andamento della propria espressività vocale.



Figura 3.4: Pannello dell'interfaccia utente prima della fase di registrazione audio

CAPITOLO 4

Analisi dei risultati

Le prestazioni del modello sono state valutate utilizzando una combinazione di metriche standard, adottate anche nel lavoro di Pentari et al. [5], quali: accuracy, precision, recall, F1-score e UAR (Unweighted Average Recall). Queste metriche permettono di ottenere una visione più completa del comportamento del classificatore e sono state inserite all'interno di un classification report, in modo da confrontare i diversi valori. Inoltre è stata utilizzata una matrice di confusione per valutare quante volte il modello ha predetto correttamente o erroneamente ogni classe.

4.1 Classification Report

Dal classification report (Tab. 4.1) emerge un forte contrasto tra le performance sulle classi più facilmente distinguibili e quelle meno nette: le classi *anger*, *disgust*, *fear* e *joy* presentano un alto valore di precision, il che vuol dire che il modello è sicuro quando le predice ma allo stesso tempo presentano un valore di recall non molto alto, quindi il modello fa confusione nel distinguerle. Il discorso è diverso per *neutrality*, *sadness* e *surprise* che presentano un valore di precision più basso, quindi il modello assegna erroneamente la loro etichetta ad altri segnali, allo stesso tempo però presentano un buon valore di recall, in particolare *sadness*, quindi molti dei veri

esempi di questa classe vengono riconosciuti, da cui possiamo dedurre che il modello assegna questa etichetta a molti input. Il valore di UAR (Unweighted Average Recall) ottenuto dal modello è pari a **0.5815**, confermando un equilibrio moderato tra le classi in fase di predizione, nonostante la presenza di squilibri nel dataset.

Tabella 4.1: Classification Report del modello Random Forest

Classe	Precision	Recall	F1-score	Support
Anger	1.00	0.64	0.78	479
Disgust	1.00	0.51	0.68	467
Fear	1.00	0.43	0.60	501
Joy	1.00	0.64	0.78	464
Neutrality	0.39	0.55	0.45	450
Sadness	0.32	0.70	0.44	466
Surprise	0.50	0.60	0.54	485
Accuracy		0.58		3312
Macro avg	0.74	0.58	0.61	3312
Weighted avg	0.75	0.58	0.61	3312

4.2 Matrice di confusione

La matrice di confusione è una tabella quadrata che mostra quante volte il modello ha predetto correttamente o sbagliato ogni classe. Le righe rappresentano le etichette reali mentre le colonne rappresentano le etichette predette dal modello. La matrice di confusione creata (Tab. 4.2) mostra errori di predizione non trascurabili da parte del modello tra alcune coppie di emozioni: *anger* è frequentemente confusa con *sadness* (92 casi) e *neutrality* (39 casi). *Disgust* viene spesso confusa con *sadness* (106) e *neutrality* (71). *Fear* è fortemente confusa con *sadness* (155), indicando una difficoltà strutturale nel distinguere tra emozioni negative. *Neutrality* e *sadness* sono le classi

con il maggior numero di predizioni errate a favore l'una dell'altra, questa confusione è causata dal fatto che alcune emozioni presentano delle caratteristiche simili tra loro.

Tabella 4.2: Matrice di confusione

	anger	disgust	fear	joy	neutrality	sadness	surprise
anger	307	0	0	0	39	92	41
disgust	0	239	0	0	71	106	51
fear	0	0	215	0	86	155	45
joy	0	0	0	296	46	77	45
neutrality	0	0	0	0	249	149	52
sadness	0	0	0	0	83	327	56
surprise	0	0	0	0	71	125	289

4.3 Confronto con un modello di rete neurale convoluzionale

Una rete neurale convoluzionale(CNN) è un tipo di rete neurale artificiale capace di estrarre ed apprendere automaticamente caratteristiche da dati strutturati, come immagini o segnali audio. In letteratura sono usate spesso per problemi di questo genere, grazie alla loro capacità di apprendere in autonomia le caratteristiche strutturali e statistiche dei segnali audio per ciascuna emozione [16]. In questo lavoro è stato creato un ulteriore modello, in cui è stata implementata una rete neurale convoluzionale e confrontato con il modello precedente.

4.3.1 Costruzione del nuovo modello

La rete implementata presenta due strati convoluzionali: uno da 64 filtri e uno da 128, essi hanno lo scopo di identificare dei pattern significativi all'interno dei segnali audio. Entrambi gli strati sono seguiti da una normalizzazione batch che

ha lo scopo di normalizzare l'output, portandoli a valori con media prossima a 0 e variazione standard prossima a 1, in questo modo saranno più facilmente trattabili. Inoltre viene eseguita un'operazione di max-pooling per riassumere i dati utilizzando un minor numero di valori e l'output generato viene appiattito e passato in input a due dense layer, in cui il primo è composto da 64 neuroni ed ha lo scopo di elaborare le informazioni passate e imparare le caratteristiche fondamentali per identificare le emozioni, il secondo è responsabile della classificazione. Per la valutazione delle prestazioni sono stati utilizzati gli stessi metodi usati per il modello Random Forest, ovvero un classification report con le relative metriche e una matrice di confusione.

4.3.2 Classification Report

Come mostrato nella Tabella 4.3, il modello CNN ha ottenuto risultati complessivamente deludenti, con un'accuratezza globale pari a 16%. Anche le metriche derivate, come F1-score e macro average, risultano molto basse: il valore di macro F1-score è pari a 0.09, e l'Unweighted Average Recall (UAR) coincide con il valore di macro recall, pari a 0.17. Tra le emozioni, l'unica che raggiunge un recall soddisfacente è *anger* (84%), ma a scapito della precisione (15%), il che suggerisce che il modello tende a predire frequentemente questa classe anche quando non è corretta. Al contrario, le emozioni come *disgust*, *fear*, *joy* e *surprise* presentano precision, recall e F1-score pari a 0, indicando un'incapacità totale del modello nel riconoscerle correttamente.

4.3.3 Matrice di confusione

Come già osservato nel classification report, anche la matrice di confusione (Tab. 4.4) mostra chiaramente che il modello CNN 1D tende a predire quasi esclusivamente la classe *anger*, anche quando l'emozione reale è diversa. Questo comportamento spiega l'elevato valore di recall per *anger* (84%) unito alla bassissima precisione (15%).

Tabella 4.3: Classification Report del modello CNN

Classe	Precision	Recall	F1-score	Support
Anger	0.15	0.84	0.25	90
Disgust	0.00	0.00	0.00	123
Fear	0.00	0.00	0.00	110
Joy	0.00	0.00	0.00	101
Neutrality	0.15	0.18	0.17	84
Sadness	0.23	0.19	0.21	100
Surprise	0.00	0.00	0.00	94
Accuracy		0.16		702
Macro Avg	0.08	0.17	0.09	702
Weighted Avg	0.07	0.16	0.08	702

4.3.4 Conclusioni del confronto

Il modello Random Forest ha mostrato prestazioni più stabili e complessivamente migliori, con un buon bilanciamento tra precision e recall per diverse classi emozionali. In particolare, è riuscito a distinguere in modo accettabile emozioni come *joy*, *anger* e *disgust*, mantenendo un Unweighted Average Recall (UAR) pari a 0.58. Al contrario, la rete CNN ha evidenziato prestazioni inferiori, con un'accuratezza globale del 16% e un UAR pari a 0.17. Come mostrato nella matrice di confusione, la rete ha mostrato un comportamento fortemente sbilanciato verso la classe *anger*, che tende a predire anche quando l'emozione reale è diversa. Le restanti classi non vengono mai riconosciute correttamente, questo comportamento suggerisce una difficoltà della rete nell'apprendere pattern significativi. In conclusione, il modello Random Forest si è dimostrato più adatto al tipo di feature utilizzate, garantendo maggiore capacità di discriminazione tra le classi.

Tabella 4.4: Matrice di confusione del modello CNN

Reale \ Predetto	Anger	Disgust	Fear	Joy	Neutrality	Sadness	Surprise
Anger	76	0	0	0	7	7	0
Disgust	87	0	0	0	21	15	0
Fear	74	0	0	0	16	20	0
Joy	88	0	0	0	8	5	0
Neutrality	55	0	0	0	15	14	0
Sadness	63	0	0	0	18	19	0
Surprise	78	0	0	0	12	4	0

4.4 Confronto con i risultati ottenuti in letteratura

Nel lavoro di Pentari et al. (2024) [5], su cui si basa il lavoro svolto, sono stati condotti esperimenti su diversi dataset noti, quali EMODB, DEMoS e AESDD, che hanno mostrato risultati eccellenti, con un valore medio di Unweighted Average Recall (UAR) pari al 77.8% su EMODB, 79.1% su DEMoS e 70% su AESDD, utilizzando un classificatore Random Forest. I risultati ottenuti sul presente lavoro hanno mostrato performance inferiori, in cui il miglior modello (Random Forest) ha ottenuto un UAR pari a 58%. Questa differenza nelle prestazioni potrebbe essere dovuta all'impiego di un diverso dataset (Emozionalmente[3.2.2]) meno strutturato, scelta motivata dalla sua maggiore accessibilità e facilità di reperimento. Nonostante queste limitazioni, i risultati ottenuti possono comunque essere considerati soddisfacenti. Il modello, pur non raggiungendo le prestazioni dei metodi più avanzati, ha dimostrato un funzionamento coerente ed è potuto essere stato integrato con successo all'interno dell'ambiente virtuale, consentendo il riconoscimento in tempo reale delle emozioni dell'utente durante l'esperienza immersiva.

CAPITOLO 5

Conclusioni

In questo lavoro è stato sviluppato un sistema per il riconoscimento delle emozioni vocali, successivamente integrato in un ambiente virtuale immersivo. L'obiettivo era quello di identificare in tempo reale lo stato emotivo dell'utente attraverso la voce, adattando dinamicamente l'ambiente in base all'emozione rilevata. Il progetto, ispirato dalla ricerca di Pentari et al. [5], si è articolato in diverse fasi: dalla selezione e pre-elaborazione dei dati, all'estrazione delle feature, fino all'addestramento dei modelli e alla loro applicazione in tempo reale tramite visore Meta Quest. Sono stati sperimentati due modelli di classificazione: un Random Forest e una rete neurale convoluzionale (CNN). Dai risultati ottenuti si evince una netta superiorità del primo, che ha raggiunto un UAR (Unweighted Average Recall) del 58%, contro il 17% della rete convoluzionale. Nonostante le prestazioni non raggiungano quelle di alcuni modelli presenti in letteratura, il sistema ha comunque mostrato una buona affidabilità e ha permesso un'integrazione funzionale nell'ambiente virtuale sviluppato, in cui l'utente può osservare in tempo reale la propria emozione rilevata tramite voce.

5.1 Limitazioni e sviluppi futuri

Nonostante i risultati siano stati soddisfacenti in relazione agli obiettivi prefissati, il lavoro svolto presenta alcune limitazioni, che aprono la strada a possibili miglioramenti futuri. Una tra queste riguarda il dataset utilizzato, che è stato scelto per la sua accessibilità. Tuttavia, oltre a non essere bilanciato, non presenta istanze con un livello di qualità paragonabile a quello dei dataset comunemente utilizzati in letteratura per problemi di questo genere, questo ha influenzato negativamente le previsioni dei modelli creati. Per migliorare le prestazioni del sistema si potrebbe valutare l'utilizzo di dataset bilanciati e caratterizzati da istanze con qualità superiore. Inoltre, l'impiego di dataset multilingua potrebbe ampliare l'applicabilità del sistema a utenti che parlano lingue diverse dall'italiano, favorendone una maggiore generalizzazione e adattabilità in contesti internazionali. Ulteriori possibilità di sviluppo riguardano l'estensione del modello a più contesti applicativi, tra cui l'ambito aziendale, terapeutico e formativo. In questi scenari, rilverare l'emozione espressa dall'utente in tempo reale potrebbe risultare efficace a migliorare l'interazione, adattando dinamicamente i contenuti o gli interventi in base allo stato emotivo rilevato. In particolare, in contesti educativi immersivi come le classi virtuali, il sistema potrebbe supportare il docente nell'identificare situazioni di disattenzione, frustrazione o coinvolgimento degli studenti, ottimizzando così l'efficacia dell'insegnamento.

Bibliografia

- [1] M. Mirror, "Face tracking technology." [Online]. Available: <https://www.magicmirror.me/Products/Photobooth-Technologies> (Citato alle pagine iii e 5)
- [2] N. u. R. Malik, U. U. Sheikh, S. A. R. Abu-Bakar, and A. Channa, "Multi-view human action recognition using skeleton based-fineknn with extraneous frame scrapping technique," *Sensors*, vol. 23, no. 5, 2023. [Online]. Available: <https://www.mdpi.com/1424-8220/23/5/2745> (Citato alle pagine iii e 6)
- [3] "Speech emotion recognition using deep neural network: Part-i - speech emotion recognition." [Online]. Available: tpsearchtool.com (Citato alle pagine iii e 6)
- [4] domestika.org, "Por qué el metaverso necesita urgentemente a las mujeres," accessed: 2023-06-20. [Online]. Available: <https://www.domestika.org/es/blog/10257-por-que-el-metaverso-necesita-urgentemente-a-las-mujeres> (Citato alle pagine iii e 7)
- [5] M. T. Anastasia Pentari, George Kafentzis, "Speech emotion recognition via graph-based representations," *Scientific Reports*, 2024. (Citato alle pagine iii, 1, 2, 9, 12, 13, 14, 18, 23 e 24)
- [6] P. Ekman, "An argument for basic emotions," *Cognition Emotion*, vol. 6, no. 3-4, pp. 169–200, 1992. (Citato a pagina 4)

-
- [7] A. Kołakowska, A. Landowska, M. Szwoch, W. Szwoch, and M. R. Wróbel, *Emotion Recognition and Its Applications*. Cham: Springer International Publishing, 2014, pp. 51–62. [Online]. Available: https://doi.org/10.1007/978-3-319-08491-6_5 (Citato a pagina 4)
- [8] Y. Tian, T. Kanade, and J. F. Cohn, *Facial Expression Recognition*. London: Springer London, 2011, pp. 487–519. [Online]. Available: https://doi.org/10.1007/978-0-85729-932-1_19 (Citato a pagina 5)
- [9] A. Oğuz and Ömer Faruk Ertuğrul, “Emotion recognition by skeleton-based spatial and temporal analysis,” *Expert Systems with Applications*, vol. 238, p. 121981, 2024. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0957417423024831> (Citato a pagina 5)
- [10] M. Sparkes, “What is a metaverse,” 2021. (Citato a pagina 7)
- [11] Meta Platforms, Inc. (n.d.) Meta quest – virtual reality headsets. Accessed: 2025-07-19. [Online]. Available: <https://www.meta.com/quest/> (Citato a pagina 7)
- [12] J. Zheng, K. Chan, and I. Gibson, “Virtual reality,” *IEEE Potentials*, vol. 17, no. 2, pp. 20–23, 1998. (Citato a pagina 7)
- [13] F. Arena, M. Collotta, G. Pau, and F. Termine, “An overview of augmented reality,” *Computers*, vol. 11, no. 2, p. 28, 2022. (Citato a pagina 7)
- [14] O. I. Khalaf, D. Srinivasan, S. Algburi, J. Vellaichamy, D. Selvaraj, M. S. Sharif, and W. Elmedany, “Elevating metaverse virtual reality experiences through network-integrated neuro-fuzzy emotion recognition and adaptive content generation algorithms,” *Engineering Reports*, vol. 6, no. 11, p. e12894, 2024. (Citato a pagina 8)
- [15] L. Breiman, “Random forests,” *Machine learning*, vol. 45, no. 1, pp. 5–32, 2001. (Citato a pagina 15)
- [16] S. Hershey, S. Chaudhuri, D. P. W. Ellis, J. F. Gemmeke, A. Jansen, R. C. Moore, M. Plakal, D. Platt, R. A. Saurous, B. Seybold, M. Slaney, R. J. Weiss, and

K. Wilson, "Cnn architectures for large-scale audio classification," in *2017 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 2017, pp. 131–135. (Citato a pagina 20)