



UNIVERSITÀ DEGLI STUDI DI SALERNO

Dipartimento di Informatica

Corso di Laurea Triennale in Informatica

TESI DI LAUREA TRIENNALE

Progettazione e Valutazione di un Sistema in Realtà Virtuale per la Simulazione del Rischio di Diabete Basato su Dati NHANES

RELATORE

Prof. Fabio Palomba

Dott.ssa Viviana Pentangelo

Università degli Studi di Salerno

CANDIDATO

Giovanni Sorrentino

Matricola: 0512106095

Anno Accademico 2024-2025

Questa tesi è stata realizzata nel

sesa^{lab}
SOFTWARE ENGINEERING
SALERNO

Ai miei genitori, per aver rispettato il mio percorso, senza giudicarlo.

A chi non ha potuto disporre del mio stesso tempo,

a chi ha dovuto fermarsi,

a chi non ce l'ha fatta.

Abstract

L'obiettivo della seguente tesi di laurea è dimostrare la validità dell'utilizzo della realtà virtuale (VR) come strumento di supporto alla comprensione e alla valutazione del rischio di diabete, attraverso l'analisi di dati clinici reali. Il lavoro si concentra sullo sviluppo di un sistema interattivo che consente all'utente di analizzare pazienti virtuali generati a partire dai dati del dataset NHANES (National Health and Nutrition Examination Survey).

Il problema oggetto di studio riguarda la difficoltà nell'interpretazione dei fattori di rischio associati al diabete in contesti educativi, in cui l'analisi dei dati clinici risulta spesso astratta e poco intuitiva per utenti non esperti.

La ricerca indaga se un approccio immersivo basato su realtà virtuale possa migliorare la comprensione dei profili di rischio rispetto ai metodi tradizionali, rendendo l'esperienza di apprendimento più coinvolgente tramite elementi di gamification.

La metodologia adottata prevede la selezione, la pulizia e l'integrazione di variabili demografiche e biometriche rilevanti dal dataset NHANES, successivamente utilizzate per generare pazienti virtuali all'interno di uno studio medico sviluppato mediante il motore Unity, ai quali è possibile fornire una diagnosi basata sull'analisi della relativa cartella clinica.

I risultati dimostrano la fattibilità tecnica dell'approccio proposto e suggeriscono che la realtà virtuale possa migliorare la fruizione delle informazioni sanitarie, rendendole maggiormente comprensibili e favorendo un apprendimento più dinamico.

In conclusione, il sistema rappresenta un valido strumento educativo, con sviluppi futuri orientati all'integrazione di modelli di machine learning e alla validazione sperimentale su utenti reali.

Indice

Elenco delle Figure	iii
Elenco delle Tabelle	iv
1 Introduzione	1
1.1 Contesto applicativo	1
1.2 Motivazioni e obiettivi	2
1.3 Risultati ottenuti	3
1.4 Struttura della tesi	3
2 Stato dell'Arte	5
2.1 Immersione e apprendimento esperienziale	6
2.2 VR in ambito sanitario	7
2.3 VR per la formazione tecnica	7
2.4 VR per il ragionamento clinico	7
2.5 Visualizzazione e interpretazione dei dati clinici	8
2.6 Gamification e coinvolgimento nell'apprendimento sanitario	9
2.7 Limiti della letteratura	10
2.8 Posizionamento del presente lavoro nel panorama scientifico	10
3 Metodologia e preparazione dei dati	12

3.1	Preparazione e integrazione dei dati NHANES	13
3.1.1	Analisi preliminare delle variabili NHANES	14
3.1.2	Preprocessing e gestione dei valori mancanti	16
3.2	Sistema iniziale di classificazione rule-based	16
3.2.1	Valutazione preliminare del modello rule-based	17
3.3	Analisi degli errori e implementazione dei modelli ML	18
3.4	Costruzione del dataset finale per il sistema VR	22
4	Progettazione e implementazione del sistema VR	24
4.1	Processo di sviluppo del sistema	24
4.2	Architettura del sistema	25
4.3	Ambiente immersivo e interazione utente	26
4.4	Sistema di generazione dei pazienti	27
4.4.1	Prefab dei pazienti	27
4.4.2	Animazioni e movimento del paziente	28
4.4.3	Sistema di spawn dei pazienti	29
4.4.4	Caricamento dei dati clinici	29
4.5	Interazione utente e cartella clinica	30
4.6	Sistema di diagnosi, punteggio e feedback	31
4.7	Spiegazioni cliniche e supporto educativo	32
4.8	Sintesi del sistema sviluppato	34
4.9	Possibili scenari di utilizzo e impatto del sistema	34
5	Conclusioni e sviluppi futuri	36
5.1	Limiti del lavoro	37
5.2	Sviluppi futuri	38
	Bibliografia	39

Elenco delle figure

3.1	Importanza variabili nella classificazione errori tramite modello Random Forest.	19
3.2	Distribuzione dei valori di glicemia per falsi positivi e positivi confermati.	20
3.3	Distribuzione dei valori di insulina per falsi positivi e positivi confermati.	21
4.1	Vista dello studio medico virtuale sviluppato in Unity, utilizzato come ambiente immersivo per la simulazione clinica.	26
4.2	Esempio di prefab femminile utilizzato per la generazione dinamica dei pazienti virtuali all'interno dell'ambiente VR.	28
4.3	Cartella clinica del paziente virtuale visualizzata in VR, contenente i principali parametri clinici derivati dal dataset NHANES.	30
4.4	Interfaccia di diagnosi in realtà virtuale che consente all'utente di classificare il paziente come Diabetico, Non Diabetico o Borderline.	31
4.5	Feedback visivo mostrato all'utente dopo la selezione della diagnosi, con aggiornamento del punteggio associato.	32
4.6	Pannello di spiegazione clinica generato dal sistema rule-based per supportare l'interpretazione della diagnosi effettuata.	33

Elenco delle tabelle

2.1	Confronto tra gli studi analizzati	8
2.2	Estratto originale del dataset NHANES (codifica grezza)	8
3.1	Domande di ricerca affrontate nel presente lavoro.	13
3.2	Variabili selezionate dal dataset NHANES	15
3.3	Sistema di valutazione del rischio basato su regole cliniche	17
3.4	Classificazione del rischio complessivo	17
3.5	Risultati della valutazione del sistema rule-based sul dataset filtrato .	23

CAPITOLO 1

Introduzione

1.1 Contesto applicativo

Il diabete rappresenta una delle principali sfide sanitarie a livello globale. La crescente diffusione della patologia, insieme alla complessità dei fattori di rischio coinvolti, rende sempre più importante lo sviluppo di strumenti in grado di supportare la comprensione e l'analisi dei dati clinici. In questo contesto, i dataset epidemiologici rappresentano una risorsa fondamentale per lo studio dei fattori associati allo sviluppo della malattia.

Uno dei dataset più utilizzati in ambito epidemiologico è il National Health and Nutrition Examination Survey (NHANES), un programma di ricerca condotto negli Stati Uniti che raccoglie informazioni demografiche, cliniche e comportamentali su un ampio campione della popolazione. Questi dati consentono di analizzare relazioni tra variabili cliniche, stili di vita e condizioni di salute, fornendo una base informativa utile per studi statistici e modelli predittivi.

Parallelamente, negli ultimi anni si è assistito a una crescente diffusione delle tecnologie di realtà virtuale (Virtual Reality, VR), utilizzate in diversi ambiti applicativi tra cui formazione, simulazione e supporto all'apprendimento. In ambito medico e sanitario, gli ambienti immersivi consentono di creare simulazioni interattive in cui

gli utenti possono analizzare scenari clinici e sviluppare capacità di ragionamento diagnostico in contesti controllati.

Tuttavia, molte delle applicazioni esistenti basate su pazienti virtuali si fondano su scenari clinici simulati o su casi costruiti manualmente, spesso privi di un collegamento diretto con dataset epidemiologici reali. Questo limita in parte il realismo delle simulazioni e la varietà dei casi presentati agli utenti.

1.2 Motivazioni e obiettivi

Alla luce di queste considerazioni, il presente lavoro si propone di esplorare l'integrazione tra dati epidemiologici reali e ambienti immersivi in realtà virtuale, con l'obiettivo di sviluppare un sistema interattivo che permetta di analizzare i fattori di rischio associati al diabete attraverso pazienti virtuali generati dinamicamente.

Il lavoro si articola in due componenti principali. In primo luogo, è stata condotta un'analisi dei dati provenienti dal dataset NHANES, con l'obiettivo di individuare le variabili cliniche più rilevanti nella classificazione del rischio di diabete. A partire da un sistema iniziale di classificazione basato su regole cliniche semplificate, sono state successivamente applicate tecniche di machine learning per supportare l'analisi delle variabili e migliorare la comprensione dei pattern presenti nei dati.

In secondo luogo, è stato sviluppato un ambiente immersivo in realtà virtuale utilizzando il motore grafico Unity. In questo ambiente, i pazienti virtuali vengono generati dinamicamente a partire dai record del dataset NHANES e presentano parametri clinici realistici che l'utente può analizzare attraverso una cartella clinica virtuale.

L'utente può quindi osservare i dati disponibili, formulare una valutazione diagnostica e ricevere feedback immediati accompagnati da spiegazioni sintetiche basate sui parametri clinici del paziente. L'ambiente include inoltre elementi di gamification, come un sistema di punteggio e un personaggio non giocante che fornisce suggerimenti educativi sui principali fattori di rischio.

1.3 Risultati ottenuti

Il lavoro ha portato allo sviluppo di un prototipo funzionante che integra dati epidemiologici reali, tecniche di analisi dei dati e un ambiente immersivo interattivo.

Durante la fase di analisi dei dati è stato inizialmente sviluppato un sistema di classificazione rule-based basato su soglie cliniche relative a variabili come glicemia, BMI e colesterolo. L'analisi degli errori di questo modello ha permesso di individuare alcune variabili particolarmente informative, tra cui glicemia e insulina.

Sulla base di queste osservazioni è stato costruito un dataset filtrato contenente i record più completi rispetto a queste variabili. L'applicazione del sistema rule-based sul dataset filtrato ha portato a un miglioramento significativo dell'accuratezza complessiva, raggiungendo circa l'85%.

Il dataset così ottenuto è stato successivamente integrato in un ambiente VR sviluppato in Unity, nel quale i pazienti virtuali vengono generati dinamicamente a partire dai dati clinici reali. L'utente può interagire con i pazienti, analizzare i parametri clinici disponibili e formulare una diagnosi attraverso un'interfaccia immersiva.

Questo approccio dimostra la fattibilità tecnica dell'integrazione tra dataset epidemiologici e simulazioni immersive, evidenziando il potenziale della realtà virtuale come strumento educativo per la comprensione dei fattori di rischio associati al diabete.

1.4 Struttura della tesi

Il resto della tesi è organizzato come segue.

Il Capitolo 2 presenta lo stato dell'arte relativo all'utilizzo della realtà virtuale in ambito formativo e sanitario, con particolare attenzione alle simulazioni basate su pazienti virtuali e alle principali limitazioni delle soluzioni esistenti.

Il Capitolo 3 descrive il processo di preparazione e analisi dei dati NHANES, l'implementazione dei modelli di classificazione e la costruzione del dataset finale utilizzato nel sistema.

Il Capitolo 4 presenta la progettazione e l'implementazione del sistema immersivo sviluppato in Unity, descrivendo l'architettura del sistema, la generazione dei pazienti virtuali e le principali interazioni disponibili per l'utente.

Infine, il Capitolo 5 riassume i risultati principali del lavoro, discute i limiti del sistema sviluppato e presenta alcune possibili direzioni per sviluppi futuri.

CAPITOLO 2

Stato dell'Arte

In questo capitolo viene analizzato il ruolo della realtà virtuale (VR) nell'evoluzione dei processi di apprendimento e formazione, con particolare riferimento alla medicina e all'istruzione sanitaria. L'attenzione è rivolta alle simulazioni cliniche immersive, che consentono agli studenti di acquisire competenze attraverso esperienze interattive e contestualizzate.

Vengono inoltre esaminati gli approcci tecnologici che supportano l'interpretazione dei dati clinici e gli elementi di gamification che possono incrementare il coinvolgimento e la motivazione durante il percorso formativo.

L'obiettivo è delineare il quadro teorico e scientifico entro cui si colloca il presente lavoro, evidenziando potenzialità e limiti delle tecnologie immersive nella formazione sanitaria.

L'analisi della letteratura è inoltre orientata a identificare le principali dimensioni attraverso cui la realtà virtuale viene valutata in ambito formativo. In particolare, verranno considerate le evidenze relative agli outcome cognitivi (quali ritenzione delle conoscenze e ragionamento clinico), agli aspetti motivazionali e percettivi (soddisfazione ed engagement) e alle implicazioni metodologiche legate all'integrazione di dati clinici e strumenti immersivi. Tale inquadramento consente di collocare il presente lavoro all'interno delle linee di ricerca attualmente sviluppate nel settore.

2.1 Immersione e apprendimento esperienziale

La realtà virtuale rappresenta una tecnologia in grado di offrire esperienze immersive all'interno di ambienti simulati tridimensionali. Tali ambienti consentono agli utenti di interagire con scenari virtuali in modo diretto, favorendo una percezione di presenza all'interno dello spazio simulato.

Diversi studi nel campo dell'istruzione hanno evidenziato come l'apprendimento basato sull'esperienza diretta e su scenari simulati possa facilitare la comprensione delle informazioni rispetto a modalità di apprendimento più passive, come la semplice lettura o l'ascolto.

In questo contesto, gli ambienti immersivi offerti dalla realtà virtuale permettono agli utenti di esplorare attivamente le informazioni disponibili e di applicarle in situazioni realistiche, favorendo un approccio più interattivo e partecipativo al processo di apprendimento.

Secondo David Kolb, un esperto nel campo dell'apprendimento, limitarsi a ricevere informazioni senza essere coinvolti attivamente non aiuta a comprendere profondamente i concetti. Kolb propone un modello di apprendimento ciclico che include quattro fasi: esperienza concreta, osservazione riflessiva, concettualizzazione astratta e sperimentazione attiva. Questo modello trova una applicazione naturale nella realtà virtuale, dove gli utenti possono sperimentare situazioni concrete, riflettere sulle loro azioni, teorizzare sui risultati e applicare ciò che hanno imparato in nuove situazioni [1].

Nel campo sanitario, questo approccio è particolarmente importante perché il processo di diagnosi non si limita a leggere numeri, ma richiede di integrare diverse informazioni per avere un quadro clinico completo. La possibilità di interagire con pazienti virtuali e dati clinici in uno spazio tridimensionale può aiutare a comprendere meglio i fattori di rischio e le decisioni cliniche.

In questo contesto, l'integrazione tra ambienti immersivi e dati clinici reali può rappresentare un'opportunità per sviluppare strumenti educativi più interattivi e realistici. L'utilizzo di dataset epidemiologici consente infatti di costruire scenari clinici basati su dati reali, aumentando il valore formativo delle simulazioni.

2.2 VR in ambito sanitario

Negli ultimi anni, l'uso di ambienti simulati nella formazione medica è aumentato notevolmente. La simulazione è diventata uno strumento fondamentale nell'istruzione sanitaria, permettendo di riprodurre scenari clinici complessi senza mettere a rischio operatori e pazienti reali. La realtà virtuale offre ambienti immersivi, interattivi e ripetibili, con applicazioni che vanno dalla formazione chirurgica al supporto al ragionamento clinico [2].

2.3 VR per la formazione tecnica

Come evidenziato da Pottle, [2] l'uso di simulazioni standardizzate e ripetibili nella formazione medica favorisce l'apprendimento, riduce i rischi associati ai metodi tradizionali e, in alcuni studi, abbatte anche i costi. La realtà virtuale nella formazione chirurgica ha mostrato un aumento significativo delle conoscenze e delle abilità tecniche degli operatori, oltre a una riduzione degli errori e a un miglioramento della velocità nell'esecuzione delle procedure.

2.4 VR per il ragionamento clinico

In uno studio randomizzato controllato condotto su studenti di infermieristica, l'introduzione di un simulatore clinico virtuale basato su casi ha mostrato un miglioramento significativo nella ritenzione delle conoscenze sia nel breve che nel medio periodo, oltre a livelli più elevati di soddisfazione rispetto a metodologie tradizionali con simulatori a bassa fedeltà [3].

Ulteriori studi hanno confermato il potenziale della realtà virtuale immersiva nello sviluppo delle competenze comunicative e decisionali in ambito medico. In uno studio pilota basato sull'utilizzo di pazienti virtuali tramite visore Meta Quest 3, sono stati osservati miglioramenti significativi nella fiducia comunicativa e nei processi decisionali clinici degli studenti di medicina [4].

Tabella 2.1: Confronto tra gli studi analizzati

Studio	Obiettivo	Risultato
Pottle (2019)	Training tecnico chirurgico	Riduzione degli errori e incremento performance
Padilha (2019)	Ragionamento clinico	Maggiore conoscenza e soddisfazione
Dávidovics (2025)	Decision-making	Incremento della fiducia e del realismo percepito

Nel complesso, la letteratura evidenzia grandi benefici rilevanti dall'utilizzo della VR nella formazione sanitaria.

2.5 Visualizzazione e interpretazione dei dati clinici

Oggi è disponibile una quantità crescente di dati clinici e sanitari, il che consente di analizzare in modo approfondito le cause delle patologie e le loro conseguenze cliniche. Solitamente, questi dati vengono mostrati in forma di numeri o tabelle molto complesse da decifrare, tramite cartelle cliniche online, statistiche o grafici bidimensionali. Tuttavia, tali rappresentazioni possono risultare di difficile interpretazione per utenti con poca esperienza.

Tabella 2.2: Estratto originale del dataset NHANES (codifica grezza)

SEQN	SDDSRVYR	RIDSTATR	RIAGENDR	RIDAGEYR
130378	12	2	1	43
130379	12	2	1	66
130380	12	2	2	44
130381	12	2	2	5
130382	12	2	1	53

Nel campo della letteratura, molti studi hanno esaminato come visualizzare i dati clinici in modo efficace. Questi studi hanno messo in luce diversi approcci per rendere le informazioni più facili da capire e utilizzare, sottolineando l'importanza di strumenti visuali per supportare le decisioni cliniche [5]. Altri lavori hanno esplorato come utilizzare tecniche di visualizzazione nel settore sanitario. Ad esempio, grafici interattivi e presentazioni visive possono aiutare a identificare pattern e trend nei dati sanitari[6].

Tuttavia, molte soluzioni continuano a utilizzare rappresentazioni bidimensionali tradizionali.

Per comprendere i fattori di rischio associati a patologie croniche come il diabete, è necessario integrare molteplici variabili demografiche e biometriche. Questo può essere difficile con le rappresentazioni tradizionali.

In questo contesto, gli ambienti immersivi rappresentano un possibile approccio alternativo alla visualizzazione tradizionale, consentendo una rappresentazione più intuitiva, interattiva e multidimensionale delle informazioni cliniche.

2.6 Gamification e coinvolgimento nell'apprendimento sanitario

Un altro aspetto rilevante nell'educazione sanitaria è il concetto di gamification. Con il concetto di gamification si intende l'utilizzo di elementi tipici del gioco in contesti non ludici per aumentare il coinvolgimento e la motivazione degli utenti.

Secondo Hamari et al. [7], l'integrazione di meccaniche come feedback immediato e sistemi di ricompensa può favorire una maggiore partecipazione e motivazione. Tuttavia, l'efficacia della gamification dipende dalla qualità del design e dalla coerenza con gli obiettivi formativi.

Nel contesto della formazione sanitaria in realtà virtuale, l'introduzione di dinamiche interattive e di elementi ispirati alla gamification può rendere l'esperienza più attiva e coinvolgente. Ciò può favorire un maggiore investimento cognitivo da parte dell'utente.

2.7 Limiti della letteratura

Sebbene la realtà virtuale abbia dimostrato un impatto positivo sia sullo sviluppo delle abilità tecniche sia sul potenziamento del ragionamento clinico, la maggior parte degli studi analizzati si concentra su scenari simulati predefiniti e su contesti formativi limitati [2], con poca integrazione di elementi di gamification.

In particolare, risultano ancora limitate le applicazioni che integrano dataset clinici reali all'interno di ambienti immersivi per rappresentare in modo dinamico e multidimensionale i fattori di rischio.

Molti sistemi di simulazione basati su pazienti virtuali si fondano infatti su casi clinici progettati manualmente o su scenari didattici predefiniti, sviluppati per specifici obiettivi formativi e non necessariamente derivati da basi dati cliniche o epidemiologiche strutturate [8, 9].

Si evidenzia pertanto uno spazio di ricerca nell'intersezione tra realtà virtuale immersiva, visualizzazione dei dati clinici e utilizzo di dataset epidemiologici reali a supporto dei processi decisionali.

Un ulteriore elemento critico riguarda l'eterogeneità metodologica degli studi esaminati. I lavori presenti in letteratura utilizzano strumenti di valutazione differenti (test di conoscenza, scale di soddisfazione, misure di autoefficacia o indicatori di performance tecnica), rendendo talvolta complessa la comparabilità dei risultati. Inoltre, molti studi si basano su campioni numericamente limitati o su disegni pilota, con follow-up temporali ridotti. Questa variabilità metodologica suggerisce la necessità di approcci più strutturati e replicabili, capaci di integrare dimensione immersiva, dati clinici realistici e metriche di valutazione coerenti [10].

2.8 Posizionamento del presente lavoro nel panorama scientifico

La realtà virtuale rappresenta, come dimostrato precedentemente, uno strumento promettente nella formazione sanitaria, con benefici sia sul piano tecnico che su quello cognitivo. Tuttavia, molte applicazioni proposte si basano su scenari simulati costruiti appositamente per il contesto didattico, spesso svincolati da basi dati reali.

L'integrazione di dataset clinici strutturati all'interno di ambienti immersivi è ancora poco esplorata, soprattutto quando l'obiettivo è quello di supportare la comprensione dei fattori di rischio in una prospettiva preventiva.

Il presente lavoro si inserisce in questo contesto proponendo lo sviluppo di un ambiente di realtà virtuale basato su dati reali provenienti dal dataset NHANES per la generazione dinamica di pazienti virtuali.

L'obiettivo è valutare se l'integrazione di dati epidemiologici strutturati all'interno di un ambiente immersivo possa migliorare la comprensione dei fattori di rischio.

Metodologia e preparazione dei dati

Nel presente capitolo viene descritto l'approccio metodologico adottato per la preparazione dei dati e lo sviluppo dei modelli utilizzati nello studio.

In particolare, verranno illustrate le fasi di integrazione e preprocessing dei dataset NHANES, lo sviluppo e la valutazione dei modelli di machine learning per la classificazione del rischio di diabete e il processo che ha portato alla costruzione del dataset finale utilizzato nell'ambiente di realtà virtuale.

L'obiettivo del capitolo è fornire una descrizione delle procedure adottate, degli strumenti utilizzati e delle scelte metodologiche effettuate, in modo da chiarire il processo che ha condotto alla realizzazione del dataset utilizzato nel sistema VR.

Tabella 3.1: Domande di ricerca affrontate nel presente lavoro.

RQ	Domanda di ricerca	Ambito
RQ1	È tecnicamente possibile integrare dataset epidemiologici reali (NHANES) all'interno di un ambiente immersivo in realtà virtuale per la generazione dinamica di pazienti virtuali?	Fattibilità tecnica
RQ2	In che misura l'utilizzo di modelli di machine learning supervisionati migliora la classificazione del rischio di diabete rispetto a un approccio rule-based iniziale?	Performance predittiva
RQ3	L'integrazione di elementi di gamification all'interno dell'ambiente immersivo contribuisce a rendere l'esperienza di apprendimento più interattiva e strutturata rispetto a una simulazione tradizionale?	Coinvolgimento educativo
RQ4	L'integrazione di tecniche di Explainable AI in un contesto immersivo contribuisce alla comprensione dei fattori di rischio oppure introduce complessità interpretative?	Interpretabilità

3.1 Preparazione e integrazione dei dati NHANES

I dataset utilizzati provengono dal programma NHANES (National Health and Nutrition Examination Survey), che raccoglie dati epidemiologici su variabili demografiche, cliniche e comportamentali della popolazione statunitense. Nello specifico sono stati analizzati i dati del biennio 2021-2023.

Sono stati selezionati i dataset contenenti variabili rilevanti per la valutazione del rischio di diabete, includendo informazioni demografiche (età, sesso, genere, etnia, livello di istruzione), misure corporee (peso, altezza, BMI), parametri biochimici (glucosio, insulina, colesterolo), dati nutrizionali e attività fisica dichiarata.

Le variabili di interesse sono state selezionate sulla base della letteratura clinica e della loro rilevanza epidemiologica rispetto al rischio di diabete.

3.1.1 Analisi preliminare delle variabili NHANES

È stata condotta un'analisi esplorativa delle variabili selezionate al fine di comprenderne struttura, codifica e distribuzione.

Particolare attenzione è stata dedicata alla variabile target `DIQ010`, che identifica la diagnosi di diabete da parte di un medico. La codifica originale prevede le seguenti categorie: 1 = Yes, 2 = No, 3 = Borderline, 7 = Refused, 9 = Don't know.

Ai fini dell'analisi predittiva, le categorie 7 e 9 sono state escluse.

Le variabili incluse nell'analisi comprendono:

- Identificativo record: `SEQN`;
- Variabile target: `DIQ010`;
- Parametri clinici: `LBXGLU`, `LBXIN`, `LBXTC`, `LBDHDD`;
- Misure antropometriche: `BMXWT`, `BMXHT`, `BMXBMI`;
- Variabili nutrizionali (Day 1 recall): `DR1TKCAL`, `DR1TPROT`, `DR1TCARB`, `DR1TSUGR`, `DR1TFIBE`, `DR1TTFAT`, `DR1TSFAT`;
- Attività fisica: `PAD680`, `PAD800`, `PAD820`;
- Variabili demografiche e socioeconomiche: `RIDAGEYR`, `RIAGENDR`, `RIDRETH1`, `DMDEDUC2`, `INDFMPIR`, `WHQ070`.

Tabella 3.2: Variabili selezionate dal dataset NHANES

Variabile	Descrizione	Tipo
DIQ010	Diabetes diagnosis	Categorica nominale (3 classi: Yes / No / Borderline)
LBXGLU	Fasting Glucose (mg/dL)	Continua
LBXIN	Insulin (μ U/mL)	Continua
BMXBMI	Body Mass Index	Continua
BMXWT	Weight (kg)	Continua
BMXHT	Standing Height (cm)	Continua
LBDHDD	HDL Cholesterol (mg/dL)	Continua
LBXTC	Total Cholesterol (mg/dL)	Continua
RIDAGEYR	Age (years)	Continua
RIAGENDR	Gender	Categorica nominale (binaria)
RIDRETH1	Ethnicity	Categorica nominale
DMDEDUC2	Education level	Categorica ordinale
INDFMPIR	Income-to-poverty ratio	Continua
PAD680	Sedentary activity minutes/day	Continua
PAD800	Moderate activity minutes/day	Continua
PAD820	Vigorous activity minutes/session	Continua
WHQ070	Tried to lose weight in past year	Categorica nominale
DR1TKCAL	Daily energy intake (kcal)	Continua
DR1TPROT	Protein intake (g)	Continua
DR1TCARB	Carbohydrate intake (g)	Continua
DR1TSUGR	Sugar intake (g)	Continua
DR1TFIBE	Fiber intake (g)	Continua
DR1TTFAT	Total fat intake (g)	Continua
DR1TSFAT	Saturated fat intake (g)	Continua

3.1.2 Preprocessing e gestione dei valori mancanti

Il dataset iniziale aggregato, ottenuto dall'integrazione dei diversi file NHANES selezionati, conteneva 11933 record complessivi.

Una prima fase di pulizia ha previsto l'eliminazione dei record privi della variabile target relativa alla diagnosi di diabete.

I valori mancanti residui sono stati gestiti mediante imputazione con valore 0 per le variabili numeriche.

Questa scelta è stata adottata per consentire l'utilizzo dei record anche in presenza di alcune informazioni mancanti, evitando una drastica riduzione del dataset disponibile. L'eliminazione completa dei record con valori nulli avrebbe infatti ridotto il numero di osservazioni utilizzabili a 224 casi, compromettendo la possibilità di effettuare analisi esplorative significative.

3.2 Sistema iniziale di classificazione rule-based

Prima dell'introduzione di modelli di machine learning è stato sviluppato un sistema di classificazione basato su regole cliniche semplificate. L'obiettivo di questo approccio era comprendere il contributo relativo delle diverse variabili cliniche nella valutazione del rischio di diabete e individuare i fattori maggiormente informativi per la successiva progettazione dell'interfaccia VR.

Il sistema assegna un punteggio cumulativo a ciascun soggetto sulla base di soglie cliniche per alcune variabili rilevanti, tra cui glucosio, BMI, colesterolo totale, HDL e peso corporeo. Valori elevati o clinicamente critici contribuiscono con punteggi positivi al rischio complessivo.

Il punteggio totale ottenuto consente di classificare il soggetto in tre livelli di rischio: basso, medio o alto.

Tabella 3.3: Sistema di valutazione del rischio basato su regole cliniche

Parametro	Condizione	Punteggio
Glucosio (mg/dL)	< 100 (normale)	0
	100–125 (prediabete)	+2
	≥ 126 (diabete)	+3
Colesterolo (mg/dL)	200–239 (borderline)	+1
	≥ 240 (alto)	+2
HDL (mg/dL)	<40 (uomini), <50 (donne)	+1
BMI	25–29.9 (sovrappeso)	+1
	≥ 30 (obesità)	+2
Peso corporeo	>120 kg (uomini), >90 kg (donne)	+1

Tabella 3.4: Classificazione del rischio complessivo

Punteggio totale	Livello di rischio
0–2	Rischio basso
3–6	Rischio medio
7 o più	Rischio alto

3.2.1 Valutazione preliminare del modello rule-based

Per valutare l'efficacia del sistema rule-based è stato sviluppato un modulo di confronto tra le predizioni generate e le diagnosi effettive presenti nel dataset NHANES.

I risultati hanno evidenziato un'accuratezza complessiva pari a circa il 70%, accompagnata da un numero elevato di falsi positivi (2612) e falsi negativi (462), evidenziando una tendenza del sistema a sovrastimare il rischio.

Questo indica che il sistema rule-based, pur mostrando una capacità discreta di classificazione complessiva, tendeva a sovrastimare il rischio per molti soggetti e a non identificare correttamente altri casi.

Questa analisi preliminare ha evidenziato i limiti dell'approccio rule-based nell'identificare correttamente i soggetti a rischio. Per questo motivo è stata avviata una fase di analisi più approfondita dei dati, utilizzando modelli di machine learning come strumenti di supporto per l'identificazione delle variabili cliniche più informative.

3.3 Analisi degli errori e implementazione dei modelli ML

L'elevato numero di errori osservati nel sistema rule-based ha reso necessaria un'analisi più approfondita delle variabili coinvolte nella classificazione.

In particolare sono stati analizzati separatamente i casi classificati correttamente, i falsi positivi e i falsi negativi.

A tal fine sono state effettuate diverse analisi esplorative sui dati, tra cui la visualizzazione delle distribuzioni delle principali variabili cliniche e l'analisi della loro importanza tramite modelli di machine learning supervisionato.

Le analisi sono state condotte utilizzando Python e le librerie *Pandas*, *Scikit-learn*, *Matplotlib* e *Seaborn*.

Implementazione iniziale con Random Forest Come primo passo è stato implementato un modello *Random Forest Classifier*, scelto per la sua efficacia nella gestione di dataset tabellari e per la capacità di stimare l'importanza relativa delle variabili.

Il modello è stato addestrato su un sottoinsieme dei dati disponibili contenente esclusivamente record privi di valori nulli nelle variabili selezionate (224). Dopo la suddivisione del dataset in training set e test set, il modello ha raggiunto un'accuratezza complessiva pari a circa 0.83.

L'analisi del *classification report* ha mostrato buone prestazioni nella classificazione dei soggetti ad alto rischio (classe positiva), con valori elevati di precision e recall,

mentre la capacità di identificare correttamente i soggetti a basso rischio risultava più limitata. Questo comportamento è dovuto principalmente allo sbilanciamento delle classi presenti nel dataset.

Analisi dell'importanza delle variabili Uno dei principali vantaggi del modello Random Forest è la possibilità di stimare l'importanza relativa delle variabili utilizzate nella classificazione.




Figura 3.1: Importanza variabili nella classificazione errori tramite modello Random Forest.

La Figura 3.1 mostra l'importanza relativa delle variabili nella classificazione degli errori ottenuta tramite un modello Random Forest.

Dall'analisi emerge chiaramente come i livelli di glucosio e insulina rappresentino i fattori più informativi per la classificazione del rischio di diabete. Variabili come BMI, età e colesterolo risultano comunque rilevanti, ma con un contributo inferiore.




Figura 3.2: Distribuzione dei valori di glicemia per falsi positivi e positivi confermati.

Come mostrato nella Figura 3.2, i soggetti con diagnosi confermata presentano in media valori di glicemia significativamente più elevati rispetto ai falsi positivi generati dal sistema rule-based.

Questa differenza evidenzia come la glicemia rappresenti una variabile fortemente discriminante nella valutazione del rischio di diabete.




Figura 3.3: Distribuzione dei valori di insulina per falsi positivi e positivi confermati.

La Figura 3.3 mostra come analogamente a quanto osservato per la glicemia, si evidenzia una differenza tra le due distribuzioni. I soggetti con diagnosi confermata tendono a presentare valori di insulina più elevati, mentre i falsi positivi mostrano una concentrazione maggiore nei valori più bassi.

Questo risultato suggerisce che i livelli di insulina rappresentano un ulteriore indicatore rilevante nella valutazione del rischio di diabete, in linea con la letteratura clinica.

Ottimizzazione del modello Per migliorare ulteriormente le prestazioni del modello sono state adottate alcune strategie di ottimizzazione. In primo luogo è stato introdotto un controllo sul numero massimo di variabili mancanti per paziente, mantenendo esclusivamente i record con al massimo tre valori nulli. Questa scelta ha permesso di preservare un numero maggiore di osservazioni evitando una riduzione eccessiva del dataset.

Successivamente è stata applicata la tecnica *SMOTE* (Synthetic Minority Over-sampling Technique) per affrontare lo sbilanciamento tra le classi presenti nel dataset.

Infine è stato addestrato un modello *XGBoost Classifier*, particolarmente efficace per dataset tabellari e capace di gestire in modo robusto relazioni non lineari tra le variabili.

Il modello finale ha raggiunto un'accuratezza complessiva pari a circa 0.83, con un valore di recall pari a 0.91 per la classe positiva, indicando una buona capacità di identificare correttamente i soggetti a rischio di diabete.

3.4 Costruzione del dataset finale per il sistema VR

Le analisi esplorative e i modelli di machine learning descritti nella sezione precedente hanno evidenziato come alcune variabili cliniche risultino particolarmente informative nella classificazione del rischio di diabete.

In particolare, sia l'analisi dell'importanza delle variabili sia lo studio delle distribuzioni dei dati hanno mostrato come i livelli di glucosio e insulina rappresentino i parametri più discriminanti nella distinzione tra soggetti con diagnosi confermata e casi classificati erroneamente dal sistema rule-based.

Alla luce di questi risultati è stato costruito un nuovo dataset filtrato contenente esclusivamente i record per i quali erano disponibili almeno i valori relativi a glucosio (LBXGLU) e insulina (LBXIN).

Questa scelta è stata adottata con l'obiettivo di garantire la presenza delle informazioni cliniche fondamentali per la valutazione del rischio di diabete e migliorare l'affidabilità delle successive analisi predittive.

Dopo l'applicazione di questo filtro, il dataset risultante conteneva 3483 record utilizzabili.

Il sistema rule-based è stato quindi leggermente aggiornato sulla base dell'analisi degli errori effettuata nella fase precedente e applicato nuovamente al dataset filtrato.

Tabella 3.5: Risultati della valutazione del sistema rule-based sul dataset filtrato

Categoria	Numero di casi
Totale pazienti analizzati	3483
Diagnosi borderline	119
Diagnosi negativa	2942
Diagnosi positiva	422
Predizioni corrette	2964
Falsi positivi	178
Falsi negativi	323
Accuratezza complessiva	85.10%

Come mostrato nella Tabella 3.5, l'applicazione del sistema rule-based sul dataset filtrato ha portato a un miglioramento significativo dell'accuratezza complessiva, raggiungendo l'85.10%.

Questo miglioramento è stato reso possibile dall'analisi esplorativa dei dati e dall'utilizzo di modelli di machine learning come strumento di supporto all'identificazione delle variabili cliniche più informative.

Il dataset finale è stato successivamente utilizzato per generare i pazienti virtuali all'interno dell'ambiente immersivo in realtà virtuale. Ogni paziente virtuale viene infatti costruito a partire da un record reale del dataset, consentendo di presentare all'utente finale un insieme coerente di parametri clinici su cui basare la propria valutazione diagnostica.

In questo modo l'ambiente VR non utilizza dati simulati, ma rappresenta scenari clinici realistici derivati direttamente da dati epidemiologici reali provenienti dal programma NHANES.

Il dataset così costruito costituisce la base informativa utilizzata per la generazione dei pazienti virtuali e per la progettazione delle interazioni diagnostiche all'interno dell'ambiente immersivo, descritto nel capitolo successivo.

Progettazione e implementazione del sistema VR

4.1 Processo di sviluppo del sistema

Lo sviluppo dell'ambiente VR è stato condotto in modo incrementale attraverso diverse fasi successive, che hanno portato dalla configurazione dell'ambiente di sviluppo alla realizzazione completa del sistema interattivo.

Le principali fasi di sviluppo sono state le seguenti:

- **Setup dell'ambiente di sviluppo VR:** installazione e configurazione del motore Unity, integrazione dei pacchetti XR Plugin Management per la gestione dei diversi visori VR e Pper il supporto a piattaforme come OpenXR, Oculus e Windows Mixed Reality e XR Interaction Toolkit per la gestione dei controller.
- **Prototipazione dell'ambiente immersivo:** progettazione e realizzazione dello studio medico virtuale, con importazione degli asset 3D, configurazione della scena e definizione degli elementi principali dell'ambiente.
- **Implementazione delle meccaniche di interazione:** sviluppo delle interazioni principali tramite controller VR, tra cui la manipolazione degli oggetti, l'attivazione di elementi della scena e l'introduzione del sistema di spawn dei pazienti tramite portale attivato da leva.

- **Integrazione dei dati clinici:** collegamento del dataset NHANES ai pazienti virtuali generati all'interno della scena, con caricamento dei dati da file CSV e associazione dinamica delle informazioni cliniche ai prefab dei pazienti.
- **Sviluppo del sistema di diagnosi e feedback:** implementazione dell'interfaccia della cartella clinica, dei meccanismi di diagnosi selezionabili dall'utente, del sistema di punteggio e dei feedback esplicativi basati sui parametri clinici.

4.2 Architettura del sistema

Il sistema sviluppato integra dati epidemiologici reali provenienti dal dataset NHANES con un ambiente immersivo realizzato tramite il motore grafico Unity e utilizza OpenXR in combinazione con XR Interaction Toolkit. La scelta di OpenXR garantisce inoltre la compatibilità con dispositivi come Meta Quest e con gli standard più diffusi nello sviluppo di applicazioni immersive.

L'architettura del sistema è composta da tre componenti principali:

- il dataset clinico derivato dai dati NHANES e preparato nella fase di preprocessing descritta nel Capitolo 3;
- il modulo di gestione dei dati clinici, responsabile del caricamento e del parsing dei record del dataset;
- l'ambiente immersivo sviluppato in Unity, che gestisce la generazione dei pazienti virtuali e l'interazione con l'utente.

Durante l'esecuzione della simulazione, i dati clinici vengono caricati da file CSV e utilizzati per popolare dinamicamente le informazioni associate ai pazienti presenti nella scena VR. Tali informazioni vengono quindi visualizzate nella cartella clinica virtuale associata al paziente, permettendo all'utente di analizzare i parametri disponibili e formulare una valutazione diagnostica.

4.3 Ambiente immersivo e interazione utente

L'ambiente progettato riproduce uno studio medico virtuale, all'interno del quale l'utente assume il ruolo di osservatore e analista dei dati clinici dei pazienti. La scena include gli elementi principali di uno studio medico, come scrivania, porta, finestre e altri oggetti di arredamento, con l'obiettivo di creare un contesto realistico e coerente con lo scenario di simulazione clinica.

Gli asset tridimensionali utilizzati per la costruzione dell'ambiente sono stati ottenuti principalmente da librerie gratuite disponibili online, tra cui piattaforme come *Sketchfab*, *Unity Asset Store* e *Kenney.nl*. L'utilizzo di queste risorse ha permesso di realizzare rapidamente una scena credibile dal punto di vista visivo, mantenendo allo stesso tempo un approccio leggero dal punto di vista computazionale e facilmente integrabile nel motore Unity.



Figura 4.1: Vista dello studio medico virtuale sviluppato in Unity, utilizzato come ambiente immersivo per la simulazione clinica.

All'interno dell'ambiente l'utente può interagire con diversi elementi della scena tramite i controller VR. In particolare, è stato implementato un sistema di attivazione che consente di generare nuovi pazienti virtuali tramite un portale attivato da una leva interattiva. Una volta attivato il portale, viene effettuato lo spawn di un paziente

all'interno della scena, il quale si muove verso la posizione prevista tramite un sistema di animazioni e controllo del movimento.

Quando il paziente viene generato, l'utente può interagire con esso per accedere alla cartella clinica associata. La cartella clinica mostra i principali parametri clinici del paziente, derivati dai dati reali del dataset NHANES, e costituisce lo strumento principale attraverso cui l'utente può analizzare le informazioni disponibili e formulare una valutazione diagnostica.

Le principali interazioni implementate nel sistema includono:

- attivazione del sistema di generazione dei pazienti tramite leva e portale;
- apertura e chiusura della cartella clinica associata al paziente;
- visualizzazione dei parametri clinici del paziente;
- selezione della valutazione diagnostica tramite l'interfaccia interattiva.

4.4 Sistema di generazione dei pazienti

La generazione dei pazienti virtuali rappresenta uno dei componenti centrali del sistema sviluppato. Ogni paziente presente nell'ambiente VR viene infatti creato dinamicamente a partire da un record del dataset NHANES, combinando un modello tridimensionale (prefab) con i dati clinici associati.

4.4.1 Prefab dei pazienti

Per rappresentare visivamente i pazienti sono stati utilizzati diversi prefab 3D, selezionati per garantire una maggiore varietà visiva all'interno della simulazione. In particolare, il sistema utilizza cinque prefab differenti:

- due prefab per pazienti di sesso maschile;
- due prefab per pazienti di sesso femminile;
- un prefab dedicato ai pazienti pediatrici.



Figura 4.2: Esempio di prefab femminile utilizzato per la generazione dinamica dei pazienti virtuali all'interno dell'ambiente VR.

La selezione del prefab avviene dinamicamente in base alle informazioni presenti nel dataset clinico. Nel caso in cui l'età del paziente sia inferiore ai 16 anni, viene utilizzato automaticamente il prefab dedicato ai pazienti pediatrici; negli altri casi, il sistema seleziona casualmente uno dei prefab disponibili per il sesso corrispondente.

4.4.2 Animazioni e movimento del paziente

Per rendere il comportamento dei pazienti più realistico sono state integrate animazioni di movimento tramite l'utilizzo di *Animator Controller*. In particolare sono stati configurati due stati principali:

- *Idle*, che rappresenta lo stato di inattività del paziente;
- *Walk*, utilizzato durante il movimento del paziente all'interno della scena.

La transizione tra i due stati è gestita tramite il parametro booleano *isWalking*, che viene aggiornato dinamicamente durante l'esecuzione della simulazione.

Il movimento dei pazienti è implementato tramite il componente *NavMeshAgent*, che consente di gestire automaticamente la navigazione all'interno della scena. Quando un paziente viene generato, il sistema assegna una destinazione prestabilita nello studio medico e il *NavMeshAgent* gestisce il percorso verso tale posizione.

Durante il movimento il parametro *isWalking* viene impostato a *true*, attivando l'animazione di camminata. Una volta raggiunta la destinazione, il parametro viene aggiornato a *false*, riportando il paziente nello stato *Idle*.

4.4.3 Sistema di spawn dei pazienti

La generazione dei pazienti all'interno della scena avviene tramite un sistema di attivazione basato su un portale interattivo. Il portale può essere attivato tramite una leva presente nello studio medico virtuale.

Quando l'utente aziona la leva, viene attivato lo script *SpawnPaziente*, responsabile dell'istanza del prefab del paziente nel punto di spawn definito sopra il portale. Durante la fase di generazione viene inoltre applicata una rotazione iniziale al paziente, in modo da orientarlo verso l'utente.

Una volta generato, il paziente si muove automaticamente verso la posizione prestabilita nello studio medico, simulando l'ingresso di un paziente reale nello spazio di visita.

4.4.4 Caricamento dei dati clinici

Il caricamento dei dati clinici è gestito da uno script dedicato, responsabile della lettura del file CSV derivato dal dataset NHANES e della conversione dei record in strutture dati utilizzabili all'interno di Unity.

Lo script *DatasetLoader* effettua il parsing riga per riga del file, estraendo i valori delle variabili cliniche di interesse e convertendoli nei corrispondenti tipi numerici. I dati così ottenuti vengono poi memorizzati in una struttura *CartellaClinica*, che rappresenta il contenuto informativo associato a ciascun paziente virtuale.

Questa fase è fondamentale perché consente di collegare direttamente i dati epidemiologici reali alla generazione dinamica dei pazienti presenti nella scena, rendendo possibile la creazione di casi clinici variabili e coerenti con il dataset di partenza.

4.5 Interazione utente e cartella clinica

L'interazione tra utente e paziente virtuale è stata progettata per essere diretta e coerente con il contesto immersivo. Quando l'utente tocca il paziente tramite il controller XR, viene attivato l'evento *OnSelectEnter()*, che consente l'apertura della cartella clinica associata.

Per rendere possibile questa funzionalità è stato necessario configurare correttamente i prefab dei pazienti, associando a ciascuno gli script necessari per la gestione dell'interazione. La cartella clinica viene visualizzata come un pannello in *World Space*, aggiornato dinamicamente con i dati del paziente selezionato.

La visualizzazione della cartella è gestita dalla classe *CartellaUI*, che mostra i parametri clinici del paziente e orienta automaticamente il pannello verso l'utente, migliorando la leggibilità all'interno dell'ambiente VR.

È stato inoltre implementato un pulsante *Chiudi*, con lo scopo di nascondere la cartella quando non più necessaria.




Figura 4.3: Cartella clinica del paziente virtuale visualizzata in VR, contenente i principali parametri clinici derivati dal dataset NHANES.

4.6 Sistema di diagnosi, punteggio e feedback

Per permettere all'utente di esprimere una valutazione diagnostica è stata realizzata un'interfaccia composta da tre pulsanti, corrispondenti alle possibili categorie di classificazione: *DIABETICO*, *NON DIABETICO* e *BORDERLINE*. I pulsanti sono stati inseriti in un canvas collocato nello spazio tridimensionale dello studio medico e configurati per essere selezionabili tramite i controller XR.



Figura 4.4: Interfaccia di diagnosi in realtà virtuale che consente all'utente di classificare il paziente come Diabetico, Non Diabetico o Borderline.

La Figura 4.4 mostra l'interfaccia di selezione della diagnosi, con evidenziazione visiva dell'opzione scelta dall'utente.

La gestione della diagnosi è affidata alla classe *DiagnosiManager*, responsabile del collegamento con il paziente corrente, del confronto tra la scelta dell'utente e il valore reale della variabile `DIQ010`, e dell'aggiornamento del punteggio complessivo.

Il sistema assegna un incremento positivo in caso di diagnosi corretta e una penalità in caso di diagnosi errata. Contestualmente viene aggiornato anche il numero totale di diagnosi effettuate durante la sessione.

Per migliorare la comprensibilità dell'esperienza è stato introdotto un feedback visivo immediato (+1/-1), mostrato tramite componenti *TMP_Text* all'interno della scena.




Figura 4.5: Feedback visivo mostrato all’utente dopo la selezione della diagnosi, con aggiornamento del punteggio associato.

Per evitare comportamenti non coerenti, è stato inoltre introdotto un flag booleano che impedisce all’utente di effettuare più diagnosi sullo stesso paziente. In questo modo ogni paziente può essere valutato una sola volta, garantendo una maggiore coerenza del sistema di punteggio.

4.7 Spiegazioni cliniche e supporto educativo

Oltre alla semplice restituzione del risultato diagnostico, il sistema è stato progettato per fornire all’utente un supporto interpretativo volto a spiegare in modo sintetico i motivi della classificazione.

In una prima fase è stata sperimentata l’integrazione di un backend Python basato su *Flask*, in grado di restituire spiegazioni generate tramite tecniche di explainability ispirate ad Anchor e basate sul modello Random Forest sviluppato durante la fase di analisi dei dati.

I test effettuati hanno mostrato che, pur essendo potenzialmente realistico, l’output di questo approccio risultava eccessivamente tecnico e poco leggibile per un contesto immersivo in realtà virtuale. Per questa ragione si è scelto di non integrare direttamente tali spiegazioni nel sistema finale.

È stato invece implementato un metodo dedicato, denominato *GeneraSpiegazioneRuleBased()*, che produce spiegazioni sintetiche e leggibili a partire dai parametri clinici principali del paziente, come età, sesso, glicemia, insulina e BMI. Questa soluzione, pur essendo meno generale rispetto a un sistema AI completo, consente un maggiore controllo sul linguaggio utilizzato e risulta più adatta a un'esperienza educativa immersiva.

Le spiegazioni vengono mostrate tramite un pannello dedicato, progettato per essere leggibile anche in ambiente VR.



Figura 4.6: Pannello di spiegazione clinica generato dal sistema rule-based per supportare l'interpretazione della diagnosi effettuata.

Per rafforzare ulteriormente la componente educativa del sistema è stato infine introdotto un personaggio non giocante, denominato *Dottore*, che fornisce consigli casuali relativi ai principali fattori di rischio del diabete. Il personaggio è selezionabile tramite controller XR e visualizza messaggi sintetici in un balloon testuale *world-space*, contribuendo ad aumentare il coinvolgimento dell'utente e il valore formativo dell'esperienza.

4.8 Sintesi del sistema sviluppato

Il sistema sviluppato integra dati epidemiologici reali, modelli di analisi dei dati e un ambiente immersivo interattivo con l'obiettivo di supportare la comprensione dei fattori di rischio associati al diabete. L'utilizzo di pazienti virtuali generati dinamicamente a partire dal dataset NHANES consente di presentare scenari clinici realistici. Allo stesso tempo, l'interfaccia VR permette all'utente di analizzare i parametri clinici disponibili, formulare una valutazione diagnostica e ricevere feedback immediati accompagnati da spiegazioni sintetiche.

4.9 Possibili scenari di utilizzo e impatto del sistema

Il sistema sviluppato in questo lavoro si colloca nel contesto degli strumenti educativi basati su realtà virtuale per la formazione e la comprensione dei fattori di rischio clinici. Come discusso nel Capitolo 2, molte soluzioni presenti in letteratura si basano su scenari simulati predefiniti e su casi clinici costruiti manualmente, con una limitata integrazione di dataset epidemiologici reali.

Il sistema proposto affronta parzialmente queste limitazioni integrando dati reali provenienti dal dataset NHANES all'interno di un ambiente immersivo interattivo.

Il sistema potrebbe essere utilizzato in diversi contesti educativi e formativi. In particolare, gli utenti target possono includere:

- studenti di medicina o scienze sanitarie interessati a comprendere i fattori di rischio del diabete;
- studenti di informatica o data science che desiderano esplorare applicazioni di visualizzazione dei dati clinici in ambienti immersivi;
- professionisti sanitari coinvolti in attività di formazione o sensibilizzazione sui fattori di rischio metabolici.

In questo senso, il sistema sviluppato rappresenta un primo passo verso l'integrazione tra dati epidemiologici reali e ambienti immersivi interattivi, contribuendo a colmare alcune delle limitazioni evidenziate nello stato dell'arte. In particolare,

l'utilizzo di dataset reali consente di generare casi clinici variabili e realistici, mentre l'introduzione di elementi interattivi e meccaniche di gioco favorisce un approccio più coinvolgente rispetto ai tradizionali sistemi di simulazione basati su scenari statici.

Nel capitolo successivo verranno analizzati i risultati ottenuti dall'applicazione del sistema sviluppato e verrà discussa la sua capacità di rispondere alle domande di ricerca formulate.

Conclusioni e sviluppi futuri

Il presente lavoro ha esplorato l'integrazione tra dati epidemiologici reali, tecniche di analisi dei dati e ambienti immersivi in realtà virtuale con l'obiettivo di supportare la comprensione dei fattori di rischio associati al diabete.

A partire dai dataset NHANES, è stata condotta una fase di analisi e preparazione dei dati finalizzata alla costruzione di un dataset utilizzabile per l'analisi del rischio di diabete. In una prima fase è stato sviluppato un sistema di classificazione basato su regole cliniche semplificate, utilizzato come punto di partenza per comprendere il contributo delle principali variabili cliniche.

Successivamente, l'analisi degli errori del modello rule-based ha permesso di individuare le variabili maggiormente informative, in particolare i livelli di glicemia e insulina. L'utilizzo di modelli di machine learning supervisionati ha consentito di supportare questa analisi e di evidenziare come alcune variabili risultino particolarmente discriminanti nella classificazione dei soggetti a rischio.

Sulla base di queste osservazioni è stato costruito un dataset filtrato contenente le informazioni cliniche più rilevanti. L'applicazione del sistema rule-based su questo dataset ha portato a un miglioramento significativo dell'accuratezza complessiva, raggiungendo circa l'85%.

Il dataset così ottenuto è stato successivamente integrato all'interno di un am-

biente immersivo sviluppato con il motore grafico Unity. Il sistema VR consente di generare dinamicamente pazienti virtuali a partire dai record del dataset NHANES e di presentare all'utente un insieme coerente di parametri clinici da analizzare.

L'ambiente immersivo permette all'utente di interagire con i pazienti virtuali, consultare le cartelle cliniche, formulare una diagnosi e ricevere feedback immediati e spiegazioni sintetiche basate sui parametri clinici osservati. L'introduzione di elementi di gamification, come il sistema di punteggio e l'interazione con un personaggio non giocante che fornisce consigli educativi, contribuisce a rendere l'esperienza più coinvolgente e potenzialmente utile in contesti formativi.

Nel complesso, il lavoro dimostra la fattibilità tecnica dell'integrazione tra dati epidemiologici reali e ambienti immersivi interattivi, evidenziando il potenziale della realtà virtuale come strumento di supporto alla comprensione dei fattori di rischio e ai processi di ragionamento clinico.

5.1 Limiti del lavoro

Nonostante i risultati ottenuti, il sistema sviluppato presenta alcune limitazioni. In primo luogo, l'analisi dei dati è stata condotta su un sottoinsieme dei dataset disponibili, e il dataset finale utilizzato nel sistema VR rappresenta una selezione filtrata dei record iniziali. Sebbene questa scelta abbia migliorato l'affidabilità delle analisi, essa riduce in parte la varietà dei casi clinici rappresentati.

Un ulteriore limite riguarda il sistema di spiegazione delle diagnosi. Durante lo sviluppo è stata sperimentata l'integrazione di tecniche di explainable AI basate su Anchor, ma l'output generato è risultato poco adatto a un contesto immersivo in realtà virtuale a causa della sua complessità e della difficoltà di interpretazione da parte dell'utente finale. Per questa ragione si è scelto di adottare un sistema di spiegazioni rule-based più semplice e controllabile.

Infine, il sistema è stato sviluppato principalmente come prototipo dimostrativo e non è stato oggetto di una valutazione sperimentale con utenti reali. Pertanto, non è stato possibile misurare in modo sistematico l'effettivo impatto educativo dell'esperienza VR.

5.2 Sviluppi futuri

Il lavoro presentato apre diverse possibili direzioni di sviluppo. Una prima estensione riguarda l'integrazione completa di modelli di explainable AI all'interno dell'ambiente VR, adattando il linguaggio delle spiegazioni per renderlo più accessibile e coerente con un contesto immersivo.

Ulteriori sviluppi potrebbero riguardare l'estensione del dataset utilizzato, includendo nuove variabili relative allo stile di vita dei pazienti, come abitudini alimentari e livello di attività fisica. L'integrazione di queste informazioni permetterebbe di rappresentare scenari clinici più completi, migliorando l'analisi dei fattori di rischio.

Un ulteriore miglioramento riguarda l'aggiornamento periodico dei modelli di analisi tramite l'integrazione di nuovi dataset o di versioni aggiornate dei dati NHANES, mantenendo il sistema allineato con l'evoluzione delle conoscenze epidemiologiche..

Il sistema potrebbe inoltre essere esteso introducendo scenari clinici più complessi, nei quali l'utente debba considerare, oltre ai parametri clinici immediati, anche la storia medica del paziente, eventuali patologie pregresse o trattamenti farmacologici, avvicinando ulteriormente l'esperienza simulata ai processi decisionali della pratica clinica reale.

Dal punto di vista dell'interazione, il sistema potrebbe essere arricchito con ulteriori elementi di gamification, come livelli di difficoltà progressivi, sistemi di valutazione più articolati o modalità di confronto con un agente virtuale basato su modelli predittivi.

Infine, una direzione di ricerca particolarmente interessante riguarda la valutazione dell'efficacia educativa del sistema attraverso studi sperimentali con studenti o professionisti in ambito sanitario.

In conclusione, il lavoro evidenzia il potenziale dell'integrazione tra analisi dei dati epidemiologici e ambienti immersivi in realtà virtuale come strumento di supporto alla comprensione dei fattori di rischio e ai processi di ragionamento clinico. Pur rappresentando un primo prototipo dimostrativo, il sistema mostra come l'utilizzo di dati reali e tecnologie immersive possa aprire nuove prospettive per lo sviluppo di strumenti educativi innovativi in ambito medico.

Bibliografia

- [1] D. A. Kolb, *Experiential Learning: Experience as the Source of Learning and Development*. Englewood Cliffs, NJ: Prentice Hall, 1984. (Citato a pagina 6)
- [2] J. Pottle, "Virtual reality and the transformation of medical education," *Future Healthcare Journal*, vol. 6, no. 3, pp. 181–185, 2019. (Citato alle pagine 7 e 10)
- [3] J. M. Padilha, P. P. Machado, A. Ribeiro, J. Ramos, and P. Costa, "Clinical virtual simulation in nursing education: Randomized controlled trial," *J Med Internet Res*, vol. 21, no. 3, p. e11529, Mar 2019. (Citato a pagina 7)
- [4] A. Dávidovics, K. Dávidovics, P. Hillebrand, S. Rendeki, and T. Németh, "Virtual patient simulation to enhance medical students' clinical communication and decision-making skills: a pilot study," *BMC Medical Education*, vol. 26, no. 1, p. 171, 2025. (Citato a pagina 7)
- [5] J. Wanderer, S. Nelson, J. Ehrenfeld, S. Monahan, and S. Park, "Clinical data visualization: The current state and future needs," *Journal of Medical Systems*, vol. 40, 10 2016. (Citato a pagina 9)
- [6] N. A. Abudiyab and A. T. Alanazi, "Visualization techniques in healthcare applications: A narrative review," *Cureus*, vol. 14, no. 11, p. e31355, 2022. (Citato a pagina 9)

- [7] J. Hamari, J. Koivisto, and H. Sarsa, "Does gamification work? – a literature review of empirical studies on gamification," in *Proceedings of the 47th Hawaii International Conference on System Sciences*, 2014. (Citato a pagina 9)
- [8] D. A. Cook and M. M. Triola, "Virtual patients: a critical literature review and proposed next steps," *Medical Education*, vol. 43, no. 4, pp. 303–311, 2009. (Citato a pagina 10)
- [9] A. A. Kononowicz, L. A. Woodham, S. Edelbring, N. Stathakarou, D. Davies, N. Saxena, L. Tudor Car, J. Carlstedt-Duke, J. Car, and N. Zary, "Virtual patient simulations in health professions education: Systematic review and meta-analysis by the digital health education collaboration," *Journal of Medical Internet Research*, vol. 21, no. 7, p. e14676, 2019. [Online]. Available: <https://www.jmir.org/2019/7/e14676> (Citato a pagina 10)
- [10] C. Jans, F. Bogossian, P. Andersen, and T. Levett-Jones, "Examining the impact of virtual reality on clinical decision making – an integrative review," *Nurse Education Today*, vol. 125, p. 105767, 2023. (Citato a pagina 10)

Ringraziamenti

Desidero ringraziare il mio relatore per il supporto, la celerissima disponibilità e per avermi dato la possibilità di lavorare a un progetto ambizioso e interessante.

Ringrazio la Dottoressa Pentangelo per la costante presenza e guida, sia durante la fase di tirocinio sia nella stesura di questa tesi. Lavorare sotto la sua supervisione è stata un'esperienza formativa e piacevole.

Un ringraziamento speciale va ai miei genitori e a mio fratello per l'immenso supporto durante tutto il mio percorso universitario; se ce l'ho fatta, se non ho mollato, gran parte del merito è vostro.

Ringrazio inoltre tutti i miei amici, tutta la mia famiglia e chiunque abbia incoraggiato, anche solo per poco, il mio cammino nel corso di questi anni. Sono onorato di poter festeggiare questo traguardo insieme a voi.

Questa tesi ha contribuito a piantare un albero in Kenya tramite il progetto Treedom.

<https://www.treedom.net/it/user/sesalab/event/sesa-random-forest>